

密 级_____



桂林电子科技大学
GUILIN UNIVERSITY OF ELECTRONIC TECHNOLOGY

硕 士 学 位 论 文

(全日制专业学位硕士)

题 目 基于卷积神经网络的滑坡识别与滑坡易发性评价方法研究

(英文) Research on Landslide Identification and Landslide
Susceptibility Evaluation Method Based on Convolutional
Neural Networks

研 究 生 学 号: 21022303143

研 究 生 姓 名: 万逸轩

指导教师姓名、职称: 黄建华 高级工程师

申请专业学位类别: 电子信息硕士

专 业 名 称: 通信工程 (含宽带网络、移动通信等)

论 文 答 辩 日 期: 2024 年 6 月 2 日

摘要

滑坡是一种普遍且极具破坏力的地质灾害，不仅威胁到人们的生命安全，还会造成基础设施的严重损坏。因此，有必要对滑坡进行有效预防与精准识别。由于滑坡的形态差异较大、种类繁多以及边界轮廓大小变化无固定规律，现有的滑坡识别算法常常难以精确地分割和识别滑坡区域。加之传统的滑坡监测技术因其高昂的成本，难以实现大范围部署。相比之下，滑坡易发性评价能够在监测资源有限的情况下，为特定地区进行滑坡易发性评估，从而指导相关部门合理规划土地利用。与聚焦局部地表形变监测相比，滑坡易发性评价在覆盖范围上更具优势，能够对大面积区域进行风险评估。然而，当面对大规模、高维度的滑坡易发性因子数据时，传统的滑坡易发性评价方法往往难以有效捕捉数据间的深层次信息。针对上述问题，本文基于卷积神经网络开展了滑坡识别与滑坡易发性评价的研究。本文的主要研究内容如下：

（1）针对现有的方法难以精确的分割滑坡边界的问题，提出了一种基于改进 DeepLabv3+ 模型的滑坡识别方法。该方法为了平衡模型的性能与响应速度选取 ResNet50 作为主干网络，通过残差连接 ECA-Net 注意力模块优化了模型对不同尺度特征的处理能力。为了解决不同尺度特征间的不一致性，平衡不同层级的特征图，聚焦微小目标的细节及其边界特征构建了一个地貌特征融合模块。本研究基于重建的样本库进行了实验，与 ResNet50 为主干网络的 DeepLabv3+ 模型相比，本研究所提出的方法在 Recall、PA、mIoU 和 mCPA 上分别提高了 3.51%、1.24%、3.03% 和 1.8%，验证了改进算法的有效性。

（2）本研究设计并开发了一个综合的滑坡影像训练预测系统。该系统利用 PyTorch 框架和 PyQt5 进行开发。系统主要由模型训练和模型预测两大核心模块组成，模型训练模块中集成了影像标注与模型训练功能，模型预测模块中则包含单张影像预测与批量预测功能，该系统使非技术背景的监测人员也能轻松地进行滑坡识别任务中的训练和预测工作。

（3）收集并处理了广西梧州市区的 11 个滑坡影响因子，分别利用传统信息量模型和优化后的卷积神经网络模型对梧州市区的滑坡易发性进行了评估。实验结果表明，相比于传统信息量模型，优化后的卷积神经网络模型所评估的高易发性区域的分区面积更小，滑坡点密度更高。

关键词：滑坡识别；特征融合；注意力机制；DeepLabv3+；卷积神经网络；滑坡易发性评价

Abstract

Landslide is a common and very destructive geological disaster, which not only threatens people's life safety, but also causes serious damage to infrastructure. Therefore, it is necessary to effectively prevent and accurately identify landslides. Due to the large differences in the morphology of landslides, the variety of landslides, and the irregularity of the size of the boundary contour, the existing landslide identification algorithms are often difficult to accurately segment and identify landslide areas. In addition, traditional landslide monitoring techniques are difficult to deploy on a wide scale due to their high cost. In contrast, landslide susceptibility assessment is able to assess landslide susceptibility for a specific area with limited monitoring resources, thus guiding the relevant authorities to rationally plan land use. Compared with localized surface deformation monitoring, landslide susceptibility assessment is more advantageous in terms of coverage, and is able to assess the risk of a large area. However, when facing large-scale and high-dimensional landslide susceptibility factor data, traditional landslide susceptibility evaluation methods are often difficult to effectively capture the deep information among the data. Aiming at the above problems, this thesis carries out the research on landslide identification and landslide susceptibility evaluation based on convolutional neural network. The main research content of this paper is as follows:

(1) Aiming at the problem that existing methods are difficult to accurately segment landslide boundaries, a landslide identification method based on the improved DeepLabv3+ model is proposed. The method selects ResNet50 as the backbone network in order to balance the performance and response speed of the model, and optimizes the processing capability of the model for different scale features through the residual connection ECA-Net attention module. In order to solve the inconsistency between different scale features and balance the feature maps at different levels, a geomorphic feature fusion module is constructed by focusing on the details of tiny targets and their boundary features. This study conducted experiments based on the reconstructed sample libraries, and compared with the DeepLabv3+ model with ResNet50 as the backbone network, the proposed method in this study improves 3.51%, 1.24%, 3.03%, and 1.8% on Recall, PA, mIoU, and mCPA, respectively, which verifies the effectiveness of the improved algorithm.

(2) A comprehensive landslide image training prediction system was designed and developed in this study. The system was developed using PyTorch framework and PyQt5. The system mainly consists of two core modules, model training and model prediction. The model training module integrates image annotation and model training functions, while the model prediction module contains single image prediction and batch prediction functions, which makes it easy for monitors with non-technical backgrounds to carry out training and prediction work in the landslide identification task.

(3) Eleven landslide impact factors in Wuzhou City, Guangxi were collected and processed, and the landslide susceptibility of Wuzhou City was evaluated using the traditional informative model and the optimized convolutional neural network model, respectively. The experimental results show that compared with the traditional informative model, the optimized convolutional neural network model evaluates the high susceptibility areas with smaller zoning area and higher density of landslide sites.

Keywords: Landslide Recognition; Feature Fusion; Attention Mechanism; DeepLabv3+; Convolutional Neural Network; Landslide Susceptibility Assessment

目 录

第一章 绪论.....	1
§1.1 研究背景与意义.....	1
§1.2 国内外研究现状.....	3
§1.2.1 滑坡识别研究现状.....	3
§1.2.2 滑坡易发性评价研究现状.....	5
§1.3 本文研究内容.....	7
§1.4 论文组织结构.....	8
第二章 相关理论基础	10
§2.1 卷积神经网络.....	10
§2.1.1 卷积层.....	10
§2.1.2 激活函数.....	11
§2.1.3 批归一化层.....	14
§2.1.4 池化层.....	14
§2.1.5 全连接层.....	15
§2.1.6 损失函数.....	16
§2.2 经典的语义分割网络.....	17
§2.2.1 全卷积神经网络.....	17
§2.2.2 U-Net 网络.....	18
§2.2.3 PSPNet 网络	19
§2.2.4 HRNetV2 网络	20
§2.2.5 DeepLab 系列.....	20
§2.3 卷积神经网络的训练.....	22
§2.3.1 反向传播算法.....	22
§2.3.2 Adam 算法	23
§2.4 本章小结.....	24
第三章 基于改进 DeepLabv3+模型的滑坡识别	25
§3.1 数据集概述.....	25
§3.2 改进的 DeepLabv3+算法.....	27
§3.2.1 基于 ResNet50 的 DeepLabv3+算法.....	27
§3.2.2 残差连接 ECA-Net 注意力模块	28
§3.2.3 地貌特征融合模块.....	29
§3.3 实验结果与分析.....	32
§3.3.1 实验环境说明.....	32
§3.3.2 模型训练的超参数设置.....	33

§3.3.3 评价指标.....	33
§3.3.4 消融实验.....	34
§3.3.5 对比实验.....	37
§3.4 工程化应用.....	38
§3.4.1 滑坡影像训练预测系统概述.....	38
§3.4.2 系统设计与开发.....	38
§3.4.3 功能模块与软件界面.....	39
§3.5 本章小结.....	44
第四章 基于卷积神经网络的滑坡易发性评价	45
§4.1 滑坡评价流程概述.....	45
§4.2 研究区域及数据.....	46
§4.3 影响因子分析.....	47
§4.4 信息量模型.....	58
§4.5 卷积神经网络模型.....	60
§4.5.1 数据集划分	60
§4.5.2 卷积神经网络模型构建.....	61
§4.6 CNN 实验结果与分析	62
§4.6.1 实验环境说明.....	62
§4.6.2 模型训练的超参数及训练策略设置.....	62
§4.6.3 模型评价指标.....	63
§4.6.4 预测结果与分析	64
§4.7 易发性评价结果.....	65
§4.8 本章小节.....	68
第五章 总结与展望	69
§5.1 本文工作总结.....	69
§5.2 未来工作展望.....	70
参考文献.....	71

第一章 绪论

§ 1.1 研究背景与意义

滑坡是一种常见的地质灾害类型,表现为地表物质在重力作用下沿着一定的滑动面发生整体移动的现象。根据滑坡的形态、组成物质及动力学特征,可将其细分为滑块型滑坡、泥石流型滑坡等多种类型^[1]。滑坡具有规模大、数量多、破坏性强、形态复杂等特点^[2]。随着人类活动能力的增强,对自然环境的干扰不断加剧,地质灾害的发生频率明显上升^[3]。我国国土广袤,地形地貌丰富多样,其中山区占据了相当大的比例。这种广泛的山地分布格局导致滑坡等地质灾害频繁发生。此类灾害不仅造成了严重的经济损失,还导致大量的人员伤亡。下图 1-1 根据中国国家统计局编写的中国统计年鉴 2023^[4],统计了 2010 年起到 2022 年这十三年的地质灾害变化趋势以及危害影响。




图 1-1 地质灾害变化趋势及危害影响

2022 年的地质灾害类型分布如图 1-2 所示,当年全国共发生了 3919 起滑坡事件,占同年所有地质灾害的 69.25%。进一步分析 2010 至 2022 年间的的历史数据,共发生地质灾害次数 141770 次,其中 99148 次为滑坡事件,滑坡事件占据地质灾害事件的 69.94%。这一数据表明,滑坡灾害在发生的地质灾害中占比较高,对国家财产和人民安全造成了严重影响。因此,滑坡易发性评价和识别工作显得尤为重要。通过定量计算滑坡发生的概率,滑坡易发性评价能够准确评估某一区域的滑坡风险,进而提前识别潜在危险区域,为制定预防措施和合理规划土地利用提供有力支持。滑坡识别则可以帮助快速准确地评估灾害的规模 and 影响,进而进行有效的损失估算。灾后的滑坡区域仍然存在二次滑坡的风险。滑坡识别能够精准地识别出这些灾害区域,从而采取有针对性的措施,有效避免次生灾害的发生,确保救援人员和重建工作的安全。




图 1-2 2022 年地质灾害类型分布

为全面贯彻落实习近平总书记关于应急管理工作的指示精神及党中央和国务院的决策部署，中国政府致力于安全生产、防灾减灾救灾等领域的工作，积极推动应急管理体系与能力的现代化。依据《中华人民共和国国民经济和社会发展第十四个五年规划和 2035 年远景目标纲要》，“十四五”规划被制定并实施。规划中强调，将充分利用基于星载、航空、地面的空天地一体化多源立体观测体系，执行多方法、多层次、多尺度的综合遥感动态调查，全面进行地质灾害易发区隐患的识别及地面验证，以深入掌握地质灾害隐患的基本情况及其动态变化，为地质灾害综合信息平台提供必要的支撑。利用人工智能、移动互联、区块链、大数据等技术，加强地质灾害风险评价，并致力于全国地质灾害综合信息平台的完善。根据地质灾害发育分布特征，结合地形地貌、岩土体类型及性质、地质构造等影响因素划定高、中、低三级地质灾害易发区。这些政策和措施体现了我国政府在面对自然灾害，特别是地质灾害时，采取全面、综合、系统的方法，通过提高预防、应对和恢复能力，来减少灾害风险，以保护人民的生命财产安全。

传统的滑坡监测方法面临着多项挑战，如精度不足、测量周期过长、易受环境因素干扰，以及无法实现连续监测等，这些问题使得传统监测方法难以满足现代滑坡监测的要求。相比之下，全球导航卫星系统（GNSS）中的 rtk 技术有效解决了这些难题，提供了一种远程监测手段，减少了现场勘测，并能够提供持续不断的监测数据。然而，采用 rtk 技术对大范围区域进行长期连续观测时会导致布设监测站成本较高，这使其难以在大范围内进行应用^[5]。滑坡易发性评价则作为一种补充方法，能够对特定区域进行滑坡易发性评估，并指导我们进行资源的高效规划与合理分配。与现有的滑坡监测技术的局部监测相比，滑坡易发性评价能够覆盖更广泛的区域，为大尺度的易发性评估提供了有力的支持。

在灾后快速准确地提取滑坡信息对于及时启动紧急应对措施、确保人员安全以及推动高效、有序的重建工作十分重要。传统的人工滑坡识别方法依赖于专家的经验

判断,在特定情况下准确性较高,但面对大量滑坡隐患的识别和分析,这种方法显得力不从心。随着遥感技术的发展和大数据时代的到来,基于图像分析的自动化方法已成为处理滑坡影像数据的高效手段。特别是深度学习算法,它能够从多时相遥感影像中自动提取关键特征,实现快速且准确的滑坡识别^[6]。然而,深度学习算法在实际应用中仍面临挑战,例如算法训练所需的高质量标记数据获取难度较大,且算法需要针对不同地区的特定地理和气候条件进行调整。尽管如此,基于深度学习的滑坡识别算法仍展现出巨大潜力,能够显著提高灾后滑坡数据处理的效率和滑坡识别的准确性。

本研究立足于国家与广西实施的地质灾害防治战略,以 Ji^[7]等基于历史滑坡编录数据、现场调查及 TripleSat 卫星遥感影像资料整合的 770 个滑坡正样本为基础,并收集整合互联网上的滑坡影像构建的数据集作为滑坡识别的研究对象。通过优化现有滑坡识别算法并封装成具有训练预测功能的可视化界面,便于用户在系统中进行样本标注、模型训练及滑坡样本预测操作。该系统的开发使算法模型能够适应不同地区的数据,为相关从业人员提供了极大的便利。同时选取广西梧州市区作为滑坡易发性等级评价的研究区域,并使用卷积神经网络等方法进行滑坡易发性评价,为该研究区域的土地规划和风险管理提供科学依据,助力该地区的灾害防治工作。

§ 1.2 国内外研究现状

§ 1.2.1 滑坡识别研究现状

准确识别滑坡边界对于灾后应急响应、滑坡预警、稳定性预测及防治措施的制定具有非常重要的意义。在遥感卫星技术普及之前,滑坡识别主要依赖于野外地质调查,地质工作者需亲自前往潜在滑坡区域进行实地考察和物理测量^[8]。虽然该方法可以提供详尽的地质数据,但在识别大面积滑坡时,其效率较低,难以满足快速响应的需求。

20 世纪 70 年代起,人们开始将遥感影像与地面调查结果相结合,利用专业的地学知识对滑坡进行室内人工目视解译^[9]。第一张黑白航空遥感影像被用于绘制滑坡分布图,标志着利用航空技术监测地表滑坡的研究正式开启。此后,出现了多种遥感数据,如干涉雷达、雷达、卫星立体影像、高分遥感影像、无人机影像、SAR、LiDAR 等, Kimura^[10]等利用合成孔径雷达干涉测量技术对日本板谷滑坡区域进行监测,研究中采用了三通道方法和数字高程模型消除法来分析不同时间段内的位移情况,并初步构建了滑坡区域的运动模型。Notti^[11]等利用 X 波段卫星雷达数据对滑坡进行监测和评估,并通过实例展示了其在实际应用中的效果。Stumpf^[12]等使用了基于图像相关性的多时相影像匹配技术来监测缓慢移动的滑坡,该技术通过分析滑坡大小和速度之间的关系来预测未来滑坡的发生。彭令^[13]等利用高分辨率遥感影像识别地震滑坡,并

通过多尺度最优分割方法构建多层次滑坡对象,融合多种影像特征和地形特征信息建立多维滑坡识别规则集合,实现了地震滑坡空间分布及其滑源区、滑移区和堆积区的准确识别。Rossi^[14]等利用新型多传感器无人机对意大利托斯卡纳地区某村庄进行滑坡监测,通过多次飞行调查和光学相机的数据采集,成功检测并准确建模分类了两个滑坡事件,并识别出潜在滑坡区域及其规模。Mondini^[15]等对已知滑坡事件前后的 SAR 影像进行系统评估,分析滑坡对 SAR 幅值的影响,并结合光学影像和实地调查数据,实现了对不同类型、规模、地形、气候条件下的滑坡事件的有效检测。Jaboyedoff^[16]等简述了 LiDAR 的历史背景和技术原理,随后深入探讨了其在滑坡检测、风险评估、建模和监测等方面的实际应用,特别强调了高分辨率数字地形模型在滑坡研究中的关键作用和潜力。这些遥感数据因其高时间分辨率、空间分辨率、光谱分辨率的优点,逐渐成为滑坡检测的主要数据源。尽管雷达探测数据在各种天气条件下均有效,可通过深度学习方法应用于滑坡图的生成,但其解析难度高于光学图像,因此光学图像仍是滑坡识别的重点研究对象^[17]。

在探讨滑坡识别与提取的方法时,可以从两个不同的维度进行分类:一是基于数据处理的维度,二是基于处理技术的维度。基于数据处理的维度包括基于像元的滑坡识别方法和基于面向对象的滑坡识别方法。基于像元的方法是将每个像素作为一个独立的分析单元,依据其光谱特征进行分类。这种方法处理速度快、节约资源,尤其适用于大范围的快速分析。然而,单个像元的光谱特征可能忽略了地形和地质环境的复杂性。基于面向对象是在图像分割的基础上,将分割后的对象作为分析单元,能够综合考虑纹理、形状、光谱等多种信息。这两种分类方式各有侧重点,但也存在一定的交叉和重叠。本文主要基于处理技术的维度进行阐述:

(1) 目视解译法

目视解译法主要依赖于专业人员对灾后遥感影像的色调、纹理、形状等特征的解读。作为最原始的滑坡提取方法,在灾情快速解译中发挥着重要作用,特别是在重大单体滑坡的提取和分析上,目视解译是不可或缺的。这种方法的优势在于能够结合非遥感资料和专家的地学知识进行综合分析,从而获得可靠的滑坡隐患的相关信息^[18]。然而,这种方法的效率相对较低,且受限于解译者的经验和知识水平。

(2) 特征设计法

特征设计法根据滑坡的特点制定相应的规则,以便从数据中提取关键特征。这种方法通过设置阈值、多尺度切割、灰度共生矩阵等技术手段来进行滑坡识别。Xian^[19]等针对陡峭且复杂的地形环境,采用面向对象的图像分析技术和机器学习算法,通过 LiDAR 数据获取的像素特征与基于灰度共生矩阵的纹理特征相结合,实现了对森林滑坡区域的精确识别。Rau^[20]等使用了多尺度分割技术,结合地形数据和颜色信息提取出五个特征,然后通过规则集分类实现了滑坡区域的自动识别。Bakhtiar^[21]等设计一种基于对象的图像分析方法,用于滑坡区划和多时相卫星影像中滑坡相关变化检测

的研究。该方法通过光谱分析、形状分析、灰度共生矩阵纹理测量以及模糊逻辑成员函数实现对滑坡的识别。万保峰^[22]等采用灰度共生矩阵对预处理后的滑坡影像进行纹理分析以完成滑坡识别。特征设计法能够针对特定的滑坡特征进行定制化分析，但它需要多次试验来确定最佳的阈值规则，且该方法对影像质量有较高的要求。

（3）特征学习法

在滑坡识别的研究中，特征学习方法能够从图像数据中自主学习并提取关键特征，实现了端到端的机器学习模型，而无需使用人工设计的特征提取算法。该方法不仅从原始图像中自动识别出有助于滑坡识别的特征，还将这些特征的提取过程与分类器的参数估计紧密结合。通过这种处理方式，模型能够更深入地理解并准确识别与滑坡相关的复杂特征，从而提高滑坡识别的准确性。Ghorbanzadeh^[23]等应用机器学习和卷积神经网络对尼泊尔拉苏瓦地区进行滑坡检测，发现基于特征学习的卷积神经网络方法在没有额外信息支持的情况下，实现了 78.26% 的准确率，表现最为优异。Sameen^[24]等使用卷积神经网络（CNN）和残差网络（ResNet）对遥感影像中的滑坡进行检测。通过比较不同网络架构和数据融合策略的效果，发现使用特征级融合可以提高检测结果，并且残差网络比其他模型更快速地收敛并更好地泛化到测试区域。王煜^[25]等提出的遥感图像滑坡识别方法采用了深度学习技术，相比于传统的基于规则或人工设计特征的方法，具有更高的准确率和鲁棒性。朱庆^[26]等提出的滑坡隐患分析方法结合了数据驱动和模型驱动，建立知识图谱与深度学习模型的耦合机制，实现知识引导的滑坡隐患精准分析。Yang^[27]等将深度学习方法应用于遥感图像中的滑坡提取，使用语义分割模型完成滑坡的自动识别，通过实验论证了深度学习方法在滑坡识别中的可行性和有效性。Wang^[28]等利用 GF-1 卫星获取同一空间但不同时间序列的前灾和后灾遥感图像作为输入图像，尝试添加归一化植被指数和近红外光谱来增强特征，通过基于卷积神经网络的遥感滑坡识别方法来确定山体滑坡，该方法在准确率和识别效率方面均优于传统方法。

在机器学习领域，特征设计法是传统机器学习方法的一个关键环节，主要依赖于专家的领域知识来手动选择和构造数据特征，从而提高支持向量机和决策树等模型的性能。特征学习法则是深度学习技术的核心，卷积神经网络和循环神经网络等深度学习模型不仅能够自动从原始数据中提取浅层特征，也能够通过叠加模型的深度来学习更高级的语义特征^[29]。特征设计法和特征学习法分别在机器学习和深度学习的不同阶段发挥着重要作用。本文滑坡识别主要使用的是深度学习方法，将在第三章进行详细介绍。

§ 1.2.2 滑坡易发性评价研究现状

滑坡易发性评价是一种用于评估特定区域内滑坡发生概率的方法。这种评价通常

需要分析多种可能导致滑坡的因素,包括地质条件、地形地貌、水文条件以及人类活动等^[30]。评价的目的是为了量化这些因素对滑坡发生的贡献程度,从而确定哪些区域更可能发生滑坡。

在 20 世纪中叶至 70 年代,国外对滑坡易发性评价的研究依赖于地质学家和工程师的经验判断。这一时期的研究方法主要是对滑坡发育机理进行研究,专家结合影响滑坡隐患的多种成因并用定性的方法对滑坡进行评价,这种方法具备极强的主观性,不同的专家判断的结果可能并不相同。20 世纪 70 年代中期以来,统计学方法已广泛的应用于各个领域。与此同时,滑坡易发性评价开始引入统计学方法。研究者们利用历史滑坡数据,结合地质、气象、水文等多种因素,通过统计分析来预测滑坡发生的概率^[31]。Neuland^[32]首次采用统计方法来解释德国西南部 250 个稳定与不稳定斜坡之间的形态测量、岩石力学、岩性和结构特征与稳定性或不稳定性条件的关系,并运用双变量判别分析方法构建了一个专门针对滑坡稳定性/不稳定性的预测模型。在 1983 年,Carrara^[33]总结了他在意大利南部卡拉布里亚地区关于滑坡地质和地貌因素方面所做的研究。针对该地区的 Ferro 流域和 Buonamico 流域,基于丰富的滑坡地质和地貌数据,运用判别分析和多元回归分析来预测滑坡易发性。这一时期的方法增强了评价的客观性,使预测结果更精确。然而,由于数据的质量仍待提高,该方法在实际应用中受到了一定影响。

20 世纪 50 年代到 70 年代,中国在地质灾害领域的研究主要集中在基础地质调查和灾害的防治上。这一时期,地质灾害的研究多以经验判断为主。20 世纪 80 年代以后,中国开始加强对地质灾害的重视,借鉴国外经验,逐步开展滑坡易发性区域评价工作,并与国际研究接轨。鉴于前面几十年的研究积累,学者们也意识到单纯依靠主观意识进行滑坡易发性评价的局限性,并开始探索数理统计模型在滑坡易发性评价中的应用,实现了从定性到半定量再到定量方法的转变。自 20 世纪 70 年代中期至 80 年代中期的开创性尝试之后,基于统计学的滑坡易发性分区方法不断涌现,并被应用于不同类型和不同地理区域的滑坡。Aleotti^[34]等介绍了滑坡灾害评估和风险分析的相关方法和技术,回顾了滑坡灾害的重要性和影响,并指出定量和定性两种评估方法的区别。

到了 20 世纪 90 年代,地理信息系统(GIS)和遥感技术的发展为滑坡易发性评价领域带来了革命性的变革。借助这些先进的技术,研究者能够高效地处理和分析海量的空间数据,从而实现滑坡风险的精准识别与科学评估。值得一提的是,遥感技术的应用使得我们得以远程监测和分析那些难以接近的地区,极大地拓宽了研究的视野,并加深了我们对滑坡现象的理解。Huabin^[35]等人梳理了基于 GIS 的滑坡危险性评估的研究现状和方法,并提出了一个以 GIS 为基础的滑坡危险性评估框架。滑坡易发性评价领域近年来取得了长足的进步,许多学者开始采用 ArcGIS 软件,利用其强大的空间分析功能来展示区域滑坡评价的分区图。这不仅为滑坡易发性分析提供了更

为精确的空间视角,还有助于决策者更加直观地了解滑坡风险的分布情况,从而制定更为有效的防治措施^[36,37]。

自 21 世纪初以来,随着计算能力的提升以及机器学习、深度学习算法的不断演进,滑坡易发性评价领域开始融入这些前沿技术,以进行更为细致深入的分析。Liu^[38]等人结合五种机器学习模型与六种特征选择方法,创建了十三个特征选择型机器学习模型。以中国湖南省的四个县为研究区域,采用 15 个条件因子和 1017 个已知滑坡事件进行实验。实验证实了特征选择型机器学习模型优于传统的机器学习模型。Wang^[39]等人首次提出使用卷积神经网络(CNN)框架进行滑坡易发性制图,他们根据不同的数据表示构建了三种不同的卷积神经网络架构,并与传统机器学习模型和常用的分类网络进行对比,其中 CNN-2D 方法预测性能最好,AUC 值达到 0.813。这一发现表明,相较于传统方法,这些 CNN 模型在滑坡防治和管理方面更具优势。深度学习作为机器学习的一个重要分支,以其出色的处理复杂非线性关系的能力,极大地提升了滑坡易发性预测模型的精确度。同时,这些技术的应用使得海量数据集的自动化分析成为可能。考虑到传统的数理统计模型在处理复杂的非线性地质数据时,往往受限于数据分布的假设,因此无法提供足够准确的预测。尽管传统的机器学习模型在某些特定场景下表现不俗,但在捕捉非线性关系和识别复杂特征上不够灵活。因此,本文针对滑坡易发性评价主要采用的是深度学习的方法。

§ 1.3 本文研究内容

通过对国内外滑坡识别和滑坡易发性评价相关文献的分析总结,滑坡识别主要面临着两大难题,一是高质量滑坡影像数据的获取难度大,二是现有的滑坡识别算法在应对不同地区的滑坡时往往表现出鲁棒性不足和分割精度不高的问题。为解决上述问题,本研究计划采用迁移学习与数据增强策略,以应对高质量滑坡影像数据较少的难题。同时,针对算法鲁棒性不足及分割精度低的问题,本研究对 DeepLabv3+模型进行一系列改进和优化。当前滑坡易发性评价主要依赖于统计学方法和传统机器学习方法。然而这些方法在处理大规模数据集时常面临计算复杂度高和模型泛化能力不足的问题,难以有效捕捉数据中的深层信息。针对这一问题,本研究采用卷积神经网络进行滑坡易发性评价,以提高评价的准确性和效率。本文的研究内容及工作如下:

(1) 制作了一个用于滑坡识别的数据集,该数据集包含了从互联网收集的滑坡影像数据和公开的滑坡影像数据集。该数据集涵盖了不同地区、不同类型和不同规模的滑坡样本,能够有效地反映滑坡识别的实际应用场景。同时,本研究还采用了迁移学习方法,有效地将其他数据集上已经训练好的带有低语义特征信息的参数迁移至本模型中,提高了模型的识别精度。

(2) 本研究提出了一种基于改进 DeepLabv3+模型的滑坡识别方法。该方法对

DeepLabv3+模型进行了改进,包括选取 ResNet50 作为主干网络,以平衡模型的性能与响应速度。采用残差连接 ECA-Net 注意力模块,优化模型对不同尺度特征的处理能力。构建地貌特征融合模块,解决不同尺度特征间的不一致性,平衡不同层级的特征图,聚焦微小目标的细节及其边界特征。本研究基于重建的样本库进行了实验,实验结果表明,该方法在 Recall、PA、mIoU 和 mCPA 等指标上均取得了较好的效果。

(3) 基于优化后的网络模型设计并实现了基于深度学习的滑坡影像训练预测系统。该系统包含模型训练和模型预测两大功能模块。其中模型训练模块集成了标注与训练功能,滑坡预测模块则包含预测单张影像和批量预测多张影像的功能。该系统提供了一个友好的用户界面,方便缺乏编程技能的人员也可以轻松地使用该系统进行训练和预测,极大地提升了滑坡灾害识别的效率和准确性。

(4) 本研究综合考虑广西梧州市区的区域地质、地形地貌、水文地质及人类工程活动等多种影响因子。分别利用传统信息量模型和优化后的卷积神经网络模型对梧州市区的滑坡易发性进行了评估。通过整理统计这两类方法预测出的易发性分区图的滑坡占比与分区面积比重求得滑坡点密度,进而根据滑坡点密度数据评估这两类方法的优劣。结果表明,优化后的卷积神经网络模型效果更好,预测的高易发性区精度更高。

§ 1.4 论文组织结构

基于本文研究内容,全文共分为五章。

第一章,绪论。首先阐述了滑坡识别与滑坡易发性评价的研究背景与意义,紧接着阐述了近年来相关领域的研究现状,然后对本文的研究内容和所做的工作进行了概述,最后梳理本文的组织结构。

第二章,相关理论基础。系统梳理了深度学习在图像处理特别是滑坡影像分析的关键理论与方法,包括卷积神经网络的核心组成部分以及主流语义分割网络的详细解析。

第三章,基于改进 DeepLabv3+模型的滑坡识别。构建了滑坡影像数据集,详细介绍了以 ResNet50 作为主干网络的 DeepLabv3+模型的结构。为了优化模型对不同尺度特征的处理能力引入 ECA-Net 注意力模块。并构建了一个地貌特征融合模块以解决不同尺度特征间的不一致性,平衡不同层级的特征图,聚焦微小目标的细节及其边界特征。此外,将优化后的模型部署到一个易于操作的滑坡影像训练预测系统中,从而便于非技术用户进行有效的滑坡训练和预测。

第四章,基于卷积神经网络的滑坡易发性评价。收集并处理了滑坡数据、地形数据以及与滑坡发生密切相关的多种环境因子。基于广西梧州市区的 11 个滑坡影响因子,分别利用传统信息量模型和优化后的卷积神经网络模型对梧州市区的滑坡易发性

进行了评估。将研究区分为五个不同的易发区，并分析了两类模型得到的各易发区的分布情况。

第五章，总结与展望。总结本论文所做的工作，分析本论文中的不足之处，针对本次研究的现有成果，提出了对未来研究方向和改进空间的建议，并对当前研究中未能解决的问题进行了分析。

第二章 相关理论基础

深度学习借鉴了人脑神经网络的结构和功能原理,通过构建多层非线性模型来学习和理解复杂的数据模式。近年来,深度学习在图像处理、自然语言处理及语音识别等应用取得了重大进步。如今,深度学习的方法也逐渐应用于遥感领域,特别是在滑坡识别和易发性评价方面展现出巨大潜力。通过对遥感图像和地理数据的深入剖析,深度学习的方法不仅能有效识别滑坡区域,还能对研究区域进行精准的易发性评估,为滑坡灾害的预防和治理提供了有力支持。

§ 2.1 卷积神经网络

卷积神经网络(Convolucional Neural Networks, CNN)是深度学习领域的一个重大突破,它是一种特殊类型的前馈神经网络,其核心在于有效地利用卷积计算来处理数据。CNN的设计灵感源于生物视觉感知机制,特别是对局部感受野的模拟。这种网络结构实质上是对传统多层感知机(MLP)的扩展和改进,它通过引入卷积层来增强网络的特征提取能力。在当今的图像处理领域,CNN已成为构建各类图像处理神经网络框架的基础。CNN的核心优势在于三个关键操作:局部感受野、权值共享和池化层。这些操作不仅减少了网络中权值的数量,降低了模型的复杂度,而且有效降低了过拟合的风险,进而提升了模型的训练效率和泛化能力。卷积神经网络模型基本结构通常由卷积层、激活函数、批归一化层、池化层、全连接层组成。

§ 2.1.1 卷积层

卷积层(Convolutional Layer)^[40]是卷积神经网络的核心部分,主要负责从输入数据中提取特征。它利用特定的卷积核对输入数据进行处理,以捕捉数据中的局部特征。在图像处理应用中,卷积层特别擅长识别图像中的关键特征,如边缘和纹理等。卷积核B的大小通常根据输入数据的特性来选择。卷积核会按照预定的步长在输入特征矩阵A上进行滑动,以此覆盖输入数据的不同区域。当卷积核在输入特征矩阵A上滑动时,它会与当前窗口内的数据元素逐一进行乘积运算。随后将这些乘积求和,形成一个新的特征值。这个过程在整个输入数据上重复进行,最终生成一个新的特征图即输出特征矩阵C,该特征图代表了输入数据中的关键信息,如图2-1所示。




图 2-1 卷积层特征提取

目标特征图的大小即输出特征矩阵 C 的大小由输入特征图的尺寸、卷积核的尺寸和步长共同决定。输出特征矩阵 C 的大小计算公式如式 2-1 所示。

$$N = (W - F + 2P) / S + 1 \quad (2-1)$$

其中, W 表示输入特征图的尺寸, F 表示卷积核的尺寸, P 表示零填充的数量, S 表示卷积的步长。当处理具有多维特性的输入特征矩阵时, 为了确保卷积操作的一致性, 所选用的卷积核需要在深度上与输入特征矩阵相匹配。若输入特征矩阵具有三个维度, 则卷积核也应具备相同数量的通道。

§ 2.1.2 激活函数

在卷积神经网络 (CNN) 的架构中, 卷积和池化层本质上执行的是线性操作。即使通过增加网络层来加深网络, 最终得到的模型仍然是一个线性函数, 其特征表达能力有限。然而, 现实世界中的数据分类问题往往涉及复杂的非线性关系, 这超出了纯线性模型的处理范畴。非线性激活函数的引入大大提升了网络的表征能力, 使其能够捕捉和学习更为复杂的数据模式, 而且保证了网络函数的可微性。因此, 在卷积层之后通常会添加非线性激活函数, 以引入必要的非线性特性。常用的激活函数包括 Sigmoid 函数^[41]、Tanh 函数^[42]、ReLU 函数^[43]和 Leaky_ReLU 函数^[44]等。

(1) Sigmoid 函数

Sigmoid 函数是一种非线性网络激活函数, Sigmoid 函数如式 (2-2) 所示。

$$\text{Sigmoid}(x) = \frac{1}{1 + e^{-x}} \quad (2-2)$$




图 2-2 Sigmoid 函数

由图 2-2 可知，当输入值过大或过小时，函数的梯度趋近于 0，这在神经网络的反向传播过程中可能导致梯度消失，从而阻碍网络的学习。因此，Sigmoid 函数通常应用于二分类的输出层，用于输出概率值。

(2) Tanh 函数

Tanh 函数与 Sigmoid 函数相似，Tanh 函数的输出范围是 $(-1,1)$ ，相比于 Sigmoid 函数的 $(0,1)$ 输出，Tanh 的输出均值为 0，这一特性使得它在某些情况下的收敛速度更快，减少了网络在训练过程中的迭代更新次数。然而，Tanh 函数在输入值较大或较小时也会遇到梯度消失的问题，其函数式为式 2-3，Tanh 函数图如图 2-3。

$$\text{Tanh}(x) = \frac{e^x - e^{-x}}{e^x + e^{-x}} \quad (2-3)$$




图 2-3 Tanh 函数

(3) ReLU 函数

ReLU 函数的数学定义式如式 2-4 所示。

$$\text{ReLU}(x) = \max(0, x) \quad (2-4)$$




图 2-4 ReLU 函数

由图 2-4 的 ReLU 函数曲线可知，当输入为正数时，ReLU 函数输出是线性的，而对负数输入则输出为零。这种特性使得 ReLU 在神经网络中的计算变得非常高效，同时也有效的缓解了深层网络中的梯度消失问题。不过，ReLU 也存在所谓的“死亡 ReLU”现象，即网络中的某些神经元可能永远不会被激活，导致相应的参数无法更新。

(4) Leaky ReLU 函数

Leaky ReLU 函数的数学表达式如式 2-5 所示，函数曲线图如图 2-5 所示。

$$\text{LeakyReLU} = \max(\alpha x, x) \quad (2-5)$$




图 2-5 Leaky ReLU 函数

Leaky ReLU 函数是 ReLU 的一个改进版本，主要目的是为了解决 ReLU 中可能出现的“死亡神经元”问题。与标准的 ReLU 不同，当输入为负数时，Leaky ReLU 允许有一个非零的梯度，这样即使在输入为负的情况下，神经元也不会完全停止工作，从而保持了网络的学习能力。通过引入 Leaky ReLU，模型对负输入的反应变得更为敏感，这有助于提升网络在某些特定情况下的性能。尽管 Leaky ReLU 在理论上解决

了部分 ReLU 的问题，但在实际应用中，它是否总是优于标准的 ReLU 函数还有待进一步的实验验证。

§ 2.1.3 批归一化层

在深度神经网络的训练过程中，随着参数的持续更新，各层输入数据的分布往往会发生变化，这种现象被称为内部协变量偏移。此外，许多激活函数在输入值较大或较小时会进入饱和区，导致梯度消失，使得网络难以进一步学习。为了解决这些问题，Ioffe 和 Szegedy^[45]提出了批归一化（Batch Normalization, BN）技术。批归一化的核心思想是对每个批次的数据进行归一化处理，这样每层输出的特征值分布会更接近正态分布，进而将数据保持在激活函数的非饱和区域。这不仅减少了内部协变量偏移的影响，还使得网络能够使用更大的学习率，从而加速了训练过程。同时，它还能增大梯度的变化范围，有效缓解梯度消失问题，进而提高了模型训练的稳定性与效率。

设每一个批次的输入数据为 $X = x_1, x_2, \dots, x_m$ ，其中 m 为训练样本的批次大小， ε 是为了避免分母为 0 时造成计算不稳定加入的接近 0 的微小值，而 γ ， β 是神经网络中学习的参数，批归一化的过程的如下所示：

（1）计算每一个批次输入数据的均值，其公式如下：

$$\mu_X = \frac{1}{m} \sum_{i=1}^m x_i \quad (2-6)$$

（2）计算每一个批次输入数据的方差，其公式如下：

$$\sigma_X^2 = \frac{1}{m} \sum_{i=1}^m (x_i - \mu_X)^2 \quad (2-7)$$

（3）根据求得的均值与方差做归一化处理：

$$\hat{x}_i = \frac{x_i - \mu_X}{\sqrt{\sigma_X^2 + \varepsilon}} \quad (2-8)$$

（4）强制的规范化可能会减弱原始特征在模型训练中的作用，将规范化后的特征乘以尺度参数 γ 并加上偏移参数 β ，这样模型就具备了重新调整规范化特征的能力，其公式如下：

$$y_i = \gamma \hat{x}_i + \beta = BN_{\gamma, \beta}(x_i) \quad (2-9)$$

§ 2.1.4 池化层

池化层^[46]主要通过下采样技术来降低特征图的维度，从而减少计算量、降低过拟合风险，并增强网络模型的泛化能力。池化操作主要有两种形式：最大池化和平均池

化。最大池化是通过在特定区域内选择最大值来代表该区域，这种方式能够有效地保留图像的显著特征。而平均池化则是计算区域内所有值的平均值，以减少图像局部区域的极端值对整体的影响。这两种池化方式不仅有助于增大网络的感受野，降低信息冗余，还能增强模型对输入特征位置变化的鲁棒性。在实际应用中，池化层使得网络能够更高效地处理大尺寸的输入图像，同时保持对关键特征的敏感性。池化操作如下图 2-6 所示，图 2-6（a）为最大池化，图 2-6（b）为平均池化。




图 2-6 池化操作运算示意图

§ 2.1.5 全连接层

全连接层主要负责综合前面层提取的特征并进行最终的分类决策。在典型的 CNN 架构中，网络末端的两个全连接层承担着这一任务。倒数第二层的全连接层将输入的特征图展平成一维向量，并通过与权重矩阵和偏置项进行线性变换，进一步整合这些特征。而最后一层全连接层的神经元数量通常与目标分类的类别数相匹配，其作用是将整合后的特征映射到分类空间，从而输出最终的分类结果。全连接层的数学表达式如式 2-10 所示。

$$f(x) = W \cdot x + b \quad (2-10)$$

其中 x 表示输入向量， W 和 b 分别表示权重和偏置， $f(x)$ 为输出。由于全连接层的输出并非直接的概率分布，因此通常需要将其输出传递给 Softmax 层。Softmax 层的作用是对全连接层的输出进行归一化，使得输出的每个值都在 0 到 1 之间，并且所有值的总和为 1，从而得到每个类别的预测概率。全连接的网络结构图如图 2-7 所示。




图 2-7 全连接层结构

§ 2.1.6 损失函数

损失函数是衡量分类器预测值与真实值之间差异程度的关键工具，其输出为非负实值，这个值可以作为反馈信号来调整分类器的参数，以降低当前样本对应的损失值，从而提高分类器的性能。在模型训练过程中，每个批次的训练数据经过前向传播得到预测值，随后损失函数会量化这些预测值与实际值之间的差距，并计算出损失值。这个损失值会经过反向传播算法，用于更新卷积神经网络中的权重参数，通过这样的方式，模型能够逐渐调整其预测值，使之更加接近真实值，从而有效地实现图像识别等任务。损失函数分为基于度量的损失函数和基于概率分布度量的损失函数两大类。其中，基于度量的损失函数包括均方误差损失函数（MSE）、L1 损失函数、Smooth L1 损失函数和 Dice 损失函数等。而基于概率分布度量的损失函数包括 KL 散度、交叉熵损失和 Focal Loss 等。

在分类任务中，特别是当使用 Sigmoid 和 Softmax 激活函数时，交叉熵损失函数因其处理数值溢出问题的能力而被广泛采用。在多分类任务中，通常会结合 Softmax 函数使用多分类交叉熵损失函数。而在二分类任务中，则更倾向于使用 Sigmoid 函数结合二分类交叉熵损失函数。交叉熵损失函数的公式如 2-11 所示。

$$L = - \sum_{i=1}^c p(x_i) \log(q(x_i)) \quad (2-11)$$

其中， c 表示一共有 c 个样本， $q(x_i)$ 为分类器预测的概率分布， $p(x_i)$ 表示第 i 个样本 x 属于真实类别的概率， L 是用来度量预测值与真实值之间的不一致程度。

Dice 损失函数常用于图像分割领域，它属于基于度量的损失函数。Dice 损失函

数是基于 Dice 系数的，Dice 系数是一种用于度量两个集合相似性的统计工具。在处理数据不平衡问题时，Dice 损失函数表现尤为出色，例如在一幅图像中，当目标区域相较于背景区域所占的比例很小时。Dice 损失函数的计算公式如 2-12 所示。

$$Dice\ Loss = 1 - \frac{2 \times |X \cap Y|}{|X| + |Y|} \quad (2-12)$$

其中， X 表示预测的像素集合， Y 表示真实的像素集合。这个公式的分子是预测像素和真实像素交集大小的两倍，分母则是两个像素集合大小之和。通过这种方式，Dice 损失函数计算出一个介于 0 到 1 之间的值，0 表示完美的重叠，1 则表示没有重叠。因此，在训练过程中 Dice 损失函数的值越小越好。

§2.2 经典的语义分割网络

在深度学习领域，图像语义分割已经取得了瞩目的进展。语义分割的目标是让计算机理解图像的内容，并在像素级别上对其进行分类，即将图像中的每个像素划分到对应的类别中。这一过程涉及到对图像中的不同物体进行精确识别和定位，例如区分图像中的人、车辆、建筑物等不同对象。随着技术的不断发展，语义分割也开始逐渐应用于遥感影像。语义分割的基本流程如图 2-8 所示，它清晰地展示了从输入图像到最终生成分割结果的整个过程。目前，常用的语义分割模型包括全卷积神经网络^[47]、U-Net^[48]、PSPNet、HRNet、DeepLab 系列等。



图 2-8 语义分割流程图

§2.2.1 全卷积神经网络

全卷积神经网络（FCN）是专为图像语义分割设计的深度学习模型，它实现了对图像的像素级分类。相较于传统卷积神经网络，FCN 彻底摒弃了固定尺寸的全连接层，转而采用全卷积层，从而能够处理任意尺寸的输入图像。在 FCN 中，最后一个卷积层的特征图通过上采样技术，恢复至与原始输入图像相同的尺寸，使得模型能够对每个像素点进行预测，同时保持原始图像的空间信息。尽管卷积和上采样操作能够定位目标区域的大致位置，但由于卷积、池化和非线性激活函数等操作的连续应用，输出的特征图相对粗糙，丢失了图像中的许多细节信息。为了弥补这一缺陷，FCN 创新性地引入了跳跃连接结构。这种结构通过融合不同层级的特征图来恢复丢失的细节信息，进而提升分割的准确性。FCN 的结构图如下图 2-9 所示，FCN-32s 是上采样后输出放大 32 倍的结果，其分类结果较为粗糙。FCN-16s 则是步长为 16 的反卷积操

作，它融合了倒数第二层的池化层与最后一层卷积层的特征，再进行上采样得到更精细的结果。而 FCN-8s 进一步融合了倒数第三层的池化层特征，通过步长为 8 的反卷积操作，获得了更为精准的分割结果。尽管 FCN 通过跳跃连接实现了多特征融合，提高了分割精度，但在预测结果的边缘部分仍存在模糊问题。此外，FCN 忽略了各像素之间在空间上的一致性，这使其在捕获图像的全局上下文信息时不够全面。




图 2-9 FCN 网络结构图

§2.2.2 U-Net 网络

U-Net 是一种专门用于图像分割任务的深度学习模型，因其独特的编码-解码结构而被广泛应用于医学图像处理。在编码部分，U-Net 采用了与全卷积网络（FCN）类似的层级结构，通过连续的卷积和池化操作来提取图像的低层次特征，并捕获关键的空间信息。而在解码阶段，U-Net 采用多层上采样和卷积层，不仅恢复了图像的分辨率，还重建了图像细节。U-Net 采用的跳跃连接方式是将编码阶段的低层次特征与解码阶段的高层次特征进行串联，而非简单的求和操作。这种特征融合方式在保留更多细节信息的同时，实现了多尺度特征的有效识别。总体而言，U-Net 的这些特性不仅提高了图像分割的准确性，也为复杂图像分割问题提供了新的解决方案。其结构如图 2-10 所示。




图 2-10 U-net 网络模型结构

§2.2.3 PSPNet 网络

PSPNet^[49] (Pyramid Scene Parsing Network) 是 Zhao 等人于 2017 年提出的一种深度学习模型, 专为处理复杂图像的语义分割任务而设计。该模型在多个重要数据集, 如 ImageNet 场景分析挑战赛、Cityscapes 数据集和 Pascal VOC2012 数据集上均表现出色, 表明该模型在处理城市街景、自然场景等复杂环境时表现优异。PSPNet 的创新之处在于引入空间金字塔池化模块, 该模块通过对输入特征图进行不同尺度的池化操作, 有效捕捉图像中的多尺度上下文信息。这种设计使得模型能够综合考虑图像的局部细节和全局特征, 从而在像素级分类中实现更高的准确性。在 PSPNet 中, 特征图首先通过预训练的 ResNet 模型进行特征提取。随后, 这些特征图进入金字塔池化模块, 并被划分为大小不同的区域并进行平均池化。接着, 通过上采样和通道拼接的方式, 这些多尺度特征被融合在一起。这种结构设计不仅减少了分割歧义, 还增强了模型对不同层级特征的表征能力。最后, 融合后的特征图经过卷积层处理, 并通过 Softmax 分类器进行最终的像素级分类。PSPNet 的网络结构图如图 2-11 所示。




图 2-11 PSPNet 网络结构图

§2.2.4 HRNetV2 网络

区别于传统的 CNN 模型如 VGG、MobileNet 和 ResNet 系列，这些模型通常经过连续的下采样过程逐步降低特征图的空间分辨率。然而，HRNet 采取了一种创新的方法，它在整个网络处理过程中都保持了高分辨率特征图，从而能够融合不同尺度的特征并捕获丰富的细节信息。这种独特的设计使得 HRNet 在人体姿态检测等应用上取得了一定成果。其后续版本 HRNetV2^[50]进一步提升了模型的适用性和性能，使其能够有效地应用于语义分割领域。HRNetV2 的核心优势在于能够提取包含各种分辨率的特征，这使得模型理论上可以适应多种不同的计算机视觉需求，如目标检测、语义分割和实例分割等。




图 2-12 HRNetV2 网络结构图

HRNetV2 由三部分构成：主干特征提取部分，特征整合部分以及预测头部分。在图 2-12 中，灰色框左侧是主干特征提取部分，灰色框右侧则是特征整合部分。在主干特征提取部分，网络采用了并行的多分辨率分支，同时进行下采样和上采样，从而获取不同尺度的特征图并进行实时融合。在特征整合部分，HRNetV2 将所有分辨率的特征图进行融合。为了确保特征的一致性和连续性，较小的特征图会通过上采样操作扩展到与最大特征图相同的尺寸，并进行融合。最后，预测头部分负责将整合后的特征图转换为最终的输出。它首先通过 1×1 卷积调整通道数，以匹配目标类别的数量。随后，通过上采样操作将输出特征图的尺寸调整至与输入图像相同，以实现精确的像素级预测。

§2.2.5 DeepLab 系列

DeepLab 系列由 Google 团队开发，是一系列针对图像语义分割任务的深度学习模型，涵盖了 DeepLabv1 至 DeepLabv3+ 等多个版本。其中，DeepLabv1 作为该系列的开山之作，该模型基于经典的 VGG16 网络架构，并进行了针对性的改进以更好地满足语义分割任务的需求。特别地，为了减少因池化操作导致的空间信息损失，DeepLabv1 去除了 VGG16 中的最后两个池化层。为了弥补去除池化层后感受野减小的问题，DeepLabv1 引入了空洞卷积技术。这种卷积方式通过在卷积核中增加空间间

隔,有效扩大了感受野,使网络能够在不增加计算负担的情况下捕获更广泛的上下文信息。与标准卷积相比,空洞卷积为网络提供了更强大的特征提取能力,与标准卷积的对比图如图 2-13 所示。此外,DeepLabv1 还采用了条件随机场作为后处理步骤,进一步优化分割边界并提高了像素级分类的精度。CRF 通过考虑相邻像素之间的关系,能够有效地改善分割结果的细节。



图 2-13 标准卷积与空洞卷积对比

DeepLabv2 作为 DeepLab 系列的第二代模型,在继承 DeepLabv1 优秀特性的基础上,又进行了一系列改进。首先,DeepLabv2 在特征提取层上进行了重要更新,将原先的 VGG16 网络替换为更加精确的 ResNet101 网络。其次,DeepLabv2 引入了空洞空间金字塔池化(ASPP)模块,有效增强了模型对复杂场景的理解和处理能力,ASPP 模块的结构如图 2-14 所示。最后,DeepLabv2 还采用了更加高效的学习策略,相比于传统的使用固定步长降低学习率的方法,这些新策略能够更好地适应模型的训练过程,从而加快了收敛速度并提升了训练效率。




图 2-14 ASPP 模块结构图

DeepLabv3 中有以下几个改进点。第一,DeepLabv3 决定移除条件随机场(CRF)模块。第二,在特征提取方面,DeepLabv3 对 ResNet101 进行加深,在第四个残差块后增加 3 个 block 模块。此外,为了保持更高的空间分辨率,DeepLabv3 对网络结构的下采样策略进行了优化,减少了不必要的下采样次数,从而保留了更多的空间细节。通过引入不同膨胀率的空洞卷积,模型能够捕捉更广泛的上下文信息,有效地提升了

级联网络的性能。带有空洞卷积的级联模块如图 2-15 所示。第三，为了提高网络的训练性能，在空洞卷积之后加入 BN 层。第四，DeepLabv3 引入了改进的 ASPP 结构。该结构结合了不同膨胀率的空洞卷积、 1×1 卷积以及全局平均池化，有效地克服了空洞卷积中有效权重减少的问题。带有空洞卷积的并联模块如图 2-16 所示。




图 2-15 带有空洞卷积的级联模块




图 2-16 带有空洞卷积的并联模块

DeepLabv3+在 DeepLabv3 的基础上进行了多项改进。首先，它引入了一个解码器模块来增强细节信息的恢复，从而提高分割图的质量。其次，DeepLabv3+对编码器部分进行了升级，采用了改进的 Xception 模型^[51]。最后，DeepLabv3+还使用了大量的深度可分离卷积，有效的减少了模型的参数量，提高了处理速度。

§ 2.3 卷积神经网络的训练

§2.3.1 反向传播算法

反向传播算法^[52]是神经网络中用于计算损失函数相对于网络权重的梯度的方法。这些梯度信息会被优化算法使用，来调整网络权重以此优化模型性能。

假设有一个简单的多层神经网络，用 l 表示网络的层数，共有 m 层。在前向传播过程中，输入数据沿着网络前行，逐层计算每一层的输出直到得到最终的预测结果。在网络中的每个神经元都会计算一个加权求和，具体操作如式 2-13 所示，在加权求和后会通过一个激活函数产生最终的结果，公式如式 2-14 所示。

$$z^{(l)} = W^{(l)}a^{(l-1)} + b^{(l)} \quad (2-13)$$

$$a^{(l)} = f(z^{(l)}) \quad (2-14)$$

式中 $W^{(l)}$ 和 $b^{(l)}$ 分别为第 l 层的权重和偏差, $f(\cdot)$ 表示激活函数, $a^{(l)}$ 则是第 l 层的激活函数输出结果。

反向传播开始于输出层, 输出层需要选择一个损失函数, 为了方便推导这里选择均方误差损失函数, 其公式如 2-15 所示。

$$L(W, b) = \frac{1}{2} \|a^m - \hat{y}\|^2 \quad (2-15)$$

其中 $L(W, b)$ 为损失函数, a^m 为输出层的预测结果, $\hat{y}$ 为真实值。

为了计算各层的梯度值, 首先需要计算输出层的梯度 $\delta^{(l)}$, 具体计算公式如下 2-16 所示。

$$\delta^{(l)} = (a^{(l)} - \hat{y}) \cdot f'(z^{(l)}) \quad (2-16)$$

对于隐藏层中任意一层 l ($l = m, m-1, \dots, 2$) 的梯度, 其计算公式如 2-17 所示。

$$\delta^{(l)} = ((W^{(l+1)})^T \delta^{(l+1)}) \cdot f'(z^{(l)}) \quad (2-17)$$

§2.3.2 Adam 算法

对于参数优化策略, 本文使用 Adam 算法^[53]。Adam 算法融合了动量和自适应梯度的思想, 在参数更新时, 根据该参数梯度的一阶矩和二阶矩计算不同参数的自适应学习率。Adam 优化方法步骤如下:

- ①从训练集中采样 m (批量大小) 个样本 $\{x^{(1)}, \dots, x^{(m)}\}$ 对应目标 $\{y^{(1)}, \dots, y^{(m)}\}$
- ②计算梯度, 其公式如下:

$$g = \frac{1}{m} \nabla_{\theta} \sum_i L(f(x^{(i)}; \theta), y^{(i)}) \quad (2-18)$$

其中, θ 为预训练参数, $y^{(i)}$ 为对应目标, $f(x^{(i)}; \theta)$ 预测值, L 为损失函数。

- ③计算累积梯度, 其公式如下:

$$v = \mu v + (1 - \mu)g \quad (2-19)$$

其中, μ 为动量系数, 用于控制动量和当前梯度的权值。本文将其设置为 0.9。

- ④计算累积平方梯度, 公式如下:

$$r = \rho r + (1 - \rho)g * g \quad (2-20)$$

其中, ρ 为衰减速率, 用于控制累积平方梯度的权值。本文将其设置为 0.999。

- ⑤由于 v 和 r 初始化累积变量都为 0, 使其结果偏向于 0, 因此需要对这两个参数进行偏差修正, 公式为:

$$\tilde{v} = \frac{v}{1 - \mu^t} \quad (2-21)$$

$$\tilde{r} = \frac{r}{1 - \rho^t} \quad (2-22)$$

⑥最后根据各超参数更新权值，公式如下：

$$\theta = \theta - \frac{\eta}{\sqrt{\tilde{r}} + \delta} \tilde{v} \quad (2-23)$$

其中， η 为学习率， δ 为小参数，避免了分母为 0。

§ 2.4 本章小结

本章探讨了深度学习在图像处理，特别是在滑坡影像分析领域的关键技术和理论基础。从深度学习的起源和发展历程入手，介绍了深度学习模型框架的基本构成，包括卷积神经网络（CNN）及其核心组件如卷积层、激活函数、批归一化层、池化层和全连接层。本章还分析了损失函数的重要性以及在图像语义分割任务中广泛应用的经典语义分割网络，如全卷积网络（FCN）、U-Net、PSPNet、HRNet 和 DeepLab 系列，详细阐述了它们的网络结构与创新点。

第三章 基于改进 DeepLabv3+模型的滑坡识别

滑坡是一种突发性的地质灾害，一旦发生滑坡，往往伴随着房屋倒塌、道路中断以及人员伤亡等严重后果。目前，滑坡的识别主要依赖于遥感影像的目视判别、现场核查以及机器学习等方法。在紧急滑坡灾害发生时，传统方法难以快速获取、处理和分析数据，影响灾害响应速度。虽然已有大量深度学习的方法被应用于滑坡影像的分割，但仍然面临着诸多挑战。一方面，滑坡的形态因地形、地貌、植被等因素的影响往往差异较大，这无疑加大了滑坡分割任务的不确定性。另一方面，滑坡的种类繁多以及边界轮廓大小变化无固定规律进一步增加了分割的难度。针对这些问题，本章提出了一种基于改进 DeepLabv3+模型的滑坡识别方法。考虑到滑坡灾害通常发生突然，需要迅速的响应以减少潜在的人员伤亡和财产损失，通过部署一个高效的滑坡影像训练预测系统来大幅度提升滑坡灾害响应的速度。

§ 3.1 数据集概述

(1) 滑坡数据集样本制作

毕节滑坡数据集是一个比较准确的公共滑坡数据集，研究区位于中国贵州省毕节市，由 770 幅滑坡样本和 2003 幅负样本组成，所有的滑坡都从空间分辨率为 0.8 米的 TripleSat 卫星影像中提取而来，并经过了专家的目视解译及现场调查验证。滑坡样本包括崩塌、岩石滑坡和碎屑滑坡等，负样本由山、村、路、河、林和农地等影像构成。在该数据集的 770 幅滑坡正样本基础上，从互联网搜集相似场景的滑坡影像，由于搜集的影像没有对应的标签，本文使用 Labelme 工具对滑坡进行标注，背景为默认类别。同时为了让数据集适应所选用的算法，需要将标注后的数据集转化为二值图像，最终滑坡影像数据集达到 1227 张。数据集划分为训练集和验证集，并按 9:1 的比例进行划分。输入的图像数据会在网络中自动将分辨率调整为 512×512。





图 3-1 研究样本展示

图 3-1 展示了毕节滑坡数据集和扩充数据集的滑坡影像数据，前三行是公开滑坡数据集的样本示例，最后一行是扩充的滑坡数据集的样本示例。

(2) 数据集增广

在深度学习领域，尤其是图像处理任务中，样本增强是一种关键的技术，用于提高模型的泛化能力并增强模型的鲁棒性。样本增强通过对原始数据集进行一系列变换，创造出多样化的训练样本，从而帮助模型学习到更全面的特征。常见的样本增强方法包括镜像、旋转、平移缩放和加噪等，如图 3-2 所示。镜像，即水平翻转图像，可以增强模型对图像方向变化的适应能力。旋转，通过对图像进行不同角度的旋转（如 30 度、45 度、60 度、90 度），使模型能够识别不同角度下的对象特征。平移缩放，通过改变图像的尺寸和位置，增强模型对尺寸和位置变化的鲁棒性。加噪，特别是高斯噪声的添加，有助于提高模型对含有噪声干扰的图像的处理能力。这些技术的应用不仅增加了训练数据的数量，更重要的是提高了数据的多样性，使得深度学习模型在面对多变的实际应用场景时表现出更高的准确性。因此，在进行图像分割、目标检测等高精度要求的任务时，合理的样本增强策略对于提升模型性能十分关键。



(a) 原图

(b) 水平翻转

(c) 垂直翻转

(d) 变亮



图 3-2 数据增广方法

§ 3.2 改进的 DeepLabv3+算法

§ 3.2.1 基于 ResNet50 的 DeepLabv3+算法

DeepLabv3+[⁵⁴]的架构原本是基于 Xception 主干网络来提取特征。尽管选用 Xception 作为主干网络时，它在各项评价指标上均表现出色，达到了最佳性能，但 Xception 的设计特点是将传统卷积操作分解为深度卷积和逐点卷积，在保留性能的前提下可能会增加浮点运算的次数。鉴于滑坡灾害的突发性和快速识别需求，需要模型具备较快的训练和推理速度。考虑到 ResNet50 的结构相对简单，能够更快速地进行训练，本文决定选用 ResNet50 作为 DeepLabv3+的主干网络，以期在保证性能的同时提高模型的响应速度，更好地满足滑坡灾害快速识别的需求。

DeepLabv3+的网络结构由两部分组成。其中，编码器部分继承了原 DeepLabv3 的结构。在此基础上，添加了解码器部分，形成了 DeepLabv3+这一新模型，如图 3-3 所示。




图 3-3 基于 ResNet50 的 DeepLabv3+

由上图可知，主干网络 ResNet50[⁵⁵]分为四个阶段，从 stage1 到 stage3，特征图的尺寸会随着步长为 2 的卷积和下采样操作而依次缩小，变为输入图像的 1/4、1/8 和 1/16。到了第 4 个 stage，为了保持特征图大小不变（仍为输入图像的 1/16），同时

增大感受野，采用空洞卷积替代了原有的下采样操作。为了进一步提取更具语义化的特征，第4阶段输出的特征图会经过ASPP模块。该模块对输入的特征图进行五种不同的操作：包括一个 1×1 的卷积、三个膨胀率分别为6、12和18的 3×3 空洞卷积，以及一个全局平均池化操作来捕获全局信息。之后，将这五种操作得到的特征图在通道维度上进行拼接，并通过一个 1×1 卷积将通道数减少到256，特征图大小变为 32×32 。解码器部分则负责将编码器输出的高语义特征图与stage1输出的低语义特征图进行融合。首先，通过 1×1 卷积减少低语义特征图的通道数，然后将编码器输出的高语义特征图进行4倍上采样。接着，将上采样后的高语义特征图与低语义特征图进行concat融合。最后，将融合后的结果传输给一个 3×3 卷积，并再次进行4倍上采样，以得到最终的语义分割结果。

§ 3.2.2 残差连接 ECA-Net 注意力模块

以ResNet50作为DeepLabv3+模型的主干网络，其连续的卷积和池化操作虽然可以提取出深层次的特征信息。但在具有不同尺度和复杂背景的山区滑坡图像中，特别是在处理尺寸较小或形态不规则的滑坡区域时，这些操作可能导致细节信息的丢失，影响滑坡的分割精度。现有的注意力机制虽然通过全局池化和全连接层增强了网络对全局信息的敏感性，提升了分割准确度，但仍忽略了局部细节特征。为了解决这一问题，本研究引入ECA-Net注意力模块^[56]，一个利用局部一维卷积来捕捉和强化局部通道特征的模块，即使在背景复杂和目标尺寸多变的情况下，也能保持高准确性的分割。ECA-Net的核心优势在于动态调整卷积核大小的能力，根据输入特征自动选择最合适的卷积核尺寸，从而优化模型对不同尺度特征的处理能力。此外，ECA-Net通过整合周边信息来增强对全局上下文的理解，特别适用于复杂和动态变化的自然环境。其轻量化和高效计算设计降低了计算负担，有利于实现快速部署。该模块的结构如下图3-4所示。




图 3-4 ECA-Net 注意力模块

首先假设有一个特征图的维度为 $H\times W\times C$ ，其中 H 是高度， W 是宽度， C 是通道数。将该特征图输入到全局平均池化GAP中将特征图的每个通道缩减为一个单一的标量，得到一个 $1\times 1\times C$ 维度的特征向量。此操作是为了提供一个压缩的全局特征，作为通道注意力机制的输入。随后将这个特征向量通过一个1D卷积层（conv1d）处理，卷积层的核大小 k 通常由模型的通道数自动确定，以便捕捉不同尺度的特征依赖。

该模块中一维卷积核大小与通道数有关，其公式如公式 3-1 所示。

$$k = \psi(C) = \left\lceil \frac{\log_2(C)}{\gamma} + \frac{b}{\gamma} \right\rceil_{\text{odd}} \quad (3-1)$$

其中， C 表示通道数， $\lceil x \rceil_{\text{odd}}$ 表示选择最近的奇数， $\gamma = 2$ ， $b = 1$ 。

经过卷积层后，特征向量的维度依然保持为 $1 \times 1 \times C$ 。接下来，这个特征向量通过一个 Sigmoid 函数，输出一个 $1 \times 1 \times C$ 的权重向量，每个值都介于 0 和 1 之间。最后，这个权重向量与原始输入特征图按通道进行逐元素相乘，以便加权每个通道的特征，最终输出的特征图维度还是 $H \times W \times C$ 。本研究将 ECA-Net 作为残差连接的一部分，ECA-Net 的加权特征与主干网络 stage4 阶段的特征相结合，保留了通过前面层次所学习到的原始特征信息，同时也学习到了通道注意力引导下的特征变化。

§ 3.2.3 地貌特征融合模块

由于本文所选用的 DeepLabv3+模型的主干网络是 ResNet50，该网络分为四个阶段，每个阶段都能生成不同层级的特征图。将这些不同层级的特征图进行合理融合，可以有效提升模型的性能。考虑到滑坡的边界轮廓和尺度大小变化无固定规律，这使得基于单一尺度的特征很难准确捕捉滑坡的全部信息。通过融合多尺度的特征，可以更好地捕捉滑坡的全貌。以往的多尺度特征融合技术往往采用简单的加权平均或级联融合等固定的融合规则，这种固定的融合机制在处理具有高度异质性的山区滑坡图像数据时显得不够灵活。其次，传统的融合方法常常忽视了特征间的不一致性，即高层特征虽然具有更抽象的语义信息，但可能缺乏足够的细节信息，而低层特征虽然细节丰富但语义较弱。这种语义层次和细节层次的不匹配，可能导致在实际应用中，特别是在复杂场景下，导致模型性能不足。尽管现有方法在一定程度上改进了特征融合的效果，但在处理变化复杂的地形或不同尺度的滑坡特征时，这些方法的分割性能仍有待提高。

针对上述问题，本文提出了一个地貌特征融合模块（Geomorphological Feature Fusion Module, GFFM）。不同于传统的多尺度特征融合模块，GFFM 采用了动态权重分配机制，允许模型根据输入特征的语义重要性自适应调整融合策略。此外，GFFM 集成了增强的注意力机制，通过迭代地细化特征融合过程，进一步提升了对细节的捕捉能力和整体的分割精度。GFFM 主要由自适应空间特征融合（Adaptive Spatial Feature Fusion, ASFF）和迭代注意力特征融合模块（iterative Attentional Feature Fusion, iAFF）两部分组成，这两种机制共同作用，高效地整合了从不同深度和尺度提取的特征，提升了模型对复杂地形变化下滑坡边界的识别能力。

自适应空间特征融合模块 ASFF^[57]利用空间注意力机制，自适应地调整来自不同尺度的特征图在每个像素位置的重要性，分为两步：恒等缩放和自适应特征融合。如下图 3-5 所示是本文使用到的自适应空间特征融合模块 ASFF 融合多尺度特征的过程。




图 3-5 ASFF 融合多尺度特征结构图

其中待融合的三个特征图为主干网络 ResNet50 的前三个阶段 stage1、stage2、stage3。这三个阶段分别输出三个不同尺度的特征图，表示为 X^1 、 X^2 和 X^3 ，其中 X^1 是最高层次的特征图，具有最小的空间维度和最高的语义信息， X^3 是最底层的特征图，具有最大的空间维度和最丰富的细节信息， X^2 位于两者之间。在多尺度特征融合过程中，首先需要对特征图进行通道数和尺寸的对齐，确保它们能够有效地融合。具体来说，以 ResNet50 网络的 stage1 输出的特征图作为参照基准，通过一系列 1×1 卷积操作，调整 stage2 和 stage3 输出的特征图的通道数，使之与 stage1 的输出通道数一致。这一步标准化了特征图的维度，并保留了跨尺度的特征信息。随后，采用上采样技术，精确调整 stage2 和 stage3 的空间分辨率，使其与 stage1 的特征图具有相同的尺寸。通过这一恒等缩放的过程，不同尺度的特征图达到了尺寸和通道的一致性，为接下来的特征融合创造了条件。

随后，完成通道和尺寸对齐的特征图进行自适应特征融合。对于位置 (i, j) 上的特征向量，通过对来自 stage1，stage2 和 stage3 的对应特征 $X_{ij}^{1 \rightarrow 3}$ ， $X_{ij}^{2 \rightarrow 3}$ 和 $X_{ij}^{3 \rightarrow 3}$ 进行加权求和来实现自适应融合，加权求和的权重 α_{ij} ， β_{ij} 和 γ_{ij} 是通过 Softmax 函数动态计算得到，以确保它们的总和为 1，具体公式如式 3-2 所示。

$$Y_{ij} = \alpha_{ij} \cdot X_{ij}^{1 \rightarrow 3} + \beta_{ij} \cdot X_{ij}^{2 \rightarrow 3} + \gamma_{ij} \cdot X_{ij}^{3 \rightarrow 3} \quad (3-2)$$

其中 Y_{ij} 代表了输出特征图 Y 在位置 (i, j) 的特征向量，而权重 α_{ij} ， β_{ij} 和 γ_{ij} 分别对应三个尺度的空间重要性权重。这些权重是跨所有通道共享的，由网络学习得到。

ASFF 模块通过平衡不同层级的特征图，实现了细节与语义信息的有效结合。在 ASFF 优化过程中，对于那些微小目标的细节及其边界特征，细节信息的表示可能还

不够充分。为此，本文进一步引入了 iAFF 模块^[58]，iAFF 利用迭代注意力机制对特征进行更深层次的细化，以增强对细节的捕捉能力。如下图 3-6 所示，(a) 为迭代注意力特征融合模块 iAFF，(b) 为 iAFF 模块中的多尺度特征注意力模块 (Multi-Scale Channel Attention Module, MS-CAM)。




图 3-6 iAFF 模块与 MS-CAM 模块结构图

在迭代注意特征融合模块 iAFF 中，输入 X ， Y 是待融合的不同尺度的特征图，两个特征图经过初始的特征集合后输入到 MS-CAM 模块中，应用注意力机制计算权重参数。为了克服传统线性融合方法的局限，并增强模型对复杂特征关系的捕捉能力，iAFF 将上述加权特征图再次通过 MS-CAM 模块处理。依靠迭代注意力机制优化权重分布，最终的权重参数将用于输入的多尺度特征图的融合。iAFF 具体融合策略如公式 3-3、3-4 所示。

$$Z' = MC(X \oplus Y) \otimes X + (1 - MC(X \oplus Y)) \otimes Y \quad (3-3)$$

$$Z = MC(Z') \otimes X + (1 - MC(Z')) \otimes Y \quad (3-4)$$

其中， X 是 ResNet 主干网络中的 stage1， Y 是 ASFF 融合后的特征图， $\otimes$ 是对应元素相乘， $\oplus$ 是对应元素相加， MC 指的是多尺度特征注意力模块， Z' 指的是第一次特征融合的输出， Z 则是第二次特征融合的输出。

如图 3-6 中的 (b) 部分所示，MS-CAM 引入局部和全局上下文信息对标准的 SENet 框架进行了扩展，来提升通道注意力机制的性能，以更好地处理不同尺度的对象。MS-CAM 主要包含两部分，分别为局部特征的通道注意力与全局特征的通道注意力。全局特征的通道注意力只比局部特征通道注意力多出一个全局平均池化，正是由于全局平均池化操作才使得全局特征的通道注意力能够捕捉到全局特征。局部特征通道注意力中采用两个点卷积操作来捕捉局部特征。其中还嵌入了激活函数与批归一化层来加速训练并提高泛化能力。最终，将局部特征通道注意力与全局特征的通道注意力加

和后通过 Sigmoid 函数得到输入特征图的权重。具体操作如公式 3-5、3-6、3-7 所示。

$$L(X) = B(PWConv_2(\delta(B(PWConv_1(X))))) \quad (3-5)$$

$$g(X) = B(PWConv_2(\delta(B(PWConv_1(GAP(X))))) \quad (3-6)$$

$$X' = X \otimes MC(X) = X \otimes \delta(L(X) \oplus g(X)) \quad (3-7)$$

其中， X 是 ResNet 主干网络中的 stage1 与 ASFF 融合后的特征图进行逐像素相加得到的特征图， $PWConv_1$ 是第一个 1×1 点卷积， B 表示批归一化层 BatchNorm， δ 表示的是激活函数 ReLU， $PWConv_2$ 是第二个 1×1 点卷积， $L(X)$ 是局部特征的通道注意力的输出， $g(X)$ 是全局特征的通道注意力的输出， X' 是 MS-CAM 模块输出的参数权重。

滑坡的边界轮廓和尺度大小变化无固定规律，使得单一尺度的特征难以准确捕捉滑坡的全部信息。为了捕捉滑坡的全貌以提升分割精度，需要融合多尺度的特征。传统的融合方法往往忽视了不同尺度特征间的不一致性，而在本文中采用的地貌特征融合模块 GFFM 首先通过 ASFF 模块平衡不同层级的特征图，实现了细节与语义信息的有效结合。在面对微小目标的细节及其边界特征时，ASFF 提取的细节信息可能还不够充分，因此进一步引入了 iAFF 模块，利用迭代注意力机制对特征进行更深层次的细化，以增强对细节的捕捉能力，确保在细粒度层面上也能保持较高的准确性，GFFM 模块操作示意图如下图 3-7 所示。




图 3-7 GFFM 模块结构图

§ 3.3 实验结果与分析

§ 3.3.1 实验环境说明

本文中所有用于滑坡识别的语义分割实验均在表 3-1 所列出的软硬件平台配置上进行。

表 3-1 实验软硬件平台配置基本情况表

名称	配置版本
操作系统	Windows10
CPU	Intel® Core™ i9-10900K
GPU	NVIDIA GeForce RTX 3090
Cuda	CUDA11.1
Python	Python3.6
框架	Pytorch1.10.2

§ 3.3.2 模型训练的超参数设置

在本文针对滑坡识别的实验中，采用了迁移学习的策略，并将训练过程分为冻结阶段和解冻阶段。在冻结阶段，主干网络不参与训练，选取在大规模数据集上预先训练好的 ResNet50 与 HRNetV2-w48 权重作为主干网络的初始权重。这一策略不仅节省了计算资源，还为模型提供了丰富的低语义特征。在此阶段，模型的训练轮数（Epoch）被设置为 50，批次大小（Batch_size）为 8，初始学习率（lr）设定为 0.0005，损失函数采用交叉熵损失（Cross Entropy Loss）与 Dice loss 的组合。进入解冻阶段，此时模型的所有层都参与训练，解冻阶段的训练轮数同样设置为 50，但批次大小减半至 4，以便实现对参数更细致的调优。这种分阶段的训练方法有助于在初期利用预训练模型丰富的通用特征，并在后期通过细致的调整使模型更好地适应特定任务。通过这种方法，使得模型能够更准确提取滑坡影像中的关键特征，从而提高滑坡识别的准确性。具体的超参数设置如下表 3-2 所示。

表 3-2 超参数设置

参数	数值
Batch_size	8（冻结阶段）、4（解冻阶段）
Initial Learning Rate(lr)	0.0005
lr_decay_type	cos
Epoch	100
Loss type	Cross Entropy+Dice
Optimizer	Adam
momentum	0.9
衰减速率	0.999
Number of Class	2

§ 3.3.3 评价指标

为了验证改进的 DeepLabv3+算法对滑坡图像的分割效果，本文采用召回率（Recall）即预测滑坡类别正确的像素数占真实的滑坡类别像素数的比例、像素准确

率 (pixel Accuracy, PA) 即预测类别正确的像素数占总像素数的比例、平均交并比 (mean Intersection over Union, $mIoU$)、类别平均像素准确率 (mean Class pixel Accuracy, $mCPA$) 作为模型的评价指标, 公式如下所示。

$$Recall = \frac{TP}{TP + FN} \quad (3-8)$$

$$PA = \frac{TP + TN}{TP + TN + FP + FN} \quad (3-9)$$

$$IoU_p = \frac{TP}{TP + FP + FN} \quad (3-10)$$

$$IoU_N = \frac{TN}{TN + FN + FP} \quad (3-11)$$

$$mIoU = \frac{IoU_p + IoU_N}{2} \quad (3-12)$$

$$CPA_p = \frac{TP}{TP + FP} \quad (3-13)$$

$$CPA_N = \frac{TN}{TN + FN} \quad (3-14)$$

$$mCPA = \frac{CPA_p + CPA_N}{2} \quad (3-15)$$

本实验类别数为 2, 正例是滑坡, 反例是背景, 其中 TP 表示真实值与预测值相同, 即真实标签为滑坡且模型也将其预测为滑坡的像素个数。 FP 是真实标签为背景但模型却将其预测为滑坡的像素个数。 FN 表示真实标签是滑坡但模型将其预测成了背景的像素个数。 TN 表示真实标签是背景且模型也将其预测为背景的像素个数。 IoU_p 滑坡类预测结果和真实标签的交集与并集的比值, IoU_N 背景类预测结果和真实标签的交集与并集的比值, $mIoU$ 为每一个类的交并比的平均。 CPA_p 表示预测为滑坡类的像素准确率, CPA_N 表示预测为背景类的像素准确率, $mCPA$ 为每一个类的像素准确率的均值。

§ 3.3.4 消融实验

本文基于 DeepLabv3+模型, 选用 Xception、MobileNetV2^[59]以及 ResNet50 三种主干网络进行训练, 并在验证集上对这些模型进行了验证, 以评估其性能。

表 3-3 不同主干网络的实验结果

主干网络	Recall/%	PA/%	mIoU/%	mCPA/%	FLOPs/G
Xception	83.09	93.13	81.27	89.23	166.841
MobileNetV2	89.20	88.96	74.17	81.92	52.867

续表 3-3

主干网络	Recall/%	PA/%	mIoU/%	mCPA/%	FLOPs/G
ResNet50	84.07	92.99	81.09	88.75	138.902

表 3-3 详细展示了 DeepLabv3+模型在使用 Xception、MobileNetV2 和 ResNet50 作为主干网络时的性能表现。从表中可以看出, Xception 在多个评价指标上表现出色, 但高计算成本(以 FLOPs 衡量)可能使其在资源有限的条件下不太适用。另一方面, MobileNetV2 在 Recall 指标上表现良好, 表明其对正类目标具有较高的识别率。然而, 它在 mIoU 方面的得分相对较低, 表明模型在特定类别的分割准确性上存在不足。在对各个主干网络模型进行综合评估后, 发现 ResNet50 在保证合理计算成本的同时, 展现了与 Xception 相近的准确性。因此, 本文最终选择了 ResNet50 作为 DeepLabv3+ 的主干网络。

在许多工作中, 融合不同尺度的特征是提升分割性能的一种重要的手段。为验证本文提出的地貌特征融合模块 GFFM 的有效性, 对比了多种特征融合技术。实验中, 尝试了以下特征融合方法: 第一, 采用 ASFF 自适应融合技术, 对 ResNet50 主干网络的前三个 stage 的特征图进行融合^[60]。第二, 主干网络 ResNet50 的 stage2 中引入空洞卷积^[61], 将网络的下采样率从 16 倍降至 8 倍, 并使用迭代注意特征融合模块 iAFF 将 stage2 与 stage1 的特征图进行融合。第三, 在主干网络的 stage2 采用空洞卷积, 保持 8 倍下采样, 并使用 iAFF 模块融合 stage3 和 stage2 的特征图, 然后再将融合后的特征图与 stage1 的特征图进行 iAFF 融合。第四, 本文所采用的特征融合方法 GFFM, 先通过 ASFF 融合前三个 stage 的特征图, 再利用 iAFF 将融合后的特征图与 stage1 的特征图进行融合。

表 3-4 不同特征融合方法的实验结果

融合方式	Recall/%	PA/%	mIoU/%	mCPA/%
DeepLabv3+	84.07	92.99	81.09	88.75
ASFF	82.13	92.83	80.52	88.79
iAFF 融合前两层 stage	84.92	93.58	82.42	89.77
iAFF 迭代融合三层 stage	83.28	93.31	81.66	89.55
GFFM	88.17	93.99	83.65	89.94

实验结果如表 3-4 所示, 包含了五组实验分别为无特征融合模块的 DeepLabv3+ 模型、采用 ASFF 进行特征融合、iAFF 融合前两层 stage、iAFF 迭代融合三层 stage 与地貌特征融合模块 GFFM 方法。由表中数据可以发现, 采用 ASFF 自适应融合技术几乎没有提高甚至下降了, 这可能是因为 ASFF 并未有效的融合底层的细节特征。而包含 iAFF 模块的后面三种特征融合模块, 在各项评价指标上都有提高, 这也验证了该模块能够更好的处理细节特征。本文所使用的 GFFM 方法在所有指标上都达到了最优性能。与无特征融合模块、采用 ASFF 进行特征融合、iAFF 融合前两层 stage、

iAFF 迭代融合三层 stage 相比, GFFM 方法的 Recall 分别提高了 4.1%、6.04%、3.25% 和 4.89%, 说明 GFFM 方法对滑坡特征的检测较为全面, 遗漏率较低。对于分割任务来说 mIoU 是一个综合指标, 因为它既考虑了真正的正类又平衡了假正假负的影响。本文所使用的 GFFM 方法 mIoU 值为 83.65%, 相比于前四组实验分别提高了 2.56%、3.13%、1.23% 和 1.99%。

为了验证本文改进模块的有效性, 在构建的数据集上进行了实验。分别尝试了仅加入 ECA-Net 注意力模块、仅加入 GFFM 地貌特征融合模块以及同时加入这两个模块, 并对它们进行了对比分析, 实验结果如表 3-5 所示。

表 3-5 不同模块的组合实验结果

模型	ECA-Net	GFFM	Recall/%	PA/%	mIoU/%	mCPA/%
DeepLabv3+			84.07	92.99	81.09	88.75
1	√		83.57	93.71	82.56	90.34
2		√	88.17	93.99	83.65	89.94
Ours	√	√	87.58	94.23	84.12	90.55

(1) 加入 ECA-Net 注意力模块结果分析

根据表 3-5 中的第二组实验结果, 观察到相比于以 ResNet50 为主干网络的 DeepLabv3+, 残差接入 ECA-Net 注意力模块时, Recall 略微下降了 0.5%, 但其他三个指标都有所提升, 特别是 mCPA 增加了 1.59%。因为 ECA-Net 通过整合周边信息增强了对全局上下文的理解, 使得模型适用于复杂的自然环境。

(2) 增加地貌特征融合模块 GFFM 结果分析

根据表 3-5 中的第三组实验结果, 当只引入地貌特征融合模块 GFFM 时, 所有评价指标都比原始模型要高, Recall、PA、mIoU 与 mCPA 分别提高了 4.1%、1%、2.56% 和 1.19%。这是由于 GFFM 基于前置动态权重分配机制很好的处理了不同尺度间的不一致性, 同时借助迭代的注意力多尺度特征注意力模块很好的协调了细节信息和高层语义信息, 使得模型能够更精确地识别各种滑坡。

(3) 同时加入所有改进点结果分析

根据表 3-5 中的第四组实验结果, 同时加入 ECA-Net 注意力模块和地貌特征融合模块 GFFM, 相比于原 DeepLabv3+ 模型, 各项评价指标都有所提升。与只加入 GFFM 相比, 只有 Recall 值下降了 0.59%, PA、mIoU、mCPA 分别提升了 0.24%、0.47%、0.61%。这表明, 将两种改进点同时引入模型可以产生协同作用, 进一步提升模型的性能。

§ 3.3.5 对比实验

为了客观评价本文所提出的改进算法的性能,在相同的实验环境和初始训练参数的条件下,与经典的语义分割网络 PSPNet、U-Net、HRNetV2、DeepLabv3+算法进行了对比实验,各模型在验证集上的实验结果如表 3-6 所示。

表 3-6 对比实验

模型	主干网络	Recall/%	PA/%	mIoU/%	mCPA/%
PSPNet	ResNet50	76.02	92.04	78.14	88.48
U-Net	ResNet50	76.68	92.70	79.57	89.83
HRNetV2	HRNetV2-w48	84.22	93.22	81.58	89.17
DeepLabv3+	ResNet50	84.07	92.99	81.09	88.75
Ours	ResNet50	87.58	94.23	84.12	90.55

由表 3-6 可知,本文所改进的算法 Recall 为 87.58%、PA 为 94.23%、mIoU 为 84.12%、mCPA 为 90.55%,在所有关键性能指标上均优于对比算法。与 PSPNet 模型相比,PA 和 mIoU 分别提高了 2.19%和 5.98%,与 U-Net 模型相比,PA 和 mIoU 分别提高了 1.53%和 4.55%。HRNetV2 模型因并行连接的网络结构能够保持高分辨率的同时融合多尺度特征,因此在各项评价指标表现出色。但本文算法相比于 HRNetV2,在 mIoU 指标上仍提高了 2.54%。综上所述,可以发现本文所改进的 DeepLabv3+算法对滑坡整体的分割效果达到了最优。

为了更直观地对比各模型在滑坡分割任务上的性能差异,使用上述五种模型对验证集中的滑坡样本进行了详细的分割效果分析,如图 3-8 所示。




图 3-8 不同网络模型的分割结果图

标注图中的白色区域是人工标注的真实滑坡区域,作为各个分割模型分割效果的参照标准。如图 3-8 的第一组对比中,对于具有清晰边界的滑坡地形,大部分模型都能够实现较好的分割效果,但在捕捉边界细节上仍存在差异。我们的方法在复杂地形的接缝部分可以更精确的刻画边界。在第二组对比中,我们的模型在处理较小滑坡区域时表现出了较好的性能。与其他模型相比,它能够更完整地捕获和刻画滑坡的全貌。在第三组对比中,对于边界不连续的滑坡区域,我们的模型能够更连贯且完整地分割出滑坡形状,而其他模型则存在分割不完整或对边界的识别不准确的情况。最后一组中的结果进一步证实了我们模型在处理非常复杂和不规则滑坡形状时保持了高质量的分割效果,而其他比较模型则在边缘细节上识别较差。

§ 3.4 工程化应用

滑坡识别中传统的人工解译方法耗时且容易出错,无法满足紧迫的应急响应。为了提升滑坡灾害识别的效率和精确性,并响应快速自动化处理的现实需求,本研究开发了一个综合的滑坡影像训练预测系统,实现了滑坡灾害的自动化训练到快速准确识别的一体化流程。

§ 3.4.1 滑坡影像训练预测系统概述

根据第 3.1 节的指导,本研究首先构建了一个包含滑坡影像的样本库。这一数据库整合了来自公开数据集及自行采集的数据,经过严格筛选,以确保所选影像适用于模型训练和验证。从样本库中按照一定比例划分出训练集和测试集,确保模型能在多样化的数据上进行训练和验证,这里模型中已内置比例为 9:1。考虑到滑坡的形态因地形、地貌、植被等因素的影响往往差异较大,采用提出的地貌特征融合模块和引入的注意力机制能够更准确地区分滑坡区域与背景。训练过程中,利用损失函数指导反向传播,不断优化模型参数。整个系统通过集成先进的深度学习技术和用户友好的界面设计,实现了从模型训练到滑坡识别的自动化流程,大大提高了滑坡灾害快速解译的效率和准确性。

§ 3.4.2 系统设计与开发

为了使本文所设计的改进的滑坡识别算法更好地应用于实际需求,该系统基于 PyTorch 框架和 Python 语言,结合 PyQt5 进行开发,以满足生产单位对滑坡灾害快速解译的需求。系统的核心特点之一是采用了多线程技术来提高处理效率和用户体验。系统中的模型训练模块使用了 QThread 类创建独立线程,允许模型训练在后台进行,

而不干扰主界面的交互。这一设计通过定义一个继承自 `QThread` 的 `Runthread` 类实现，其中封装了模型训练的核心逻辑。此外，系统还包含 `Runthread2` 和 `Runthread3` 两个线程，分别负责处理模型训练文件的生成和图像识别操作。这些线程通过信号和槽机制与主界面交互，确保了用户界面的流畅性和稳定性。

滑坡影像训练预测系统主要由两个核心模块组成：（1）模型训练模块，负责接收处理后的训练数据集，并通过迭代学习的方式训练出滑坡识别模型。（2）模型预测模块，用于加载训练好的模型，并对新的滑坡影像进行滑坡区域的识别。这两个模块的协同工作提高了系统的运行效率，为滑坡识别提供了自动化的手段。滑坡影像训练预测系统功能框架图如图 3-9 所示。




图 3-9 系统功能框架图

§ 3.4.3 功能模块与软件界面

系统的主要界面包括操作窗口和执行显示两个部分。

由于公开的标注软件 `Labelme` 还需要额外的安装操作，本系统将标注功能集成了进来，对 `Labelme` 操作界面进行了简化，让其只包含分割任务的标注功能，在操作窗口中，存在一个标注按钮，用户通过点击可以跳转到标注工具界面，标注界面如下图 3-10 所示。




图 3-10 标注界面展示

用户可以通过 **Open Dir** 工具打开保存了滑坡样本数据的文件夹，进而将需要标注的滑坡样本加载到标注工具中，如图 3-11 所示。




图 3-11 加载样本数据

用户可以通过 **Create Polygons** 工具对滑坡样本进行标注操作，标注完成后通过 **save** 功能模块保存标注信息为 json 格式的数据，标注操作如图 3-12 所示。




图 3-12 标注操作

保存的 json 格式样例数据如下图 3-13 所示，label 表明标注数据的类别，points 是标注样本时标注点信息，shape_type 表明标注的类型，imagepath 表明标注的样本的名称，imageDate 存储了标注的样本图像的 base64 形式的数据，imageHeight 与 imageWidth 分别表示样本数据的高和宽。

```

{
  "shapes": [
    {
      "label": "landslide",
      "points": [
        [
          241.44880546075083,
          283.9146757679181
        ],
        [
          296.0477815699659,
          298.4744027303754
        ],
        [
          321.5273037542662,
          316.6740614334471
        ],
        [
          330.0204778156996,
          349.4334470989761
        ],
        [
          313.0341296928328,
          384.61945392491464
        ]
      ],
      "shape_type": "polygon",
      "flags": {}
    }
  ],
  "imagePath": "1_4.jpg",
  "imageData": "/9j/4AAQSkZJRgABAQEAAeAB4AAD/2wBDAAgGBgcGBQ",
  "imageHeight": 622,
  "imageWidth": 711
}

```

图 3-13 json 格式样例数据

用户可以通过“加载训练图片”和“加载标注文件”按钮来导入滑坡影像及其对应的标注数据。此外，用户还可以设置模型保存路径，选择训练的批次大小（Batch_size）和迭代次数（Epoch），并且可以选择是否使用 gpu 加速训练。系统提供了“训练”按钮来启动滑坡识别模型的训练过程，训练过程中的信息会实时显示在屏

幕上，方便用户监控训练状态。下图 3-14 是在操作窗口进行的各种参数设置，其中 JPEGImages 中的图片是用于训练的数据集，SegmentationClass 中的图片是用于训练的标注文件，而 log 是训练好的模型权重进行保存的路径，Epoch 设置为 100，指的是总训练轮数，Batch_size 设置为 4，这里指的解冻阶段的 Batch_Size，gpu 选中表示的是选择 gpu 进行训练。参数设置好后就可以点击训练按钮，系统会根据传入的训练图片和标注文件将数据集以 9:1 的比例分成训练集和验证集，并自动进行图像增强，其训练步骤可以在下方灰色区域显示出来，如图 3-15 所示。




图 3-14 系统操作窗口参数设置





图 3-15 系统操作训练操作展示

执行显示界面包括两个功能，即识别单张图片和批量识别文件夹中的多张图片。

用户可以加载已训练好的模型，并通过“图片”按钮选择单张图片进行识别，或者通过“批量识别”按钮选择文件夹进行批量处理，识别结果会在界面中直观展示。单张图片识别的结果图如下图 3-16（a）与 3-16（b）所示。“批量识别”的结果将保存在对应的文件夹中，如图 3-17 所示。同时单张图片识别以及“批量识别”所花费的时间也将在操作窗口下方灰色区域中显示，如图 3-18 所示。



(a) 加载图片

(b) 识别界面

图 3-16 单张图片识别操作展示




图 3-17 批量识别操作展示




图 3-18 推理性能测试

§ 3.5 本章小结

本章首先介绍了滑坡数据集的样本制作过程，包括数据集的组成、样本的标注以及数据增广技术的应用。接着，详细阐述了基于 ResNet50 的 DeepLabv3+模型、引入的 ECA-Net 注意力模块、地貌特征融合模块 GFFM 以及基于 ECA-Net 和 GFFM 的模型改进策略。通过与其他主干网络的比较、不同特征融合方法的效果对比，以及消融实验和对比实验的结果，验证了所提出方法的有效性。最后，还详细讨论了模型的部署策略和针对滑坡影像训练预测开发的系统，展示了系统的结构设计、关键功能模块以及用户界面设计。

第四章 基于卷积神经网络的滑坡易发性评价

随着遥感技术和地理信息系统（GIS）的迅速发展，获取大量地理、地质和环境数据变得更加容易。然而，滑坡易发性评价需要考虑的数据往往来源复杂，各因子之间存在着错综复杂的非线性关系。传统的滑坡易发性评价方法往往难以有效捕捉和建模这些数据间的深层次关系，在处理大规模复杂数据集时，模型的泛化能力和预测精度方面存在不足。卷积神经网络作为一种深度学习模型，具有强大的特征提取能力。它能够通过多层卷积操作，从原始数据中自动提取出高层次的特征表示，从而有效捕捉数据之间的深层次信息。一维卷积层通过在输入数据上滑动窗口并进行局部加权求和，捕捉序列中的局部特征^[62]。这一特性使得一维卷积层非常适合处理序列数据，因此本研究主要通过一维卷积层来构建滑坡易发性评价的卷积神经网络。

§ 4.1 滑坡评价流程概述

为了准确评价滑坡易发性，首先需筛选出关键的影响因子，并对其进行分级。随后，这些分级后的影响因子将分别应用于信息量模型和卷积神经网络模型。在信息量模型中，通过计算每个影响因子分级的信息量，并将其整合到对应分级的字段中。接着，利用栅格叠加法汇总各影响因子的信息量，最终通过自然间断点法生成滑坡易发性分区图。针对卷积神经网络模型，数据集的制作尤为关键。本研究将滑坡点位置上的影响因子分级数据整理成序列，作为模型训练的样本。同时，从滑坡点 50 米外的区域随机选择非滑坡点作为对照样本。每个样本的最后一列标记为 1（表示滑坡）或 0（表示非滑坡），从而构建出一个完整的数据集。模型训练完成后，利用最好的模型权重对验证集进行评估，以全面衡量模型在不同评价指标上的性能。最后，应用得到的权重预测每个栅格点的滑坡易发性，并通过自然间断点法绘制出滑坡易发性分区图。本章的技术路线图如下图 4-1 所示。




图 4-1 技术路线图

§ 4.2 研究区域及数据

梧州市位于广西东南部，地形特点以丘陵为主，属亚热带季风气候，年平均降雨量为 1478.2 毫米。大部分地区为早古生代和中、新生代碎屑岩及燕山期岩浆岩组成，其中第四系风化层厚度在 0~30 米，山坡坡度在 25° ~ 45° ，标高 80 至 300 米。建成区内大部分的沟谷被开发为居民区，建筑多依山而建，对地质环境影响大^[63]。梧州市地层主要以寒武系为主，岩性涵盖了粉砂岩、砂岩、砾岩夹泥岩，上覆薄层含砾粘性土。岩浆岩以酸性岩为主，风化强烈。梧州市区历经了包括加里东运动和燕山运动在内的多次构造运动。其中，加里东运动使得梧州市区内的古生代地层发生全型褶皱，进而隆起形成陆地，燕山运动主要表现为断裂和褶皱^[64]。鉴于梧州市山区多、平地少，山体稳定性较差，加上人为工程活动频繁以及暴雨的频发，使得该地区成为了地质灾害的高发区。因此，对该地进行滑坡易发性研究显得尤为重要。

本研究所使用的滑坡隐患点、水系线、道路线、地形地貌、地质构造、工程岩组、人类工程活动等数据均来自广西壮族自治区梧州市地质环境监测站。DEM 数据则是从地理空间数据云下载的，用于提取坡度、坡向和地形起伏度等关键信息。此外，本研究还使用了 2010 年的 GlobeLand30 数据集作为土地利用数据的来源，该数据集涵盖了耕地、森林、草地、灌木地、湿地、水体、苔原、人造地表、裸地、冰川和永久积雪十一种主要的地表覆盖类型。广西壮族自治区梧州市地质环境监测站提供的梧州市区滑坡隐患点数目为 141 处，滑坡隐患点的空间分布如下图 4-2 所示。




图 4-2 研究区滑坡分布概况

§ 4.3 影响因子分析

本文分别选取了高程、坡度、坡向、地形起伏度、土地利用类型、距水系距离、距道路距离、距断层距离、地形地貌、人类工程活动、工程岩组共 11 个影响因子进行滑坡易发性评价。

(1) 高程

高程是滑坡易发性评价的核心因子，它直接影响气候变化、水文条件、植被分布以及土壤的风化程度^[65]。高海拔地区因其特殊的气候条件，直接影响了植被的生长周期和类型，同时加速了土壤的风化和侵蚀过程。因此，高程成为滑坡灾害发生的重要影响因子之一，高程影响因子分级统计如下表 4-1 所示。

表 4-1 高程分级统计

影响因子	级别(1~6)	区域面积(km ²)	滑坡个数	发育密度(处/km ²)
高程(m)	-58~72	569.7625	84	0.147
	73~136	520.385	48	0.092
	137~213	357.55	1	0.003
	214~312	203.5925	3	0.015
	313~455	100.385	5	0.050
	456~842	40.945	0	0

根据自然间断点法将梧州市区高程划分为-58~72m、73~136m、137~213m、214~312m、313~455m 和 456~842m 六个区间，经上表的统计整理，滑坡多出现于低海拔区间，集中在-58~72m、73~136m 两个区间内。采用 ArcGIS 软件绘制高程影响因子图层，如图 4-3 所示。




图 4-3 梧州市区高程分区图

(2) 坡度

在地质灾害易发性评价中，坡度是直接影响斜坡稳定性的关键地形指标。坡度反映了地表斜坡的陡峭程度，影响岩土体在重力作用下的相对稳定性^[66]。在实际应用中，利用数字高程模型（DEM）数据提取得到坡度信息。坡度影响因子分级统计如下表 4-2 所示。

表 4-2 坡度分级统计

影响因子	级别(1~6)	区域面积(km ²)	滑坡个数	发育密度(处/km ²)
坡度°	0~5	356.635	19	0.053
	6~11	417.725	52	0.124
	12~16	391.785	36	0.092
	17~21	330.4025	24	0.073
	22~27	211.59	9	0.043
	28~55	84.4825	1	0.012

根据自然间断点法将梧州市区坡度划分为 0~5°、6~11°、12~16°、17~21°、22~27°、28~55°，经上表的统计整理，滑坡多出现在坡度为 6~11°、12~16° 两个区间内。采用 ArcGIS 软件绘制坡度评价影响图层，如图 4-4 所示。




图 4-4 梧州市区坡度分区图

(3) 坡向

坡向是影响斜坡稳定性的关键因素，它决定了斜坡接收阳光的强度和持续时间，进而影响植被生长状况、地表水分的分布以及土壤侵蚀的情况^[67]。可以利用数字高程模型（DEM）提取坡向数据以生成研究区的详细坡向图。坡向影响因子分级统计如下表 4-3 所示。

表 4-3 坡向分级统计

影响因子	级别(1~9)	区域面积(km ²)	滑坡个数	发育密度(处/km ²)
坡向	平面	11.4925	0	0
	北	226.48	8	0.035
	东北	226.0425	10	0.044
	东	220.05	16	0.073
	东南	227.3	31	0.136
	南	234.8775	27	0.115
	西南	221.9025	20	0.090
	西	208.455	16	0.077
	西北	216.02	13	0.060

一般坡向分为 9 个类别，分别为平面、北、东北、东、东南、南、西南、西、西北。经上表的统计整理，滑坡多分布在坡向为东南、南两个方向。采用 ArcGIS 软件绘制坡向影响因子图层，如图 4-5 所示。




图 4-5 梧州市区坡向分区图

(4) 地形起伏度

地形起伏度是指在特定区域内最高点与最低点之间的高度差异，它是衡量地形变化剧烈程度的关键指标^[68]。在地质灾害潜在风险评估中，显著的地形起伏往往意味着斜坡的陡峭或悬崖的存在，这些地形特征容易形成不稳定的悬空结构。当这些结构受到降雨、震动等外部力量的作用时，滑坡等地质灾害的风险会明显增加。可以利用数字高程模型（DEM）提取研究区的地形起伏度数据，地形起伏度影响因子分级统计如下表 4-4 所示。

表 4-4 地形起伏度分级统计

影响因子	级别(1~6)	区域面积(km ²)	滑坡个数	发育密度(处/km ²)
地形起伏度(m)	0~18	352.84	23	0.065
	19~31	504.7475	65	0.129
	32~43	450.085	31	0.069
	44~56	310.44	20	0.064
	57~73	153.54	2	0.013
	74~160	20.9675	0	0

根据自然间断点法将梧州市区高程划分为 0~18m、19~31m、32~43m、44~56m、57~73m 和 74~160m 六个区间，经上表的统计整理，滑坡多集中在 19~31m、32~43m 两个区间内。采用 ArcGIS 软件绘制地形起伏度影响因子图层，如图 4-6 所示。




图 4-6 梧州市区地形起伏度分区图

(5) 土地利用类型

土地利用类型是滑坡发生的一个关键因素。不同的土地利用方式，如林地、农田、建筑用地等，在保持水土和调节地表径流方面拥有不同的能力，相同的土地利用模式在不同地形地貌下会产生不同的效果^[69]。例如，陡峭斜坡上的土地开发活动更有可能诱发滑坡，而在平缓地区同样的活动对斜坡稳定性影响可能相对较小。土地利用类型影响因子分级统计如下表 4-5 所示。

表 4-5 土地利用类型分级统计

影响因子	级别(1~6)	区域面积(km ²)	滑坡个数	发育密度(处/km ²)
土地利用类型	耕地	330.95	25	0.076
	林地	1374.49	107	0.078
	草地	1.105	0	0
	湿地	0.9	0	0
	沼泽	43.2425	2	0.046
	人工地表	41.9325	7	0.167

本研究区域内的土地利用类型被分为耕地、林地、草地、湿地、沼泽和人工地表六类。经上表的统计整理，按照滑坡发育密度来看，人工地表区域内的滑坡灾害是最为密集的。这主要是由于该市地形以山地为主，平原相对较少，导致许多居民的住房紧贴着山体进行建设。这种建设模式不仅破坏了山体的自然地质结构，还可能对地下水的正常流动和土壤稳定性产生不良影响。特别是在极端天气条件下，已经受损的地质结构更容易发生滑坡、崩塌等地质灾害。采用 ArcGIS 软件绘制土地利用类型影响

因子图层，如图 4-7 所示。




图 4-7 梧州市区土地利用类型分区图

(6) 距水系距离

斜坡与水系的相对位置直接关系到滑坡隐患的形成。河流通过侵蚀坡脚，进而影响斜坡的整体稳定性。长期的水流作用会使斜坡内的软化夹层结构变得松散，从而降低斜坡的抗剪强度^[70]。距水系距离影响因子分级统计如下表 4-6 所示。

表 4-6 距水系距离分级统计

影响因子	级别(1~6)	区域面积(km ²)	滑坡个数	发育密度(处/km ²)
距水系距离(m)	0~200	410.045	68	0.166
	200~400	351.275	29	0.083
	400~600	293.465	14	0.048
	600~800	225.3725	2	0.009
	800~1000	165.3975	0	0
	>1000	347.065	28	0.081

将梧州市区距水系距离等分为 0~200m、200~400m、400~600m、600~800m、800~1000m、>1000m 六个区间，经上表的统计整理，按照滑坡发育密度来看，距离河流越近的区域发生滑坡灾害的概率越大。采用 ArcGIS 软件绘制距水系距离影响因子图层，如图 4-8 所示。




图 4-8 梧州市区距水系距离分区图

(7) 距道路距离

在道路建设过程中，挖掘、填土、排水不当等活动往往会改变原有的地形地貌和水文条件，进而威胁到周边斜坡的稳定性^[71]。因此，通过分析斜坡与道路的相对距离，能够更准确地识别那些因人类工程活动而增加的滑坡风险区域。距道路距离影响因子分级统计如下表 4-7 所示。

表 4-7 距道路距离分级统计

影响因子	级别(1~6)	区域面积(km ²)	滑坡个数	发育密度(处/km ²)
距道路距离(m)	0~200	174.08	21	0.121
	200~400	145.61	20	0.137
	400~600	125.5475	15	0.119
	600~800	109.1475	13	0.119
	800~1000	98.145	6	0.061
	>1000	1140.09	66	0.058

将梧州市区距道路距离等分为 0~200m、200~400m、400~600m、600~800m、800~1000m、>1000m 六个区间。经上表的统计整理，按照滑坡发育密度来看，距离道路越近的区域发生滑坡灾害的概率越大。采用 ArcGIS 软件绘制距道路距离影响因子图层，如图 4-9 所示。




图 4-9 梧州市区距道路距离分区图


(8) 距断层距离

斜坡与断层的相对位置是评估斜坡稳定性和地质灾害风险的关键因素之一。断层作为地壳应力释放的自然界面，不仅直接破坏了岩体的结构完整性，削弱了岩石的强度，而且为地下水的流动提供了通道。这两方面的综合作用进一步加剧了斜坡的不稳定性^[72]。距断层距离影响因子分级统计如下表 4-8 所示。

表 4-8 距断层距离分级统计

影响因子	级别(1~4)	区域面积(km ²)	滑坡个数	发育密度(处/km ²)
距断层距离(m)	<100	94.735	9	0.072
	100~250	134.0325	11	0.112
	250~500	206.22	23	0.082
	>500	1357.6325	98	0.072

将梧州市区距断层距离划分为<100m、100~250m、250~500m、>500m 四个区间。经上表的统计整理，按照滑坡发育密度来看，距离断层相对近的区域发生滑坡灾害的概率较大。采用 ArcGIS 软件绘制距断层距离影响因子图层，如图 4-10 所示。



(9) 地形地貌

梧州市区的主要地貌类型包括高丘、低山浅切割地形、波状低丘和河谷阶地。具体来看，低山浅切割地形和高丘区域的滑坡隐患密度明显高于波状低丘和河谷阶地。地形地貌影响因子分级统计如下表 4-9 所示。

表 4-9 地形地貌分级统计

影响因子	级别(1~4)	区域面积(km ²)	滑坡个数	发育密度(处/km ²)
地形地貌	高丘	1048.5825	101	0.096
	低山浅切割地形	181.215	22	0.121
	波状低丘	438.5125	15	0.034
	河谷阶地	124.31	3	0.024

采用 ArcGIS 软件绘制地形地貌影响因子图层，如图 4-11 所示。




图 4-11 梧州市区地形地貌分区图

(10) 人类工程活动

将梧州市区人类工程活动划分为很弱区、强烈区、中等区和较弱区，具体的分级统计信息如表 4-10 所示。从统计数据中可以观察到，人类工程活动强烈区的滑坡灾害发育密度高达 0.691 处/km²，人类活动中等区的滑坡灾害分布的发育密度达到了 0.252 处/km²，而较弱区与很弱区的滑坡灾害发育密度达到了 0.080 处/km² 与 0.005 处/km²，由此可见人类工程活动越强的区域，发生滑坡灾害的可能性就越大。

表 4-10 人类工程活动分级统计

影响因子	级别(1~4)	区域面积(km ²)	滑坡个数	发育密度(处/km ²)
人类工程活动	很弱区	596.8725	3	0.005
	中等区	166.775	42	0.252
	强烈区	23.1475	16	0.691
	较弱区	1005.825	80	0.080

采用 ArcGIS 软件绘制人类工程活动影响因子图层，如图 4-12 所示。




图 4-12 梧州市区人类工程活动分区图

(11) 工程地质岩组

根据表 4-11 的统计整理，砂岩区域面积较小，其滑坡灾害发育密度为 0.015 处/km²。在第四系岩组范围内，滑坡地质灾害共发生了 16 处，发育密度为 0.104 处/km²。而在碎屑岩岩组范围内，滑坡地质灾害数量最多，共发生了 98 处，发育密度也最大，达到了 0.122 处/km²。此外，花岗岩岩组范围内的滑坡地质灾害共发生 26 处，发育密度为 0.034 处/km²。

表 4-11 工程地质岩组分级统计

影响因子	级别(1~4)	区域面积(km ²)	滑坡个数	发育密度(处/km ²)
工程地质岩组	砂岩	68.2552	1	0.015
	第四系	154.2608	16	0.104
	碎屑岩	805.944	98	0.122
	花岗岩	764.16	26	0.034

采用 ArcGIS 软件绘制工程地质岩组影响因子图层，如图 4-13 所示。




图 4-13 梧州市区工程岩组分区图

§ 4.4 信息量模型

信息量方法是一种基于条件概率和信息理论的统计方法^[73]。该方法的核心在于将影响滑坡隐患的各影响因子按照其分类区间量化为具体的信息量值，进而通过空间叠加这些信息量值来精准描述滑坡事件发生的可能性。影响因子信息量值越大，说明该因子对滑坡发生的影响越大^[74]。当多个影响因子的信息量值叠加后，形成的总信息量越大，即表示该区域的滑坡易发性程度越高。对于每个影响因子的每个区间的信息量，其计算公式如 4-1 所示。

$$I(x_i, H) = \ln \frac{N_i / N}{S_i / S} \quad (4-1)$$

其中， N 表示整个区域内的滑坡总面积， N_i 指影响因子 x_i 的某一分级的滑坡覆盖面积， S 表示整个研究区的面积总和， S_i 则描述了影响因子 x_i 某一分级的区域面积。 H 则表示目标事件滑坡。如果影响因子的个数为 n ，那么滑坡隐患的总信息量值公式如 4-2 所示。

$$I = \sum_{i=1}^n I(x_i, H) \quad (4-2)$$

经过计算得到本研究所使用的各类影响因子对滑坡发生的信息量值如下表 4-12 所示。

表 4-12 影响因子信息量统计

因子名称	类别分级	信息量	因子名称	类别分级	信息量
高程(m)	-58~72	0.626053725	坡度°	0~5	-0.391817337
	73~136	0.157088623		6~11	0.456876931
	137~213	-3.338818679		12~16	0.153262252
	214~312	-1.677051624		17~21	-0.081801244
	313~455	-0.459118347		22~27	-0.616969329
	456~842	0		28~55	-1.847955918
坡向°	平面	0	地形起伏度 (m)	0~18	-0.17727602
	北	-0.802758565		19~31	0.503573426
	东北	-0.577681408		32~43	-0.122204789
	东	-0.080809537		44~56	-0.189013912
	东南	0.548173008		57~73	-1.787569478
	南	0.377229298		74~160	0
	西南	0.133950711		0~200	0.745707998
	西	-0.026677934		200~400	0.04819364
	西北	-0.269965105		400~600	-0.50023385
	耕地	-0.041199141		600~800	-2.182140206
土地利用类 型	林地	-0.011116857	距水系距离 (m)	800~1000	0
	草地	0		>1000	0.02515963
	湿地	0		0~200	0.4276811
	沼泽	-0.531784287		200~400	0.557474084
	人工地表	0.751741307		400~600	0.418039654
	<100	0.188814683		600~800	0.414922804
距断层距离 (m)	100~250	0.04248659	距道路距离 (m)	800~1000	-0.252012882
	250~500	0.349224281		>1000	-0.306534118
	>500	-0.085856549		很弱区	-2.750417609
	高丘	0.202582876		中等区	1.163697645
地形地貌	低山浅切割地形	0.434015172	人类工程活 动	强烈区	2.173375564
	波状低丘	-0.832681227		较弱区	0.011136881
	河谷阶地	-1.181267906			
	砂岩	-1.680365757			
工程地质岩 组	第四系	0.276609192			
	碎屑岩	0.435618364			
	花岗岩	-0.838015507			

§ 4.5 卷积神经网络模型

§ 4.5.1 数据集划分

鉴于本实验仅包含 141 个滑坡隐患点，样本数量相对较少，不利于深度学习模型的充分训练。因此，我们采用多环缓冲方法，在滑坡点周围 50 米的范围内扩充滑坡隐患点，使总数增至 2639 处。为了平衡数据集，在滑坡隐患点 50 米外的区域，通过随机采样方法选取了相同数量的 2639 个非滑坡隐患点，从而使得数据集总样本数达到 5278 个。利用 ArcGIS 平台提取了这 5278 个样本数据的各因子值，并整理成电子表格形式。表格中每行代表一个样本，每列则对应一个影响因子的值或目标标签。为确保模型训练与验证的有效性，将这些样本划分为训练集和验证集。

具体而言，从正样本（滑坡）和负样本（非滑坡）中各自随机选取 70% 的样本作为训练集，共计 3694 个样本。剩余的 30% 样本则作为验证集，共计 1584 个样本。数据集示例如下图 4-14 所示，其中用于训练的各影响因子分级数据为前 11 列，包括人类工程活动、距断层距离、工程岩组、土地利用、地形起伏、坡向、坡度、高程、地形地貌、距水系距离以及距道路距离。最后一列则是数据集的标签，1 为滑坡正样本，0 为非滑坡负样本。

1	人类工程活动	距断层距离	工程岩组	土地利用	地形起伏	坡向	坡度	高程	地形地貌	距水系距离	距道路距离	是否滑坡
2	3	1	5	80	10	141.70984	4.3573384	33	1	1200	200	0
3	2	1	3	20	13	167.00539	7.2044988	55	1	200	400	1
4	4	4	5	80	19	110.32314	10.36525	47	1	1000	600	0
5	4	1	3	20	23	205.86636	13.202727	145	1	200	1200	0
6	2	1	4	20	15	266.42368	5.7712388	62	1	800	1200	0
7	4	1	5	10	13	229.39871	6.638072	100	1	600	600	1
8	4	3	5	20	17	263.65982	4.8899078	59	3	200	1200	0
9	1	1	4	20	33	248.58704	19.721298	319	2	1000	1200	0
10	4	1	5	20	21	354.66785	13.558673	157	1	1000	1200	0
11	4	1	3	20	29	179.43274	18.180891	388	2	200	1200	1
12	1	1	5	20	31	164.74489	16.418526	151	3	600	1200	0
13	4	1	5	20	23	6.9529576	7.4346757	176	1	200	1200	0
14	2	1	3	20	27	187.04578	16.141895	62	1	200	400	1
15	4	1	3	20	8	48.576336	4.0808821	313	2	200	1200	1
16	4	1	3	20	18	102.80427	8.1219702	102	1	400	1200	0
17	4	2	3	10	11	18.434948	0.56921	57	1	1200	1200	1
18	2	1	2	10	13	317.38596	6.1147037	23	4	400	200	0
19	4	2	3	10	11	31.607502	5.4951615	21	1	400	200	1
20	1	1	5	20	40	27.552811	18.678415	126	1	1200	1200	0
21	2	1	5	20	17	287.02054	9.2240124	78	1	600	1000	1
22	2	1	4	20	18	275.7106	10.853866	34	1	200	1200	1
23	4	3	3	20	35	317.2605	19.361507	49	1	600	800	0
24	4	1	5	10	28	345.57922	19.514856	68	1	200	400	0
25	4	3	5	10	7	243.43495	2.4149535	60	1	1200	1200	1
26	4	1	3	20	41	261.35721	22.758436	121	3	800	400	0
27	4	4	3	20	21	176.08176	13.170786	103	2	200	1200	1
28	1	1	3	20	19	167.61925	7.5557132	236	1	1200	1200	0
29	1	1	5	20	35	165.37912	17.114204	159	3	400	1200	0
30	4	3	3	20	18	93.576332	11.542478	72	1	1200	200	1
31	4	2	5	20	10	45	0.5091169	141	3	1200	1200	0
32	4	3	2	20	17	20.69545	8.6587296	55	3	400	600	0
33	1	1	4	20	41	41.593556	21.420755	323	1	1000	1200	0

图 4-14 部分样本数据集

§ 4.5.2 卷积神经网络模型构建

在研究滑坡易发性评价时，本文设计了一个基于 PyTorch 框架的 CNN 模型，专门用于处理和分析梧州市区的地质数据，以预测滑坡灾害的易发性。模型的输入数据包括地形、地质结构、人类活动等多维度特征，这些均为影响滑坡发生的关键因素。首先，对梧州市区的地质灾害数据进行了读取和预处理，确保数据格式符合 CNN 模型的输入要求。然后，构建了一个包含卷积层、池化层和全连接层的 CNN 模型，其结构如图 4-15 所示。该模型通过学习地质数据中的空间特征，能够有效捕捉影响滑坡发生的复杂模式。卷积层负责提取地质数据中的局部特征，而池化层则有助于降低特征维度、减少计算量，并增强模型对输入数据微小变化的鲁棒性。经过一系列的特征提取和转换，模型能够逐步抽象出更加复杂的特征，这些高级特征在区分滑坡点和非滑坡点方面发挥着关键作用。模型训练完成后，能够根据新的输入数据预测滑坡发生的可能性，这种预测以模型输出的概率值形式展现，概率值接近 1 表示高滑坡风险，而接近 0 则表示低滑坡风险。




图 4-15 卷积神经网络模型结构图

针对序列数据的特点，本研究选择了一维卷积层（1D 卷积）来进行处理。这与常用于处理二维空间数据的二维卷积层（2D 卷积）存在明显差异。2D 卷积通过在图像的水平和垂直方向滑动二维卷积核，提取出如边缘和纹理等空间特征。而 1D 卷积则专门设计用于处理时间序列或信号这类序列数据，它通过一维卷积核在序列长度上的滑动，有效捕捉序列中的局部特征。尽管 1D 卷积和 2D 卷积在数据处理的维度、卷积核的结构以及应用领域上有所不同，但它们都基于深度学习的核心原理，即通过卷积核来提取数据的局部特征，并利用参数共享机制高效地学习数据特征。为了提高模型的性能，我们在卷积层和第一个全连接层之后分别添加了归一化层，并进

行了一系列实验来验证归一化层是否能够有效降低模型在训练数据上的过拟合现象，从而增强模型对未知数据的预测能力。表 4-13 详细列出了卷积神经网络模型各层的参数设置。

表 4-13 卷积神经网络模型参数

层	卷积核大小	filter 数量	步长	输出大小
输入层	-	-	-	$64 \times 1 \times 11$
卷积层 1	3×3	16	(1,1)	$64 \times 16 \times 11$
批归一化层	-	-	-	$64 \times 16 \times 11$
ReLU 激活函数	-	-	-	$64 \times 16 \times 11$
池化层	-	-	-	$64 \times 16 \times 5$
全连接层 1	-	15	-	64×15
批归一化层	-	-	-	64×15
ReLU 激活函数	-	-	-	64×15
全连接层 2	-	2	-	2

§ 4.6 CNN 实验结果与分析

§ 4.6.1 实验环境说明

本研究中，所有关于滑坡易发性评价的实验均在表 4-14 所列出的软硬件平台配置上进行，以确保实验的一致性和准确性。

表 4-14 实验软硬件平台配置基本情况表

名称	配置版本
操作系统	Windows11
CPU	Intel® Core™ i5-12490F
GPU	NVIDIA GeForce RTX 3060
Cuda	CUDA11.1
Python	Python3.6
框架	Pytorch1.9.0

§ 4.6.2 模型训练的超参数及训练策略设置

在滑坡易发性评价研究中，模型的训练采用了特定的超参数设置以优化性能。批次大小（Batch_size）设置为 64，这一设置既能确保每次迭代有足够的数量来更新权重，又能保持合理的内存使用量。损失函数选用交叉熵损失函数 Cross Entropy。

模型的优化器设置为 Adam，其初始化学率（lr）为 0.001，动量与衰减速率分别设置为 0.9、0.999，以此来平衡加快模型训练进程和确保稳定收敛的需求。为了缓解过拟合现象，我们引入了权重衰减（weight_decay），并将其值设为 1e-5。在训练过程中，使用了两种学习率调度器：CosineAnnealingLR（CALRS）和 ReduceLROnPlateau（RLROP）。CALRS 调度器根据余弦函数逐渐减小学习率，有助于模型在训练后期进行更精细的权重调整。而 RLROP 调度器则根据模型在验证集上的性能动态调整学习率。这个调度器会根据模型的性能来自动调整学习率。此外，训练过程中还设置了早停策略（early stopping），当验证集上的损失在连续 10 个训练周期内没有进一步下降时，训练将提前终止。总的训练轮数设定为 100 轮。具体的超参数设置如下表 4-15 所示。

表 4-15 超参数设置

参数/策略	设置
Batch_size	64
Epoch	100
Loss type	Cross Entropy
Optimizer	Adam
Initial Learning Rate(lr)	0.001
weight_decay	1e-5
momentum	0.9
衰减速率	0.999
学习率调度器	CALRS、RLROP
Number of Class	2

§ 4.6.3 模型评价指标

为了验证 4.5 节所设计的卷积神经网络在验证集上的分类效果，采用准确率 *Accuracy*、精确率 *Precision*、敏感度 *Sensitivity*、特异度 *Specificity* 以及 *F1* 分数作为模型的评价指标，公式如下所示：

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN} \quad (4-3)$$

$$Precision = \frac{TP}{TP + FP} \quad (4-4)$$

$$Sensitivity = \frac{TP}{TP + FN} \quad (4-5)$$

$$Specificity = \frac{TN}{TN + FP} \quad (4-6)$$

$$F1 = 2 \times \frac{Precision \times Sensitivity}{Precision + Sensitivity} \quad (4-7)$$

本实验类别数为两类，正例是滑坡，反例是非滑坡。其中，*TP* 为模型正确预测的滑坡事件数量，*TN* 为模型正确预测的非滑坡事件数量，*FP* 为模型错误地将非滑坡事件预测为滑坡事件的数量，*FN* 为模型错误地将滑坡事件预测为非滑坡事件的数量。*Accuracy* 表示模型正确预测的样本数占总样本数的比例，*Precision* 表示被模型正确预测为正例的样本数占模型预测为正例的总样本数的比例，*Sensitivity* 表示被模型正确预测为正例的样本数占实际正例总数的比例，它反映了模型捕捉正例的能力，*Specificity* 表示正确预测为反例的样本占所有实际反例样本的比例。*F1* 表示精确率和敏感度的调和平均数，提供了一个综合考虑精确率和敏感度的单一指标。

§ 4.6.4 预测结果与分析

由于本实验采用的数据集规模较小，使用复杂模型容易发生过拟合。因此，本研究只基于所提出的卷积神经网络模型进行少量模块的添加以验证新增模块的有效性。表 4-16 展示了在使用两种不同学习率调度器情况下，纯 CNN 模型与加入批归一化层（BN）的 CNN 模型在验证集上的各项评价指标结果。

表 4-16 基于 CNN 分类器的精度评价

模型	学习率调度器	准确率/%	精确率/%	敏感度/%	特异度/%	F1/%
CNN	RLROP	71.65	69.6	76.89	66.41	73.07
CNN+BN	RLROP	80.68	78.39	84.72	76.64	81.43
CNN	CALRS	75.38	72.74	81.19	69.57	76.73
CNN+BN	CALRS	83.02	81.85	84.85	81.19	83.32

由上表可知，使用 CALRS 调度器明显更适合此模型，同时加入批归一化层也大大的提高了各评价指标的精度。其中最优的选择为 CNN+BN+RLROP，准确率达到 83.02%、精确率为 81.85%、敏感度为 84.85%、特异度为 81.19% 以及 F1 分数为 83.32%。

在全面分析了卷积神经网络（CNN）模型在多个评价指标上的性能后，将进一步探讨这些模型在接收者操作特征（ROC）曲线及曲线下面积（AUC）的表现，以便对模型性能进行更深入的评估。AUC 值反映了模型区分正类（滑坡）和负类（非滑坡）的综合能力，其中更高的 AUC 值表明模型具有更强的分类性能。ROC 曲线图如下图 4-16 所示，CNN+CALRS 调度器的 AUC 值为 0.83，CNN+BN+CALRS 调度器的 AUC 值为 0.91，CNN+RLROP 调度器的 AUC 值为 0.79，CNN+BN+RLROP 调度器的 AUC 值为 0.89。由此可以看出 CNN+BN+CALRS 调度器在分类性能上表现最佳。基于这些综合评估结果，本研究将利用 CNN+BN 模型配合 CALRS 调度器训练得到

的最佳权重来进行分类，并依据每个栅格点预测的概率进行滑坡易发性评价制图。




图 4-16 各模型分类器的 ROC 曲线

§ 4.7 易发性评价结果

前面 4.4 节已经详细介绍了影响因子各分类区间的信息量计算公式，并求出了每个影响因子的信息量值。随后，利用 ArcGIS 平台的栅格计算器将这些信息量值进行累加求和，并利用自然间断点法将求得的信息量总和划分为低易发区、较低易发区、中等易发区、较高易发区和高易发区这五个易发性分区，易发性评价结果如图 4-17 所示。




图 4-17 信息量法易发性分区图

相较于信息量法，卷积神经网络模型在生成易发性分区图时，依赖于概率值而非信息量值。ArcGIS 平台将研究区域划分为多个网格点，并提取各影响因子的值到这些点中，从而构建了用于预测的数据。接着，这些数据被输入到已训练好的卷积神经网络模型中，模型经过复杂的计算后，会输出每个网格点为滑坡的概率。接着，将这些滑坡概率提取到要素属性表中，并通过 ArcGIS 的“要素转栅格”功能，将概率值转换为栅格数据。最后，采用自然间断点法，将栅格数据划分为低易发区、较低易发区、中等易发区、较高易发区和高易发区这五个不同的易发性分区。易发性评价结果如图 4-18 所示。




图 4-18 卷积神经网络模型法易发性分区图

在对梧州市区进行滑坡易发性评价时，本研究采用了信息量模型和卷积神经网络模型两种方法。仅依据易发性分区图来判断模型的准确性是不够充分的，这无法全面反映模型的可靠性。因此，为了科学和理论性地验证模型评价的准确性，本研究进一步计算了每个易发性区域的面积占比及相应区域内滑坡事件的数量。通过引入相对密度的概念对评价结果的合理性进行了验证。一般而言，高易发区的滑坡相对密度应明显高于低易发区。

对于信息量模型所得出的五个易发性等级区域，本研究分别计算了这些区域在研究区域总面积中的比重以及每个区域内包含的滑坡事件数量。根据公式：滑坡点密度（ 100km^2 ）=滑坡占比/易发性区域的面积比重 $\times 100$ ，得出表 4-17：

表 4-17 信息量模型滑坡易发性分区与灾害分布表

易发分区等级	分区面积比重(%)	滑坡事件(个)	滑坡占比(%)	滑坡点密度
低易发区	8.58%	1	0.71%	8.28

续表 4-17

易发分区等级	分区面积比重(%)	滑坡事件(个)	滑坡占比(%)	滑坡点密度
较低易发区	21.60%	1	0.71%	3.29
中等易发区	19.51%	3	2.13%	10.92
较高易发区	36.20%	50	35.46%	97.96
高易发区	14.11%	86	60.99%	432.25

由上表可知，低、较低、中等、较高和高易发区的面积分别占研究区总面积的 8.58%、21.60%、19.51%、36.20%、14.11%。其中高易发区只占研究区域面积的 14.11%，但滑坡占比却达到了 60.99%，这也说明了高易发区的发生滑坡隐患事件的概率较大，符合实际情况。

对于卷积神经网络评价模型所得的五个易发性等级区域，本研究同样分别计算了这些区域在总面积中的比重以及各自包含的滑坡事件数量。根据公式：滑坡点密度（100km²）=滑坡占比/易发性区域的面积比重×100，得出表 4-18：

表 4-18 CNN 模型滑坡易发性分区与灾害分布表

易发分区等级	分区面积比(%)	滑坡事件(个)	滑坡占比(%)	滑坡点密度	信息量模型 滑坡点密度
低易发区	50.56%	0	0%	0	8.28
较低易发区	18.61%	0	0%	0	3.29
中等易发区	13.20%	9	6.38%	48.30	10.92
较高易发区	9.78%	23	16.31%	166.77	97.96
高易发区	7.85%	109	77.31%	984.84	432.25

由上表可知，低、较低、中等、较高和高易发区的面积分别占研究区总面积的 50.56%、18.61%、13.20%、9.78%、7.85%。其中高易发区只占研究区域面积的 7.85%，但滑坡占比却达到了 77.31%，滑坡点密度点更是高达 984.84，远远高于信息量模型的 432.25。可以发现卷积神经网络评价模型在识别和划分高风险滑坡区域方面展现出更高的精度。易发性分级统计结果对比图如下图 4-19 所示，由对比图中可以直观的看出，卷积神经网络评价模型预测的中等、较高和高易发区的滑坡点密度明显要高于信息量模型预测出来的滑坡点密度。




图 4-19 易发性分级统计结果对比

§ 4.8 本章小节

本章详细介绍了研究区域的地理和地质特征，并说明了所使用的数据来源和预处理过程。随后，对选取的各个影响因子进行了详尽的分析，并通过信息量模型精确量化了这些因子与滑坡发生概率之间的关系。此外，本章着重讨论了 CNN 模型在滑坡易发性评价中的应用，包括数据集的构建、模型训练的超参数设置以及 CNN 模型的详细结构。通过对比多个 CNN 模型的评价指标，筛选出了性能最优的模型。在评价结果的对比分析中，通过计算各易发性分区内的滑坡点密度，将性能最佳的 CNN 模型与传统的信息量模型进行了对比。通过对比结果可知，卷积神经网络评价模型在识别和划分高风险滑坡区域方面展现出更高的精度。

第五章 总结与展望

§ 5.1 本文工作总结

滑坡是一种常见的自然灾害，对国民经济和人民安全造成了严重影响。在地形险峻、地质条件复杂的区域，滑坡灾害的影响尤为严重。由于滑坡类型多样、大小不一、边界形状多变，现有的识别算法难以准确识别和分割滑坡区域。考虑到滑坡位移监测方法成本高昂难以实现大范围部署，但滑坡易发性评价能够在有限的监测资源条件下，评估特定区域的滑坡风险，以指导相关部门进行合理的资源分配。当面对大规模、多维度的滑坡易发性因子数据时，传统的滑坡易发性评价方法往往难以有效捕捉数据间的深层次信息。因此本文通过卷积神经网络算法分别对滑坡识别以及滑坡易发性评价进行了详细的研究与分析。本文的研究内容及工作如下：

（1）本研究整合了一个滑坡分割数据集，该数据集包含公开的卫星遥感数据集和互联网收集的滑坡影像数据。该数据集涵盖了不同地区、不同类型和不同规模的滑坡样本，能够有效地反映滑坡识别的实际应用场景。为了防止模型过拟合，采用数据增强技术。并利用迁移学习策略，有效地将其他数据集上已经训练好的带有低语义特征信息的参数迁移至本模型中，加速了模型训练。

（2）提出了一种基于改进 DeepLabv3+ 的滑坡识别算法，引入了 ECA-Net 注意力机制模块和地貌特征融合模块，解决了不同尺度特征间的不一致性，并利用迭代注意力机制对特征进行更深层次的细化，以增强对细节的捕捉能力。通过与其他主流模型的对比分析，所改进的 DeepLabv3+ 算法对滑坡整体的分割效果更好。其各项评价指标数据如下：Recall 为 87.58%、PA 为 94.23%、mIoU 为 84.12%、mCPA 为 90.55%。

（3）本研究设计并研制了一套基于 PyQt5 的滑坡影像训练预测系统。系统包含模型训练和预测两大核心模块，模型训练模块集成了标注与训练功能，滑坡预测模块则包含了影像预测功能。该系统提供了友好的人机交互界面，方便用户实时观测训练预测过程。

（4）采集并处理了广西梧州市区的区域地质、地形地貌、水文地质及人类工程活动等多种影响因子。深入分析了传统信息量模型与优化后的卷积神经网络模型在梧州市区滑坡易发性评价中的应用。实验结果表明，利用优化后的卷积神经网络模型能够更精准地评估滑坡易发区域，其划分的高易发性分区面积更小，滑坡点密度更高。

§ 5.2 未来工作展望

本文提出的滑坡识别算法有效的提升了滑坡分割的精度及其自动化程度,将改进的滑坡识别的最优算法部署到滑坡影像训练预测系统中,完成了从滑坡训练到滑坡预测的一体化流程。对比分析了利用信息量模型与卷积神经网络模型进行滑坡易发性评价后的效果,结果表明,卷积神经网络评价模型在识别和划分高风险滑坡区域方面展现出更高的精度。然而,受时间和成本等客观因素的限制,本研究仍有若干问题未能彻底解决,需要后续工作进一步完善,未来完善的方向包括:

(1) 目前的滑坡识别方法主要基于光学影像数据,未充分利用如数字高程模型(DEM)等含有丰富地形信息的栅格数据。未来的研究可以考虑将DEM数据作为输入样本的一个新增通道,以此结合视觉数据和地形数据,从而进一步提升模型的分割性能。

(2) 尽管本研究考虑了11个影响因子,但考虑到滑坡发生受多种因素影响,未来研究应尝试收集更多相关数据,以全面评估其对滑坡易发性的影响。

(3) 多数研究在使用影响因子时进行筛选,避免共线性问题。未来可探索通过卷积神经网络中的2D-CNN技术,将每个滑坡点的一维数据转化为二维数据,并应用空间注意力机制,以识别二维化数据中对滑坡风险贡献较大的影响因子。尽管这种方法的实用性和有效性尚待验证,但它可能提供一种无需筛选影响因子直接进行实验的新途径。

参考文献

- [1] Hungr O, Leroueil S, Picarelli L. The Varnes classification of landslide types, an update[J]. Landslides, 2014, 11: 167-194.
- [2] 张江伟, 李小军, 迟明杰, 等. 滑坡灾害的成因机制及其特征分析[J]. 自然灾害学报, 2015, 24(06): 42-49.DOI:10.13577/j.jnd.2015.0605.
- [3] Du B, Zhao Z, Hu X, et al. Landslide susceptibility prediction based on image semantic segmentation[J]. Computers & Geosciences, 2021, 155: 104860.
- [4] 中华人民共和国国家统计局. 中国统计年鉴—2022 [M]. 北京: 中国统计出版社, 2023.
- [5] Malet J P, Maquaire O, Calais E. The use of Global Positioning System techniques for the continuous monitoring of landslides: application to the Super-Sauze earthflow (Alpes-de Haute-Provence, France) [J]. Geomorphology, 2002, 43(1-2):33-54.
- [6] Soares L P, Dias H C, Garcia G P B, et al. Landslide Segmentation with Deep Learning: Evaluating Model Generalization in Rainfall-Induced Landslides in Brazil[J]. Remote Sensing, 2022, 14(9): 2237.
- [7] Ji S, Yu D, Shen C, et al. Landslide detection from an open satellite imagery and digital elevation model dataset using attention boosted convolutional neural networks[J]. Landslides, 2020, 17(6): 1337-1352.
- [8] 张像源, 曾青石, 陈辉. 地质灾害野外调查数据采集系统数据模型研究[J]. 水文地质工程地质, 2007(05): 98-101.
- [9] 秦其明. 遥感图像自动解译面临的问题与解决的途径[J]. 测绘科学. 2000, (2): 21-24.
- [10] Kimura H, Yamaguchi Y. Detection of landslide areas using satellite radar interferometry[J]. Photogrammetric engineering and remote sensing, 2000, 66(3): 337-344.
- [11] Notti D, Davalillo J C, Herrera G, et al. Assessment of the performance of X-band satellite radar data for landslide mapping and monitoring: Upper Tena Valley case study[J]. Natural Hazards and Earth System Sciences, 2010, 10(9): 1865-1875.
- [12] Stumpf A, Malet J P, Delacourt C. Correlation of satellite image time-series for the detection and monitoring of slow-moving landslides[J]. Remote sensing of environment, 2017, 189: 40-55.
- [13] 彭令, 徐素宁, 梅军军, 等. 地震滑坡高分辨率遥感影像识别[J]. 遥感学报, 2017, 21(04): 509-518.
- [14] Rossi G, Tanteri L, Tofani V, et al. Multitemporal UAV surveys for landslide mapping and characterization[J]. Landslides, 2018, 15: 1045-1052.
- [15] Mondini A C, Santangelo M, Rocchetti M, et al. Sentinel-1 SAR amplitude imagery for rapid

- landslide detection[J]. Remote sensing, 2019, 11(7): 760.
- [16] Jaboyedoff M, Oppikofer T, Abellán A, et al. Use of LIDAR in landslide investigations: a review[J]. Natural hazards, 2012, 61: 5-28.
- [17] 杨萌. 基于 InSAR 与光学遥感的高山峡谷区滑坡隐患识别研究与应用[D]. 河北地质大学, 2020.
- [18] 惠文华. 滑坡遥感智能解译理论与方法研究[D]. 长安大学, 2011.
- [19] Xianju L , Xinwen C , Weitao C, et al. Identification of Forested Landslides Using LiDar Data, Object-based Image Analysis, and Machine Learning Algorithms[J]. Remote Sensing, 2015, 7(8):9705-9726.
- [20] Rau J Y, Jhan J P, Rau R J. Semiautomatic object-oriented landslide recognition scheme from multisensor optical imagery and DEM[J]. IEEE Transactions on Geoscience and Remote Sensing, 2013, 52(2): 1336-1349.
- [21] Feizizadeh B, Blaschke T, Tiede D, et al. Evaluating fuzzy operators of an object-based image analysis for detecting landslides and their changes[J]. Geomorphology, 2017, 293: 240-254.
- [22] 万保峰, 袁水华, 苏建平. 基于纹理分析的滑坡遥感图像识别[J]. 地矿测绘. 2009, (2): 11-14.
- [23] Ghorbanzadeh O, Blaschke T, Gholamnia K, et al. Evaluation of different machine learning methods and deep-learning convolutional neural networks for landslide detection[J]. Remote Sensing, 2019, 11(2): 196.
- [24] Sameen M I, Pradhan B. Landslide detection using residual networks and the fusion of spectral and topographic information[J]. IEEE Access, 2019, 7: 114363-114373.
- [25] 王煜, 张鹏, 孙恺悦等. 基于注意力融合的遥感滑坡目标识别[J]. 液晶与显示, 2022, 37(11): 1498-1506.
- [26] 朱庆, 曾浩炜, 丁雨淋, 等. 重大滑坡隐患分析方法综述[J]. 测绘学报, 2019, 48(12): 1551.
- [27] Yang S, Wang Y, Wang P, et al. Automatic identification of landslides based on deep learning[J]. Applied Sciences, 2022, 12(16): 8153.
- [28] Wang Y, Wang X, Jian J. Remote sensing landslide recognition based on convolutional neural network[J]. Mathematical Problems in Engineering, 2019, 2019.
- [29] Long W, Lu Z, Cui L. Deep learning-based feature engineering for stock price movement prediction[J]. Knowledge-Based Systems, 2019, 164: 163-173.
- [30] Anbalagan R. Landslide hazard evaluation and zonation mapping in mountainous terrain[J]. Engineering geology, 1992, 32(4): 269-277.
- [31] Reichenbach P, Rossi M, Malamud B D, et al. A review of statistically-based landslide susceptibility models[J]. Earth-science reviews, 2018, 180: 60-91.
- [32] Neuland H. A prediction model of landslips[J]. Catena, 1976, 3(2): 215-230.

- [33] Carrara A. Multivariate models for landslide hazard evaluation[J]. Journal of the International Association for Mathematical Geology, 1983, 15: 403-426.
- [34] Aleotti P, Chowdhury R. Landslide hazard assessment: summary review and new perspectives[J]. Bulletin of Engineering Geology and the environment, 1999, 58: 21-44.
- [35] Huabin W, Gangjun L, Weiya X, et al. GIS-based landslide hazard assessment: an overview[J]. Progress in Physical geography, 2005, 29(4): 548-567.
- [36] Chen X, Chen W. GIS-based landslide susceptibility assessment using optimized hybrid machine learning methods[J]. Catena, 2021, 196: 104833.
- [37] 石菊松, 石玲, 吴树仁. 利用 GIS 技术开展滑坡制图的技术方法与流程[J]. 地质通报, 2008(11): 1810-1821.
- [38] Liu L L, Yang C, Wang X M. Landslide susceptibility assessment using feature selection-based machine learning models[J]. Geomech. Eng, 2021, 25(1): 1-16.
- [39] Wang Y, Fang Z, Hong H. Comparison of convolutional neural networks for landslide susceptibility mapping in Yanshan County, China[J]. Science of the total environment, 2019, 666: 975-993.
- [40] Dreyfus S E. Artificial neural networks, back propagation, and the Kelley-Bryson gradient procedure[J]. Journal of guidance, control, and dynamics, 1990, 13(5): 926-928.
- [41] Marreiros A C, Daunizeau J, Kiebel S J, et al. Population dynamics: variance and the sigmoid activation function[J]. Neuroimage, 2008, 42(1): 147-157.
- [42] Fan E. Extended tanh-function method and its applications to nonlinear equations[J]. Physics Letters A, 2000, 277(4-5): 212-218.
- [43] Nair V, Hinton G E. Rectified linear units improve restricted boltzmann machines[C]//Proceedings of the 27th international conference on machine learning (ICML-10). 2010: 807-814.
- [44] Xu B, Wang N, Chen T, et al. Empirical evaluation of rectified activations in convolutional network[J]. arxiv preprint arxiv:1505.00853, 2015.
- [45] Ioffe S, Szegedy C. Batch normalization: Accelerating deep network training by reducing internal covariate shift[C]//International conference on machine learning. pmlr, 2015: 448-456.
- [46] Yu D, Wang H, Chen P, et al. Mixed pooling for convolutional neural networks[C]//Rough Sets and Knowledge Technology: 9th International Conference, RSKT 2014, Shanghai, China, October 24-26, 2014, Proceedings 9. Springer International Publishing, 2014: 364-375.
- [47] Long J, Shelhamer E, Darrell T. Fully convolutional networks for semantic segmentation[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2015: 3431-3440.
- [48] Ronneberger O, Fischer P, Brox T. U-Net: Convolutional networks for biomedical image

- segmentation[C]//Medical image computing and computer-assisted intervention—MICCAI 2015: 18th international conference, Munich, Germany, October 5-9, 2015, proceedings, part III 18. Springer International Publishing, 2015: 234-241.
- [49] Zhao H, Shi J, Qi X, et al. Pyramid scene parsing network[C].Proceedings of the IEEE conference on computer vision and pattern recognition, 2017: 2881-2890.
- [50] Sun K, Zhao Y, Jiang B, et al. High-resolution representations for labeling pixels and regions[J]. arxiv preprint arxiv:1904.04514, 2019.
- [51] Chollet F. Xception: Deep learning with depthwise separable convolutions[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2017: 1251-1258.
- [52] Rumelhart D E, Hinton G E, Williams R J. Learning representations by back-propagating errors[J]. nature, 1986, 323(6088): 533-536.
- [53] Kingma D , Ba J . Adam: A Method for Stochastic Optimization[J]. Computer Science, 2014.
- [54] Chen L C, Zhu Y, Papandreou G, et al. Encoder-decoder with atrous separable convolution for semantic image segmentation[C]//Proceedings of the European conference on computer vision (ECCV). 2018: 801-818.
- [55] He K, Zhang X, Ren S, et al. Deep residual learning for image recognition[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2016: 770-778.
- [56] Wang Q, Wu B, Zhu P, et al. ECA-Net: Efficient channel attention for deep convolutional neural networks[C]//Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2020: 11534-11542.
- [57] Liu S, Huang D, Wang Y. Learning spatial fusion for single-shot object detection[J]. arxiv preprint arxiv:1911.09516, 2019.
- [58] Dai Y, Gieseke F, Oehmcke S, et al. Attentional feature fusion[C]//Proceedings of the IEEE/CVF winter conference on applications of computer vision. 2021: 3560-3569.
- [59] Sandler M, Howard A, Zhu M, et al. Mobilenetv2: Inverted residuals and linear bottlenecks[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2018: 4510-4520.
- [60] Zhang Y, Chen H, Li Y, et al. ImDeeplabV3plus with instance selective whitening loss in domain generalization semantic segmentation[J]. IET Intelligent Transport Systems, 2023, 17(1): 180-192.
- [61] Yu F, Koltun V. Multi-scale context aggregation by dilated convolutions[J]. arxiv preprint arxiv:1511.07122, 2015.
- [62] 黄发明, 陈彬, 毛达雄, 等. 基于自筛选深度学习的滑坡易发性预测建模及其可解释性[J]. 地球科学, 2023, 48(05): 1696-1710.
- [63] 陈婷, 李百寿, 康弋, 等. 基于遥感阴影与财产密度的城市房屋滑坡灾害风险评估方法——

- 以广西梧州市为例[J]. 桂林理工大学学报, 2017, 37(01): 154-162.
- [64] 刘昶. 梧州市区地质灾害特征及防治建议[J]. 南方国土资源, 2007, (06): 33-35.
- [65] Rabby Y W, Ishtiaque A, Rahman M S. Evaluating the effects of digital elevation models in landslide susceptibility mapping in Rangamati District, Bangladesh[J]. Remote Sensing, 2020, 12(17): 2718.
- [66] Dai F C, Lee C F. Landslide characteristics and slope instability modeling using GIS, Lantau Island, Hong Kong[J]. Geomorphology, 2002, 42(3-4): 213-228.
- [67] Qiu Y, Fu B, Wang J, et al. Soil moisture variation in relation to topography and land use in a hillslope catchment of the Loess Plateau, China[J]. Journal of Hydrology, 2001, 240(3-4): 243-263.
- [68] Różycka M, Migoń P, Michniewicz A. Topographic Wetness Index and Terrain Ruggedness Index in geomorphic characterisation of landslide terrains, on examples from the Sudetes, SW Poland[J]. Zeitschrift für geomorphologie, Supplementary issues, 2017, 61(2): 61-80.
- [69] Schmaltz E M, Steger S, Glade T. The influence of forest cover on landslide occurrence explored with spatio-temporal information[J]. Geomorphology, 2017, 290: 250-264.
- [70] Li C, Fu Z, Wang Y, et al. Susceptibility of reservoir-induced landslides and strategies for increasing the slope stability in the Three Gorges Reservoir Area: Zigui Basin as an example[J]. Engineering Geology, 2019, 261: 105279.
- [71] Hua Y, Wang X, Li Y, et al. Dynamic development of landslide susceptibility based on slope unit and deep neural networks[J]. Landslides, 2021, 18: 281-302.
- [72] Brideau M A, Yan M, Stead D. The role of tectonic damage and brittle rock fracture in the development of large rock slope failures[J]. Geomorphology, 2009, 103(1): 30-49.
- [73] Shannon C E. A mathematical theory of communication[J]. The Bell system technical journal, 1948, 27(3): 379-423.
- [74] 许英姿, 卢玉南, 李东阳, 等. 基于 GIS 和信息量模型的广西花岗岩分布区滑坡易发性评价[J]. 工程地质学报, 2016, 24(04): 693-703.