

分类号:P23

10710-2019026022



长安大学

博士学位论文

基于多源遥感数据和深度学习的
滑坡编目方法研究

陈雪蓉

导师姓名职称	赵超英 教授 路 中 教 授		
申请学位级别	工学博士	学科专业名称	测绘科学与技术
论文提交日期	2024 年 10 月 15 日	论文答辩日期	2024 年 12 月 04 日
学位授予单位	长安大学		

Research on Landslide Inventories Method by Multi-source Remote Sensing Data and Deep Learning

A Dissertation Submitted for the Degree of Doctor

Candidate: Xuerong Chen

Supervisor: Prof. Chaoying Zhao

Prof. Zhong Lu

Chang'an University, Xi'an, China

答辩委员会名单

答辩委员会	姓名	职称	工作单位
主席	张勤	教授，博导	长安大学
委员	路中	教授，博导	中国矿业大学 (徐州)
委员	李滨	研究员，博导	中国地质科学院地质力学研究所
委员	邱海军	教授，博导	西北大学
委员	李真芳	教授，博导	西安电子科技大学
委员	赵超英	教授，博导	长安大学
委员	杨成生	教授，博导	长安大学
秘书	张静	讲师	长安大学

摘 要

滑坡是一种广泛分布的自然灾害，严重威胁着人类的生命和财产安全。滑坡编目是调查记录一个区域内滑坡灾害的发生范围和分布位置，对进一步评价灾害易发性、服务于灾害应急救援、保障人民生命财产安全具有重要意义。遥感技术在滑坡编目中发挥重要作用，通过大范围、高分辨率，高重访周期的光学影像、合成孔径雷达影像（SAR）等能有效获取滑坡的地表形态、形变量级等。按广义滑坡的定义，滑坡分为历史变形破坏区（已发生滑坡）、正在变形区（潜在滑坡）和潜在不稳定斜坡。目前，已发生滑坡主要通过光学影像以及光谱因子，识别滑坡发生后地表“损伤”的形状和大小；潜在滑坡通过干涉合成孔径雷达（InSAR）技术获取地表形变，辅助数字高程模型（DEM）及光学影像判识。潜在不稳定斜坡无明显变形，大多由于外因扰动发生破坏，遥感和一般地质调查手段很难判断。基于此，本研究主要针对已发生滑坡和潜在滑坡开展研究。

遥感滑坡编目是基于遥感影像和信息提取方法的一种应用。深度学习技术的不断发展，给遥感数据处理带来了新的机遇，也为遥感滑坡编目提供了新的解决方案。针对大范围的遥感影像，获取滑坡编目图的主要方法逐步从传统的机器学习方法发展到先进的深度学习方法。但滑坡提取是一项复杂的工作，基于深度学习方法的滑坡编目尚处于探索阶段。结合深度学习和遥感数据进行滑坡自动化编目依旧面临许多挑战。

已发生滑坡分布范围广，类型多，表现差异大，准确解译大区域滑坡分布需要花费大量的人力物力，目前公开的滑坡样本库较少。光学影像的光谱差异容易带来噪声，仅靠浅层或深层特征，很难实现对大区域复杂地形的精确滑坡绘图。潜在滑坡主要依靠InSAR技术，而广域的形变产品解译耗时耗力，且仅依靠单一产品的滑坡提取不够可靠。此外，仅InSAR产品和深度学习很难获取潜在滑坡的完整形状，需要结合InSAR、DEM和光学影像等多源数据进行综合判断，目前鲜少有多模态数据融合进行潜在滑坡编目的尝试。

本文围绕已发生滑坡和潜在滑坡自动化编目的关键技术开展研究。主要从小样本、不平衡样本问题，复杂场景影像变化检测的噪声抑制，潜在滑坡的数据集和特征提取，以及多模态数据的潜在滑坡边界提取进行技术攻关。旨在提高滑坡编目的精度和效率，为防灾减灾提供解决方案。本文的主要研究内容如下：

(1) 开展了不均衡、小样本场景下样本增强、损失函数改进和交叉验证用于滑坡编目的研究。首先,该方法利用公开的滑坡样本为训练数据,通过数据增强降低数据结构的不均衡比,扩充样本量;其次,利用焦点损失为损失函数降低易分类的背景损失值对模型影响,使模型专注对滑坡样本的学习;最后,利用 K-折交叉验证训练的模型,通过平均输出提高结果的鲁棒性。结果表明了所提策略在小样本场景下能有效提高单时相影像滑坡编目的精度。

(2) 开展了复杂光谱场景下多特征变化检测、独立成分分析和 UNet3+模型用于事件诱发型滑坡编目的方法研究。首先,本研究从光学图像和 DEM 中提取辅助因子用于辅助事件后的影像,包括归一化植被指数、灰度共生矩阵、以及高程、坡度和坡向。然后,采用独立成分分析法对辅助因子进行分析,提取独立成分,和震后影像输入具有多尺度特征跳跃连接的深度监督 UNet3+。实验结果证明 ICA 获取的辅助数据能够增强类内一致性,改善类间异质性,降低多特征造成的噪声影响,优于已有信息熵选择的特征。UNet3+网络可以适应滑坡的多尺度特征,减少复杂背景的影响,优于经典的 UNet 模型。

(3) 建立了结合形变速率和相位梯度的潜在滑坡位置编目数据集,提出了改进的 Yolo 网络进行潜在滑坡位置编目的方法。本研究结合 InSAR 形变速率、相位梯度和可视性 C 指数,建立了潜在滑坡数据集,提出了一种以 Swin Transformer 为骨干网络,加入多尺度时空注意力机制的 Yolo 模型。实验结果证明,结合 InSAR 形变速率、相位梯度和 C 指数的数据集比单一数据集抗差能力更强, Swin Transformer 可以提高特征图的挖掘能力,多尺度时空注意力模块可以融合滑坡大小和尺度多样性的特征,优于传统的目标检测网络,在测试区验证其具有很好的泛化能力。

(4) 建立了光谱因子、地形因子和形变速率结合的多模态潜在滑坡形态编目数据集,提出了一种速率约束的多模态输入网络结构,实现潜在滑坡自动化编目。本研究利用光学影像提取了 3 个光谱因子(归一化植被指数,归一化建筑指数,归一化水体指数)、利用 DEM 提取了 3 个地形因子(高程、坡度、坡向),和形变速率建立了潜在滑坡形态编目数据集。提出了一个多模态输入的网络,采用速率约束模块和注意力机制提高形变速率对模型决策的权重贡献,金字塔池化增强多尺度信息提取。实验结果证明,多模态数据的潜在滑坡数据集优于单一模态数据,能有效减少错判漏判。多模态输入网络增强

了关键特征的决策权重，对滑坡区域进行精确的分类和定位，有效提升潜在滑坡编目的精度，减少误差干扰。

关键词：滑坡编目，干涉合成孔径雷达，深度学习，多模态数据，注意力机制

Abstract

Landslide is a widely distributed natural disaster that seriously threatens human life and engineering construction. Landslide inventory can evaluate disaster susceptibility and emergency relief by investigating and recording the size and extent of multi-scale landslide hazards, which is important to disaster prevention and mitigation. Remote sensing technology is the dominant technical approach for landslide inventory. Remote sensing technology can effectively obtain the surface morphology and deformation of landslides through optical images with wide range, high resolution, and high revisiting optical images and synthetic aperture radar (SAR) images. According to the definition of generalized landslides, landslides are categorized into historical deformation zone (existing landslides), active deformation zone (potential landslides), and potentially unstable slopes. Presently, optical images and spectral factors are applied to identify the shape and size of surface damage for existing landslides, and interferometric synthetic aperture radar (InSAR) technology is used to obtain the surface deformation with the assist of digital elevation model (DEM) and optical images. It is difficult to recognize the weak deformation of potentially unstable slopes resulting from external disturbance by remote sensing and geological investigation. Therefore, this study focuses on the inventory methods of existing landslides and potential landslides.

Landslide inventory by remote sensing is one of the applications with information extraction. The advent of deep learning introduces new opportunities for remote sensing data processing, in which deep learning is currently widely used to the remote sensing information extraction. The acquisition methods of landslide inventory maps have gradually developed from traditional machine learning to advanced deep learning for large-scale remote sensing images. However, the landslide inventory based on deep learning methods is still in the exploratory stage, and the automated landslide inventory combined deep learning and remote sensing data still faces many challenges.

The existing landslides are characterized by wide distribution, numerous types, and high variability. The accurate interpretation of landslide distribution over large area is labor-intensive, and there is currently a limited library of publicly available landslide samples. The spectral

differences in optical imagery are prone to create noise, and the accurate landslide mapping of large area of complicated landscape is difficultly achieved by shallow characteristics or deep characteristics. The recognition of potential landslides is mainly based on the interferometric synthetic aperture radar (InSAR) technique. However, the interpretation of wide-area deformation products is time-consuming and labor-intensive, and landslide extraction relying on single product cannot afford reliable result. In addition, it is difficult to obtain the complete shape of potential landslides with only InSAR products and deep learning. The comprehensive identification is required in the combination with multi-source data such as InSAR, DEM and optical imagery. The studies in multimodal data fusion for inventory potential landslides are still lacking.

This paper studies the key techniques for automated inventory of existing and potential landslides, involving small and unbalanced sample problems, noise suppression for image change detection in complex scenes, dataset and feature extraction for potential landslides, and potential landslide boundary extraction from multimodal data. This paper is expected to improve the accuracy and efficiency of landslide inventory and provide solutions for disaster prevention and mitigation. The main results are as follow:

(1) A sample augmentation, loss function improvement, and cross-validation strategies were employed for imbalanced landslide inventories for small sample cases. This method adopts publicly available landslide samples as training data. The unbalanced ratio of data structures is reduced by data enhancement. The focus loss is used as loss function to reduce the impact of background loss from easy categorization on the model, which focuses the model on learning about landslide samples. The mode is trained by 5-fold cross-validation, and outputted the average result of five models which can obviously improved the robustness.

(2) An approach of multi-feature change detection, independent component analysis, and UNet3+ was used for event-triggered landslide inventory in complex spectral scenes. The post-event image assisted by spectral factors and topographic factors which are extracted from optical images and DEM including the normalized vegetation index (NDVI), gray-level covariance matrix (GLCM), elevation, slope, and aspect, were inputted into the model. The

assistance factors are analyzed by independent component analysis (ICA), and extracted independent components. The post-event image and the assistance factors are input to the UNet3+ which is depth supervised and with multi-scale feature skip connections. This method is used to detect the landslides after the Jiuzhaigou earthquake. The experimental results demonstrate that the assistant factors acquired by ICA improves intra-class homogeneity, enhances inter-class heterogeneity. The UNet3+ can reduce the noise effect caused by multiple features.

(3) A potential landslide location inventory dataset was developed that combines deformation rates and phase gradients, as well as an improved Yolo network of potential landslide location inventories. A potential landslide dataset combining InSAR deformation rate, phase gradient, and visibility C-index is established, and a Yolo model improved with a multi-scale spatio-temporal attention mechanism and Swin Transformer is proposed. The experimental results demonstrated that Swin Transformer can improve the mining ability of feature maps, and the multi-scale spatio-temporal attention module can incorporate the features of landslide size and scale diversity, which is superior to the traditional target detection network. The dataset combining InSAR deformation rate, phase gradient and C-index is more resistant to aberration than a single dataset, and proves good generalization in the test area.

(4) A potential landslide morphology inventory dataset was developed, combining spectral factors, topographic factors, and deformation rates, as well as a network structure with multimodal inputs. Three spectral factors (normalized vegetation index, normalized building index, and normalized water index) and three topographic factors (elevation, slope, and slope direction) were extracted using optical imagery, DEM, and deformation rates to establish a potential landslide inventory dataset. A network with multimodal inputs is proposed with a rate constraint module and an attention mechanism, which can improve the contribution of the deformation rate to the results, and extract multiscale information by pyramid pooling. The experimental results proved that the potential landslide dataset with multimodal data is better than the single-model data, and can effectively reduce misjudgment and omission. The multimodal input network enhances the decision weights of key features, accurately classifies

and localizes landslide areas, effectively improves the accuracy of inventory potential landslides, and reduces error disturbances.

Key words: Landslide Inventory Mapping, Interferometric Synthetic Aperture Radar, Deep Learning, Multimodal data, Attention Mechanism

目 录

第一章 绪论.....	1
1.1 研究背景及意义.....	1
1.2 滑坡编目研究现状.....	3
1.2.1 滑坡分类.....	3
1.2.2 滑坡编目的发展.....	4
1.2.3 深度学习滑坡编目的发展.....	6
1.2.4 已发生滑坡编目研究现状.....	8
1.2.5 潜在滑坡编目研究现状.....	10
1.3 存在问题.....	12
1.4 研究内容.....	13
1.5 论文章节安排.....	15
第二章 滑坡编目样本和深度学习方法	17
2.1 引言.....	17
2.2 滑坡和滑坡样本集.....	17
2.2.1 滑坡及滑坡要素.....	17
2.2.2 已发生滑坡样本制作.....	19
2.2.3 潜在滑坡样本制作.....	22
2.3 滑坡编目的机器学习和深度学习方法	26
2.3.1 机器学习方法.....	26
2.3.2 卷积神经网络(CNN)基本原理	28
2.3.3 滑坡编目的语义分割网络.....	32
2.3.4 滑坡编目的目标检测网络.....	36
2.4 滑坡编目精度评价指标.....	39
2.5 本章小结.....	41
第三章 小样本场景下单时相已发生滑坡编目方法	42
3.1 引言.....	42
3.2 改进的全卷积神经网络.....	42
3.3 小样本模型训练方法和分析	43
3.3.1 样本增强.....	43
3.3.2 损失函数.....	48
3.3.3 K-折交叉验证	49
3.4 测试区编目结果及分析.....	52
3.4.1 公开的滑坡数据集概况.....	52
3.4.2 测试区概况.....	54

3.4.3 贵州省六盘水市测试结果和分析.....	56
3.4.4 甘肃省天水市测试结果和分析.....	63
3.5 本章小结.....	65
第四章 复杂光谱场景下双时相事件诱发型滑坡编目方法	67
4.1 引言.....	67
4.2 全尺度连接深度监督模型	67
4.2.1 U-Net3+模型结构	69
4.2.2 全尺度特征连接.....	70
4.2.3 特征处理方法.....	71
4.3 多特征提取和分析过程.....	73
4.3.1 研究区域和数据概况.....	73
4.3.2 多特征变化检测结果.....	74
4.3.3 多特征选择和分析结果.....	76
4.4 不同特征辅助定量对比及定性分析	80
4.4.1 多特征辅助与模型结果定量分析.....	80
4.4.2 可视化输出结果定性分析.....	81
4.4.3 多特征辅助分析.....	83
4.4.4 已有研究对比.....	84
4.5 本章小结.....	85
第五章 基于 In SAR 产品的潜在滑坡位置编目方法	87
5.1 引言.....	87
5.2 In SAR 产品数据集和深度学习模型	88
5.2.1 MISDNet 网络结构.....	88
5.2.2 GRCI 数据集	92
5.2.3 技术流程.....	94
5.3 训练样本和测试样本概况	94
5.3.1 训练区和测试区概况.....	94
5.3.2 原始数据概况.....	95
5.4 不同数据集结果对比分析	96
5.4.1 形变速率数据集评估.....	96
5.4.2 相位梯度数据集评估.....	99
5.4.3 GRCI 数据集评估	101
5.5 编目结果精度评估分析与讨论	103
5.5.1 测试区泛化性评估.....	103
5.5.2 误差可视化分析.....	104
5.5.3 混淆矩阵分析.....	105
5.6 本章小结.....	106
第六章 基于多模态遥感数据的潜在滑坡形态编目方法	107

6.1 引言.....	107
6.2 多模态融合模型.....	107
6.2.1 MMNet 网络结构.....	107
6.2.2 速率约束的多模态输入模块.....	108
6.2.3 特征融合模块.....	109
6.2.4 网络训练优化过程.....	110
6.3 多模态样本及数据概况.....	111
6.3.1 研究区概况.....	111
6.3.2 原始数据概况.....	112
6.3.3 多模态样本介绍.....	115
6.4 实验结果与分析.....	117
6.4.1 机器学习识别结果及分析.....	117
6.4.2 不同输入特征的深度学习实验结果及分析	119
6.4.3 不同深度学习模型多模态输入对比实验及分析	121
6.4.4 测试区可视化结果分析.....	122
6.5 本章小结.....	123
第七章 总结与展望	125
7.1 研究成果与结论.....	125
7.2 研究创新点.....	126
7.3 问题与展望.....	126
参考文献.....	127

第一章 绪 论

1.1 研究背景及意义

滑坡是指岩石、泥土或碎石在重力作用下沿着斜坡向下的运动，造成地表物质损失或迁移，导致地貌发生重大变化，并造成严重的财产损失、人工建筑物破坏和人员伤亡^[1]。滑坡包括，滑坡、崩塌、泥石流等^[2]，是世界上最严重的地质灾害之一，据世界卫生组织报告，在1998年至2017年间，超过480万人口被滑坡灾害影响，有约2万人因滑坡死亡(<https://www.who.int/health-topics/landslides/>)。图1.1显示了美国国家航空航天局(NASA)编制的自2007年以来全球强降雨、热带风暴等因素引起的滑坡灾害分布图。随着全球极端气候的增加，滑坡灾害带来的灾难有可能进一步加剧^[3-5]。




图 1.1 全球滑坡分布图 (<https://maps.nccs.nasa.gov/>)

我国地域辽阔，地质环境复杂多样，是世界上滑坡灾害最严重的国家之一^[6]，超过三分之二的土地受到滑坡灾害威胁（图1.1）。我国地势西高东低，呈阶梯状分布，山地面积占据了国土总面积的70%以上^[7]，这种复杂的地质环境也带来了诸多挑战。地震^[8]、暴雨^[4]、台风^[9]等极端事件在我国时有发生，这些自然灾害不仅直接威胁着人们的生命财产安全^[10]，也加剧了滑坡等地质灾害的发生。在地震的影响下，山体岩石破裂、松动，为滑坡的发生提供了条件^[11-13]；而暴雨和台风则通过增加坡体的含水量和冲刷力，进一步破坏了坡体的稳定性^[7,3]。

除了自然因素外,人类活动也对我国的地质环境造成了显著影响。采矿活动通过破坏山体斜坡的稳定性和增加废渣堆积,增大了滑坡的风险^[14-16];开挖坡脚、农业灌溉^[17]和堆填加载等活动通过改变坡体的结构、增加地表荷载,进一步加剧了滑坡的发生概率^[18,19]。滑坡灾害对生态环境的影响显著,也严重威胁人类的生命和财产安全。统计显示,我国约 80%的地质灾害发生在未知区域^[20]。这些滑坡不仅造成巨大的经济损失,还导致大量的人员伤亡。滑坡作为一种常见的地质灾害,因其突发性和破坏性,已引起广泛的社会关注与研究^[21]。

滑坡编目是一项细致而重要的工作^[22],它旨在系统地记录一个地区内滑坡的分布情况、规模大小以及边界等重要信息。这项工作不仅是滑坡灾害监测、易发性评价和灾害应急救援的基石^[23],更是理解和应对滑坡灾害的关键^[24]。准确且全面的滑坡编目图能有效展示滑坡在特定区域的分布模式,通过对这些数据的分析,可以深入了解滑坡的发生频率、类型及其空间分布特征,了解研究区域的滑坡类型、发育模式、以及预测未来的危险性,结合地质和地貌特征研究主控因子,结合人文地理等资料制定合理的灾害防治策略^[25]。

在滑坡灾害频发的区域,准确的滑坡编目有助于及时识别潜在的风险点,为灾害预警和应急救援提供关键依据^[26]。通过对比不同时期的滑坡编目图,能够识别滑坡灾害的发展趋势和变化规律,从而为制定有效的防治策略提供科学依据。因此,对滑坡的准确编目不仅具有重大的实际意义,能够直接减少滑坡带来的生命威胁和财产损失,同时也是推动滑坡防治科学研究和技术进步的重要动力^[27]。

滑坡编目是一项耗时耗力的工作,需要对大范围的地质环境进行详细的调查和分析^[28]。这不仅包括对地形、地貌等地质数据的全面评估,还涉及到对历史滑坡事件的记录和研究。此外,编目工作通常需要结合多种技术手段,如遥感技术^[26,27]、地理信息系统^[29-31]以及现场勘测,才能准确地识别和定位潜在的滑坡区域。这些步骤每一个都需要投入大量的人力、物力和时间,确保编目的准确性和全面性,从而为防灾减灾工作提供可靠的数据支持^[32],海量的遥感数据为滑坡编目带来了新的机遇^[33]。人工智能技术的发展和广泛应用为滑坡编目工作带来了新的解决方案,相比传统的滑坡编目方法,人工智能可以实现自动化处理和分析,极大地减少了人力成本和时间消耗^[34]。同时,人工智能能够综合分析多种因素,减少主观因素的干扰,提高滑坡编目的准确性和效率。尽管人工智能在滑坡编目中具有诸多优势,但也面临一些挑战和限制。例如,数据采集和应用中

可能存在不确定性和误差^[35]，建立预测模型需要大量的历史数据和专业支持等^[36]。因此，需要不断的研究和实践，进一步完善和优化人工智能算法，提高智能算法在滑坡编目的准确性和实用性。

本文基于以上背景和当前智能算法在滑坡编目中存在的问题，以已发生滑坡和潜在滑坡为研究对象，基于样本建立、算法优化、结果提升等方面开展深度学习算法在滑坡编目中应用的关键技术研究。最终建立了深度学习算法在滑坡编目中的方法体系，为准确、快速的滑坡编目提供参考。

1.2 滑坡编目研究现状

1.2.1 滑坡分类

根据广义滑坡隐患的定义，滑坡隐患可分为三类：第一类为历史变形破坏区（已发生滑坡），第二类为正在变形区（潜在滑坡），第三类为潜在不稳定斜坡^[6]。

已发生滑坡是指曾经发生滑坡等地质灾害的地区，其主要表现形态包括地表出现明显的滑坡沟、塌陷和堆积物；植被稀疏或消失；土壤结构松散，存在土壤剥蚀和沉积；地表可见裂缝，伴随地基沉降和倾斜现象。通过光学遥感影像、数字高程模型（DEM）等进行特征提取、分类等可以进行识别。主要包括计算归一化植被指数（NDVI）^[37]、变化检测（CVA）^[9,38,39]、边缘检测^[36]、分类算法^[40]、三维重建和深度学习等。

潜在滑坡是指地表正在发生变形的斜坡，其主要表现为地表的微小位移、裂缝的形成、地表倾斜度的变化，以及土壤水分含量的波动等。这些特征通常表明斜坡的不稳定性和滑坡的风险增加。主要依靠主动式微波遥感手段获取地表形变数据，包括干涉合成孔径雷达干涉测量（InSAR）、SAR 偏移量等技术，随后依靠地形、光学影像等辅助综合判断进行识别。这些方法能够高精度监测地表的变形，帮助评估潜在滑坡的风险，并为防灾减灾提供重要依据。

不稳定斜坡是指在自然条件下处于基本稳定或欠稳定状态的斜坡，历史上未曾发生过变形破坏，且当前无明显变形迹象^[6]。这类滑坡很难在光学影像或者 SAR 影像上进行识别，需要物探及其他手段进行。

基于此，本研究主要以已发生滑坡和潜在滑坡为研究对象，开展遥感对地观测数据和深度学习进行滑坡编目的方法研究。

1.2.2 滑坡编目的发展

滑坡编目方法经历了从野外调查、遥感图像目视解译、多源遥感数据综合解译，及目前的机器学习和深度学习相结合的过程^[22]（图 1.2）。




图 1.2 滑坡编目方法发展趋势

野外调查能为滑坡特征、范围、形状等提供详细的数据，但其往往效率不高，且调查不够全面^[41]。遥感技术的出现为滑坡编目提供了新的手段，通过航空飞机拍摄的影像建立立体模型进行目视解译降低了野外工作量^[25,32]。卫星影像出现后，专家通过对不同分辨率的影像和数字高程模型结合判读，提高了目视解译判读的准确率^[42,43]。我国利用光学遥感进行滑坡识别起源于 20 世纪 80 年代，到 21 世纪初开始用于大规模单体滑坡调查与区域滑坡调查。王治华等^[44]利用 Landsat TM、IKONOS、Quickbird 三种光学影像和 1:10000 地形图绘制了 2004 年发生的四川省天台乡滑坡。许冲等^[45]综合利用 SPOT5，Quickbird 等遥感影像精细解译了 2008 年汶川地震诱发的次生地质灾害，共解译出约 46560 处崩塌、滑坡、泥石流等地震次生地质灾害，灾害总面积约 687.1km²。这些存档的滑坡清单为当地滑坡调查和分析提供了重要支撑。

为了提高滑坡编目的效率，学者们开始尝试半自动的方法进行滑坡编目^[46]。主要采用基于像素^[37,47-49]和面向对象^[36,50,51]的遥感影像分类方法。无论采用何种技术，在尝试基于多光谱信息分类时，原始卫星数据的预处理都是必不可少的。图像预处理，包括锐

化、正射校正、配准和辐射校正。图像预处理能够提高影像质量，减少噪声影响，为滑坡编目提供准确的原始数据。

像素级的影像分类，主要利用单个像素的光谱信息，通过像素的大小、各波段的像素值，辐射特性等给像素分类，主要有监督分类和非监督分类两种。非监督分类不使用样本训练，Rau 等^[52]结合变化向量分析（CVA）和归一化植被指数（NDVI），以实验阈值法识别了滑坡。Li 等^[53]提出了基于马尔科夫随机场的变化检测方法用于滑坡识别，使用滑坡前后的影像进行变化检测来识别滑坡，有较好的精度。变化检测的方法需要影像具有相似的获取视角，光照条件和季节特征。对于这种方法来说，非常重要的一点是归一化植被指数的变化，因此影像的选择和预处理非常重要。Yang 等^[54]利用 Sentinel-2 影像计算归一化植被指数时间剖面。然后利用 K 均值分类器获取了识别滑坡的最佳阈值。但是，以上基于像素的方法经常会导致比较严重的错分和椒盐现象，因此精度有限，非监督的方法也依赖于经验阈值，很难在大范围推广。

为了克服像素级的分类问题，提出了利用面向对象的方法来识别滑坡。这种方法通过一定的分割参数，将地面的像素聚合为对象。这种方法更多的考虑到像素的空间属性。从而大大降低了椒盐噪声，提取出更多的光谱、形态和环境特征（如形状指数、结构、局部纹理等）用于滑坡制图，因此可以提取更详细的滑坡特征^[55]。Stumpf 和 Kerle^[56]提出了基于面向对象分析和随机森林算法的监督分类识别滑坡的方法。采用波段比、坡度和地形纹理等方法可以提高精度。采用基于区域的主动学习启发式方法^[57]，并且通过分层抽样解决了分类不平衡的问题。Chen 等^[50]利用国产 ZY-3 卫星影像和随机森林（Random Forest, RF），并采用数学形态学提高模型精度，实现了三峡库区滑坡识别，对该地区的灾害响应有积极意义。Behling 等^[58]通过分析滑坡相关的地表变化和其他土地覆盖变化的时序 NDVI 来识别滑坡。结合基于像素的多阈值和面向对象分析相结合的方法获得了较高的精度。Bui 等^[59]利用机载合成孔径雷达(AIRSAR)数据和高分辨率遥感数据结合支持向量机（Support Vector Machine, SVM）和熵指数的方法进行滑坡检测。尽管面向对象的方法已经可以利用遥感影像较好地识别滑坡，但同样受到主观因素的影响，且机器学习算法非线性特征提取能力弱，提取特征深度有限，面对大区域的滑坡对象识别也比较困难。

随着计算机视觉技术的进一步发展，越来越多的深度学习算法被用在遥感影像分类任务中^[60-62]。深度学习算法在遥感分类和识别领域应用已取得了较好的结果，灾害环境

监测和检测也是遥感重要的应用领域之一^[28,63]。在滑坡编目方面,深度学习算法也开始显现出其优势,超越了传统机器学习算法^[34]。在基于网络深度^[64]、网络结构^[65]、不同深度学习算法等^[66,67]方面不断的探索。但利用深度学习算法进行自动化的滑坡编目依然面临滑坡形态多样、背景复杂、样本不足等问题^[68]。准确高效的更新滑坡编目图,仍是一项亟待解决的难题。

深度学习算法是基于数据驱动的计算,它往往需要大量准确的样本以学习目标特征。遥感滑坡编目比遥感地物分类更复杂,滑坡分布范围广,类型较多,表现不同,解译大区域准确滑坡分布需要花费大量的人力物力^[22,69]。因此,目前公开的已发生滑坡样本较少^[64,66],且滑坡在地物分类中属于极少数^[69]。样本少、样本不均衡的问题限制了深度学习用于滑坡编目的精度^[35]。此外,样本中非滑坡的像素量远大于滑坡像素,在训练过程中损失函数主要被易分类的非滑坡样本主导,使模型偏离了学习方向,样本的不均衡比是影响深度学习分类结果的重要因素之一^[70]。此外,遥感影像存在光谱差异大,物谱不一致的情况,相似背景区分难。且滑坡提取任务复杂,单一遥感产品很难实现高精度编目。面对滑坡编目任务,还需要考虑深度学习方法的适用性。

1.2.3 深度学习滑坡编目的发展

滑坡智能编目是一项复杂且多学科交叉的工作,它结合了对地观测数据、机器学习和深度学习算法、地学专家知识等多个领域的知识^[71](图 1.3)。通过遥感分类算法、专家知识解译以及地学模型等多种手段,高效准确的实现滑坡编目^[72]。




图 1.3 滑坡智能编目任务

对地观测数据是滑坡智能编目的基础^[73]。这些数据来源广泛,包括卫星影像、无人机拍摄数据、地面传感器数据等^[26]。对地观测数据提供了丰富的地理信息和环境变化的详细记录,为滑坡监测提供了基础性资料。基础资料的精确度和时效性会影响滑坡识别的精度^[74]。在获取了丰富的地观测数据后,通过专家知识、遥感分类算法进行分析和处理。利用图像处理技术识别地表特征和变化,包括光谱分析、纹理分析和形态分析等^[43]。通过图像处理技术可以自动检测存在滑坡风险的区域,提供初步筛选结果,为后续分析奠定基础。

机器学习和深度学习算法在滑坡智能编目中也扮演着重要角色,他们能够处理和分析大量地观测数据,从中提取有用的信息。机器学习和深度学习通过学习专家解译的知识,进一步解释滑坡的发生规律和特征。其中,机器学习算法能够在新数据中识别出类似模式,从而预测潜在滑坡区域。深度学习算法,特别是卷积神经网络(CNN)和递归神经网络(RNN),在处理图像和时序数据方面表现优异,进一步提升滑坡识别的精度和可靠性。

此外,地学专家的知识解译是滑坡智能编目中不可或缺的一部分^[8,75-77]。地学专家通过对地质、地貌和滑坡历史数据的深度分析,提供了宝贵的经验和见解。这些专家知识不仅用于验证算法结果,还为制定更精确的滑坡预警和防治策略提供支持。地学模型也是滑坡智能编目中的关键要素之一。这些模型模拟地质过程和滑坡机制,预测滑坡发生的可能性及其影响范围^[78]。地学模型通常结合地质勘探数据、地形数据和气象数据,通过综合分析为滑坡预警提供科学依据^[26]。模型的准确性直接影响到滑坡编目的有效性。综上所述,滑坡智能编目是一项综合性极强的工作。它通过结合对地观测数据、遥感分类算法、机器学习和深度学习算法、地学专家知识和地学模型等多种手段,实现对滑坡的全面监测、准确识别和有效预警^[79]。各个领域的知识和技术相互结合,形成一个协同工作的平台,极大地提升了滑坡编目的效率和准确性。这种多学科、多技术的集成方法,是滑坡研究和防治的前沿方向,能够显著降低滑坡带来的灾害风险。

卷积神经网络(Convolutional Neural Networks, CNN)作为深度学习的一种重要架构,彻底改变了图像数据提取信息的方式。在遥感分类和识别领域,深度学习算法的应用已经取得了显著的成果^[80-82],特别是在处理海量的、复杂的图像数据时,其优势尤为明显^[83-86]。近年来,随着技术的不断发展和创新,CNN也开始被尝试用于滑坡编目这一地质灾害识别领域。




图 1.4 CNN 网络结构用于滑坡编目（引自[34]）

Ghorbanzadeh 等^[34]研究者于 2019 年率先进行了不同机器学习方法和 CNN 在滑坡检测中的对比实验。他们的研究表明，相较于传统的机器学习方法，如支持向量机（SVM）和随机森林（RF），CNN 在滑坡检测中展现出了更高的准确率和效率。这一发现不仅为滑坡编目提供了新的思路，也证明了 CNN 在地质灾害识别领域的巨大潜力。随着研究的深入，越来越多的学者开始探索 CNN 在滑坡识别中的应用。Ji 等^[64]就成功地将 CNN 应用于结合光学影像和数字高程模型（DEM）的滑坡识别中。他们通过构建多源数据融合模型，有效地提高了滑坡识别的精度和效率。Shi 等^[87]则进一步将变化检测技术和 CNN 相结合，开发出了一种新的滑坡编目方法。这种方法不仅能够快速准确地识别出滑坡区域，还能够进一步提取滑坡要素，为滑坡的监测和预警提供了有力的支持。2020 年，Anantrasirichai 等^[59]人提出一个基于卷积神经网络的形变监测模型。他们以英国为研究区，成功探测出了英国境内几个区域内的采矿塌陷以及由降水、隧道工程等活动诱发的地面沉降。这一研究再次证明了深度学习在地质灾害识别领域的强大能力，同时也提供了新的研究思路和方法。

1.2.4 已发生滑坡编目研究现状

目前，对于已发生滑坡的编目主要采用语义分割，这是一种像素级分类的方法，能获得滑坡的形状和边界，以经典的 U-Net 模型和它的改进模型为主。Qi 等^[72]和 Liu 等^[88]人对传统的 U-Net 进行了改进，以更好地提取滑坡信息。研究表明，这些深度学习模型在滑坡检测中表现出了出色的性能，能够准确地识别出滑坡区域^[89]。尽管光学图像在

滑坡检测中发挥了重要作用，但单一的数据源难以全面捕捉滑坡的复杂特征。Zhang 等^[79]人的研究利用 ENVI 软件，通过调整深度学习模型的参数，显著提升了滑坡编目的精度。然而，光学图像的局限性促使研究者们探索多源数据融合的方法。Nava 等^[90]人修改了 U-Net 模型，加入了注意力机制模块，并应用于 Sentinel-1 卫星图像，即使在云层覆盖较厚的情况下，也能够准确绘制滑坡图。这一成果表明，雷达图像在滑坡检测中的潜力巨大，尤其是在光学图像受限的情况下。此外，研究人员还尝试将归一化差异植被指数(NDVI)、数字高程模型(DEM)等因素与卷积神经网络(CNN)结合使用。这些研究表明，结合多源数据可以显著提高滑坡检测的准确性。Gao 等^[91]人通过全卷积网络 (FC-DenseNet) 结合多种特征，进一步提高了模型性能。Soares 等^[92]则通过结合 RapidEye 卫星图像、NDVI 和 DEM 来创建数据集，并通过背景增强样本来改善模型的训练效果。他们发现，NDVI 层有助于平衡模型的性能，而形态学后处理操作则有效提高了分割精度。Yang 等人^[93]则提出了一种减少背景物体错误提取的模型。他们通过改进模型结构和算法，成功降低了背景物体对滑坡检测的影响。考虑到遥感图像的复杂背景和多样性，Chen 等人^[15]采用了一个基于特征融合的 Squeeze-and-Excitation Networks (SENet)，用于改善传统 UNet 的缺点。他们利用 Sentinel-2 图像进行滑坡提取，并取得了良好的效果。

地理环境因素在滑坡形成过程中起着主导作用，因此环境属性（如 DEM、坡度和与河流的距离）也可以作为补充信息，为滑坡提取模型提供额外的帮助^[94,95]。Ghorbanzadeh 等^[96]的研究就证明了这一点。他们发现，通过结合地形因子和光谱信息来训练数据集，可以更好地区分滑坡与其他类似特征。此外，Wang 等人^[97]的研究还表明，采用主成分分析 (PCA) 多特征和集合策略可以提高同震滑坡提取的准确性。这些研究都表明，多特征可以帮助 CNN 更好地进行滑坡清单绘制。准确标注地面实况掩模对于训练可靠的分割算法至关重要。单个专家提供的标注可能存在偏差和错误，对多个专家的注释进行综合融合可以减少偏差和错误。其次，与标签相比，经过训练的深度学习算法的输出概率图仍然可能包含误差。可以利用考虑上下文相关性和像素概率分布的后处理工具来进一步优化分割质量^[98]。例如，当深度学习分割算法输出的地图边界不清晰、连续性差时，后处理优化步骤可以显著改善结果^[99]。在灾后影像中，山体滑坡背景复杂，形态各异。同样的方法应用于各种遥感平台的数据时，可能会产生不同的结果。利用无人机图像和深度学习模型来有效识别滑坡的需求日益增长，尤其是在滑坡分布密集的地区。因此，

受限于应用场景和目标特征,传统的深度学习模型在基于无人机的滑坡提取中存在局限性^[98]。

在具有复杂背景和滑坡分布稀疏性的场景中,针对滑坡编目的研究却相对较少。此外,滑坡同时呈现出时间分布不均和空间分布不均,现有研究在构建深度学习模型时,往往忽视了样本量小和样本集分布不均所带来的挑战。深度学习算法是一种基于数据驱动的计算,它往往需要大量的准确的样本库学习目标的特征。但目前公开的已发生滑坡样本库较少^[11],且滑坡在地物分类中属于极少数^[96],样本库少、样本不均衡的问题限制了深度学习滑坡编目的精度。样本中非滑坡的像素量太大,在训练过程中损失函数主要被易分类的非滑坡样本主导,使模型偏离了学习方向,样本的不均衡比是影响深度学习分类结果的重要因素之一。复杂场景下仅依靠红绿蓝波段组成的 RGB 影像难以提供更多信息,甚至因为同物异谱或同谱异物现象带来更多的噪声,需要进一步增加辅助信息来提高编目精度^[100]。

1.2.5 潜在滑坡编目研究现状

潜在滑坡通常被植被覆盖,难以用光学影像探测。激光雷达能够探测地表的微小变形,但价格昂贵且难以在大范围内推广。干涉合成孔径雷达(InSAR)技术是探测潜在的缓慢变形滑坡(典型速度小于 1.6 米/年^[101])最先进、最有效的方法,具有全天候、昼夜、大面积覆盖的优势^[102]。

表 1-1 滑坡速率分类 (引自^[101])

类别	名称	典型速度
5	极快速	5 m/s
4	非常快速	3 m/min
3	快速	1.8 m/h
2	一般	13 m/month
1	缓慢	1.6 m/year

InSAR 技术利用雷达卫星影像的相位信息,通过干涉处理获取地表的微小形变^[103]。其原理如下,雷达卫星在不同时间点拍摄同一地表区域的影像。通过对比这些影像的相位差异,计算出地表在两个时间点之间的形变。InSAR 技术能够检测到毫米级的地表形变,适用于大范围、长时间的地表形变监测。InSAR 技术在滑坡监测和预警中的应用具

有多个优势^[102]：能够提供高精度和高分辨率的影像，进行毫米级的地表位移监测，适合检测微小的地表变化；一次卫星观测可以覆盖广阔的地表区域，适合大面积滑坡风险区的监测；不需要接触地表，适用于难以接近或危险的区域；具有长期的存档数据，可以进行历史数据积累和变化分析，帮助识别长期趋势和突发事件。

在滑坡监测和预警中，InSAR 技术的应用包括以下几方面。监测潜在滑坡区域：InSAR 可以持续监测潜在滑坡区的地表变化，帮助识别滑坡前兆^[104]。一方面，通过 InSAR 数据分析，评估已经发生的滑坡活动及其影响区域，制定相应的减灾措施。另一方面，结合地质数据和 InSAR 形变监测结果，划分滑坡风险区域，为土地利用和规划提供参考。此外，在滑坡发生后，InSAR 能够迅速评估滑坡区域的形变和影响，为救援行动提供重要信息^[105]。

随着 SAR 卫星技术的发展和多源 SAR 数据的便捷获取，推动 InSAR 滑坡识别进入流域尺度阶段，如 Liu^[106]等人基于 InSAR 技术开展了金沙江全流域约 2200 多公里的滑坡识别，共识别各类滑坡 900 余处。特别是 Sentinel-1 数据的免费开放以及云平台快速发展技术的发展，推动 InSAR 滑坡识别迈入国家尺度以及洲级尺度^[86,107]。

InSAR 技术滑坡识别的前提是滑坡的特征与 InSAR 可监测的形变特征相吻合。主要包括滑坡的空间尺度与 InSAR 的相干点密度，滑坡的形变梯度与 InSAR 视向形变可监测能力。前者受到 InSAR 几何畸变以及各种去相干因素的影响；后者受到 InSAR 形变监测精度和最大与最小形变监测梯度的影响^[108]，以及滑坡几何与 SAR 成像几何的转换关系以及波长的联合影响^[109]，即形变灵敏度。滑坡特征与 InSAR 可监测形变不匹配将识别漏判或错判。

InSAR 技术利用多时相 SAR 数据揭示地表形变，并根据形变速率、相位梯度和其他 InSAR 产品生成潜在滑坡的编目图^[22,105]。专家们已应用 InSAR 产品探测未知的潜在滑坡^[103,110]，绘制不稳定斜坡的边界，并获取滑坡的变形过程^[111-114]。然而，在有大量合成孔径雷达图像的情况下，大规模解释 InSAR 产品仍然耗时耗力。

滑坡检测中的经验方法依赖于专家知识，直观但准确性有限。聚类和时间序列分析^[115]等无监督方法可自动划分滑坡区域，但在复杂情况下处理起来具有挑战性。半自动方法结合了两者的优势，可提高准确性^[116]。机器学习等监督方法具有潜力，但需要解决数据问题^[117]。阈值的确定依赖于专家经验，结果具有主观性。

深度学习方法逐步在 InSAR 产品的自动检测中显示出优越性。随着深度学习在光学遥感领域的探索,许多地表物质提取任务都采用了深度学习技术,包括人类活动(建筑物^[83,109]、土地覆盖^[86,107]、船舶^[118])和自然地物(冰川^[108,119,120]、火山^[112]和地面沉降^[121])。Zhou 等人^[122]利用深度学习将对流层延迟校正应用于 InSAR 的滑坡监测。

近年来,利用 InSAR 产品进行滑坡检测取得了进展,包括将 InSAR 相位梯度、形变速率与目标检测相结合(如 Faster R-CNN、Yolo)、语义分割(如 U-Net)以及其他模型。Li 等人^[123]提供了一种分两个阶段获取潜在滑坡位置的方法。首先,使用 Faster R-CNN 获取潜在滑坡的位置。然后利用 U-Net 网络和光学图像获取滑坡的形状。Chen 等人^[124]通过改进的 U-Net 模型和 D-InSAR 产品获得了潜在滑坡的分布。Zhang 等人^[125]通过改进的 Faster R-CNN 获得了中国茂县缓慢移动滑坡的分布和形状。Guo 等^[126]结合 SBAS-InSAR 和 YOLOv5 模型,获得了山区潜在滑坡的分布。Fu 等人^[127]通过 InSAR 相位梯度和改进的 YOLOv3 模型获得了中国四川的缓变滑坡的分布。

此外,滑坡的形状和大小变化很大,从覆盖面积有限的小型浅层山体滑坡到横跨大片地区的大型深层山体滑坡。有些可能是圆形洼地,有些则呈现长条状或复杂的断层形态。这些形状和大小的变化极大地影响了深度学习算法赖以检测的视觉特征和模式。因此,可靠的自动滑坡检测方法仍有待探索。

1.3 存在问题

滑坡编目方法经历了从野外调查、遥感图像目视解译、多源遥感数据综合解译,及目前的机器学习和深度学习方法相结合的过程。野外调查能为滑坡特征、范围、形状等提供详细的数据,但其往往效率不高,且调查不够全面。通过遥感影像进行目视解译降低了野外工作量,为滑坡半自动化提供了良好的参考标签。基于遥感数据和机器学习的监督分类和非监督分类方法提高了滑坡编目的效率,但受限于参数选择的主观性且难以在大范围推广。

随着计算机视觉技术的进一步发展,越来越多的深度学习算法被用在遥感影像分类任务中。深度学习算法在遥感分类和识别领域应用已取得了较好的结果,在滑坡编目方面,深度学习算法也开始显现出其优势,超越了传统机器学习算法。在基于网络深度、网络结构、不同深度学习算法等方面不断的探索。但利用深度学习算法进行自动化的滑坡编目依然面临滑坡形态多样、背景复杂、样本不足等问题。

(1) 滑坡数据集少、样本不均衡,且滑坡样本解译不够精确,主观性较强,样本存在不确定性。深度学习算法通常需要大量丰富的样本以学习目标特征。滑坡分布范围广,类型较多,表现不同,解译大区域准确滑坡分布需要花费大量的人力物力,目前公开的已发生滑坡样本库较少。且滑坡在地物分类中属于极少数,样本库少、样本不均衡的问题限制了深度学习用于滑坡编目的精度。

(2) 不同分辨率、光谱、纹理特征的样本集较缺乏,样本简单难以反映真实滑坡场景。光学影像的光照条件、季节变化以及其他环境因素的变化,往往使得直接的变化检测方法容易产生误差。而这种差异难以在模型训练中被平衡和抑制,导致迁移效果不理想,泛化性低的问题。尽管引入辅助信息有助于提高模型的识别能力,但也可能带来额外的噪声。在模型方面,仅靠浅层或深层特征,很难实现对大面积复杂地形的精确滑坡绘图,需要综合多层次、多尺度的特征进行分析和处理。

(3) 单一 InSAR 产品获取的变形区不够可靠,传统模型对噪声抑制差,鲁棒性低。InSAR 技术是获取潜在滑坡最有效的手段,而广域的形变产品解译耗时耗力。利用深度学习获取形变异常区可以有效提高解译效率。InSAR 形变速率由于失相干而产生不连续,相位梯度则与真实地表存在一定的偏差。因此仅依靠单一产品的提取变得不可靠。此外,滑坡分布不均,尺寸和形状差异大,这些都极大地影响了深度学习算法赖以检测的视觉特征和模式。

(4) 仅依靠单一遥感数据很难获取滑坡的形状,需要结合 InSAR、光学和 DEM 等多源数据进行综合判断。已有的潜在滑坡获取主要依靠单主干网络提取特征,未能考虑多模态数据的贡献,很难获取高精度的滑坡边界。

1.4 研究内容

针对以上存在的问题,本文从以下四个方面开展研究。

(1) 针对不均衡、小样本问题的已发生滑坡编目问题,开展了样本增强、损失函数及模型 K-折交叉验证的研究。

研究利用公开的滑坡数据库为训练数据,通过数据增强降低了数据结构的失衡比;利用一种改进的全卷积焦点损失网络(FCN-FL),以全卷积神经网络为基础,采用对称连接结构,以焦点损失为损失函数降低易分类的背景损失值(Loss)对模型影响;最后利用 5-折交叉验证训练的 FCN-FL 模型(FCN-FLK)获取测试区的滑坡编目图。结果显示,FCN-

FLK 网络比原始 FCN 网络具有更好的分割精度，比 U-Net、SegNet 网络具有更好的鲁棒性。在测试区证明该方法能有效提高小样本场景下滑坡编目的精度，且具有较好的泛化性。

(2) 针对光谱差异大、噪声抑制不足的问题。开展了复杂光谱场景下多特征变化检测的独立成分分析和 UNet3+ 方法的事件诱发型编目研究。

从光学图像和地形特征中提取的信息用于辅助事后图像，包括地形特征（高程、坡度和坡向）、NDVI 和从光学图像中提取的灰度共生矩阵 (GLCM) 特征，用于辅助 UNet3+ 滑坡编目工作。采用独立成分分析法 (ICA) 对 13 个辅助因子进行分析，提高类内一致性，增强类间异质性，降低多特征造成的噪声影响。采用具有多尺度特征跳跃连接的深度监督 UNet3+，以适应滑坡的多尺度特征。同时，深度监督处理可以减少复杂背景的影响。实验以九寨沟地震诱发的滑坡为对象，证明 ICA 获取的辅助特征优于传统信息熵方法，UNet3+ 模型比经典的 UNet 模型具有更多的边界信息获取能力，编目精度优于传统方法。

(3) 针对单一 InSAR 产品解译不确定性的问题，开展了融合 InSAR 产品数据集和改进的 Yolo 网络用于潜在滑坡位置编目的研究。

研究结合 InSAR 形变速率、相位梯度和可视性 C 指数，建立了潜在滑坡位置编目数据集 (GRCI)，用于训练深度学习模型。采用了一种多尺度 Swin Transformer 为编码器的 InSAR 检测网络 (MSIDNet)，该网络以 Swin Transformer 作为骨干，并考虑了多尺度时空注意力机制。实验结果证明，GRCI 数据集能结合形变速率位置准确和相位梯度空间连续的优势，并去除了速率误差，验证结果优于单一数据集。所提出的 MSIDNet 模型具有更强的多尺度特征挖掘能力，且多尺度注意力机制适用于滑坡大小和尺度多样性的特征，模型可以改进滑坡检测的位置和边界。在测试区的结果显示，本研究的数据集和网络具有最优的精度，能有效提高滑坡位置编目的效率，具有较好的泛化性。

(4) 针对单一 InSAR 产品边界获取不准确的问题，开展了多模态数据集和多模态输入的速率约束网络用于潜在滑坡形态编目的研究。

研究构建了一种多模态潜在滑坡编目数据集，利用光学影像提取了光谱因子（归一化植被指数、归一化建筑指数和归一化水体指数），利用 DEM 提取了地形因子（高程、坡度、坡向），结合 InSAR 形变速率作为深度学习网络的输入。提出了一种多模态输入的网络结构，采用金字塔池化增加多尺度信息，通过注意力机制进行速率约束。实验结

果证明，深度学习算法显著优于传统的机器学习算法，所使用的数据集能有效利用地形因子、光谱因子和 InSAR 形变速率的输入特征互补，并生成稳定的预测结果。该网络可抑制不同模态之间的特征干扰，并有效增强多模态联合特征。实验结果证明多模态信息能提高潜在滑坡编目的精度，减少错判漏判。

1.5 论文章节安排




图 1.5 论文研究框架图

针对以上存在的问题本论文开展了以下七个章节的论述，从研究背景和意义、论文所用研究方法概述、数据源和数据集的预处理、复杂场景滑坡编目研究、潜在滑坡位置编目研究、潜在滑坡形态编目研究展开。如图 1.5 所示，研究各章节安排如下：

第一章为绪论。本章介绍了滑坡和滑坡编目的研究背景，分析了滑坡编目研究的重要性，其次综述了目前滑坡编目的主要研究方向，指出了目前深度学习滑坡编目存在的问题，最后陈述了本论文的主要研究内容。

第二章为滑坡编目的主要方法介绍。本章首先介绍了滑坡及滑坡要素，介绍了已发生滑坡和潜在滑坡样本的解译标志，介绍了滑坡数据集的制作方法。其次概述了深度学习滑坡编目的主要方法，包括语义分割方法和目标检测方法，介绍了本文用到的主要精度评价指标。

第三章针对不均衡小样本场景问题，提出了一套解决方法，即在样本方面采用数据增强降低不均衡比，在模型中采用加权损失函数提高滑坡样本的贡献。最后通过 K-折交叉验证，充分利用数据训练模型，对输出结果进行投票优化，得到最优解。

第四章针对事件前后光学影像光谱不一致导致的事件诱发型滑坡编目精度低的问题。提出了多特征变化检测，随后采用独立成分分析方法进行降噪，提高类内一致性和类间异质性。最后采用多尺度深监督的卷积神经网络进行事件诱发型滑坡编目。

第五章潜在滑坡位置编目方面，提出了一种结合形变速率和相位梯度的数据集，解决单一 InSAR 产品提取不准确的问题。采用嵌入 Swin Transformer 的 YoloV5 网络，并在特征融合中加入多尺度注意力机制模块，提高潜在滑坡位置编目的精度。

第六章针对潜在滑坡形态编目任务，提出多模态数据融合方法，结合地形因子、光谱因子和 InSAR 形变速率，提出一种多模态网络有效利用多模态数据和 InSAR 形变速率的输入特征互补，减少潜在滑坡编目错判漏判。

第七章总结本文的研究成果，并展望未来的研究计划。

第二章 滑坡编目样本和深度学习方法

2.1 引言

本章主要概述了论文中提到的滑坡的基本概念，已发生滑坡和潜在滑坡的遥感判识标志，样本制作，在第三章、第四章、第五章和第六章内容中用到的主要深度学习算法的基础理论知识，精度评价指标。

首先介绍了滑坡和滑坡要素，明确了不同类型的滑坡在遥感影像上的表征，指出了判别标志。介绍了已发生滑坡的语义分割样本和潜在滑坡位置编目样本的制作方法。然后，介绍了几种用于分类的机器学习方法；介绍了深度学习的基础知识：从卷积的数学表达，到影像处理中的应用；接着介绍了几种常用的卷积包括卷积层、池化层和反向传播，以及基本的卷积神经网络。最后，介绍了几种典型的用于滑坡编目的深度学习方法，包括用于已发生滑坡编目的语义分割网络，如全卷积神经网络 FCN，UNet，ResUnet，和潜在滑坡编目的 InSAR 基础知识，用于一阶段目标检测的 Yolo，两阶段目标检测网络 Faster R-CNN。

2.2 滑坡和滑坡样本集

2.2.1 滑坡及滑坡要素




图 2.1 滑坡要素示意图

滑坡是指在斜坡上的土体或者岩体，受河流冲刷、地下水活动、雨水浸泡、地震及人工切坡等因素影响，在重力作用下，沿着一定的软弱面或者软弱带，整体地或者分散地顺坡向下滑动的自然现象。如图 2.1 所示，滑坡的要素包括以下 12 个。

表 2-1 滑坡要素及其特征

序号	滑坡要素	特征
1	滑坡体	滑坡发生后，与稳定坡体脱离而滑动的部分岩土体叫做滑坡体，简称滑体。
2	滑坡周界	滑坡体与周围不动体在平面上的分界线叫做滑坡周界。它圈定了滑坡的范围，在多个滑坡构成的滑坡区内，它可以是不同滑动块体的界线。
3	滑坡后壁	滑体下滑后，后缘暴露出的陡壁。常表现为陡峭的裸露面，是滑坡体与稳定坡体的分界面，滑坡后壁的暴露为研究滑坡的形成和滑动机制提供了重要的观察点。
4	滑动面	指滑坡体沿其下滑的面或带。它通常是软弱、易剪切的地质层面，如黏土层、断层带等。滑动面决定了滑坡的滑动方式和规模。
5	滑坡床	滑坡体以下的稳定岩土体。它作为滑坡体滑动所经过的基底，提供了滑动面的下部支撑，其稳定性直接影响滑坡的发生和发展。
6	滑坡剪出	在滑坡体的最前端，滑动面与地表面的交线。滑坡体前缘最下部的显著地貌特征。是滑坡活动的前沿标志，其位置和形态可以帮助判断滑坡的运动方向和速度。
7	滑坡台阶	滑坡体滑动时，由于各种岩、土体滑动速度差异，在滑坡体表面形成台阶状的错落台阶。滑坡台阶记录了滑坡的运动历史，其形态有助于分析滑坡的速度和运动模式。
8	滑坡舌	滑坡前缘形如舌状的凸出部分，简称滑舌。是滑坡体的延伸部分，其形态和范围有助于评估滑坡的影响区域和潜在风险。
9	滑坡后缘	主滑壁与山坡原地面的交线称为滑动后缘。
10	拉张裂缝	滑坡活动时，在滑体及其边缘所产生的一系列裂缝。这些裂缝可能包括拉张裂缝、剪切裂缝、羽状裂缝和鼓张裂缝等。滑坡裂缝记录了滑坡的应力状态和运动路径，其分布和形态有助于预测滑坡的进一步发展和可能的危害。
11	滑坡裂缝	位于滑体上部因滑坡体下滑而张开的长达数十米至数百米、方向与滑坡壁吻合或大致平行的裂缝称为拉张裂缝，其中与主滑壁重合的一条称为主裂缝。
12	滑坡侧壁	位于滑坡体两侧的陡壁。滑坡体边缘的垂直或近似垂直的壁状结构。滑坡侧壁的形态和特征有助于界定滑坡体的横向边界和滑坡体积。

表 2-1 显示了滑坡要素的具体描述特征，对应图 2.1 的序号。其中，滑坡周界、滑坡后壁、滑坡舌等要素为遥感影像解译滑坡的主要识别要素。他们确定了滑坡的大小、形状和面积。

2.2.2 已发生滑坡样本制作

2.2.2.1 单时相影像已发生滑坡解译

在滑坡遥感解译中，主要是基于兼有空间信息的遥感图像特征（灰度、色调、亮度、纹理、阴影），通过人机交互，以目视方法为主识别滑坡的地质环境信息，获取其位置、形态、边界范围等特征信息^[21]。




图 2.2 滑坡目视解译要素（引自[21]）

一个完整的滑坡包括 12 个滑坡要素，其中滑坡后壁、滑坡体和滑坡边界是遥感识别中 3 个滑坡基本地形（形态）要素。如滑坡在遥感影像上的表现有“圈椅状”洼地、“双沟同源”以及“凹岸突出”等特征(图 2.2 (a))。据此，便可在光学影像中判读滑坡的三个部位：滑坡后壁、滑坡体和滑坡舌(图 2.2 (b))。Fiorucci 等^[128]评估了不同类型和特征的光学影像对滑坡识别的影响，并总结出具有不同光谱和空间特征的光学影像可有效应用于滑坡识别，此外，提出影像特征、滑坡特征、研究区域的大小及其它相关外部数据，定义了用于滑坡编目的遥感影像数据选择标准。

我国利用遥感手段进行滑坡识别的尝试起源于 20 世纪 80 年代，到 21 世纪初开始将遥感影像用于大规模区域滑坡调查。王治华等^[44]利用 TM、IKONOS、QUICKBIRD 三种卫星影像和调查区 1:10000 地形图绘制了 2004 年发生的四川省天台乡滑坡，并基于滑坡地学原理分析了此次滑坡的诱发因素。许冲等^[31]利用遥感影像精细解译了 2008 年

汶川地震诱发的大量滑坡，为进一步研究汶川地震诱发灾害的规律、机理以及灾区重建选址等提供了重要的基础信息。殷跃平等^[129]对比分析了大光包滑坡前后的 4 期遥感影像，结合现场调查和地面测绘建立了滑坡滑动的三维模型，并计算了滑坡的长、宽、体积等参数。李为乐^[130]利用遥感影像分析我国多个地震滑坡的分布空间规律，并做了易发性评价和强震地质灾害后效应研究。基于光学影像目视解译法，主要针对新发生的滑坡灾害体，或地表形态特征明显的古滑坡。该方法工作强度大，自动化程度低，且受专家的地学知识和遥感专业知识的影响，主观性较强。

2.2.2.2 双时相影像事件诱发型滑坡解译

在滑坡事件发生后，地表地物往往会发生显著的变化。原本稳固的山体、道路和建筑物可能因地震波的强烈震动而失去平衡，发生滑坡。通过对比震前和震后的影像，可以清晰地观察到这些变化^[131]。例如，原本连续的山体在滑坡后可能出现断裂、塌陷，道路和建筑物也可能因滑坡而被掩埋或损坏^[18]。




图 2.3 滑坡前后光学影像

除了地表地物的变化，滑坡还会对地表形态产生显著影响^[53]。原本粗糙不平的地表，在滑坡发生时，由于土壤和岩石的铲刮作用，会变得相对平滑。这种平滑化的过程在影像上表现得尤为明显，为识别滑坡提供了重要的线索。

此外，地表植被的变化也是滑坡识别的重要标志之一，如图 2.3 所示。滑坡发生时，地表植被往往会被破坏，产生明显的擦伤痕。这些擦伤痕在影像上呈现出不规则的形状

和颜色，与周围的地表植被形成鲜明的对比。通过分析这些擦伤痕的分布和特征，可以进一步确认滑坡的发生和范围。在滑坡识别过程中，遥感技术发挥着至关重要的作用。通过获取高分辨率的遥感影像，可以精确地提取出地表地物的变化信息，包括滑坡体的形态、大小、位置和分布等。同时，地理信息系统也为同震滑坡识别提供了强大的支持，可以对影像数据进行处理、分析和可视化，从而更加直观地展示滑坡的发生情况。

由于地震等极端事件的复杂性和不确定性，滑坡的发生往往具有突发性和难以预测性。因此，在滑坡识别时，需要充分考虑各种可能的影响因素，如地震烈度、地形地貌、地质结构等。同时，需要借助专业的知识和经验，对影像数据进行深入的分析和解读，以确保识别的准确性和可靠性。

2.2.2.3 滑坡形状编目样本制作方法

目前常用的用于滑坡形状编目的样本制作有两种，方法一是利用基于 Python 语言开发的 LabelMe 软件获取滑坡边界，方法二是利用 Arcmap 软件获取滑坡矢量边界转换成标签。

使用 LabelMe 制作样本的步骤包括：首先安装 LabelMe，并通过命令 LabelMe 启动应用。在应用中创建项目，然后打开导入要标注的图像。使用工具栏中的绘制工具（如多边形或矩形）标注感兴趣的区域，并为每个标注输入标签。标注完成后，保存标注结果为 JSON 文件。每个图像的标注信息将以 JSON 格式输出，包含图像路径、标注形状、标签和坐标等信息。

本研究主要采用 Arcmap 软件进行标签制作，这样可保持标签具有地理坐标，更符合滑坡编目的需求。首先，准备研究区的光学影像、DEM 等，对他们进行重采样、地理编码，使其有相同的分辨率和参考系统。然后，创建 2 个面矢量文件，一个和光学影像栅格范围、坐标系相同的处理范围面矢量文件，另一个*.shp 格式的面文件作为标签，根据准备的光学影像、DEM 等解译研究区的滑坡对象。编辑处理范围面要素类别 id 为 0 表示非滑坡，标签面要素类别 id 为 1，表示滑坡。最后，更新合并两个矢量面要素，面转栅格，选择和光学影像相同的分辨率，处理范围和光学影像相同，将*.shp 转为*.tif 格式的标签文件。至此，便做好了裁剪样本所需的原始数据。

将准备好的影像栅格、标签栅格生成深度学习所需的样本，需要将其裁剪为若干个小影像。在此，有两种方法可以完成，其一是 Arcmap 中的深度学习模型里，有样本裁

剪工具，可以裁剪为想要的大小，比如 256×256 。其二是生成渔网矢量文件，利用模型构建迭代器裁剪。




图 2.4 Arcmap 制作深度学习滑坡样本流程图

在此，本研究采用方法二。首先，确定影像的行和列数，生成渔网，此处行列数的确定，应尽可能使裁剪后的影像保持长宽比 1: 1 的情况。根据标签分布情况编辑渔网，去除纯背景的渔网，保留包含滑坡样本的渔网。然后，采用模型构建器进行矢量要素迭代，以 FID 为字段分组。最后采用栅格裁剪，选择待裁剪的影像或标签，以矢量迭代为输出范围，循环 FID 完成小影像裁剪，输出模式为*.tif 或者*.png。以上的方法，可以保证生成的样本内均含有滑坡样本，裁剪的小样本尽量大于深度学习网络需要的输入。

2.2.3 潜在滑坡样本制作

2.2.3.1 InSAR 获取地表形变基本原理

InSAR（Interferometric Synthetic Aperture Radar）是利用卫星或飞机上的雷达系统来获取地表的高精度三维形变信息的遥感技术。利用 InSAR 技术比较不同时间段内同一地点的雷达影像，能够检测出地表形变，甚至是毫米级别的细微变化^[132]。

InSAR 技术可以提供极高的测量精度，达到毫米级别，适合于监测缓慢而持续的地表形变，比如潜在滑坡。InSAR 能够对大范围区域进行同时监测，在监测大规模或分布广泛的滑坡时具有高效的优点。相比于传统的地面监测方法，InSAR 可以一次性覆盖

更大的区域^[132]。由于雷达信号不受光照和大气条件的影响，InSAR 可以在白天和夜间以及各种天气条件下进行观测，确保监测的连续性和可靠性^[133]。

通过对已有的历史雷达数据进行分析，InSAR 能够追溯过去的地表形变过程，帮助科学家理解滑坡的历史动态和发展趋势。与许多传统的监测方法相比，InSAR 可以显著降低长时间、大范围监测的成本，特别是在地形复杂或难以接近的区域^[133]。




图 2.5 干涉合成孔径雷达示意图（引自[133]）

合成孔径雷达干涉测量技术(InSAR)集合成孔径雷达技术与干涉测量技术于一体。合成孔径雷达(SAR)是一种主动式微波遥感，用来记录地物的散射强度信息及相位信息，前者反映了地表属性(含水量、粗糙度、地物类型等)，后者则蕴含了传感器与目标物之间的距离信息。干涉的基本原理是同一区域两次或多次过境的 SAR 影像的复共轭相乘，来提取地物目标的地形或者形变信息。雷达干涉的模式分为：沿轨道干涉法、交叉轨道干涉法、重复轨道干涉法。其中利用重轨干涉最为常用的方式，以此为例，所得到的干涉相位表达式如下^[134]：

$$\varphi_{\text{int}} = \varphi_{\text{flat}} + \varphi_{\text{topo}} + \varphi_{\text{dcf}} + \varphi_{\text{atmo}} + \varphi_{\text{noise}} \quad (2.1)$$

式中, φ_{flat} 为平地相位; φ_{topo} 为地形相位; 该相位可以用来恢复地形信息; φ_{dcf} 为地表引起的形变相位; φ_{atmo} 为大气延迟相位; φ_{noise} 为观测噪声引起的相位。

将平地相位、地形相位、噪声相位、大气相位去除,即可得到地表形变相位,这样的雷达干涉技术被称为雷达差分干涉技术(D-InSAR), 该项技术可用于探测厘米级的地表形变。其几何关系如图 2.5 所示,

从图 2.5 中可以导出以下关系:

$$\Delta r = \frac{\lambda}{4\pi} \varphi_{\text{def}} \quad (2.2)$$

式中 Δr 为所求解的地面点目标的 LOS 向形变信息, λ 为雷达波长。

本研究中通过小基线集 (SBAS) 技术和多时相 SAR 影像获取地表形变。SBAS-InSAR 技术能有效削弱解缠粗差、大气误差以及 DEM 误差等因素的影响, 从而获取更高精度的地表形变成果。具体原理如下:

首先基于配准后的 $N+1$ 幅 SAR 影像, 通过设置合适的时间基线与空间基线阈值组合生成 M 幅差分干涉图, 然后进行相位解缠获得绝对相位值。对于 t_A 与 t_B 时刻获取的两景 SAR 影像生成的差分干涉图 i , 其任意一点的干涉相位可用下式来表示^[135]:

$$\Delta\phi_i = \phi_{t_B} - \phi_{t_A} \approx -\frac{4\pi}{\lambda}(d_{t_B} - d_{t_A}) + \Delta\phi_i^{\text{topo}} + \Delta\phi_i^{\text{atm}} + \Delta\phi_i^{\text{noise}} \quad (2.3)$$

式中, $i \in (1, L, M)$, d_{t_B} 与 d_{t_A} 分别为 t_B 与 t_A 时刻雷达视线向累积地表形变。去除掉差分干涉图中地形相位 $\Delta\phi_i^{\text{topo}}$ 、大气延迟相位 $\Delta\phi_i^{\text{atm}}$ 以及噪声相位 $\Delta\phi_i^{\text{noise}}$ 之后, 公式 (2.1) 仅包含地表形变相位。同时, 为了使获得的地表形变时间序列具有物理意义, 通常将公式 (2.1) 式中的形变相位改写成两个获取时刻之间的平均形变速率与时间间隔的乘积。因此, 公式 (2.1) 可进一步简化为:

$$\sum_{k=t_{A,i}+1}^{t_{B,i}} (t_k - t_{k-1}) \cdot v_k = \Delta\phi_i \quad (2.4)$$

基于 M 幅解缠差分干涉图, 公式 (2.2) 可进一步写成矩阵形式:

$$A \cdot v = \Delta\phi \quad (2.5)$$

式中, A 表示一个维度为 $M \times N$ 的系数矩阵。当所有干涉图同属于一个子集时, 采用最小二乘方法对公式 (2.3) 进行求解即可获得地表形变速率, 在此基础上对求解的形变速率在各个时间段内进行数值积分即可获得时间序列形变。当干涉图位于不同子集时, 系数

矩阵 A 会出现秩亏。在此情况下,常采用奇异值分解(SVD)方法求得 A 的广义逆矩阵,进而得到地表形变速率的最小范数解。

SBAS-InSAR 技术^[135]能生成冗余的差分干涉图,可以有效消除大气延迟效应等误差及粗差的影响;可增加时序形变时间采样率,提供高空间密度的形变监测结果。同样其也存在一些不足:大量冗余差分干涉图会增加计算的负担;低相干区干涉相位精度较低,需进行相位优化提高信噪比^[133]。

2.2.3.2 InSAR 产品潜在滑坡解译

潜在滑坡识别主要依赖于合成孔径雷达、激光雷达、地基雷达等主动式微波遥感技术。其中,合成孔径雷达干涉测量(InSAR)技术在大范围潜在滑坡普查中发挥了至关重要的作用。InSAR 技术通过捕捉地表微小形变来识别出可能存在的不稳定边坡,这些边坡在地质构造或环境因素的影响下,有发生滑坡的潜在风险。




图 2.6 潜在滑坡解译(引自[106])

在利用 InSAR 技术进行潜在滑坡解译时,还需要与其他技术手段相结合,以进一步提供更为精确的识别效果。其中,数字高程模型(DEM)和光学影像是两种重要的辅助手段。DEM 能够提供详细的地形数据,滑坡受地形因素影响明显,通过 DEM 生成的坡度、坡向等数据,可以识别容易受到滑坡等地质灾害影响的区域。而光学影像能够捕捉到地表的具体细节,如植被覆盖、地表纹理以及可能存在的裂隙等信息。这些要素往往是滑坡发生的预兆,如 2.2.1 中介绍的滑坡要素,它们的存在会进一步增加滑坡发生的风险。

因此，在潜在滑坡识别过程中，首先需要利用 InSAR 技术对边坡进行形变监测，初步筛选出可能存在风险的区域（图 2.6）。然后，结合 DEM 数据，确定地形因素影响的区域，判断滑坡发生的高风险地带，去除地形平缓的区域。最后，通过分析光学影像的植被覆盖度、地表地物、纹理特征等，进一步确认裂隙等滑坡前兆，从而实现对潜在滑坡的精准识别。

2.2.3.3 滑坡位置编目样本制作方法

滑坡位置样本制作主要采用基于 Python 语言的 LabelImg 软件。通过 2.2.2.3 中的方法将速率影像栅格文件裁剪成需要的大小。打开 LabelImg，加载图像所在的文件夹。然后，点击创建滑坡位置所在的区域四边形，输入“滑坡”标签名称。完成图像标注，将标注信息保存为.xml 文件，或者导出标注为其他需要的格式（如 YOLO 格式）。

最后，在编目时将获得的结果信息文件（一般包含目标框的四个角点信息）与裁剪的栅格文件地理编码，使其具有相同的地理坐标系，以完成滑坡位置编目任务。

2.3 滑坡编目的机器学习和深度学习方法

2.3.1 机器学习方法

2.3.1.1 支持向量机

支持向量机（Support Vector Machine, SVM）是一种用于分类和回归分析的监督学习模型，在统计学习理论中有着重要的地位。SVM 的基本思想是通过寻找最佳的超平面(hyperplane)，将数据点划分到不同的类别中。以下是 SVM 的关键概念和工作原理：

超平面（Hyperplane）：在二维空间中，超平面是将数据集分开的直线；在三维空间中，超平面是将数据集分开的平面。SVM 尝试找到一个在 n 维空间中将数据分成不同类别的最佳超平面。**支持向量（Support Vectors）：**支持向量是离超平面最近的数据点。这些点对确定超平面的方向和位置起着重要作用。

间隔（Margin）：支持向量到超平面的距离被称为间隔。SVM 试图最大化这个间隔，这样就可以使分类器具有更好的泛化能力。

2.3.1.2 随机森林

随机森林 (Random Forests, RF) 是一种使用多个决策树作为分类器的分类模型, 由 Breiman 在 2001 年提出, 它结合了“Bootstrap aggregating”技术和“Random subspace”技术的优点, 且它将多个单一模型相结合, 目前已经广泛应用于信号处理、人脸识别、医学和经济学等众多学科领域。由于随机森林回归模型是由多个决策树随机组合而成的, 所以又可以称之为随机决策树模型。随机森林回归模型的分类误差取决于所构建的每棵树的分类能力以及树与树之间的相关性。它在训练过程中构造大量的去相关决策树。

给定数据集 D , 假定 D 中第 i 类样本所占比例为 $p_i (i = 1, 2, \dots, |y|)$ 。将 D 分成 V 个子集 $\{D^1, D^2, \dots, D^V\}$, 每个子集中的样本在 A 上取值相同, 计算属性子集 A 的信息增益:

$$Gain(A) = Ent(D) - \sum_{v=1}^V \frac{|D^v|}{|D|} Ent(D^v) \quad (2.6)$$

其中信息熵定义为:

$$Ent(D) = - \sum_{k=1}^{|y|} p_k \log_2 p_k \quad (2.7)$$

信息增益 $Gain(A)$ 越大, 意味着特征子集 A 包含的有助于分类的信息越多, 从原始训练样本集 D 中有放回地重复随机抽取 k 个样本生成新的训练样本集合, 然后根据自助样本集生成 k 个分类树组成随机森林, 新数据的分类结果按分类树投票多少形成的分数而定。其实质是对决策树算法的一种改进, 将多个决策树合并在一起, 每棵树的建立依赖于一个独立抽取的样品, 森林中的每棵树具有相同的分布, 分类误差取决于每一棵树的分类能力和它们之间的相关性。特征选择采用随机的方法去分裂每一个节点, 然后比较不同情况下产生的误差。能够检测到的内在估计误差、分类能力和相关性决定选择特征的数目。单棵树的分类能力可能很小, 但在随机产生大量的决策树后, 一个测试样品可以通过每一棵树的分类, 可以显著提高随机森林模型的分类能力。

2.3.1.3 人工神经网络 (ANN)

人工神经网络 (Artificial Neural Networks, ANNs) 是一种模仿生物大脑神经元连接和信息处理方式的计算模型。其基本结构由输入层、隐藏层和输出层组成, 节点 (或神经元) 通过加权连接和激活函数来处理和传递信息。网络的训练通过前向传播和反向传播过程来实现: 前向传播将输入数据逐层传递以生成输出, 而反向传播则根据输出与目

标值之间的误差，调整网络中的权重和偏置，从而优化模型性能。通过反复的训练和优化，神经网络能够从复杂的、多维数据中提取模式和规律，适用于各种分类、回归和预测任务。

在遥感领域，人工神经网络被广泛用于处理和分析卫星图像及其他遥感数据。通过神经网络的图像分类能力，可以将地表区域区分为不同的地物类型，如森林、城市和水体；其目标检测功能可以识别并定位特定的地物，如船只或建筑物。同时，变化检测技术使得监控地表变化成为可能，例如，监测城市扩展或环境变化。在滑坡监测中，神经网络能够综合分析地形、地质和气象数据，对滑坡危险区域进行划分，识别已发生的滑坡，并通过实时数据监测滑坡前兆，以提供准确的预警。通过与遥感技术和传感器网络结合，人工神经网络在自然灾害预防和环境监测中发挥着关键作用，显著提升了分析和决策的效率与准确性。

2.3.2 卷积神经网络（CNN）基本原理

卷积神经网络（Convolutional Neural Network, CNN），是一种深度学习算法，适用于处理具有网格结构的数据，如图像^[136]。CNN 通过一系列卷积操作来提取输入数据的特征，这些特征在后续的网络层中被进一步处理和分类。CNN 的基本结构包括卷积层、激活函数、池化层和全连接层。卷积层是 CNN 的核心组件，它通过卷积操作提取输入数据的局部特征。激活函数则用于增加网络的非线性特性，使得网络能够学习更复杂的模式。池化层主要用于降低特征图的空间尺寸，减少参数数量和计算复杂度。全连接层通常位于 CNN 模型的末端，将提取到的特征信息进行最终的分类或回归任务。

CNN 的应用领域非常广泛，包括自然语言处理、图像识别和处理^[137-139]、语音信号处理^[140]以及计算机视觉和视频处理等^[141]。在图像识别领域，CNN 已被广泛用于手写数字识别^[142]、人脸识别、目标检测等任务^[143,144]。此外，CNN 还可以应用于医学图像分析^[141,145,146]，通过学习医学图像中的特征来辅助医生进行疾病诊断。

2.3.2.1 卷积运算的原理

卷积（Convolution）广泛应用于信号处理、图像处理及其相关的工程和科学领域。卷积是数学、信号处理、图像处理、机器学习等领域中的一个重要操作。它通过将一个函数与一个卷积核（或滤波器）进行运算，从而在许多应用中起到特征提取、平滑或增

强信号等作用。在数学上，卷积是两个函数 f 和 g 的一个积分运算。对于一维连续函数，卷积定义如下：

$$(f \times g)(t) = \int_{-\infty}^{\infty} f(\tau) g(t - \tau) d(\tau) \quad (2.8)$$

其中 t 是卷积运算的变量， τ 是积分变量， $f(\tau)$ 和 $g(t - \tau)$ 是两个待卷积的函数。对于离散情况下，卷积定义为：

$$(f \times g)(n) = \int_{m=-\infty}^{\infty} f(m) g(n - m) \quad (2.9)$$

其定义是两个函数中一个函数 g 经过反转和位移后再相乘得到的积的积分。如下图，函数 g 是过滤器。它被反转后再沿水平轴滑动。在每一个位置，都计算 f 和反转后的 g 之间相交区域的面积。这个相交区域的面积就是特定位置出的卷积值。如图 2.7 所示。




图 2.7 卷积技术计算示意图

2.3.2.2 卷积层和池化层

卷积神经网络（CNN）通过设计的卷积核在图像上进行滑动操作，执行与图像的卷积运算，从而生成新的图像数据。在图像处理领域，卷积操作通常用于图像滤波、边缘检测、模糊、锐化等。具体而言，卷积过程包括以下步骤：首先，卷积核覆盖图像的一个区域，该区域与卷积核大小相同。接着，将卷积核的元素与覆盖区域的对应元素相乘并求和，得到一个输出值。然后，卷积核按照设定的步长（通常为 1）在图像上移动，

重复上述操作，直到遍历图像的每一个部分。通过使用特定的卷积核（或滤波器），可以提取图像中的特定特征，例如边缘特征。这种特征提取的能力使得卷积在图像处理中具有重要作用。




图 2.8 图像卷积计算示意图

随后借助训练数据和深度神经网络，使用反向传播算法自动学习这些卷积核参数。针对不同参数卷积核提取不同特征，获取局部的、更深层次和更全局的特征以应用于决策。




图 2.9 池化和上采样示意图

池化层的作用是对特征图进行降维，从而减少模型参数和计算复杂度。池化操作通常包括最大池化（Max Pooling）和平均池化（Average Pooling），分别从局部窗口中提取最大值或平均值，可以简化特征图，增强模型对微小变形的鲁棒性。最后，全连接层位

于网络的末端，用于处理经过前几层压缩的高维特征数据，并生成最终的输出结果。在这一层，每个神经元与前一层的所有神经元相连接，需要大量的参数和计算资源。

全连接层通过将多维特征映射到输出空间，实现了对输入数据的分类或回归等任务。总体而言，卷积神经网络的成功应用依赖于对各组成部分的精确设计和优化，通过合理配置卷积核、步长、填充方式及选择合适的激活函数和卷积类型，可以显著提升模型的性能和计算效率。

2.3.2.3 卷积神经网络的构成




图 2.10 卷积神经网络框架图

卷积神经网络（CNN）由三个关键组成部分构成：卷积层、池化层和全连接层。首先，卷积层从输入图像中提取多尺度的局部和全局特征。卷积层由滤波器（filters）和激活函数组成，关键的超参数包括滤波器的数量和大小、步长（stride）、激活函数类型以及填充（padding）方式。通常，滤波器的尺寸如 3×3 或 5×5 ，是矩阵形式的卷积核，其大小越小，所需的参数和计算量越少，但必须大于 1 以有效扩展感受野。卷积核的数量一般是 2 的整数次方，数量越多，计算资源需求越大，模型的拟合能力也越强。步长定义了卷积核在图像上移动的步幅，较小的步长能捕捉更精细的图像特征。填充方式主要有“valid”和“same”，前者不填充边界，可能会导致输出特征图的尺寸变小；后者通过边界填充保证输出与输入尺寸一致，且保留更多边缘信息。激活函数常见的选择有 ReLU（Rectified Linear Unit）。卷积操作还可以延伸至其他类型，如反卷积、可分离卷积和分组卷积，以满足不同的应用需求。

2.3.3 滑坡编目的语义分割网络

单时相滑坡探测通常采用语义分割的方法，通过像素级的分类标签对地物进行标记。一般采用单一时相遥感影像，通过语义分割方法进行影像分类得到滑坡编目结果，常用的语义分割方法有 FCN，AttU-Net 和 ResUNet 等。

2.3.3.1 全卷积神经网络（FCN）




图 2.11 FCN 结构图

全卷积神经网络（Fully Convolutional Networks, FCN）是深度学习在图像分割领域的代表作。FCN 网络模型通过端到端的方式进行图像分割，使得网络能够直接对图像进行像素级别的预测，并输出标签映射。FCN 的主要贡献在于提出了“全卷积”的概念。传统的卷积神经网络（CNN）在图像分类任务中，通常会在卷积层之后接上若干全连接层，将卷积层产生的特征图映射为固定长度的特征向量，以便进行分类。而 FCN 则摒弃了全连接层，将全连接层替换为卷积层，从而可以接受任意尺寸的输入图像，并输出与输入图像尺寸相同的分割结果。

在 FCN 中，为了得到与输入图像相同尺寸的分割结果，采用了反卷积（或称为转置卷积）操作，对最后一个卷积层的特征图进行上采样。通过上采样，FCN 能够将低分辨率的特征图恢复到与输入图像相同的尺寸，从而实现对每个像素的预测。反卷积操作

可以通过转置卷积核来实现。在传统的卷积操作中，卷积核是一个小的窗口，通过在输入上滑动并与其重叠，计算局部区域的加权和来生成输出。而在反卷积中，卷积核的参数被“转置”或“反转”，然后用于在输出上进行操作，以生成更大或更高维度的输出。具体来说，反卷积通过在输出上放置卷积核的转置，并在输出之间留有空间，生成更大的输出。反卷积将输入信号从低分辨率恢复到高分辨率，或者从低维度恢复到高维度。




图 2.12 转置卷积示意图

此外，FCN 还采用了跳跃连接（skip）结构，将浅层的细节信息与深层的语义信息相结合，以提高分割的精度。这种结构使得 FCN 能够在保持空间信息的同时利用深层的特征信息。

2.3.3.2 U 型语义分割网络（U-Net）

U-Net 是一种编码器-解码器结构的网络，主要用于图像分割任务。U-Net 的网络结构呈现一个对称的 U 型。前半部分是编码器（encoder），用于特征提取，后半部分是解码器（decoder），用于特征恢复与精确定位。编码器和解码器之间通过跳跃连接（skip connection）进行连接，可以更好地恢复滑坡的细节。编码器的主要任务是逐层抽象地理解图像的语义信息。它通过使用卷积层提取图像特征，并通过最大池化层缩小图片的尺寸，从而用越来越少的编码描述原信息。经过多次池化后，编码器输出的每张特征图都是低分辨率的，这些特征图反映了像素级的语义信息。解码器的主要任务是通过上采样和跳跃连接逐步恢复图像的空间分辨率。上采样层通常由转置卷积层实现。跳跃连接使得网络能够保留编码器中丢失的细节信息，从而进行更精确的像素级预测。U-Net 中的跳跃连接是其核心特色之一。这些连接将编码器中不同层级的特征图与解码器中对应层级的特征图进行拼接（Concatenate），从而结合了低层次和高层次的特征，有助于网络在精确定位方面表现得更出色。




图 2.13 U-Net 网络结构图

图 2.13 展示了 U-Net 的网络结构。每个橙色的框表示一个多通道特征图 (feature map)，左下角标注了尺寸。不同的操作通过箭头来表示：蓝色箭头代表 3×3 的卷积操作，在 stride 为 1 且 padding 策略为 valid 的情况下，每次卷积后特征图的大小会减小 2 个像素。灰色箭头表示跳跃连接，复制编码器中的特征图，在 U-Net 中，每个卷积层的特征图会与对应的上采样层叠加。

U-Net 采用了一种独特的特征融合方式，即在通道维度上进行拼接 (concatenation)。由于 U-Net 在同一层的最后一个卷积操作生成的特征图尺寸通常比上采样层的第一层大，因此为了利用浅层特征，需要恢复通道数。在网络的最后一层，通过 1×1 的卷积核操作，将每个 64 维的特征向量映射到网络的输出层。U-Net 在 FCN 的基础上进行了改进，增加了特征提取和融合的能力。

在特征提取部分，每经过一个池化层，图像尺寸就减少一个尺度，共有 5 个尺度，包括原图尺度。上采样部分则与之对应，每次上采样都会与特征提取部分在相同尺度上的特征图融合。但在融合前，需要对特征图进行裁剪。这种基于通道维度的拼接融合方式，使 U-Net 特别适合处理超大图像的分割任务。

注意力模型建立在一个标准的 U-Net 架构之上。U-Net 由于其良好的性能广泛应用于图像分割任务。注意力机制是通过叠加后的数据进行激活函数和卷积操作最后与上采样特征图相乘实现的。将下采样的特征图与上采样的特征图分别通过 1×1 的卷积核进行卷积操作，然后叠加在一起。通过激活函数 Relu， 1×1 的卷积操作，以及 Sigmoid 函数来获取权重，将获取的权重与上采样特征图逐像素相乘。




图 2.14 注意力机制结构图

原始 U-Net 仅连接同层的下采样层的特征和上采样层，改进后的使用注意力机制模块对下采样层同层和上采样层上一层的特征图进行处理后再和上采样后的特征图进行连接。其优势主要与多图像尺度下的图像特征提取有关。粗粒度特征地图捕捉上下文信息，并突出前景物体的类别和位置。在多个尺度上提取的特征地图随后通过跳过连接合并，以结合上下级密集预测。

2.3.3.3 残差网络的 UNet 模型（ResUNet）

通过扩展网络深度训练深度神经网络可以提高整体性能。但简单地堆叠 CNN 层可能会阻碍训练过程，在反向传播时造成梯度爆炸或梯度消失。残差网络（ResNet）是一种深度学习架构，主要通过引入残差连接来解决深层网络训练中的梯度消失问题^[147]。它允许信息在网络中跳跃传播，从而提高模型的训练效果和精度。残差块通常包含两个或多个卷积层及其输入的直接连接，形成“捷径”连接。这样的设计使得网络可以更容易地学习恒等映射，提高了训练效率。

如图 2.15 所示，残差结构（Residual Block）是残差网络的基本单元，主要由卷积层、连接、加法操作和激活函数。卷积层通常包含两个或三个卷积层，用于提取特征。每个卷积层后面通常会接一个批量归一化（BN）和激活函数（ReLU）。连接是将输入直接添加到卷积层的输出。这个连接可以是简单的恒等映射，也可以通过 1x1 卷积进行通道数匹配，以便进行加法操作。加法在卷积层的输出和输入之间进行元素级加法，这使得网络可以学习残差（即目标输出与输入之间的差异），而不是直接学习输出。激活函数通常在加法操作之后再应用激活函数，帮助引入非线性特征。




图 2.15 残差结构

残差网络通过其深层结构能够有效提取多层次的特征。这对于分割任务非常重要，因为不同的特征层可以捕捉到图像中的不同细节^[148]。残差 UNet 模型是以 ResNet 为骨干网络的分割模型，如图 2.16 所示。残差块中的跳跃连接允许低层特征直接传递到高层，这样可以保留空间信息，有助于准确的定位分割边界^[149]。




图 2.16 ResUNet 网络结构图

2.3.4 滑坡编目的目标检测网络

2.3.4.1 一阶段目标检测网络 YoloV5

YoloV5 的网络架构包含三个主要部分：骨干网络、颈部和头部（图 2.17）。骨干网络提取输入图像的基本特征。YoloV5 采用了改进的 CSPDarknet 作为骨干网络，它相较

于已有研究中的 Darknet，具有更好的计算效率和特征提取能力。颈部利用特征金字塔网络 (Feature Pyramid Network, FPN) 和路径聚合网络 (Path Aggregation Network, PANet)，对来自不同尺度的特征进行融合和增强。这种多尺度特征融合技术使得 YoloV5 在处理不同大小的目标时，具有更强的鲁棒性和更高的检测精度。头部是最终的检测模块，生成目标的边界框和类别预测。YoloV5 通过改进的锚框机制和优化的损失函数，进一步提升了检测结果的准确性和稳定性。




图 2.17 YoloV5 网络结构图

CSPDarknet 的结构可以分为以下几个主要部分初始卷积层、跨阶段链接和多层卷积。初始的卷积层用于对输入图像进行基础的特征提取和降采样。该层通过标准的卷积操作生成初步的特征图。CSP 模块是 CSPDarknet 的核心部分。它将特征图分为两部分，一部分通过残差块 (Residual Block)，另一部分直接传递。最后，两部分特征图在通道维度上进行拼接。这种设计可以减少冗余梯度信息，提升梯度流动的有效性，从而提升模型的整体表现。跨阶段连接 (Cross Stage Connection) 在每个阶段之间进行特征的交叉融合，通过全局特征和局部特征的结合，进一步增强模型的特征提取能力。多层卷积在每个阶段的末尾进一步抽取和压缩特征，最终得到高层次的特征表示。在特征提取过程中，输入图像的尺寸会不断下降，而通道数逐渐增加。




图 2.18 DarkNet 结构细节图

FPN 通过自底向上和自顶向下两个过程来构建多尺度特征表示。自底向上路径（Bottom-Up Pathway）是通常的特征提取路径，通过骨干网络的逐层卷积操作，逐渐提取更高级的语义特征。底层特征图有高分辨率但低语义信息，高层特征图有低分辨率但高语义信息。自顶向下路径（Top-Down Pathway）使用上采样将高层特征图逐步恢复到高分辨率，同时与底层特征图进行融合。这种融合通常通过元素加和实现，即将上采样后的高层特征图与对应的底层特征图加和，从而结合了高语义信息和高分辨率信息。横向连接（Lateral Connections）用于将自顶向下路径中的特征图与自底向上路径中的特征图结合。这种结合可以使得每一个尺度上的特征图都同时具有丰富的空间细节和语义信息，增强对不同尺度目标的检测能力。




图 2.19 FPN 网络结构图

2.3.4.2 两阶段目标检测网络 Faster R-CNN

Faster R-CNN 是一种用于目标检测的深度学习模型，结构由骨干网络、区域候选网络（RPN）和分类/回归模块等几部分组成^[150]。首先，骨干网络通过卷积神经网络（如 ResNet 或 VGG）对输入图像进行处理，提取特征图。这些特征图是图像的抽象表示，保留了物体的关键特征信息，用于后续候选框的生成和目标的分类。




图 2.20 Faster R-CNN 网络结构图

由骨干网络提取的特征图被输入区域候选网络（RPN）。RPN 的任务是生成可能包含目标的候选框。通过在特征图上滑动窗口，生成不同大小和比例的锚框（Anchor Boxes）。这些锚框通过二分类网络判断是否包含目标物体，同时 RPN 还对锚框的坐标进行调整，使候选框能够更好地拟合实际目标。

将不同尺寸的候选框输入 RoI 池化（RoI Pooling）进行统一处理。将 RPN 生成的不同大小的候选框特征图转换为相同的大小，确保后续的分类与回归模块能够接受固定尺寸的输入。池化操作后的特征图包含候选框区域的关键信息，作为进一步分类和回归的依据。

候选框特征被输入分类分支和回归分支。分类分支通过 Softmax 激活函数，判断候选框中的目标类别，同时回归分支则进一步修正候选框的边界框坐标，以提高目标定位的精度。分类与回归的结果是每个候选框的目标类别预测以及更加精确的边界框。

2.4 滑坡编目精度评价指标

在滑坡分割任务中，每个像素都被分为滑坡或非滑坡。由此定义混淆矩阵的四个参数真阳性(True Positive, TP)、真阴性(True Negative, TN)、假阳性(False Positive, FP)、假阴性(False Negative, FN)。TP 即滑坡输出为滑坡，TN 即非滑坡输出为非滑坡，FP 即非滑坡输出为滑坡，FN 即滑坡输出为非滑坡，如图 2.21 所示。




图 2.21 混淆矩阵可视化图

本文采用准确度 (Accuracy) (公式 2.10), 精确度 (Precision) (公式 2.11), 召回率 (Recall) (公式 2.12), F1 得分 (F1-score) (公式 2.13) 评价模型精度, 利用混淆矩阵的四个参数计算。其中, 精确度又被称为查准率, 它表示在预测的所有正样本中, 正确预测的正样本率; 召回率又被称为查全率, 它表示所有正样本中, 被准确预测的正样本率。在滑坡编目任务中, 调节分割阈值会同时影响查全率和查准率的表现, 需要根据现实需求, 平衡两者的表现。也可以通过调整模型结构、输入数据等, 提高模型的整体表现。

$$\text{Accuracy} = \frac{\text{TP} + \text{TN}}{\text{TP} + \text{FP} + \text{TN} + \text{FN}} \quad (2.10)$$

$$\text{Precision} = \frac{\text{TP}}{\text{TP} + \text{FP}} \quad (2.11)$$

$$\text{Recall} = \frac{\text{TP}}{\text{TP} + \text{FN}} \quad (2.12)$$

$$\text{F1-score} = \frac{2 \times \text{TP}}{2 \times \text{TP} + \text{FP} + \text{FN}} \quad (2.13)$$

$$\text{mIoU} = \frac{1}{q+1} \sum_{i=0}^q \frac{\text{TP}}{\text{TP} + \text{FP} + \text{FN}} \quad (2.14)$$

上式中, q 为预测的类别数目, 本文中该值为 2。

采用平均交并比 mIoU (Mean Intersection over Union) (公式 2.14), 用于评价模型预测结果与标签之间交集和并集的比值, 比率越大, 准确率越高。

2.5 本章小结

本章介绍了滑坡要素以及遥感滑坡解译标志，介绍了已发生滑坡和潜在滑坡的解译方法和数据集制作步骤。介绍了卷积神经网络的基础知识，包括卷积运算和卷积神经网络，常用的滑坡语义分割方法，包括 FCN, U-Net 和残差网络，以及潜在滑坡编目方法，包括 InSAR 基本原理，一阶段目标检测 Yolo 和两阶段目标检测网络 Faster R-CNN。

第三章 小样本场景下单时相已发生滑坡编目方法

3.1 引言

对于已发生的滑坡，通常采用高分辨率遥感影像进行识别和编目。已有研究证明，深度学习方法在滑坡编目中优于传统的机器学习方法，具有人工干预少、客观准确、且泛化性强等优势。然而，深度学习方法在滑坡编目的应用中也面临一些挑战，特别是在样本量和样本分布方面，存在很多问题需要被进一步探索和认识。

首先，关于样本量的问题，深度学习网络均需要大量的训练数据来优化其性能，通过反向传播更新网络权重。目前，尽管在建筑物、道路、水体、森林等方面存在大量优质数据集，但滑坡数据集的数量和样本量相对较少。这限制了深度学习模型在滑坡提取方面的应用和发展。其次，关于样本分布的问题，滑坡作为少数地物，在样本中正样本（滑坡）的比例通常较低，而负样本（非滑坡）的比例较高。这种不平衡的样本比例可能会导致深度学习网络在训练过程中过于关注负样本，从而降低了滑坡提取的性能。

基于此，本章开展了样本增强、优化损失函数、改变训练策略三个方面的研究，以提升样本量小、样本比例低的滑坡编目精度。

3.2 改进的全卷积神经网络

FCN 是一种端到端的语义分割网络^[151]。它以 VGG16^[152]为骨干网络，通过前馈计算和反向传播来实现网络训练(图 3.1)。图 3.1 中蓝色方框为卷积层通过卷积操作进行特征提取，用来学习样本特征。输入图像首先通过多个卷积层，提取低级别的特征，如边缘和纹理。每个卷积层后有批量归一化（BatchNorm）和激活函数（如 ReLU）来增加网络的非线性表达能力。绿色方框为下采样池化层，经过卷积后，网络通过池化操作（如最大池化或步幅为 2 的卷积）来减少特征图的空间维度。这是为了捕获更多的上下文信息，同时降低计算复杂度。绿色箭头为上采样操作，通过上采样将特征图与上一层级的特征图大小匹配，并通过橘色箭头的叠加操作将数据相加；蓝色箭头为全卷积操作预测结果，将不同深度预测进行融合，最后得出预测结果。为了增加预测的层级特征，本文增加了第一次和第二次下采样的卷积特征融合到最后的预测图中，帮助保留空间信息。特征图通过上采样操作（如反卷积或双线性插值）恢复到原始输入图像的空间尺寸。上采样后的特征图会与对应的跳跃连接特征图进行拼接，以保留细节信息。最终通过卷积

层，网络生成与输入图像相同大小的特征图，其中每个像素的值表示该像素属于特定类的概率。最终输出的特征图用于输出图像分割结果，输出是一个二值化的掩码，用来表示分割出的滑坡区域和非滑坡区域。




图 3.1 FCN-FL 网络结构图

3.3 小样本模型训练方法和分析

3.3.1 样本增强

3.3.1.1 样本不均衡比

不均衡比是衡量样本不均衡度的参数。假设 D 表示全部训练数据样本像素的集合，每一个样本用 (x,y) 表示，其中 $y \in \{0,1\}$ 。在本文实验中， y 取值为 1 代表该像素属于滑坡，为 0 则代表该像素属于非滑坡。

由此可以定义滑坡类像素集合 P 为：

$$P = \{(x, y) | y = 1, (x, y) \in D\} \tag{3.1}$$

及非滑坡类像素集合 N 为：

$$N = \{(x, y) | y = 0, (x, y) \in D\} \tag{3.2}$$

不均衡比 IR (Imbalance Ratio) 为非滑坡像素数量与滑坡像素数量的比值:

$$\text{Imbalance Ratio (IR)} = \frac{|N|}{|P|} \quad (3.3)$$

由公式 3.3 可知, IR 和数据集中的正样本滑坡的均衡度成反比。要降低数据的不均衡度, 须提高数据中滑坡样本的数量。

3.3.1.2 样本增强策略

样本增强通过改变图像大小、方向和光谱特性来扩充样本集, 包括图像翻转、图像缩放、模糊度调整、增加随机噪声、以及缩放等。本节中分别对图像进行了左右翻转均、上下翻转并随机 gamma 拉伸、镜像翻转增加 200 个随机噪声, 图 3.2 中的 a 行、b 行、c 行分别对应以上三个操作, 其中, 对照图的左图为原始样本图像, 右图为增强图像。




图 3.2 滑坡样本增强示例图。(a-c) 表示左右翻转、上下翻转和中值滤波

在实验中, 为了提高样本增强的效果, 会叠加其中 2-3 种操作。如图 3.3 所示, 对图像进行翻转和旋转 (列 1), 翻转和随机噪声 (列 2), 翻转和随机缩放 (列 5) 等。通过这些增强可以模拟不同背景或不同影像质量下的滑坡形态, 丰富样本场景, 提高模型的鲁棒性。真实场景的遥感影像往往受多种因素的影响, 如天气条件、地形变化和拍摄角度等, 这使得图像质量和内容呈现出高度的多样性。通过应用这些增强技术, 能够更

真实地再现滑坡在复杂环境中的特征，从而丰富样本场景，增强模型的学习能力，有助于提高模型在真实场景中的鲁棒性和泛化能力。

原始影像



增强影像



增强标签



图 3.3 随机数据增强

3.3.1.3 样本增强实验结果分析

分别使用 100、300、500、700 幅高分辨率遥感影像及其滑坡标签作为训练样本来训练 U-Net 和 AU-Net 模型。如图 3.4 所示，所有样本量的模型精度均在 0.93 以上，表明语义分割算法模型提取滑坡边界是可靠的。从图 3.4 可以看出，注意力机制模块对各个样本量的模型精度提升了 0.3%到 0.9%。并且在小样本量时（100 和 300）的提升更为显著，都达到了 0.9%。样本量 300 时 AU-Net 的精度甚至高于样本量 500 的 U-Net。说明注意力机制模块对小样本量的滑坡边界提取模型是具有提升作用的。

本文对整个滑坡数据集留取了其中 70 个作为测试数据，并通过预测图和参考图计算混淆矩阵得到了 Recall、F1-Score 和 mIoU 三个指标用来衡量预测精度。

为了验证小样本量的数据集可以获取滑坡边界，本节选取了容量为 100 的样本通过水平翻转、垂直翻转和对角镜像来进行数据增强操作。数据增强可以在小样本量时增加数据样本，以达到提高模型训练精度的效果。数据增强后的 100 样本量（100-DA）可以

达到 300 样本量相当的预测结果，从 Recall、F1-Score 和 mIoU 三个指标都可以证明这一点。当然，由于数据增强是以原数据操作得到的，因此必须考虑到他们具有较强的相关性。在操作过程中，要谨慎使用，否则有可能会造成模型过拟合，也就是模型训练结果好，但是预测结果不理想，在实验中也发现了类似的情况。




图 3.4 两种模型的样本量精度和训练时间

预测精度表明在各个样本量中 AU-Net 在三种评价指标中均优于 U-Net。由于滑坡编目更关心有多少滑坡被正确预测了，因此 mIoU 是主要的考虑方向，图 3.4 可以看到 mIoU 的提高都在 0.15 以上。

本节为进一步研究数据增强倍数对精度的影响，将 3.2.1.2 节中介绍的数据增强方法进行随机组合，对原始 770 个滑坡数据分别增强 2 倍、4 倍、6 倍、8 倍和 16 倍，并统计了他们的计算时间和精度。如图 3.5 所示，在数据量增加的同时，计算时间也随之呈现相同的趋势和量级增长。在 2 倍至 8 倍数据增强中 mIoU 呈现升高趋势，而 16 倍时出现下降，实验证明 8 倍的数据增强能获得最优的 mIoU 表现。而 16 倍数据增强很可能由于数据过度相似，使模型过拟合，导致 mIoU 下降。因此，研究选择 8 倍数据增强进行接下来的实验。




图 3.5 数据增强时间和精度统计

对不同倍数数据增强的模型进行了如图 3.6 所示的可视化展示。图 3.6 中可以看出，简单背景、边界清晰的滑坡（行 1），各增强倍数区别不大；而针对复杂背景下（行 2）的滑坡提取，8 倍的数据增强表现最优，显著减少了漏判，取得了最优的分割结果。




图 3.6 数据增强可视化显示

3.3.2 损失函数

3.3.2.1 焦点损失函数

Focal Loss^[34]以交叉熵损失函数（Cross Entropy, CE）^[38]为基础，如公式 3.4 所示，其中 y 是像素预测值，0 表示非滑坡，1 表示滑坡。 $q \in [0,1]$ 为该像素的预测为滑坡的概率值，预测的概率值与损失值成反比。

$$CE(q, y) = \begin{cases} -\log(q) & y = 1 \\ -\log(1 - q) & y = 0 \end{cases} \quad (3.4)$$

为了方便表示，使 $CE(q, y) = CE(qt)$ ，即 $-\log(qt)$ 。FL 引入了 α 和 γ 两个参数，如公式 3.5 所示。

$$FL(qt) = -\alpha(1 - qt)^\gamma \log(qt) \quad (3.5)$$

其中通过设定 α 的值来控制滑坡与非滑坡样本对总的 Loss 的权重贡献。 α 取比较小的值来降低非滑坡样本的权重。 $(1 - qt)^\gamma$ 称作聚焦参数， $\gamma \geq 0$ 。通过调节 γ ，使得模型在训练时更专注于难分类样本的训练。通过实验，本研究设定 α 为 0.25， γ 为 1.75。

3.3.2.2 损失函数实验结果分析




图 3.7 CE 和 FL 精度对比

研究采用 8 倍数据增强后的影像，采用了 CE 和 FL 两种不同的损失函数进行训练。精度统计显示在图 3.7，展示了两个分类器或模型的四个指标：Recall（召回率）、Precision（精确率）、mIoU（平均交并比）和 F1（F1 分数）。图中有两条曲线，分别代表了 FL（蓝色）和 CE（橙色）在这些指标上的表现。从图中可以看出，FL 在 Recall 上表现较

好，超过 0.8，说明 FL 模型能够更好地找到正样本。在 Precision 和 F1 上，FL 表现相对一般，略高于 0.6。在 mIoU 上表现较好，意味着 FL 模型在定位物体时的精度较高。CE 在各个指标上表现较 FL 略差，尤其在 Recall 和 mIoU 上，CE 显著低于 FL。在 Precision 和 F1 上，CE 也低于 FL，但差距较小，大约在 0.5 至 0.6 之间。总体来看，FL 模型在这四个指标上的表现都优于 CE 模型，尤其是在召回率和交并比上表现突出。精度对比表明 FL 对模型的提升是显著的，可以有效提高滑坡编目的精度。

在可视化结果中（图 3.8），FL 在三个样本中均表现出较好的分割结果，第一个和第三个样本较好的符合了标签，第二个样本有部分漏判，但在可接受的范围。CE 在第一个样本接近真实标签，第二个样本存在较大的误判和漏判，第三个样本则未检出。综上，在可视化中，FL 在滑坡编目中表现良好。




图 3.8 损失函数可视化结果显示

3.3.3 K-折交叉验证

3.3.3.1 K-折交叉验证方法

K-折交叉验证会减少人为将数据集划分为训练集和验证集对模型产生的负面影响，同时能够充分利用样本数据参与模型训练，以提高数据的利用率。本研究为 5-折交叉验证，将原始数据 D 随机的平均分为 5 个大小一样的子集 D1, D2, ..., D5，每次取其中 4 个子集为训练集，1 个子集为验证集，并且验证集不重复。为了在每份数据中都均匀的

还有滑坡样本和非滑坡样本，在 5-折交叉验证划分数据集时，给滑坡样本和非滑坡样本分别赋以 1 和 0 的标签，保证随机划分数据时，按照样本中滑坡样本和非滑坡样本的比例划分。

通过使用多个验证集，可以更好地评估模型的泛化性能，避免模型对单一训练、验证集的过拟合。此外还能充分利用数据，所有的数据都能被用于训练和验证，适合数据量较小的情况，能使估计结果更为稳健。平均 K 次的性能指标能更好地反映模型的真实性能，减少单次验证的偶然性。



图 3.9 K-折交叉验证流程图

3.3.3.2 K-折交叉验证实验结果分析

本节将 8 倍数据增强后经利用 FL 进行 5 折交叉训练的数据随机划分为 5 等份，继续训练后得到 Fold_1 至 Fold_5 等 5 个训练模型。其精度统计如图 3.10 所示，其中最小的 mIoU 是 0.618，最大的是 0.659，他们的差值是 0.041。输出 5 个模型的激活图，然后对他们进行平均，输出结果根据阈值赋标签，得到最终结果的 mIoU 为 0.661。相比于最小的提升了 0.043，相比于最大的提升为 0.002。这表明，通过对激活图的平均处理，能够在一定程度上提升模型的整体性能，尤其是在较低表现的模型上获得了显著改善，而在表现较好的模型上提升幅度相对有限。实验结果证明了数据增强和模型集成的重要性，有助于提高模型在复杂场景下的准确性和稳定性。




图 3.10 K-折交叉验证 mIoU 结果

在可视化图 3.11 中，从左到右的特征图逐渐展示了更细致的区域划分，说明在不同的折中，模型提取到了更为细腻的空间信息。这表明模型在每一次的训练中都能更有效地捕捉到重要的边缘和纹理特征。可视化结果中的一致性意味着平均结果可以减少过拟合，并且在不同的测试集上都有较好的表现，平均结果显示提取较清晰且准确。综合来看，平均结果的提升可能反映在模型对细节的捕捉能力提升、一致性增强以及分类/分割精度的改进。




图 3.11 K 折交叉验证可视化结果

3.4 测试区编目结果及分析

3.4.1 公开的滑坡数据集概况

本章采用了由 Ji 等^[64]人公布的毕节市滑坡数据集，该数据集包含了丰富的地质灾害信息，包括卫星光学图像、滑坡边界形状文件和 DEM。数据集中的影像是由 Triple Sat 卫星在 2018 年 5 月至 8 月期间拍摄，分辨率高达 0.8 米，为地表特征的精确识别与分析提供了坚实的数据基础。在这些影像中，共裁剪出了 770 个滑坡样本和 2003 个负样本，这些负样本覆盖了各种不同的背景场景，确保了数据集的多样性。滑坡样本涵盖了崩塌、碎屑流和不稳定斜坡等多种灾害类型，这些类型的滑坡在影像中表现为明显的地形和表面特征变化。




图 3.12 毕节滑坡数据集滑坡位置图（改自[64]）

滑坡的检测和识别主要通过两种途径完成，或者结合两种方法进行。首先，专家通过详细分析卫星/航空光学影像和 DEM 来判断滑坡的存在。在这些影像中，滑坡通常表现为明显的地表变化，例如地表裂缝、物质的位移、色彩的变化以及地形的显著变化（如高程的突变）。专家通过这些变化特征，结合地形的起伏和表面纹理变化，初步确定可能的滑坡区域。第二种方法是在偏远地区或监测设施较少的区域，滑坡的发现往往依赖于当地村民的报告。这些地区通常缺乏及时的监测设备，村民的直接观察和报告成为发现

滑坡的重要途径。通过这些报告，研究人员可以迅速获取滑坡发生的初步信息，并结合遥感数据进行进一步的分析。

为了确保滑坡检测的准确性和数据的真实性，研究人员还进行了详尽的外业调查。外业调查是滑坡研究的关键步骤之一，研究团队在实地勘察中通过测量和观察，验证了室内判读的结果。实地调查不仅帮助确认了滑坡的实际位置和范围，还提供了详细的地质和环境信息，如土壤类型、植被覆盖、岩石结构等。实地调查的信息对理解滑坡的形成原因和发展过程至关重要。在实地调查中，研究团队还收集了滑坡区域的高分辨率地理信息和环境特征，这些数据为滑坡监测和风险评估提供了宝贵的参考。



图 3.13 毕节数据集滑坡样本细节图（引自[64]）

滑坡样本的大小各不相同，将滑坡实例的边界框增加 40m 的扩展作为背景。滑坡在遥感影像上的表现多样，主要体现在色彩、地形、纹理、形态、时间变化和空间关系特征上。滑坡区域常显示出显著的色彩变化，暴露出土壤或岩石，同时破坏植被，导致 NDVI 等植被指数降低。在 DEM 中，滑坡造成的高程和坡度变化尤为明显。高分辨率影像可揭示滑坡带来的地表粗糙或均质化，显示出滑坡头部的凹陷、滑坡体的扇形或舌形以及滑坡脚部的堆积特征。时间序列影像可捕捉滑坡前兆和恢复过程。滑坡常与道路、建筑物、水体等环境特征相邻，这些空间关系在影像中清晰可见。非滑坡样本包括不同的地貌特征，如山体、村庄、道路、河流、森林和农用地。非滑坡样本不仅从大范围的非滑坡区域中随机选取以保证样本的多样性，还考虑了与滑坡区域的空间关系，尽量选择滑坡附近，但未受影响的区域。同时，确保滑坡和非滑坡样本的数量平衡，以避免数据不

平衡对模型训练的影响。此外，数据的空间分辨率必须一致，高分辨率数据能够提供更细致的特征细节，这对于精确的滑坡检测至关重要。

3.4.2 测试区概况

3.4.2.1 贵州省六盘水市

贵州省位于中国西南部属于褶皱和断层构造发育成特殊的喀斯特地貌，如图 3.14 所示。贵州省年平均气温约为 15 摄氏度。年降雨量在 1100-1300 毫米之间，雨量充沛但降水季节分布不均，80%的降雨集中在 5-10 月。近几十年来，采矿和基础设施建设等人类活动加剧，导致滑坡和泥石流频繁发生。




图 3.14 六盘水市水城区示意图

本研究采用 Ji 等^[64]人发表的贵州省毕节市滑坡数据集作为训练数据（图 3.13）。毕节市位于中国贵州省西北部，毗邻六盘水市，面积约 26800 平方公里。主要灾害类型为崩塌、泥石流和不稳定斜坡。毕节市滑坡数据集包含 770 个滑坡和 2003 个非滑坡，图像分辨率为 0.8 m。

本研究的研究区域为六盘水市水城县，是六盘水市滑坡灾害热点地区。图 3.14 采用 WGS84 坐标系，LIM 区域位于北纬 26° - 27° ，东经 104° - 105° 。水城县滑坡清查数据来源于水城县人民政府 2019 年滑坡清查数据 (<http://www.shuicheng.gov.cn/>)。以毕节市滑坡样本数据为训练样本，对比验证了 FCN 和 FCN-FL 模型的精度。使用水城县滑坡清查数据对 FCN-FL、U-Net 和 SegNet 比较精度进行了验证。

研究获取了六盘水市水城区 2019 年滑坡编目图，为了与样本库的数据匹配（毕节市滑坡数据库是分辨率为 0.8m 的 RGB 影像），研究获取了 2021 年分辨率为 1m 的 Google 影像。水城区滑坡编目数据中共有 146 个滑坡点，其中有部分地貌特征不明显，删除了只有现场确认才能识别的滑坡，以及滑坡表面被植被覆盖难以辨识的滑坡点，同时，增加了自 2019 年来新发生的滑坡点。

3.4.2.2 甘肃省天水市

天水市位于中国西北地区的秦岭山脉南麓，地形复杂，气候多变，是中国滑坡等地质灾害高发的地区之一。2013 年 7 月 22 日至 24 日，甘肃省天水市遭遇了历史罕见的强降雨天气，引发了大规模的滑坡灾害，给当地人民的生活和财产带来了严重的损失。此次强降雨的降水量在 24 小时内达到 200 毫米以上，是天水市有气象记录以来的极端降雨事件之一。这种短时间内的降水，极大地加剧了土体的含水量，降低了土壤的稳定性，从而引发了大面积的山体滑坡。

滑坡是由于地表土体和岩石在重力作用下失去稳定性而发生的快速下滑现象，通常与强降雨、地震和人类活动等因素密切相关。在天水市，由于地形陡峭、土层厚重，加之降雨集中在短时间内，导致了土体的快速饱和，触发了滑坡灾害。滑坡的发生不仅毁坏了大量的农田和道路，还造成了人员的伤亡。据统计，2013 年天水市的滑坡灾害造成了几十人死亡，数千人被迫紧急撤离，数百间房屋被毁，交通、电力等基础设施严重受损。

本研究通过 Google Earth 获取滑坡后的卫星影像，选取了两个不同背景类型的区域（如图 3.15 所示），以分析了不同背景、不同分辨率的影像编目效果。




图 3.15 天水市测试区示意图

3.4.3 贵州省六盘水市测试结果和分析

本文使用了 K-折交叉验证的方法训练了 FCN-FL 模型（FCN-FLK）。K-折交叉验证的方法是将数据随机划分成 k 等份，选取一份作为验证集，其余数据用作训练集，迭代训练 k 次，可以有效的利用所有数据训练模型。本文将数据均匀划分为 5 份，为了均匀的划分滑坡数据和非滑坡数据，给样本分别赋以标签 1 和 0，在数据划分时，依据样本中滑坡和非滑坡的比例进行数据划分。用 Accuracy、Recall 和 F1-score 评价模型精度，用 mIoU 评价预测结果。

表 3-1 FCN-FLK 与 FCN-FL、FCN 模型精度对比

	FCN-FLK	FCN-FL	FCN
Accuracy	0.93	0.92	0.87
Recall	0.76	0.73	0.68
F1-score	0.62	0.58	0.53
mIoU	0.68	0.66	0.53




图 3.16 FCN、FCN-FL 与 FCN-FLK 模型预测结果对比图

FCN-FLK 模型在模型精度和预测结果的表现均优于 FCN-FL 和 FCN 模型(表 3-1)。与 FCN 模型相比, FCN-FL 模型在 Recall 和 F1-score 提高了 0.05, mIoU 提高了 0.13, 证明对称连接可提高模型识别滑坡边界的精度。与 FCN 模型相比, 焦点损失函数通过控制滑坡样本和非滑坡样本的权重, 提高滑坡样本对整个模型 Loss 值的贡献, 并进一步通过聚焦参数专注于难分类样本的训练来提高分类精度。FCN-FLK 模型的 Recall、F1-score 分别提高了 0.08 和 0.09, mIoU 提高了 0.15。通过图 3.16 对比可以看出 FCN-FLK 模型识别结果具有更好的相似性, 证明 K-折交叉验证的 FCN-FL 模型具有更好的鲁棒性。FCN 和 FCN-FL 模型对滑坡周围具有相似特征的裸土和道路产生了误判, 而 FCN-FLK 具有较少的漏判 (FP) 和极少的错判 (FN)。

表 3-2 FCN-FLK 与 U-Net、SegNet 模型精度对比

精度指标	FCN-FLK	U-Net	SegNet
Accuracy	0.93	0.90	0.89
Recall	0.76	0.68	0.64
F1-score	0.62	0.53	0.44
mIoU	0.68	0.63	0.59

为了验证模型的泛化性, 将毕节数据库训练获得的 FCN-FLK 模型用于水城区滑坡编目数据的获取。同时, 使用 3.4.1 中介绍的训练数据和验证数据训练了 U-Net 和 SegNet

模型,采用和 FCN 相同的 VGG16 网络作为主干网络。分别统计了四个模型的 Accuracy、Recall、F1-score 和 mIoU, 如表 3-2 所示。

如表 3-2 所示, FCN-FLK 模型优于传统网络 SegNet 和 U-Net, 其中 Recall 和 F1-score 明显优于 SegNet。FCN-FLK 模型的分割精度 mIoU 也表现最佳。图 3.17 显示 FCN-FLK 分割的形状更接近目视解译的标签边界, SegNet 模型漏分割的部分较多, U-Net 模型则存在错判较为严重的问题。




图 3.17 FCN-FLK 与 U-Net、SetNet 模型在水城区预测结果对比

图 3.18 中研究区域内的影像作为输入来检验 FCN-FLK 模型在区域滑坡编目中的表现, 以获取该区域的滑坡编目图。图 3.18 为 FCN-FLK 模型获取的编目图(图 3.18 (a))和 U-Net 获取的编目图(图 3.18 (b))。研究区域在贵州省六盘水市水城区内, 与云南省相邻。水城区是六盘水市地质灾害最严重的区域, 而发耳镇和鸡场镇在 2018 年至 2021 年每年均有大型滑坡发生。因此, 本研究主要选择此区域为研究对象, 进行滑坡编目试验研究。研究区域内共有 20 个滑坡, 其中 FCN-FLK 模型正确分割 18 个, 而 U-Net 模型正确分割 15 个, 可见, FCN-FLK 模型误检和漏检更少, 说明模型 FCN-FLK 在滑坡编目中效率更高。根据图 3.18 蓝色框中目视对比可以发现, FCN-FLK 模型在非滑坡区域的误判率较低, 可以减少目视解译去除误判的工作量, 从而提高滑坡编目效率。




图 3.18 FCFN-FLK 和 U-Net 获取的发耳-鸡场镇滑坡编目图

由于已发生滑坡编目中背景较为复杂，其中有一些误检发生在和滑坡区域类似的裸土部分，这些区域和滑坡形态较为相似，因此容易被误检。在滑坡编目中，误检可以被目视解译去除。滑坡大多发生在坡度大于 15° 的地区，由于样本库中的非滑坡样本不包含 DEM 数据，这也给训练模型增加了困难。

图 3.19 分别展示了 2018 年、2019 年和 2021 年在研究区域发生的 3 起滑坡的模型识别结果和目视解译结果的对比图。I 是尖山营滑坡，其中 a 滑坡是 2018 年发生的滑坡，通过图 3.19 (c) 和 (d) 2018 年 3 月和 2018 年 12 月的两幅 GF2 影像对比图可以明显的看出 a 滑坡的滑坡边界，在图 3.19 (a) 中，a 滑坡也被完整的识别，(b) 中仅识别到部分区域。I 中的 b 滑坡识别结果比较破碎，因为 b 滑坡为采矿引起的潜在滑坡，目前在地下采动的作用下地表较为破碎并处于持续大量级变形阶段，暂未发生大规模整体滑移，因此地表地物比较复杂，导致模型识别效果较差。II 是 2019 年 7 月 23 日发生的鸡场镇特大滑坡，造成了多人遇难和巨大的财产损失。图 3.19 (j) 和 (h) 图中可以看出，该滑坡表面发生了大量的物质迁移，边界清晰，在图 3.19 (e) 中识别效果较好，而 (f) 中识别结果则比较破碎。III 是 2021 年 7 月 15 日发生的鸡场镇菁头村滑坡，该滑坡由于预警及时成功避让，未造成人员伤亡。图 3.19 (k) 和 (l) 中显示，滑坡虽然有物质损失，但倾倒的房屋还在原来的区域，因此图 3.19 (i) 中有部分区域未能被识别，而 (j) 则完全没有识别。

高程、坡度和坡向是影响滑坡分布的重要地形因素。通过对贵州省毕节市水城区滑坡数据的统计分析，发现滑坡在不同高程、坡度和坡向条件下的分布特征。首先，高程显著影响滑坡的发生，统计数据显示，88% 的滑坡发生在 1000 米至 1900 米的高程范围内，这一高程带可能具备更为复杂的地质结构和丰富的降水条件，容易导致地表稳定性

降低。其次，坡度也是决定滑坡分布的重要因素，77%的滑坡集中在坡度为 10° 至 30° 的范围内。这一坡度区间的边坡既有足够的重力驱动力促使地表物质移动，又不至于陡峭，以至于保持一定的稳定性，这使得它们成为滑坡高发区。平缓的坡地（小于 10° ）由于重力不足，滑坡发生率较低，而陡峭的坡地（大于 30° ）则更可能发生崩塌或岩石滑落，而非典型的滑坡。




图 3.19 2018 年 2019 年和 2021 年水城区三起滑坡不同分割方法及目视解译识别结果

最后，坡向的影响相对较小，但仍显示出一定的分布规律。水城区的滑坡更多地出现在东南方向，而较少出现在西方向，这可能与区域内山体的走向及其对降水积累和太阳辐射的影响有关。东南方向通常接收更多的降水和太阳辐射，使得土壤更容易饱和和风化，增加滑坡发生的概率；相反，西方向相对干燥，土壤稳定性较高，滑坡发生的概率较低。

综合来看，高程、坡度和坡向对滑坡的影响是相互关联的，它们共同决定了滑坡的空间分布特征。这些地形因素不仅可以帮助理解滑坡的分布规律，还为滑坡的预防和监测提供了科学依据。在地质灾害防治中，考虑这些因素可以更有效地预测和评估滑坡风险，制定更有针对性的防治措施。图 3.20 中的统计图表清晰地展示了高程、坡度和坡向对滑坡分布的影响，为进一步的滑坡风险评估和管理提供了有力的数据支持。通过对这些地形因素的深入理解，可以在未来的地质灾害防治和土地规划中，精准识别高风险区域，采取有效的预防和保护措施，减少滑坡对人类活动的影响和威胁。




图 3.20 滑坡分布与地貌因子关系

为了验证滑坡编目的准确性和可靠性，本研究团队于 2021 年 9 月对位于贵州省毕节市水城区发耳镇的尖山营滑坡（见图 3.19 中的滑坡I）进行了详细的野外调查。这次实地勘察不仅核对了滑坡在遥感影像中的判读结果，还提供了滑坡现场的详细地质和环境信息，为进一步的滑坡风险评估和管理提供了重要依据。

在实地调查中，观察和记录了尖山营滑坡的后缘。如图 3.21 (a)所示，滑坡后缘区域展现出明显的拉张裂缝。这些裂缝通常是由于滑坡体在移动过程中受到拉张应力所导致的，它们是滑坡活动的重要指征。裂缝的存在表明滑坡体上部的土层或岩层已经被拉伸

并分离,这种分离通常预示着滑坡的继续扩展或进一步的滑动风险。监测和分析这些拉张裂缝的变化对于预测滑坡的未来动态具有重要的意义。图 3.21 (b)展示了滑坡体移动对地表造成的破坏。随着滑坡的下滑,地表出现了明显的破碎现象。滑坡体的移动不仅改变了地表的形态,还导致了地表物质的重新分布和堆积,这些破碎的地表特征是滑坡活动的直接结果。滑坡体的运动会在地表留下复杂的纹理和形态特征,如挤压和剪切破坏,进一步验证了在遥感影像中观察到的滑坡特征。在滑坡的坡脚区域,拍摄了滑坡的全貌,如图 3.21 (c)所示。滑坡坡脚是滑坡物质的最终堆积区,这里常常是滑坡危险最集中的地方。坡脚下方的居民建筑清晰可见,表明滑坡对该区域的居民生活和财产安全构成了直接威胁。坡脚区域的滑坡物质堆积可能会对建筑物的结构稳定性产生负面影响,尤其是在雨季或地震等诱发因素作用下,滑坡物质可能进一步下滑或扩展,从而增加灾害风险。



图 3.21 水城区尖山营滑坡野外地质调查照片

对尖山营滑坡的实地调查验证了通过遥感影像获得的滑坡特征和边界的准确性,并且揭示了滑坡区域的实际风险隐患。通过对滑坡后缘拉张裂缝、滑坡体破碎地表和滑坡坡脚堆积区的详细观察,能够更好地理解滑坡的动态特性和潜在威胁。这些现场数据不仅验证了滑坡编目的准确性,还为未来的滑坡监测和预警提供了宝贵的参考。此外,这次调查也强调了在滑坡风险管理中的多层次防护措施的重要性。对于滑坡区域特别是坡脚下方的居民区,建议采取更为严格的建筑安全标准和预防措施,如加强地基的稳定性、设立防护工程等,以降低滑坡对人类活动的影响和威胁。通过实地调查与遥感技术相结

合的方式，能够更加全面和准确地评估滑坡的实际状况和潜在风险，从而为滑坡灾害的防治和管理提供坚实的科学依据。

3.4.4 甘肃省天水市测试结果和分析

本节选取了两种不同背景的测试区，如图 3.22 所示，区域 I 是背景简单的山地，光学影像中可以看到山体较为清晰，道路和耕地在图中仅占一小部分。地形相对简单，纹理和特征相对分布均匀。区域 II 包含了大量复杂的地物，如建筑物、道路、以及河滩等。图像中的地形较为复杂，场景元素多样且密集，视觉上难以明确区分滑坡体与其他物体。




图 3.22 两种背景提取结果可视化图

在图 3.22 中，第一列是区域 I 和区域 II 的 Google 影像，第二列是目视解译的标签，第三列是检测的混淆矩阵可视化图。由于背景简单，区域 I 滑坡体的提取效果较好，轮廓清晰，变化检测结果集中且明确，该区域在滑坡检测过程中噪声较少，模型的识别能力较强。区域 II 由于复杂的背景环境，如建筑物和河滩，滑坡体提取和变化检测难度增大，噪声和干扰较多，滑坡检测的准确性有所下降。

在滑坡编目中，背景简单的区域更易于准确提取滑坡体，而复杂场景下的滑坡检测需要更多的特征处理和优化方法来提升准确率。




图 3.23 不同背景精度比较

在图 3.23 中，左边是区域 I 的表现，右边是区域 II 的表现。每个图的六个顶点分别代表了不同的评估指标：F1-Score、Recall、Precision、mIoU（平均交并比）、Kappa 和 MCC。区域 I F1-Score 和 Recall 指标相对较高，接近 0.6 到 0.8 之间，表明在该区域的检测结果中，模型能够相对较好地平衡精度和召回率。Precision 略低于 Recall 和 F1-Score，表明在该区域中虽然模型能够检测到滑坡，但存在一定的误报率。mIoU、Kappa 和 MCC 的表现较均衡，数值在 0.4 到 0.6 之间，显示模型在这一区域的总体分割效果和一致性相对适中。区域 II 的 Recall 较低，接近 0.4 左右，显示模型在该区域漏检较为严重，未能检测到所有滑坡。Precision 明显高于 Recall，达到接近 0.6，说明虽然漏检多，但检测出的滑坡区域的准确率较高。F1-Score 与 Precision 接近，表明尽管召回率较低，但模型依旧有一定的整体平衡表现。mIoU、Kappa 和 MCC 的表现略低于区域 I，反映了在区域 II 中的分割效果不如区域 I，尤其是对滑坡体边界的检测表现较差。

区域 I 中的模型在 Recall 和 F1 方面有较好表现，说明其在检测滑坡多发区域时更加有效。区域 II 的滑坡多发较高，但召回率明显不足，可能导致部分滑坡区域未被检测到。两个区域在 mIoU、Kappa 和 MCC 上的表现均衡，但总体上区域 I 的表现略好于区域 II，尤其是在整体检测效果和一致性上。




图 3.24 不同分辨率编目结果

图 3.24 展示了在不同分辨率下进行的滑坡检测结果及其精度评估。图 3.24 (a)为区域I的谷歌卫星影像，图 3.24 (b)为该区域的滑坡标签图，白色表示实际滑坡区域，黑色为非滑坡区域。图 3.24 (c)和图 3.24 (d)分别展示了 2m 和 5m 降采样后的滑坡检测结果，绿色表示正确检测的滑坡区域 (TP)，红色为误报区域 (FP)，蓝色为漏检区域 (FN)。最后，图 3.24 (e)和图 3.24 (f)为 2m 和 5m 降采样的精度统计雷达图，包括 F1-Score、Recall、Precision、mIoU、Kappa、MCC。

根据以上结果，研究发现分辨率对滑坡检测的精度有显著影响。2m 降采样（图 3.24 (c) 和图 3.24 (e)）相比 5m 降采样（图 3.24 (d) 和图 3.24 (f)）在各个指标上表现更优，尤其是在 Precision（精度）和 mIoU（平均交并比）方面，体现出更高的正确检测率和更少的误报。同时，5m 分辨率的误报（FP，红色）和漏检（FN，蓝色）较多，表明较低的空间分辨率会导致滑坡边界的模糊和细节丢失，进而影响模型的准确性。在滑坡检测任务中，较高分辨率的影像能够更精确地捕捉地形变化和滑坡特征，提升模型的整体性能。因此，选择更高分辨率的影像数据对于滑坡检测的准确性至关重要，而在实际应用中需要平衡分辨率、数据处理能力和检测需求。

3.5 本章小结

本章提出了一种适用于小样本的已发生滑坡编目方法，通过数据源、模型优化和训练方式三个方面进行尝试，并验证了方法的有效性。本章首先采用数据增强进行样本扩

充,以全卷积神经网络为基础模型,通过焦点损失函数抑制负样本对模型的损失值贡献,最后,通过 5-折交叉验证的训练方式进一步提高了模型的鲁棒性。

本章通过多组数据增强实验证明,有效的数据增强能显著提高编目的精度。通过焦点损失能有效抑制背景对模型损失值的贡献,从而提高模型对滑坡样本的学习能力。使用 K-折交叉验证提高编目结果的鲁棒性。在测试区,通过对比实验发现所提方法提高了滑坡边界的识别精度,改善了原有的识别影像破碎不完整的不足。模型对于已发生的滑坡边界提取也较为完整。本章的研究可以为解决深度学习滑坡编目存在样本不足、样本不均衡的难题提供参考。

研究中也存在一些问题,由于样本库缺乏多源遥感数据,有部分相似的场景被误检为滑坡。在下一步的研究中,将利用多源遥感数据进一步提高滑坡编目的精度,优化模型选择,提高深度学习滑坡编目效率。

第四章 复杂光谱场景下双时相事件诱发型滑坡编目方法

4.1 引言

在全球气候变化的大背景下，地震、强降雨、台风等极端事件频发，而事件诱发的滑坡也极大威胁人类的生命和财产安全。对于强降雨、地震、台风等极端事件诱发的滑坡，通常需要短时间内获取滑坡的分布以服务于应急救援等任务。而极端天气下，无云的高分辨率影像通常很难获取，重访周期短，幅宽大，易获取的中分辨率影像通常是首选，如 Landsat-8/9，Sentinel-2 影像等。

然而，由于事件发生前后气候条件复杂，光学影像的光照条件、季节变化以及其他环境因素的影响，使得直接的变化检测方法容易产生误差。此外，有研究显示引入辅助信息（如多光谱数据或地形数据）有助于提高模型的识别能力，但同时也可能带来更多的噪声。因此，如何抑制这些非相关信息，同时增强滑坡相关特征，是实现高精度滑坡检测的关键。在深度学习模型方面，仅靠浅层或深层特征，很难实现对复杂场景、地形的精确滑坡绘图，需要综合多层次、多尺度的特征进行分析和处理。

基于此，本章开展了基于多特征变化检测并进行独立成分分析，辅助震后影像和多尺度监督的 UNet3+ 进行滑坡编目的方法研究。

4.2 全尺度连接深度监督模型

MICUNet3+ 方法是利用多种遥感技术和深度学习模型来精确检测和分类滑坡的方法。该方法的流程可以分为四个主要步骤，包括特征提取、变化矢量分析、特征选择以及模型训练与预测。

首先，MICUNet3+ 方法从事件前后的光学图像中提取归一化植被指数（NDVI，）和灰度共生矩阵（GLCM）特征。NDVI 通过比较近红外和红波段的反射率，计算出植被覆盖和健康状况的指数。滑坡往往会破坏地表植被，因此这对于识别因滑坡导致的植被变化尤为重要。GLCM 是一种常用的纹理分析方法，用于评估图像中灰度级的空间分布特性。在滑坡检测中，GLCM 可以捕捉地表材料和地形变化的细微差异。具体来说，MICUNet3+ 方法计算了多个 GLCM 统计特征，包括平均值、方差、标准偏差、同质性、对比度、相似度、熵、角二阶矩和相关性，这些特征能够详细描述滑坡前后图像的纹理和结构变化。




图 4.1 研究方法流程图

接下来,进行变化矢量分析(Change Vector Analysis, CVA),计算事件前后 NDVI 和 GLCM 特征的变化量。NDVI 差值(NDVI-diff)反映了滑坡前后植被指数的变化,这对于识别滑坡区域非常关键,因为滑坡通常会导致植被的急剧减少或变化。GLCM 差值(GLCM-diff)则反映了滑坡前后地表纹理特征的变化,这有助于捕捉滑坡引起的地表形态变化。通过计算这些差值,可以量化滑坡对地表特征的影响,从而更好地识别滑坡区域。

然后,将 NDVI 差值和 GLCM 差值与事件后的地形特征(包括高程、坡度和坡向)整合,形成一个包含 13 个特征的特征集。这些特征为后续的数据降维和特征选择提供了丰富的信息基础。为了减少数据的维度和选取最具代表性的特征,采用了独立成分分析(ICA)、主成分分析(PCA)和随机森林重要性(RFI)技术。ICA 是一种用于将多维数据转换为相互独立成分的统计方法,通过这一过程,可以从 13 个特征中提取出最

独立的前三个主成分。RFI 通过递归评估每个特征对模型预测的贡献，选出最重要的三个特征。

在完成特征选择后，将事件后的图像，与 ICA 提取的前三个独立成分、PCA 的前三个主成分和 RFI 选择的三个特征，分别输入到 U-Net3+网络中进行训练。U-Net3+是一种 U 形卷积神经网络架构，其独特的全尺度跳跃连接和特征融合能力，使其在处理复杂的地理和遥感数据时具有显著的优势。在训练过程中，U-Net3+网络能学习输入数据与滑坡标签之间的复杂关系，通过优化模型参数，以准确识别和分类滑坡区域。最终，训练好的 U-Net3+模型被用于对测试区域进行预测，生成滑坡编目（LIM）。

4.2.1 U-Net3+模型结构

由于滑坡的多尺度特征和复杂背景，本章选择了全尺度跳跃连接和深度监督的 Unet3+^[140]。编码器特征图以相同的大小进行连接，通过池和双线性上采样。每个解码器激活后，损失函数会反向调整网络权重。在本章中，Dec_1 的损失函数系数为 1，其余为 0.4。

所采用的全尺寸跳变连接转换了编码器和解码器之间的互连以及解码器子网络之间的内连接。具有普通连接的 UNet 和具有嵌套连接和密集连接的 UNet 都缺乏从全尺度上探索足够的信息，不能明确地学习位置和边界。为了弥补 UNet 和 UNet++ 的缺陷，Unet3+ 中的每个解码器层都结合了来自编码器的小尺度和相同尺度的特征映射和来自解码器的大尺度特征映射，从而在全尺度上捕获细粒度细节和粗粒度语义。图 4.2 举例说明了如何构建特征映射。为了将浅层精细信息与深层语义信息无缝融合，进一步在 5 个尺度的连接特征图上进行特征聚合， 3×3 的滤波器、批处理归一化（BN）和 ReLU 激活函数组成，跳跃连接中 i 沿着编码器索引下采样层。

最终特征图将每个解码层的特征融合到一个 3×3 的卷积层中生成的，然后再进行双线性上采样，以便将特征图的分辨率恢复到输入图像的分辨率。上采样后得到的分割结果与分类模块的结果相乘。乘法后的结果经过 sigmoid 处理，得到深度监督模型的输出。





图 4.2 多尺度深度监督网络图

4.2.2 全尺度特征连接

为了增强从全尺度聚合特征图中学习层次化的表示能力，每个解码器阶段的最终特征图首先传递至一个 3×3 的卷积层，之后通过双线性上采样将其调整到与输入图像相同的分辨率，最后通过 Sigmoid 函数生成预测输出。每个阶段的输出在上采样到输入图像尺寸后，与真值进行比较，用于计算损失函数，从而优化网络权重。

图 4.3 以 Dec_3 为例显示了全尺度特征连接的过程。为了实现多尺度特征融合，将编码器的 Enc_1、Enc_2 的特征进行最大池化下采样，使它们的分辨率与 Dec_3 的特征图一致。同时，将来自 Enc_5 和 Dec_4 的特征通过上采样调整至与 Dec_3 相同的尺寸。之后，这些特征图通过通道维度上的连接操作融合在一起。这样的操作确保了来自不同尺度的特征能够有效结合，从而实现多尺度特征的融合与利用。

每个解码器阶段（Dec）都会输出一个特征图，并将这些特征图经过上采样调整至与输入图像相同的尺寸，形成最终的预测输出。在网络的训练过程中，这些多尺度输出都会产生相应的损失函数，所有损失共同作用于网络的权重更新，使得模型不仅能够学习到全局信息，还能够不同分辨率下保留细节特征。



4.2.3 特征处理方法

4.2.3.1 变化向量分析（CVA）

变化检测 CVA（Change Vector Analysis）是基于不同时相图像之间的辐射变化进行的一种特征向量空间变化检测方法。该方法主要通过对两个不同时间的遥感图像进行光谱量测与计算，来描述从第一时间到第二时间的辐射变化的方向和数量。如公式 4.1 所示：

$$\rho(I) = [\sum_{b=1}^n (I_{t_1} - I_{t_2})_b^2]^{1/2} \quad (4.1)$$

其中， I_{t_1} 和 I_{t_2} 分别为事件前 t_1 和事件后 t_2 时刻的像元值， b 为遥感影像的波段数， $\rho(I)$ 为变化图像中的像元值。

CVA 主要用于分析各波段的差异，计算与确定变化的强度与方向特征。首先，需要对遥感图像进行预处理，包括辐射校正和几何配准等步骤，以消除大气、太阳高度角和传感器等因素对图像的影响。然后，通过对两个时相的图像进行比较，可以得到每个像元在不同波段上的光谱变化向量。变化向量不仅包含了变化的强度信息，还包含了变化的方向信息。通过设定合适的阈值，区分出发生变化的区域和未发生变化的区域。此外，不同地物的变化通常具有不同的变化角度，因此通过对变化角度的分析，可以进一步判断地物变化的类型。

4.2.3.2 独立成分分析 (ICA)

独立成分分析 (ICA) 是一种非线性数据优化方法, 它将一组混合信号转换为独立分量, 这些分量相互正交、相互独立。混合数据被转换成独立分量, 即去相关性, 可用于检测和分离噪声、降低数据维度, 并提取图像中的主要信息。

如公式 4.2 所示, x 是基函数 A 的线性组合, N 表示像素总数, A_i 表示 A 的第 i 个列向量, y_i 是系数向量 y 的一个元素。

$$x = \sum_{i=0}^{N-1} A_i y_i \quad (4.2)$$

ICA 的主要目的是找到一个系数矩阵 A , 使 x 变换后得到的分量系数 y 尽可能独立。其基本思想是最大化随机梯度上升的联合熵。 A 在迭代过程中的变化如公式 4.3, 其中 T 表示矩阵的转置。

$$\Delta A = (I + (1 - 2/(1 + e^{-y}))y^T)A \quad (4.3)$$

在 ICA 训练之前, x 趋于其平均值, 并乘以白噪声矩阵。如公式 4.4 所示, 其中 $A_0 = [(x - m_x)(x - m_x)^T]^{-1/2}$ 。

$$x = A_0(x - m_x) \quad (4.4)$$

因此, 这个转换过程可以被看作是矩阵 A_0 和 ICA 训练矩阵, 即 $W_I = W W_0$, 最后 ICA 矩阵正交后得到公式 4.5。

$$A = A_I(A_I^T A_I)^{-1/2} \quad (4.5)$$

当 ICA 变换矩阵用作图像投影的基础时, 基础函数必须是正交的, A 的各行之间一定是正交的, 而且基函数的数目与每个基函数的元素数目相同。

4.2.3.3 随机森林特征分析 (RFI)

随机森林重要性 (RFI) 是指在随机森林的每棵决策树中计算未选择数据对当前决策树的影响, 即袋外误差 (errOOB1)。errOOB2 是在袋外数据 (OOB) 中加入噪声干扰后计算得出的。差值越大, 该特征对模型越重要。

$$RFI = \frac{1}{n_{tree}} \sum_{i=1}^{n_{tree}} (OOB2 - OOB1) \quad (4.6)$$

袋外 (OOB) 数据指的是训练集中未被选中的数据。每次约有 1/3 的样本未被选中, 用于测试当前决策树的分类或回归效果。在本研究中, 选择了 1000 棵树, 通过计算分类过程中的信息熵对决策的贡献, 得出特征重要性。

4.3 多特征提取和分析过程

4.3.1 研究区域和数据概况

研究区位于中国四川省九寨沟县 (图 4.4)。九寨沟县地形多样, 海拔从北部的低于 2000 米上升到南部的超过 4800 米。这种海拔差异显著的地貌特征, 使得九寨沟拥有独特的高山和峡谷景观, 也造就了丰富的生物多样性和复杂的生态系统。该地区的年降雨量较低, 平均不到 600 毫米, 但降雨的时间高度集中, 主要发生在 7 月和 8 月的夏季雨季。这种降雨模式导致在短时间内的降水量巨大, 容易引发滑坡、泥石流等地质灾害。尤其是在地震等自然事件的诱发下, 雨季的降雨量对地质稳定性产生重大影响。

九寨沟地区地质构造复杂, 断层众多且活动频繁。主要的断层系统包括南北向的岷江断层 (MJF)、北西西向的塔藏断层 (TZF) 和虎牙断层 (HYF)。这些断层的存在和相互作用, 构成了九寨沟地区地质活动的基础。岷江断层以逆冲运动为主, 而塔藏断层则主要表现为走滑运动, 这些断层活动可能引发的地震和次生灾害, 对区域的安全和环境产生了深远的影响。除了主要的断层系统, 九寨沟地区还存在多条次级断层。这些次级断层虽然规模较小, 但在地震活动中也起到了重要的作用。次级断层的活动可以在局部区域引发地表破裂和滑坡, 进一步增加地质灾害的风险。九寨沟的复杂断层系统不仅是地质学家研究的重点, 也是防灾减灾工作中的重要关注点。该地区断层众多, 如 NS 向逆冲岷江断层 (MJF)、NWW 向走向滑动的塔藏断层 (TZF) 以及一些次级断层。

2017 年 8 月 8 日, 九寨沟县发生 MW6.5 (Ms7.0) 级地震, 震源深度 20 千米。根据中国地震局的数据, 震中位于 MJF 断层、TZF 断层和 HYF 断层附近 (图 4.4)。根据 Li 等人^[153]对地表变形的实地调查, 推断震源断层呈西北走向。Xu 等^[154]根据 GeoEye-1 卫星图像, 通过目视判读确定了共震滑坡 (图 4.4 中的黑色多边形), 其中最大面积为 236338.3 平方米, 最小面积为 7.8 平方米, 平均面积为 1993.4 平方米。本研究参考了 Xu 等人的研究成果^[154], 滑坡判读准确, 保证了本研究结果的可靠性。




图 4.4 研究区域

4.3.2 多特征变化检测结果

如图 4.5 (a)、(b)和(c)所示, 从 DEM 中提取了海拔、坡度和高程地形信息。这些因素对于滑坡区域的地形特征分析至关重要。此外, 分别从滑坡事件前后的光学影像中获取了归一化植被指数 (NDVI) 和灰度共生矩阵 (GLCM) 的特征。NDVI-diff 指标用于反映植被覆盖变化, 变化值小表示植被减少, 变化值大表示植被增加。从图 4.5 (m) 中可以明显看出, 植被减少的区域与滑坡体区域高度重叠, 这一现象与光学影像的视觉解译结果一致, 进一步验证了滑坡发生后植被破坏的规律。

另一方面, GLCM 被用来描述影像的灰度分布均匀性及其纹理特征, 帮助分析滑坡区域的地表变化情况。从 GLCM 的不同参数变化值来看, 平均值 (图 4.5 (d))、标准差 (图 4.5 (e))、相似度 (图 4.5 (i))、熵 (图 4.5 (j)) 和相关性 (图 4.5 (h)) 与滑坡区的变化程度呈正相关。这意味着这些纹理参数的数值随着滑坡地表特征的变化而增大。同质性 (图 4.5 (k)) 与变化程度呈负相关, 表明随着滑坡区域的扰动增加, 表面纹理变得更

加复杂，其均匀性降低。相较而言，其他参数的变化趋势较为弱化，未能显著反映滑坡区域的特征差异。




图 4.5 地形因子、归一化植被指数、灰度共生矩阵变化检测图

滑坡后的“损伤”区域显示出明显的纹理特征，这与背景区域形成对比。由于泥石流带走了表面的松散物质，滑坡后地表的形态变得更加规则和光滑，影像中的纹理简单

且平整。这种变化不仅体现在 GLCM 的参数变化中, 也通过影像视觉表现出来, 进一步证实了滑坡地表纹理与滑坡过程的相关性。这种规则性和光滑性反映了滑坡体在自然力作用下物质搬运和沉积的过程。

4.3.3 多特征选择和分析结果

研究提取了滑坡点和非滑坡点的所有特征, 其中非滑坡点是在滑坡点数量相等的情况下随机生成的。滑坡点和非滑坡点提取了 13 个辅助特征, 用于特征处理和解释分析。本研究采用了 Python 编程环境中的 Scikit-learn 库中的随机森林 (Random Forest, 简称 RF) 包, 来进行特征选择。随机森林算法的重要性评估机制是基于信息熵的, 它通过构建大量的决策树来训练模型, 并从中挑选出对模型预测结果影响最大的特征。




图 4.6 特征因子重要性排序图

在研究中, 通过这种方法, 得到了三个最关键的特征, 分别是: 灰度共生矩阵 (GLCM) 的非相似性 (权重为 0.42)、海拔高度 (Elevation, 权重为 0.21) 以及归一化植被指数 (NDVI, 权重为 0.053), 图 4.7 展示了这些特征。

图 4.7 (a) 描绘了 GLCM 相似度的分布情况, 图 4.7 (b) 展示了海拔高度的变化情况, 而图 4.7 (c) 则反映了 NDVI 的空间分布。此外, 图 4.7 (d) 是三个特征的假色合成图, 其中红色、绿色和蓝色通道分别代表了归一化后的 NDVI、海拔高度和差异度。




图 4.7 随机森林重要性选择的 3 个因子和假彩色合成图。(a)、(b)、(c) 分别是 GLCM 非相似性，高程和归一化植被指数，(d) 是影像归一化后的假彩色合成图

主成分分析(Principal component analysis, PCA)主要用于降低数据的复杂性，识别出最重要的特征。通过协方差矩阵计算得到的特征值和特征向量，选择数据中差异最大的特征值，即数据中所包含的原始信息差异最大的特征值，达到数据降维的目的。




图 4.8 主成分 1 (PC1)、主成分 2 (PC2)、主成分 3 (PC3)与假彩色图像。(a) (b) (c) 为 PC1、PC2 和 PC3。(d)为影像归一化后的假彩色合成图

通过对 13 个特征进行主成分分析,选出特征值最大的 3 个主成分。主成分 1 (PC1)、主成分 2 (PC2)、主成分 3 (PC3)所占比例分别为 45.68、18.62、13.61。从图 4.8 可以看

出，PC1 中的信息不够突出，PC2 中滑坡与非滑坡的区分明显，而 PC3 过滤的信息较多。具体表现为，假彩色图像明显以 PC2 为主。




图 4.9 选出的前三个主成分和假彩色合成图。(a)、(b)、(c) 分别是 IC1, IC2, IC3, (d) 是影像归一化后的假彩色合成图

ICA（独立成分分析）是一种强大的统计工具，它能够将多变量信号或图像分解成一组统计上独立的分量。通过 ICA 分析，选定了三个独立分量 IC1、IC2 和 IC3，它们各自揭示了数据集中不同类型的信息。

IC1 表现出对变化信息的高度敏感性（图 4.9（a）），特别是季节性噪声，如雪的变化。这表明 IC1 捕捉到了与季节变化密切相关的动态信息，这对于需要了解环境季节性波动的应用非常重要。IC2 则与山体滑坡事件高度吻合，同时有效地分离了季节性变化，显示出较低的噪声水平（图 4.9（b））。这一分量的稳定性表明它能够准确地反映出与山体滑坡相关的信号，而排除了其他干扰因素，这对于滑坡监测和预警系统至关重要。IC3 含有的信息量最大，甚至包含了一些与地形相关的信息。这表明 IC3 可能捕捉到了数据集中的核心结构信息，这些信息可能与地形特征、长期地质变化等更为稳定和持久的地貌特征相关联。图 4.9（d）中显示的颜色变化与滑坡的相似性进一步支持了 ICA 分析的有效性。这种颜色变化可能与滑坡发生前后地表特征的改变有关，从而被 ICA 捕捉并体现在 IC3 分量中。

综上所述，ICA 分析能分离出了与季节性变化、山体滑坡以及地形特征相关的独立信息，这对于地质监测、环境保护以及灾害预警等领域具有显著的应用价值。

4.4 不同特征辅助定量对比及定性分析

4.4.1 多特征辅助与模型结果定量分析

本章所提出的 MICUNet3+模型在事后图像滑坡识别领域展现出了显著的优势。通过表 4-1 所列的各项性能指标，可以看到结合了 RFI、PCA 和 ICA 特征处理的事后图像在所有测试指标上都明显优于仅使用事后图像进行识别的方法。

与单纯依赖事后图像相比，ICA 特征处理技术来辅助事后图像分析，结合了 ICA 的处理方法在召回率上提升了 0.13，同时在 F1 分数上也有 0.22 的显著提升。此外，模型在图像分割准确率方面的表现也极为出色，mIoU 指标提高了 0.12，这一数据充分证明了 ICA 特征处理的有效性。

本章所提出的 MICUNet3+优于事后图像滑坡识别。通过比较表 4-1 中的各项指标可以看出，事件后图像组合 RFI、PCA 和 ICA 的各项指标均优于事件后图像识别。在 RFI、PCA 和 ICA 三种特征处理方法中，ICA 的性能最好，其 Recall、F1-score 和 mIoU 比 RFI

分别提高了 0.0066、0.0866 和 0.0491，比 PCA 分别提高了 0.1173、0.0578 和 0.0351。ICA 在综合评价上提高了 0.05 以上，在分割精度上提高了 0.03 ~ 0.04。

表 4-1 模型精度定量对比

方法	Recall	F1	mIoU
UNet3+	0.5457	0.4791	0.6479
UNet3+ RFI	0.6702	0.6161	0.7152
UNet3+ PCA	0.5595	0.6449	0.7292
MICUNet3+ (UNet3+ ICA)	0.6768	0.7027	0.7643
AttU-Net with ICA	0.5609	0.6545	0.7346
ResU-Net with ICA	0.6413	0.6938	0.7586

将 MICUNet3+与两种常见的网络 AttU-Net 和 ResU-Net 进行对比，由于考虑了滑坡的多尺度特征和样本不平衡性，所提方法在召回率、F1-score 和 mIoU 指标上均优于 AttU-Net(0.1159、0.0482、0.0297)和 ResU-Net(0.0355、0.0089、0.0057)。

综上所述,ICA 在总体评价上超过 RFI 方法 0.05 以上,图像分割精度上提高了 0.03。相比于传统基于信息熵的特征选择,ICA 不仅在整体评价指标上表现更优,特别是在复杂的地形条件下,ICA 处理方法能够更精确地捕捉滑坡体的边界和形态特征,提高了滑坡识别的精度与准确率。由于滑坡编目工作需要处理大量多源异构数据,ICA 的高效特征提取能力为滑坡监测和预测提供了更强的技术支撑,为高精度的滑坡编目奠定了基础。

4.4.2 可视化输出结果定性分析

图 4.10 显示了不同方法的预测结果,图 4.10 (a) - (d)是基于 UNet3+网络的结果。图 4.10 (a)是事件后图像的识别结果,(b)、(c)和(d)是 RFI、PCA 和 ICA 辅助的事件后图像的结果。图 4.10 (e)和(f)是 AttU-Net 和 ResU-Net 使用 ICA 辅助的事件后图像的结果。由于滑坡与其他地物具有相似性,分割效果不佳,在图 4.10 中(a)有更多的 FP。事件后影像叠加 GLCM 相似性,DEM,和 NDVI 能降低假阳性(错判),但同时也增加了更多噪声,如图 4.10 所示(b)。主成分分析可以减少特征噪声、突出事件前后影像中的变化部分,有效减少假阴性,但没有明显的滑坡变化也容易被遗漏,如图 4.10 (c)中大量的假阳

性。ICA 是三种特征处理方法中精度最高的一种，如表 4-1 所示。从图 4.10 (d)中可以看出，虽然预测图中有少量的假阴性，但大部分预测结果具有较好的一致性。




图 4.10 测试区编目结果图

具体来说，当采用 RFI 方法进行特征处理时，可以看到由于该方法对噪声的抑制效果不够理想，导致在滑坡预测中出现了较为明显的误识别现象。这意味着，在某些非滑坡区域，RFI 方法错误地将其识别为滑坡，或者在滑坡区域内部出现了识别不准确的情况。这种现象可能会在实际应用中导致不必要的误判和资源浪费。

图 4.11 展示了 RFI、PCA 和 ICA 辅助滑坡制图结果的细节，可以看出特征处理可以有效辅助滑坡制图，不同的处理方法可以得到不同的滑坡预测结果。具体而言，RFI 由于噪声抑制不足，存在明显的误判。同时，PCA 由于对前三个特征的表达变化不足，会导致一些分数缺失。而 ICA 能够在无缺失点和少量误分类的情况下获得最佳的分割结果。




图 4.11 光学影像、假彩色图和输出结果细节对比图。

4.4.3 多特征辅助分析

特征处理的目的是将已分类的特征聚焦于几个关键特征，并提高类内一致性和类间异质性。在本研究中，比较了 ICA 和 RFI 在特征处理方面的效果。

独立成分分析（ICA）是通过将输入空间变换为最大独立基来分离信息。在这里，ICA 可以有效地抑制多特征噪声，并保留主要的变化信息，这有利于地震等事件驱动的滑坡测绘（如表 4-1 所示）。

独立成分分析与基于信息熵或基尼系数的特征选择方法不同，后者用于选择重要特征。RFI 是一种典型的特征选择方法。研究比较了 ICA 和 RFI 的结果，发现前者更为有效。RFI 选择的 GLCM、高程和 NDVI 的差异能够反映变化信息，但难以抑制噪声，这表现为 RFI 辅助的事后图像预测图中存在严重的误分类（如图 4.12（c）所示）。ICA 减少了原始因子中的噪声，并增加了类内一致性和类间异质性。这一点得到了统计结果的证明，分别使用 2000 个非滑坡随机点和 2000 个滑坡点统计了 RFI 选择的三个辅助因子和 ICA 的前三个主成分。图 4.12（a）、（b）和（c）分别为 GLCM、NDVI 和高程的差异，（d）、（e）和（f）分别显示了前三个主成分。




图 4.12 多特征处理后分析图。(a)-(c)是 RFI 选出的 GLCM 非相似性、NDVI 和高程，(d)-(f)分别是 IC1-IC3

基于以上讨论，ICA 可以在多特征处理过程中提高类内一致性并增强类间异质性。因此，经过 ICA 处理的多特征可以有效地辅助事后图像的滑坡测绘。

4.4.4 已有研究对比

图 4.13 (b)、(c)和(d)显示了 AttU-Net, ResU-Net 和 MICUNet3+在 ICA 辅助的事件后图像的预测结果细节。MICUNet3+在多尺度跳跃连接和深度监督方面的改进体现在对不同尺度滑坡的准确预测上。ResU-Net 的预测结果优于 AttU-Net，通过对比图 4.13 (b)和(c)，可以看到 ResU-Net 的错误分类比 AttU-Net 少，只有边界预测不准确。




图 4.13 不同方法对比图。(a), (b), (c)分别是 AttU-Net, ResU-Net 和 UNet3+的结果

目前关于深度学习在滑坡编目图(LIM)中的研究主要集中在方法和数据两个方面。一些学者已经研究了先进的深度学习模块在 LIM 中的适用性。例如,残差模块、注意力机制和转换器方法等。还有一些学者主要研究数据对深度学习滑坡编目图准确性提高的贡献。例如,数据预处理、数据增强、协同因子和数据后处理。

本研究方法 MICUNet3+对滑坡样本的多特征处理在提高准确性方面比网络结构优化更为重要。不可否认的是,网络优化需要根据目标的特点进行更具针对性的设计。

4.5 本章小结

本章通过结合 ICA 和 UNet3+, 提出了一种用于事件诱发型滑坡编目图绘制的多特征 MICUNet3+方法。

研究获取了具有相似季节性特征的事件前 Landsat-8 影像和事件后 Sentinel-2 影像,以及 SRTM DEM 数据。然后,对光学图像进行预处理,获取 NDVI 和 9 个 GLCM 特征以及高程、坡度和坡向。接下来,通过变化向量分析处理 NDVI 和 GLCM,得到 CVA 处理的 NDVI-diff 和 GLCM-diff。将 IC1、IC2 和 IC3 辅助震后图像输入到 UNet3+中进

行滑坡编目图绘制。结果表明，研究提出的 MICUNet3+ 在处理复杂背景和滑坡多尺度特征方面表现良好，ICA 可以提高类内一致性和类间异质性，这为复杂条件下的滑坡识别提供了参考。

然而，由于图像分辨率低，很难识别面积非常小的滑坡。此外，光学图像容易受到云层的影响，这会影响我们方法的性能。在后续的研究中，将进一步探索高分辨率光学和 SAR 图像，以生成更准确的事件诱发型滑坡编目图。

第五章 基于 InSAR 产品的潜在滑坡位置编目方法

5.1 引言

利用 InSAR 获取大范围地表形变, 进行地质灾害的识别已经被认为是最可靠的手段之一。现有研究包括将 InSAR 相位梯度或形变速率与目标检测模型(如 Faster R-CNN、Yolo)、或语义分割(如 U-Net)模型结合获取潜在滑坡。例如, 两阶段目标检测模型获取潜在滑坡位置的方法, 首先使用 Faster R-CNN 获取潜在滑坡的位置, 然后利用 U-Net 网络和光学图像获取滑坡的形状。以及, 结合 SBAS-InSAR、相位梯度和改进的 Faster R-CNN、Yolov3 模型等, 直接获得山区活动滑坡的位置分布^[123-127]。

然而大范围的 InSAR 自动化解译始终是研究者关注的难题, 一方面 InSAR 形变速率能准确表达地表形变信息, 但由于失相干、滤波等原因造成栅格影像不连续, 对视觉信息为主的深度学习模型极具挑战; 另一方面, 相位梯度虽然可以连续表达形变变化信息, 但对于不同形变场会产生地理位置不一致的情况, 如图 5.1 所示。




图 5.1 潜在滑坡形变速率和相位梯度对比图

此外,不同区域的滑坡形状和大小区别很大,从覆盖面积有限的小型浅层山体滑坡到横跨大片地区的大型深层滑坡。有些可能是圆形洼地,有些则呈现长条状或复杂的断层形态。这些形状和大小的变化极大地影响了深度学习算法赖以检测的视觉特征和模式。因此,可靠的潜在滑坡自动检测方法仍有待探索。

为解决上述问题,本章结合 InSAR 形变速率、相位梯度和可视性 C 指数,建立了潜在滑坡数据集,用于训练深度学习模型。并提出了一种多尺度 InSAR 产品滑坡检测网络(MSIDNet),以 Swin Transformer 为骨干,采用多尺度时空注意力机制来提高特征图的挖掘能力,从而实现对潜在滑坡位置的自动编目。

5.2 InSAR 产品数据集和深度学习模型

5.2.1 MISDNet 网络结构

YoloV5 是广泛使用的深度学习模型之一,由骨干、颈部和头部三部分组成(图 5.2)^[155]。经典的 YOLOv5 利用 CSPDarknet-53^[136]和 PANet^[138]分别作为骨干和颈部。CSPDarknet 由残差网络和跳跃连接网络两部分组成,用于提取 InSAR 产品中不同层级的特征。PANet 通过自下而上的特征融合层和自适应特征池化层融合从骨干网络中提取的特征。根据从骨干网和颈部提取的特征信息,可以在输入图像上检测潜在滑坡。




图 5.2 YOLOv5 网络结构示意图

MSIDNet 的总体结构如图 5.3 所示。MSIDNet 沿用了经典的 Yolo 结构,嵌入 Swin Transformer 为骨干网络提取特征,在颈部通过多尺度注意力模块(MAB)进行融合,然后将预测结果输出到头部。此外,MAB 还结合了三个 Conv 模块(C3)来融合多尺度特征图像。本研究提出的 MSIDNet 基于改进的 YOLOv5 模型,如图 5.3 所示,图 5.3 (a)、(b)和(c)分别显示了 MSIDNet 网络的骨干网络、颈部和头部。由于滑坡空间分布不均,使用 Swin Transformer 作为骨干网络,以提高模型的多层次特征提取能力。滑坡的大小

和形状各不相同，因此提出用 MAB 进行特征融合。MAB 中的空间金字塔池化和时空注意力机制有助于挖掘图像上下文信息。




图 5.3 MSIDNet 网络示意图

5.2.1.1 骨干网络

研究使用 Swin Transformer 网络^[142]作为骨干，它包括 4 个阶段，每个阶段由一个 Patch 模块和一个 Swin 模块组成（如图 5.3 (a)所示）。Patch 模块捕捉不同尺度的图像特征，从而提高了模型的鲁棒性和性能。Swin 模块采用分层结构来捕捉图像中的局部上下文信息。Swin Transformer 将 4 个阶段堆叠在一起，逐步获取更大范围的上下文信息，从而实现对图像的整体特征获取。

如图 5.3 (a-1) 所示。首先，对输入特征层 i 进行线性归一化 (LN)，稳定模型的训练过程。然后，在局部窗口上执行自注意力机制，即基于窗口的多头自注意 (W-MSA) (图 5.4)。每个窗口包含固定数量的 patch，计算窗口内的自注意力。最后，将特征图输入多层感知器 (MLP)，感知器由两个全连接层组成，中间有一个激活函数。MLP 用于进一步提取和转换 W-MSA 处理过的特征。

在第 $i+1$ 层，使用基于移位窗口的多头自注意 (SW-MSA，图 5.3 (a-2)) 代替 W-MSA。在连续的 Swin 模块之间，窗口会循环移动，上一层窗口的边缘会与下一层窗口的内部重叠，从而使信息在不同窗口之间流动。




图 5.4 转换窗口示意图

5.2.1.2 颈部

研究在 Neck 部分使用多尺度注意力机制模块 (MAB) 进行特征恢复，以进一步挖掘特征图的多尺度信息。由于 InSAR 变形区域的大小和形状各不相同，失相干掩模会产生空值。传统的颈部操作是将骨干的特征图以级联的方式输入特征融合后的预测中，这样更容易忽略小目标或独立目标。因此，本文提出用 MAB 进行特征融合，将特征图输入空间金字塔池化 (SPP) (图 5.5 (a))，然后输入时空注意机制 (图 5.5 (b)、(c)) 处理，挖掘特征图中的多尺度信息。

首先，如图 5.5 (a) 所示，接收骨干网络输出的特征图，并根据设定的金字塔将其空间划分为 3×3 、 6×6 、 9×9 的网格。每个划分好的网格通过最大池化或平均池化计算每个网格的输出值，所有层的池化结果被串联成一个特征向量。然后，如图 5.5 (b) 所示，输入特征图的每个通道通过全局平均池化和全局最大池化进行聚合，生成两个不同的一维向量，分别代表每个通道的平均特征和最大特征。这两个向量由两个全连接层组成的 MLP 转换成特征。最后，如图 5.5 (c) 所示，对通道维度进行压缩，并通过最大池化和平均池化生成两个二维特征图，分别代表每个位置的最大和平均特征。这两个特征图通过

卷积层沿通道维度串联起来。空间注意力权重图通过一个 sigmoid 激活函数获得，它代表了每个空间位置的重要性。将获得的空间注意力权重图逐个元素相乘，以实现特征图的空间再加权。




图 5.5 多尺度注意力模块（MAB）细节图

5.2.1.3 头部

C3 模块中的三个 Conv 块增加了通道数量，缩小了通道尺寸，输入到预测头部。头部层对应三个检测特征层。颈部输出的三个特征图通过 1×1 卷积进行改变（图 5.6）。每个网格包含 3 个锚点，锚点有 4 个位置坐标（x、y、w、h）和置信度分数。置信度表示该网格中潜在滑坡存在的预测概率。




图 5.6 头部具体细节示意图

5.2.1.4 模型训练设置

在本章中，所有实验都是在英伟达 A800 GPU 上使用 Pytorch 框架进行。标注的滑坡数据集按 8:2 的比例随机分为训练数据集和验证数据集。在训练过程中，所有参数都被划分为独立的训练单元。所有训练单元的随机梯度下降（SGD）优化器，在 $(10^{-5}, 10^{-2})$ 范围内，使用 10^{-2} 的初始学习率。训练设置中的超参数包括学习率、动量和卷积核权重衰减。初始学习率设置为 10^{-2} ，有助于模型在训练初期快速收敛。学习率通过模拟退火进行衰减，使模型在接近最优解时能更精细地调整参数。初始动量为 0.937，动量取值范围为 $(0.3, 0.6)$ ，这有助于模型加速收敛并减少振荡。当卷积核权重随动量衰减时，为了平衡模型的复杂性和泛化能力，衰减的初始值为 5×10^{-4} ，衰减范围为 $(0, 10^{-3})$ 。在优化器中，学习率的衰减由模拟退火优化器更新。预测框的阈值设置为 0.5。在训练过程中，输入图像被归一化为 $(0, 1)$ 并调整为 640×640 像素，训练 epoch 设为 300。

5.2.2 GRCI 数据集

InSAR 形变图能以厘米到毫米的精度反映数万平方公里的地表变化。而相位梯度图则可以反映相对的地表变化。Notti 等人^[156]定义的 C-index（CI）是评估 InSAR 干涉相位质量的关键指标，也可用于 InSAR 产品的自动检测^[157,158]。CI 表示合成孔径雷达与地形之间的视觉关系，由合成孔径雷达卫星飞行方向、地面坡度和坡向定义，如公式 5.1 所示：

$$CI = \sin \theta \cdot \cos \gamma \cdot \cos s \cdot \sin a - \sin \theta \cdot \sin \gamma \cdot \cos s \cdot \cos a + \cos \theta \cdot \sin s \quad (5.1)$$

其中， θ 代表入射角， γ 代表飞行方向， s 代表坡度， a 代表坡向。C 指数可以显示 InSAR 变形图的可见度，因此形变速率与 C 指数之间存在负相关关系。如果 CI 为正，则形变速率为负，如果 CI 为负，则形变速率为正，否则变形包含误差。

首先，根据公式 5.1 构建 RCI（公式 5.2），用 CI 和形变率图之间的关系，消除形变速率图中的误差。

$$RCI = \begin{cases} (Rate \geq 0 \text{ and } CI < 0) & Rate \\ \text{or } (Rate \leq 0 \text{ and } CI > 0) & \\ \text{others} & 0 \end{cases} \quad (5.2)$$

然后，结合相位梯度（Grad）和 RCI 图，通过公式 5.3 构建 GRCI 图。为了强调形变速率和相位梯度对滑坡检测的影响，将相位梯度与形变速率的绝对值相结合。此外，

通过公式 5.4 将相位梯度和形变速率相加构建 GR，其中相位梯度归一化为形变速率的范围。

$$GRCI = Grad \times \frac{|RCI_{max}|}{|Grad_{max}|} + |RCI| \quad (5.3)$$

$$GR = Grad \times \frac{|Rate_{max}|}{|Grad_{max}|} + |Rate| \quad (5.4)$$

其中，Grad 表示相位梯度， $|RCI_{max}|$ 表示单场景图像中 RCI 最大值的绝对值， $|Grad_{max}|$ 表示单场景图像中相位梯度的最大绝对值。

图 5.7 展示了四个数据集，包括 Rate、Grad、GR 和 GRCI。图 5.7 第一列和第二列是与滑坡样本相对应的谷歌地球图像和 DEM，第三列至第六列分别是 Rate、Grad、GR 和 GRCI。多个数据集的组合有助于准确、完整地检测目标^[141,146,159]，研究以 Rate、Grad、GR 和 GRCI 这四个数据集分别作为输入数据来训练和测试深度学习模型。




图 5.7 速率、梯度、GR 和 GRCI 数据示意图

5.2.3 技术流程

本章采用的方法如图 5.8 所示。首先，研究从 ESA 和 JASA 获取原始 SAR 数据，获取 SRTM DEM 数据，通过 Gamma 软件进行配准、干涉和相位解缠处理得到 InSAR 时间序列形变产品（包括形变速率和相位梯度）。然后，通过对相应的光学图像、坡度和坡向的目视判读，获得潜在滑坡样本。为防止少样本量导致过拟合，对样本和标注文件进行数据增强，以训练目标检测网络。最后，在给定的测试区域内获得潜在滑坡位置编目图。

一般情况下，使用目标检测模型来检测基于 InSAR 产品的潜在滑坡，采用 YoloV5 模型，基于此，本研究采用改进的 YoloV5 模型，采用多尺度的骨干网络和特征融合的 MSIDNet，模型的细节如 5.2.1 中描述。




图 5.8 研究方法流程图

5.3 训练样本和测试样本概况

5.3.1 训练区和测试区概况

图 5.9 展示了三个研究区，包括白龙江上游、金沙江主流以及四川省雅安市和乐山市。白龙江上游位于甘肃和四川交界，属于黄土高原西南部，地势复杂、地理环境多样。金沙江主要穿越四川、云南和西藏的交界地区，地处青藏高原东部的高山峡谷地带，是

滑坡和泥石流的高发区。四川的雅安和乐山地处四川盆地与青藏高原的过渡地带，雨量充沛，地质灾害频发，适合多种地质灾害的研究。




图 5.9 训练区和测试区示意图。(a)和(b)分别是训练区白龙江流域和金沙江流域，(c)是位于金沙江下游的测试区

5.3.2 原始数据概况

本研究使用了 L 波段的 ALOS-2 图像和 C 波段的 Sentinel-1 数据。数据的具体信息如下：2014 年 9 月至 2018 年 11 月期间获取的 171 幅 ALOS-2 图像和 2017 年 3 月至 2018 年 11 月期间的 193 幅 Sentinel-1 数据，在金沙江地区共检测到 928 个潜在滑坡体。2018 年 3 月至 2021 年 5 月期间获取的 94 景 Sentinel-1 数据则在白龙江上游检测到 142 个滑坡体。所有 Sentinel-1 和 ALOS-2 数据在金沙江地区为升轨，而在白龙江和雅安地区为降轨。Sentinel-1 的重访周期为 12 天，ALOS-2 为 14 天。数据处理过程中，通过计算滤波差分干涉图的相位梯度并采用小基线集方法，生成了高精度的时间序列产品，精确监测地表的微小变动，识别潜在的地质灾害风险。

表 5-1 数据信息

研究区	白龙江	金沙江	测试区
InSAR 产品	速率图、梯度图	速率图	速率图、梯度图
滑坡数量	142	928	347
影像数	94 Sentinel-1	193 Sentinel-1 171 ALOS-2	94 Sentinel-1
获取日期	2018-03-22 至 2021-05-17	2017-03-18 至 2018-11-20 2014-09-17 至 2019-03-27	2018-03-22 至 2021-06-10

5.4 不同数据集结果对比分析

5.4.1 形变速率数据集评估

5.4.1.1 机器学习方法对比

在图 5.10 中，Faster R-CNN、Yolo 模型和 PCA+K-means 方法分别在滑坡检测任务中展示了不同的效果。Faster R-CNN 和 Yolo 模型处理的是形变速率数据，而 PCA+K-means 方法则基于时间序列数据进行分析。通过对比可以发现，Yolo 模型在多方面表现优于 Fast R-CNN，尤其是在误报率和实时性上具有明显的优势，相比之下，PCA+K-means 方法尽管能够识别滑坡体，但由于其聚类方法的局限性，误分类率较高。

具体来说，Faster R-CNN 通过区域候选网络（RPN）来提取感兴趣区域，再利用卷积神经网络（CNN）对这些区域进行分类和边界回归。这使得其在复杂场景中能够较为精准地识别目标。然而，这种两阶段的检测方式使得其处理速度较为缓慢。与之相比，Yolo 模型采用端到端的检测方式，将目标检测简化为一个单一的回归问题，可以在一个前向传播过程中同时输出边界框和类别。由于其单阶段的检测架构，Yolo 能够以较高的速度处理数据，同时保持较低的误报率，适合应用于滑坡检测任务。

而 PCA+K-means 方法通过主成分分析（PCA）对时间序列数据进行降维，再通过 K-means 聚类对数据进行分类。这种方法在滑坡体识别的初步探索中具有一定的优势，。然而，由于时间序列数据中的复杂性较高，PCA+K-means 对噪声和边界的敏感度较强，

容易产生误分类。特别是当滑坡体的形变模式不明显时，聚类的结果可能存在较大的偏差，难以在精度上与深度学习方法相媲美。




图 5.10 机器学习和深度学习滑坡检测结果。其中(a)、(b)和(c)分别是 Yolo、Faster R-CNN 和 PCA+K-means 的识别结果

因此，在滑坡检测的实际应用中，Yolo 模型由于其快速检测和低误报率的特点具有明显的优势，能够更有效地应对复杂地形和快速变化的环境。PCA+K-means 更适合在早期探索阶段作为辅助工具进行初步分析，但在面对高精度检测任务时，其局限性明显，难以胜任滑坡编码任务。

5.4.1.2 深度学习对比

InSAR 地表形变速率是从 Sentinel-1 影像获得的，大多介于-0.2 m/year 和 0.2 m/year 之间。在本研究中，包括崩塌、泥石流和滑坡在内的都被视为滑坡。在本研究中，最大

年形变速率超过 0.1 米/年,但小于 1.6 米/年的被视为潜在滑坡。目标是自动检测这些变形区域,同时排除因误差造成的误判,减少漏判。

表 5-2 比较不同网络对速率数据集的准确性

Model	Modules			Precision	Recall	mAP	F1
	SPP	CBAM	MAB				
Faster R-CNN				0.844	0.708	0.844	0.770 $\uparrow$ 12.7%
SwinT-Yolo				0.861	0.831	0.889	0.846 $\uparrow$ 4.1%
SwinT-spp	√			0.838	0.833	0.881	0.835 $\uparrow$ 5.3%
SwinT-cbam		√		0.854	0.854	0.895	0.854 $\uparrow$ 3.2%
MSIDNet			√	0.868	0.896	0.926	0.882

在形变率数据集上,MSIDNet 方法与现有的 Faster R-CNN 和不同结构的 Swin Transformer Yolo (SwinT-Yolo) (包括空间金字塔池化 (SwinT-spp) 和卷积块注意模块 (SwinT-cbam)) 进行了比较。

表 5-2 显示, SwinT-Yolo 在 F1 和 mAP 方面比 Faster R-CNN 分别提高了 0.076 和 0.045,说明 Swin Transformer 的特征提取能力更强。与 Faster R-CNN 相比, SwinT-spp 和 SwinT-cbam 的 F1 分别提高了 0.065 和 0.084,这表明有必要加入空间和多尺度注意机制。MSIDNet 的 F1 提高了 0.112,准确率、召回率和 mAP 分别达到最高的 0.868、0.896 和 0.926。Swin Transformer 可以从 InSAR 结果中提取多尺度特征, MAB 可以合成多尺度时空特征,从而获得更好的检测结果。总体而言,基于 Swin Transformer 和时空注意机制的 MSIDNet 在基于 InSAR 率产品的滑坡自动检测中表现良好。

图 5.11 显示了 Faster R-CNN、SwinT-Yolo、SwinT-spp、SwinT-cbam 方法的可视化结果。在第一行中,所有方法的性能相当,形变速率清晰,误差较小。相比之下,由于速率图中存在一些误差,第二行和第三行的表现则大相径庭。其中, Faster R-CNN、SwinT-Yolo 和 SwinT-spp 的准确度召回率较低,与 Faster R-CNN、SwinT-Yolo 和 SwinT-spp 相比, MSIDNet 方法表现出很强的鲁棒性。在第一行图像中,所有方法表现相近,目标清晰、形变少,误差较小,显示出它们在简单场景下的良好性能。然而,第二行和第三行的图像则呈现出明显的差异,这些图像可能涉及复杂的场景和变化多样的滑坡形态。在这些复杂条件下, Faster R-CNN、SwinT-Yolo 和 SwinT-spp 的准确度和召回率显著下降,

表明它们在处理背景复杂或者形变不清晰的目标时面临挑战。由此可以推测，这种优势可能源于模型在多尺度特征融合、有效的背景抑制或者更精细的目标定位能力上的技术创新和优化。此外，可能还包括对训练数据的精细选择和模型调整，以更好地适应复杂场景下的挑战。




图 5.11 速率数据集的滑坡检测结果。第一列至第五列分别为 **Faster R-CNN**、**SwinT-Yolo**、**SwinT-spp**、**SwinT-cbam** 和 **MSIDNet**

5.4.2 相位梯度数据集评估

图 5.12 显示了 MSIDNet 方法、Yolov3 和三种不同结构的 Swin Transformer 模型（SwinT-Yolov5、SwinT-spp、SwinT-cbam）在相位梯度数据集上的检测结果。在第一行中，Yolov3 和 SwinT-Yolo 显示出明显的不足，在梯度变化与背景相比并不显著的较大区域中存在检测错误。尽管 SwinT-spp 和 Swin-cbam 有了一些改进，但 MSIDNet 方法显示出了最接近标签的结果。




图 5.12 Grad 数据集的检测结果。第一列至第五列分别是 YOLOv3、SwinT-Yolo、SwinT-spp、SwinT-cbam 和 MSIDNet

相位梯度 (Grad) 提供了具有明显边界的空间连续模式。研究比较了 YOLOv3、SwinT-YOLOv5、SwinT-spp 和 SwinT-cbam 与 MSIDNet 方法在 Grad 数据集上的准确性。

表 5-3 比较不同网络对梯度数据集的准确性

Model	Modules			Precision	Recall	mAP	F1
	SPP	CBAM	MAB				
YoloV3				0.775	0.687	0.792	0.728↑16.8%
SwinT-YOLOv5				0.822	0.824	0.855	0.823↑5.9%
SwinT-spp	√			0.907	0.706	0.875	0.794↑9.2%
SwinT-cbam		√		0.817	0.647	0.778	0.722↑17.4%
MSIDNet			√	0.868	0.882	0.918	0.875

表 5-3 显示了定量评估结果。SwinT-YOLO 明显优于 YOLOv3，召回率提高了 0.137，F1 提高了 0.095，这意味着 SwinT-YOLOv5 由于嵌入了 Swin 变换器，可以大大减少滑坡

检测的遗漏。SwinT-spp 的精确度最高，达到 0.907，但由于召回率低，F1 表现不佳，SwinT-cbam 也存在同样的问题。

最后，MSIDNet 的 mAP 和 F1 分别提高了 0.126 和 0.147，并获得了最佳召回率。召回率越高，说明模型检测到的真阳性样本越多，漏报越少。在滑坡检测中，需要更少的漏报，才能更好地预防滑坡造成的危害。

5.4.3 GRCI 数据集评估

研究利用 MSIDNet 网络评估了本研究中构建的 GRCI 数据集以及 Rate、Grad 和 GR 数据集的性能。表 5-4 显示了 MSIDNet 方法在不同数据集之间的精度。GR 是形变速率和相位梯度的组合，在精度和 F1 方面表现良好，其中 F1 比速率和梯度数据集分别提高了 0.01 和 0.017。GRCI 在精度、mAP 和 F1 方面具有明显优势，分别为 0.939、0.916 和 0.945。与 Rate 和 Grad 数据集相比，GRCI 数据集的精确度提高了 5%，F1 提高了 3%，这意味着 GRCI 显著提高了精确度，减少了人工验证的工作量。尽管 Rate 和 Grad 的召回率略高于 GRCI（约为 0.1%），但 GRCI 更为稳健，这表明遗漏的滑坡检测更少。

表 5-4 MSIDNet 方法对 RATE、GRAD、GR、GRCI 数据集精度比较

数据集	Precision	Recall	mAP	F1
Rate	0.868	0.896	0.926	0.882
Grad	0.868	0.882	0.918	0.875
GR	0.892	0.894	0.911	0.892
GRCI	0.939	0.895	0.945	0.916

图 5.13 是 MSIDNet 在 Rate，Grad，GR 和 GRCI 四个数据集的可视化结果，红色框是标签，蓝色框是模型预测，从第一列至第四列分别是 Rate，Grad，GR，和 GRCI。从图 5.13 中可以看出，Rate 数据集由于空值产生的不连续性而导致采集结果不佳（图 5.13 (c1)）。Grad 在梯度变化明显的区域识别效果较好（图 5.13 (b2)、(c2)），但在图 5.13 (a2) 中表现较差。GR 数据集的表现优于前两个数据集，但无法有效去除背景噪音（图 5.13 a3）。由于 GRCI 数据集是由速率和梯度乘积组合而成，并利用 C 指数消除误差，因此是最准确的潜在滑坡检测数据集。通过 CI 降低背景噪声可以提高检测精度和边界识别能力。

综合以上结果研究发现，GRCI 数据集的高精度（0.939）与其在可视化中准确的边界识别相一致，表明其模型预测框与真实标签的重合度较高。相比之下，Rate 数据集的精度较低（0.868），可视化中则显示出因空值导致的采集不连续性，影响了模型的整体表现。Grad 数据集虽然在某些区域识别良好，但其精度（0.868）反映了模型在梯度变化不明显区域的识别困难，这在可视化结果中得到了验证。GR 数据集精度相对较高（0.892），但可视化显示仍存在背景噪音的问题，影响了模型的准确性。




图 5.13 使用 MSIDNet 模型检测 Rate、Grad、GR 和 GRCI 数据集的滑坡结果，
第一列至第四列分别为 Rate、Grad、GR 和 GRCI 数据集

5.5 编目结果精度评估分析与讨论

5.5.1 测试区泛化性评估

为了评估每个模块的贡献,对每个骨干网络和模块的影响分析如下。首先选择 Swin Transformer 作为骨干网。然后,分别添加 SPP、CBAM 和 MAB 模块。表 5-2 显示了在速率数据集上的实验结果。虽然 Faster R-CNN 的精度与 Swin Transformer 相当,但由于误报过多, F1 较低。而 Faster R-CNN 的 Recall 则明显低于其他网络,这表明 Faster R-CNN 导致了严重的滑坡漏检。SwinT-Yolo 的 F1 明显高于 Faster R-CNN,说明 Swin Transformer 作为骨干网络具有出色的特征提取能力。在颈部添加 SPP 和 CBAM 的改进效果并不明显。此外, SPP 甚至低于 SwinT-Yolov5,这说明在没有时空特征的情况下,仅考虑多尺度因素不足以提高滑坡编目的精度。




图 5.14 MSIDNet 和 GRCI 在测试区域的滑坡检测结果。背景为形变速率图,其中红色、蓝色和黄色点分别表示真阳性 (TP)、假阳性 (FP) 和假阴性 (FN)

在表 5-3 中,召回率高表明误报较少。尽管 SwinT-spp 在精度上优于新提出的方法,但召回率低导致 F1 值低。Yolov3 的召回率最低,表明许多错误被检测为山体滑坡。总

之，本研究提出的 MSIDNet 结合了多尺度因子和时空注意机制，是从速率数据集检测滑坡的最有效模型。它验证了 MAB 和 Swin Transformer 在 InSAR 产品检测中的有效性。它在检测潜在滑坡位置方面具有优势，从而提高了 InSAR 产品解释的效率。

在训练过程中，可能会面临一些挑战，如梯度消失、过度拟合和计算资源不足等。为了解决这些问题，可以采取以下措施。尝试使用更高效的优化算法、降低模型复杂度或利用分布式计算来降低计算成本。

图 5.14 显示了测试区的泛化性，测试区域经目视解译 298 个缓慢变形的滑坡，其中本研究的方法检测到 250 个，此外还有 49 处潜在滑坡为目视解译未能发现的，泛化整体精度为 0.86，实验证明深度学习方法能弥补目视解译的不足。

5.5.2 误差可视化分析




图 5.15 TP、FP 和 FN 形变速率和 Google 图像。(1)-(3)为 TP，(4)和(5)为 FP，(6)-(8)为 FN。(a)为谷歌图像上的形变速率，(b)为谷歌地球上的光学图像。白色实线表示滑坡边界

为了探究真阳性、假阳性和假阴性的原因，将形变速率图像放到谷歌地球上进行检测。图 5.15 显示了叠加在谷歌地球平台上的八个形变速率实例，其中(1) - (3)为真阳性，(4)和(5)为假阳性，(6) - (8)为假阴性，a 和 b 分别为叠加在谷歌图像和谷歌图像上的形变速率。图 5.15 (1)、(2)和(3)表明，检测到的慢速滑坡与光学图像中的地貌特征一致，说明 MSIDNet 方法可以根据 InSAR 产品可靠地检测到潜在滑坡。

图 5.15 (4)和(5)是两个误报点。图 5.15 (4)位于植被茂密的区域，可能会由于低相干性区域的过滤而导致假变形。而图 5.15 (5)是一片农田，可能会发生一些与灌溉有关的变形，但根据地形特征，这与滑坡无关。要减少这种误报，需要光学图像和时间序列变形进一步分析以提出更好的解决方案。

5.5.3 混淆矩阵分析




图 5.16 Rate、Grad、GR 和 GRCI 数据集测试区域混淆矩阵的贡献率

图 5.16 显示了基于 Rate、Grad、GR 和 GRCI 数据集的滑坡检测混淆矩阵的贡献。图 5.16 (a)显示，Rate 数据集的漏检率非常高，而 Grad 数据集比 Rate 数据集的结果更好。这表明，使用 Rate 数据集进行滑坡检测时，有相当一部分活动滑坡没有被正确识别。而 Grad 数据集的误报率较高，这给下一步的验证工作带来了很大的难度。从 GR 和

GRCI 数据集中可以发现, GRCI 的漏检率较低, 误报分布相对集中, 容易去除。此外, GRCI 数据集的误报分布比较集中, 可以通过分析误报的规律和特征来去除误报, 从而提高滑坡检测的准确性和可靠性。

在滑坡检测混淆矩阵中, 不同数据集的贡献率存在显著差异。通过分析混淆矩阵, 可以了解各数据集的性能特点和局限性, 为滑坡检测的研究和应用提供参考。

5.6 本章小结

针对单一 InSAR 产品在深度学习模型中解译滑坡不准确的问题, 本章提出了一种融合速率、梯度和 C 指数的数据集用于深度学习, 采用一种改进的 Yolo 网络, 以 Swin Transformer 为骨干网络, 加入多尺度注意力机制模块的方法进行潜在滑坡位置编目。

本研究结合形变速率、相位梯度和 C 指数构建了新的滑坡数据集 GRCI, 利用 CI 去除速率中的误差, 并与相位梯度进行归一化融合, 以顾及速率和梯度的优势形成位置准确的连续栅格数据, 作为深度学习模型的输入。提出了 MSIDNet 模型通过增强骨干特征图提取能力和颈部特征图时空挖掘能力。

实验结果表明, 与现有的三种深度学习方法相比, MSIDNet 在潜在滑坡检测方面具有很高的准确性。本研究验证了所构建的潜在滑坡数据集 GRCI 与形变率或相位梯度数据集相比具有更高的精度。所提出的 MSIDNet, 在测试区域的泛化精度达到了 0.89, 这表明本研究的方法具有良好的泛化能力。

然而, 由于滑坡数据集较小, 新模型仍存在一些检测误差。因此, 丰富滑坡数据集, 加入多种类型的遥感图像, 有望进一步提高泛化能力和检测精度。随着 InSAR 产品的多样化, 未来的工作将基于该方法建立更丰富的潜在滑坡样本, 并进一步探索多模态数据, 以准确探测包括崩塌和泥石流在内的不同类型滑坡。

第六章 基于多模态遥感数据的潜在滑坡形态编目方法

6.1 引言

InSAR 产品能反映地表形变, 是一种可靠的用于获取大范围地表变化的技术手段, 但 InSAR 产品的解译通常需综合利用多源数据进行协同判读和分析。如 2.2.3 中的描述, 首先通过 InSAR 形变数据获取地表形变信息, 定位形变区域, 再结合地形判断该区域是否满足一定的坡度, 如坡度小于 15 度的平缓地势, 通常不被认为是具有危险的滑坡。此外还要结合光学影像, 如 5.5.2 中的分析, 一些农业灌溉, 或地表人工建筑均能引起地表形变。因此基于 InSAR 产品的准确解译需要结合多源遥感数据进行进一步验证。在已有研究中, 较少考虑多模态数据的应用, 以及针对这一复杂任务的网络结构设计, 因此对潜在滑坡的边界提取不够准确, 也存在错判和漏判的难题。

基于此, 本章结合 InSAR 形变速率、光学影像和 DEM 建立了一种多模态数据集, 提出了一个多模态融合网络, 通过多模态输入丰富输入信息, 同时通过速率约束模块增强速率的决策权重, 以获取准确的潜在滑坡形态边界, 减少错判漏判。

6.2 多模态融合模型

6.2.1 MMNet 网络结构

光学影像和合成孔径雷达干涉测量 (InSAR) 产品的融合可以有效识别潜在滑坡。然而, 由于 InSAR 产品和光学影像表现不同, 采用传统简单组合 InSAR 产品和光学影像输入网络的方法, 会导致 InSAR 产品的权重被其他辅助信息淹没, 无法保障地表形变信息的准确表达。针对这个问题, 提出了一种多模态网络 (MMNet), 它能够并行处理 InSAR 产品和光学因子、地形因子等, 从中提取异构特征, 辅助 InSAR 产品进行地表信息的提取。

在 MMNet 中, 设计了两个独立的分支, 分别用于处理 InSAR 产品和多模态辅助信息, 如图 6.1 所示。这两个分支采用类似的编码器-解码器结构, 确保在相同的网络深度获得相似大小的特征图。通过主编解码器和速率编解码器的协同工作, 利用多源数据实现了对遥感影像的分割。通过特征融合模块和金字塔池化模块, 模型能够充分利用影像的局部和全局特征, 生成准确的分割结果。在滑坡检测或地表变化监测等任务中, 该网络结构能够有效捕捉地表形变特征, 提高模型的检测能力。

模型通过双输入端进行特征提取，一端包括以上多模态因子，另一端输入速率和山体阴影进行约束，使模型能提取到多模态数据的特征信息，同时具有速率约束。这种架构设计保证了各分支能够独立获取并保留各自的特征信息，避免了特征在融合过程中的相互干扰。它能有效利用成对光学输入和 InSAR 形变速率的输入特征互补，并生成稳定的预测结果。该网络可抑制不同模态之间的特征干扰，并有效增强多模态联合特征。采用了多层次上采样解码器，通过特征对齐模块保留了相邻特征层级之间的语义一致性。




图 6.1 MMNet 网络结构图

6.2.2 速率约束的多模态输入模块

编码器-解码器结构在深度学习中广泛用于特征提取和图像生成。编码器将输入数据映射到一个低维的特征空间中，而解码器则将这些特征映射回原来的空间，从而实现数据的重建。在 MMNet 中，图 6.1 左侧部分展示了主编解码器的结构，其输入为大小为(10, H, W)的多通道遥感影像数据。主编解码器包括多个下采样过程，通过卷积和池化操作，将影像数据逐层缩小。通过这种逐步下采样，模型能够提取图像的多尺度特征。主编解码器的作用在于通过逐层编码，压缩并提取影像中关键信息，为后续的解码和上采样过程提供更高层次的特征表示。

图 6.1 中的速率编解码器与主编解码器结构并行，其输入为大小为 $(4, H, W)$ 的速率图和山体阴影图。该速率图可以被视为影像形变的速率信息，在此用于辅助主编码器的解码过程。速率编解码器采用了与主编解码器相似的结构，先通过多个下采样过程逐步压缩特征图，从而获取多尺度的速率特征表示。与主编解码器不同的是，速率编解码器中的下采样数量较少，但其关键在于为主网络提供额外的特征支持。

6.2.3 特征融合模块

图 6.1 中绿色圆圈"C"代表了主编解码器和速率编解码器之间的特征融合模块。在每一个下采样层的输出处，主编解码器和速率编解码器的特征图进行连接与融合。通过这种特征融合，模型可以同时利用图像信息与速率信息，从而生成更加精确的特征表示。这一融合过程也确保了多源数据的有效结合，使得模型在面临复杂影像时能更好地应对。特征融合之后，这些高层次的联合特征被传递至后续的解码器部分，进一步实现图像的恢复与细化。

在编码器提取到高层次的特征信息后，解码器通过上采样的方式逐步恢复图像分辨率。图中的解码器（绿色多面体）通过与之前编码器特征的融合，实现了特征图的逐层上采样和细化，最终输出目标图像的分割结果。解码器通过逐步上采样，将图像的空间分辨率逐步恢复回原始尺寸。每个解码层不仅利用当前上采样后的特征图，还通过跳跃连接（skip connections）结合对应编码层的特征，确保恢复过程中不丢失关键的空间信息和语义信息。




图 6.2 空间金字塔池化结构

在图 6.1 中靠近底部的橙色模块表示金字塔池化模块（图 6.2）。该模块用于对影像的全局信息进行汇总，通过不同尺度的池化操作提取到影像的全局上下文信息。这些全局信息在后续的解码过程中能够帮助模型更好地理解图像的宏观结构，尤其是在处理包含复杂地形的遥感影像时，全局信息可以大幅提高分割的精度和一致性。

6.2.4 网络训练优化过程

在训练过程中，采用了 AdamW 优化器来最小化联合损失函数。AdamW 优化器是一种改进的 Adam 优化算法，通过引入权重衰减，有效防止模型在训练过程中出现过拟合现象。相比传统的 Adam 优化器，AdamW 在处理 L2 正则化时表现更为优越，这在处理像 InSAR 数据和光学影像这种高维数据时，能够确保模型权重更新更加稳定，从而提升模型的泛化能力。

为了进一步提升模型的训练效果，采用了模拟退火的策略逐步降低学习率。在初始训练阶段，模型通过较高的学习率快速调整参数，以便快速收敛到较优解。随着训练的过程，逐渐减小学习率，模拟退火的过程使得模型能够更好地在损失函数空间中进行微调，避免模型陷入局部最优，同时确保模型能够充分学习到数据中的细微特征。特别是在处理复杂的地质环境任务时，逐步减小学习率的策略有助于模型更好地识别地形、地貌的变化，从而提升滑坡区域的识别精度。

此外，模型在每次迭代中对网络权重进行更新。AdamW 优化器通过计算损失函数关于网络参数的梯度，并结合一阶矩估计和二阶矩估计动态调整学习率，最终更新网络权重。在迭代循环中不断重复，使得模型能够在每次迭代中进一步优化，从而逐步学习到如何从 InSAR 产品和光学影像中提取最有效的特征。

在训练过程中，模型通过对 InSAR 产品的形变信息进行解析，学习到地表形变的空间特征；与此同时，光学影像作为补充信息，为模型提供了地表的细节和纹理特征。在联合利用这两种数据的基础上，模型能够更好地捕捉滑坡发生区域的空间和地表分布特征。特别是在高精度的滑坡识别任务中，InSAR 数据提供的微小形变特征可以有效地揭示滑坡的潜在发生趋势，而光学影像则能够提供地表覆盖物的变化信息，帮助模型区分滑坡区域与其他地表扰动现象。

通过迭代更新网络权重的训练过程，逐步提升模型对滑坡区域的识别能力。随着损失函数的不断减小，模型能够更加准确地划分出滑坡区域，减少误检和漏检现象，最终

实现对滑坡的精准定位。优化过程不仅依赖于模型的结构设计，也体现了优化器和学习率衰减策略在提升模型训练中的重要作用。




图 6.3 模拟退火学习率调整过程

6.3 多模态样本及数据概况

6.3.1 研究区概况

本章的研究选取了两个训练区和一个测试区，位于我国地质灾害高发的区域，具有复杂的地质和地理环境。研究区域包括，金沙江上游青海、四川和西藏交界处的训练区一（图 6.4(b) 所示），黄河流域甘肃省和四川省交界处的训练区二（图 6.4 (c) 所示），以及黄河上游青海省和甘肃省交界处的测试区（图 6.4(d) 所示）。这些区域位于我国的主要河流流域周边，常年受自然环境和地质条件的影响，易发生滑坡等地质灾害，具有较高的研究价值。

研究中，利用哨兵-1（Sentinel-1）雷达数据获取了这些区域的地表形变速率，并结合谷歌影像和数字高程模型（DEM）对滑坡目标进行目视解译。具体来说，训练区一包括 1 个升轨 Track 的 2 个 Frame 和 1 个降轨 Track 的 1 个 Frame，观测到的地表形变速率在 0.28 m/year 到-0.26 m/year 之间，表明该区域存在较为显著的形变现象。训练区二则包括 1 个降轨 Track 的 1 个 Frame，地表形变速率范围在 0.20 m/year 到-0.22 m/year 之

间。测试区也包括 1 个降轨 Track 的 1 个 Frame，形变速率范围为 0.23 m/year 到-0.15 m/year，形变幅度略小，但仍显示出显著的地质活动迹象。

通过对这些区域的地表形变数据的分析，三个研究区具有相似的形变范围。训练区一和测试区均位于大河流域附近，受到河流侵蚀和地质运动的共同作用，地质活动频繁。训练区二位于黄土高原的周边区域，该地区具有脆弱的地质结构和较为复杂的地表覆盖，这为滑坡等灾害的发生提供了有利条件。测试区位于青海省东部，黄河上游流域，地处黄土高原西端向青藏高原过度地带。以黄河为界，两岸分别为尖扎县和化隆回族自治县。随着经济的发展，人类活动频繁，开挖山体、修路、切坡建房等活动导致砍伐森林现象较多，防护坡措施较少，在强降雨时，崩塌、滑坡、泥石流频繁发。这些研究区域具有相似的地表覆盖和地质特征，为研究地质灾害、滑坡编目提供了良好的对比和验证平台。




图 6.4 研究区样本分布和概况图。(a)是研究区位置概况，(b)和(c)分别是训练区，(d)是测试区

6.3.2 原始数据概况

训练区一和训练区二的数据情况如图 6.5 所示。图 6.5 (a)详细展示了训练区一的数据情况，其中标记为 I、II、III的是使用哨兵-1（Sentinel-1）获取的雷达数据，而标记

为 1-14 的数据则是通过哨兵-2 (Sentinel-2) 多光谱影像数据获得的。训练区二中的数据结构类似, 标记为IV的是哨兵-1 数据, 15-22 是哨兵-2 影像数据的编号。为了确保数据的质量和一致性, 从欧空局 (ESA, <https://dataspace.copernicus.eu/>) 网站上下载了所有所需的 L2A 级别数据, 这些数据已经过大气校正和辐射校正, 能够提供更为精确的地表反射率信息。




图 6.5 训练区原始数据覆盖图。(a)和(b)分别是金沙江上游和黄河上游的训练区

为确保光谱计算的准确性, 对影像的云量进行了筛选, 严格选取了云量小于 5% 的影像数据。云量低的影像不仅能提高光谱分析的准确度, 还能减少因云层干扰导致的数据噪声。在提取光谱信息时, 批量提取了这些影像的多个波段数据, 并将其重采样至 10 米的分辨率, 确保在后续的分析中空间分辨率的一致性。

研究提取了几组关键波段, 分别是 B2 (蓝)、B3 (绿)、B4 (红)、B8 (近红外波段) 以及 B11 (短波红外波段)。这些波段覆盖了从可见光到近红外的光谱范围, 能够反映地表植被、土壤湿度、岩石特征等重要信息。其中, B2、B3、B4 三个波段用于构建传统的 RGB 合成图像, 而 B8 波段由于其对植被和水体的敏感性, 常被用于归一化植被指数 (NDVI) 的计算。B11 波段则擅长捕捉植被应力、土壤水分含量等红边信息, 能够提供更丰富的地表变化特征。

哨兵-2 数据的详细信息如表 6-1 所示, 针对研究区域的地理和气候特点, 筛选了适合的影像数据集。训练区一共包含 14 景哨兵-2 影像, 而训练区二则包含 8 景哨兵-2 影像。在影像筛选过程中, 特别考虑了光照条件、季节性变化以及数据一致性等多个因素。

测试区影像如图 6.6 所示，测试区选取了哨兵-1 影像的 1/4 部分作为研究区域，同时使用了 4 景哨兵-2 影像进行辅助分析。在后续的滑坡检测实验中，测试区的影像数据为评估模型的泛化性能和实际应用能力提供了重要依据。




图 6.6 测试区数据覆盖图

为了最大限度地减少因光照条件差异引起的干扰，尤其是在复杂的地形环境中，优先选取了日照充足、光照条件较为稳定的影像数据。同时，为了避免季节性因素对地表植被、土壤水分等地物特征的影响，确保影像的可比性和分析的连贯性，限定了影像采集的时间窗口，集中选取了 6 月至 9 月之间的夏季影像。这一时间段不仅是区域内植被生长的高峰期，同时也是地表特征较为明显的时期，因此有助于提取更加稳定、有效的光谱信息。

表 6-1 训练区哨兵-2 数据概况

区域	序号	N	R	T	日期
—	1	N0510	R090	T46SFD	20240701
	2	N0510	R090	T46SGD	20240701
	3	N0510	R090	T47SKU	20240701
	4	N0400	R090	T46SFC	20220707
	5	N0400	R090	T46SGC	20220707
	6	N0400	R090	T47SKT	20220707
	7	N0400	R090	T47SLT	20220707
	8	N0400	R090	T46SFB	20220707
	9	N0400	R090	T46SGB	20220707

区域	序号	N	R	T	日期
— —	10	N0400	R090	T47SKS	20220707
	11	N0400	R090	T47SLS	20220707
	12	N0500	R047	T47SLS	20230715
	13	N0400	R090	T46SGA	20220707
	14	N0400	R090	T47SKR	20220707
	15	N0511	R104	T48SUD	20240821
	16	N0511	R104	T48SVD	20240821
	17	N0511	R061	T48SWD	20240818
	18	N0511	R104	T48SUC	20240821
	19	N0509	R104	T48SVC	20230812
	20	N0510	R061	T48SWC	20240614
	21	N0511	R061	T48SVB	20240813
	22	N0511	R061	T48SWB	20240818

通过选择这一时期的影像，能够减少季节交替对植被覆盖、地表反射率等数据的影响，从而为滑坡检测及地表形变分析提供更加可靠的遥感数据支持。这些影像的高时空分辨率确保了研究的细致性，使得训练区一和训练区二的地表变化特征能够被清晰地捕捉和识别，有效提高了模型的准确性和可靠性。

表 6-2 测试区哨兵-2 数据概况

序号	N	R	T	日期
1	N0509	R004	T47SQA	20230830
2	N0509	R004	T48STF	20230830
3	N0509	R004	T47SQV	20230830
4	N0509	R004	T47SKR	20230830

6.3.3 多模态样本介绍

在研究中，首先通过哨兵-1 数据获取了地表形变速率，这些形变速率能够直观地展示地表的变化情况，尤其是滑坡区域的潜在移动情况。地表形变速率为滑坡识别提供了关键的动态信息。其次，利用 SRTM DEM 生成了山体阴影图（Hillshade），使得地形的起伏和山体的轮廓清晰可见，进一步判断潜在的滑坡位置。此外，通过结合谷歌影像对地表地物进行判读，能够精确识别地表的变化情况，如植被、建筑和水体的分布等。依次通过这些数据解译了滑坡样本，确保滑坡的识别更加精准。

在准备数据集的过程中，对 DEM 提取了三个地形因子：高程、坡度和坡向。这些因子不仅提供了地形的几何信息，还为模型的训练提供了丰富的地表细节，有助于模型

更好地学习和获取滑坡的地表环境。此外，为了进一步提升数据的多样性和时效性，引入了哨兵-2 数据。哨兵-2 影像包含地表反射的多光谱信息，涵盖了植被、土壤和水体等地表覆盖物的光谱特征。与静态的谷歌影像相比，哨兵-2 数据具有更高的时效性，能够更及时地判断地表的变化情况。

在选择哨兵-2 影像时，主要使用了 B2（蓝）、B3（绿）、B4（红）、B8（近红外）和 B11（短波红外）这几个波段。每个波段的反射率分别表征了不同地表物质的光谱反应，结合这些波段的数据，计算了光谱因子，包括归一化建筑指数（NDBI）（公式 6.1）、归一化植被指数（NDVI）（公式 6.2）和归一化水体指数（NDWI）（公式 6.3），以描述地表的建筑、植被和水体分布。计算这些指数的公式如下：

$$NDBI = \frac{B11 - B8}{B11 + B8} \tag{6.1}$$

有助于识别地表的建筑物或裸露土壤。

$$NDVI = \frac{B8 - B4}{B8 + B4} \tag{6.2}$$

用于评估植被的覆盖情况和健康状况。

$$NDWI = \frac{B3 - B8}{B3 + B8} \tag{6.3}$$

用于识别水体区域，如河流、湖泊等，以及反应地表土壤湿度特性。




图 6.7 多模态数据示例图

通过这些指数的计算，得到了更加丰富的地表覆盖信息，有助于滑坡检测的进一步精细化分析。图 6.7 显示了样本示例，包括形变速率、标签、山体阴影、坡向、坡度、高程、NDBI、NDVI 和 NDWI。其中，为了更好的显示形变速率的大小和范围，根据图

6.4 中所示的速率分类和颜色对应,并渲染至 RGB 空间,因此速率产品为 3 通道,从山体阴影至 NDWI 的所有灰度影像均为单通道。

6.4 实验结果与分析

6.4.1 机器学习识别结果及分析

研究以 InSAR 形变量数据和 Google 影像结合获取了研究区域内 104 处潜在滑坡为研究对象。采用多源遥感数据和机器学习相结合,对潜在滑坡提取进行研究。研究选用 30 米分辨率的 Landsat8 数据的蓝、绿和红波段数据合成的真彩色图像,红波和近红外波段计算 NDVI, SRTM 30m DEM 数据,以及利用 InSAR 技术和 Sentinel 数据获取的 2019 年形变数据作为数据源进行本研究。




图 6.8 研究区归一化植被指数、DEM 和 InSAR 形变速率

采用随机森林(RF)是利用每个决策树预测一个输出和每个输出是由它所获得的选票的价值来衡量的。对产出的多数投票以及拟合收敛程度,产生最终的分类结果。经过多次实验,发现 100 棵决策树时实验结果最优。支持向量机(SVM)是在分离过程中找到

最优超平面定义的类之间的边界最大。在研究中，应用了 RBF 核，gamma 参数为 0.9。人工神经网络(ANN)方法采用多层感知器(MLP)体系结构，使用反向传播算法(BPA)训练。

表 6-3 机器学习方法精度统计

方法	精度	F1	准确度
支持向量机	0.8127	0.4960	0.4311
随机森林	0.8026	0.5091	0.4722
人工神经网络	0.7135	0.3577	0.3546

精度统计结果显示，RF 算法在模型精度统计中均优于支持向量机和人工神经网络算法。随机森林算法和支持向量机在模型精度表现相当，而 F1 和准确度均高于支持向量机，人工神经网络在样本不均衡情况下易存在误分类，精度指数均表现不佳。




图 6.9 随机森林、人工神经网络和支持向量机分类结果

随机森林算法、支持向量机算法及人工神经网络算法对面积较大的滑坡体均有较好的识别，而对小面积滑坡体的识别均不够好。通常认为识别结果中，若能占到滑坡面积

的 25%则为成功识别。由于识别过程是输入大影像，对其进行顺序裁剪，然后逐像素识别，容易遗漏小面积滑坡。且在识别过程中，较多的依赖形变量，未能提取到更高层次的语义信息，导致滑坡识别较为破碎，识别不完整。这是由于方法本身所局限的。

通过多源数据和机器学习算法结合在一定程度上降低人工和野外调查的时间和费用成本，具有可行性。随机森林算法在识别结果中的表现优于支持向量机和人工神经网络。支持向量机在三种方法中表现不佳。受到机器学习方法的局限性和数据样本较小等因素的影响，未能提取到高层语义信息，滑坡要素识别不完整。

6.4.2 不同输入特征的深度学习实验结果及分析

首先采用 2.3.3.3 中介绍的 ResUNet 模型对比了两种情况，采用目视解译的基础数据：速率（3 通道）、山体阴影（1 通道）。实验 1 加入三个地形因子（7 通道），实验 2 采用速率、山体阴影、3 个地形因子、3 个光谱因子共 10 通道。如表 6-4 所示。展示了不同输入因子的性能评估。第一行的组合因子包括“速率、山体阴影和地形因子”，总共有 7 个因子，模型的精准率为 0.7512，召回率为 0.6231，F1 值为 0.6456，平均交并比（mIoU）为 0.5267。第二行则增加了光谱因子，总数量达到 10 个因子，其 Precision 降至 0.7064，但 Recall 提高至 0.7448，F1 值为 0.7009，mIoU 为 0.5793。这表明，尽管增加光谱因子使得精准率有所下降，但召回率和 F1 值均有所提升。

表 6-4 不同数据组合精度统计

序号	输入因子	数量	Precision	Recall	F1	mIoU
1	速率+山体阴影 +地形因子	7	0.7512	0.6231	0.6456	0.5267
2	速率+山体阴影 +地形因子+光 谱因子	10	0.7064	0.7448	0.7009	0.5793

从表中可以看出，增加光谱因子后，虽然精准率有所下降（从 0.7512 降至 0.7064），但召回率却显著提高（从 0.6231 升至 0.7448），这可能表明模型在检测到更多正样本方面表现更好。然而，精准率的下降意味着模型可能出现了更多的假阳性。推测可能是，光谱因子的引入增强了模型对某些特征的敏感性，导致其能更有效地捕捉到潜在的滑坡区域，但同时也增加了误判的风险。整体来看，F1 值和 mIoU 的提升（F1 从 0.6456 升至 0.7009，mIoU 从 0.5267 升至 0.5793）表明模型的综合性能有了改善，尤其是在处理

更复杂的场景时，增加光谱因子可能带来了更好的平衡。在选择输入因子时，需要权衡精准率和召回率，以实现最佳的检测效果。

图 6.10 展示了使用不同输入因子对滑坡检测结果的可视化比较。图像分为四列，每列分别代表不同的输入因子组合：第一列是形变速率，第二列是标签+地形因子。第三列为地形因子，加入了地形特征来帮助检测滑坡区域，显示出较为明显的滑坡边界；第四列是地形因子+光谱因子，在地形基础上加入了光谱信息，显示检测结果更加细化。

从视觉上看，第三列和第四列的滑坡区域检测结果与第二列相比更加精细，特别是在加入光谱因子后，边界更加明确，可能检测到了更多的滑坡区域。结合精度统计在只有“速率+山体阴影+地形因子”的情况下，模型的精准率较高（0.7512），但召回率较低（0.6231），反映在图上可能是第二列中黄色区域相对较少，表示检测出的滑坡区域有限；




图 6.10 多模态样本输出结果可视化结果

当加入“光谱因子”后，召回率显著提高（0.7448），表现在图的第四列中，滑坡区域的检测数量有所增加，且边界更加清晰。然而，精准率略有下降，说明可能误检了一些区域（图中红色部分）。通过对比可以推测，增加光谱因子有助于提高滑坡区域的覆盖

率，但可能也会带来误检的情况，因此考虑以速率约束的双输入模型，以平衡精准率和召回率。

6.4.3 不同深度学习模型多模态输入对比实验及分析

从表 6-5 中可以看出，加入了速率约束模块的 MMNet 模型在多个指标上表现均优于 ResUNet 模型，具体表现如下：ResUNet 的精准率为 0.7064，而 MMNet 的精准率为 0.7501。这表明 MMNet 模型更进一步减少误报，意味着其检测出的滑坡区域中有更高比例是真实的。ResUNet 的召回率为 0.7448，而 MMNet 的召回率略微下降为 0.7385。虽然召回率略有降低，但幅度不大，表明 MMNet 仍能检测出大部分滑坡区域。F1 值是精准率和召回率的平衡指标，MMNet 的 F1 值为 0.7193，高于 ResUNet 的 0.7009，说明 MMNet 在平衡精准率和召回率方面表现更好，整体检测效果更为理想。ResUNet 的 mIoU 为 0.5793，而 MMNet 的 mIoU 为 0.6057。交并比的提升表明，MMNet 模型预测的滑坡区域与真实区域的重合度更高，检测结果更准确。

表 6-5 不同模型精度统计

模型	Precision	Recall	F1	mIoU
ResUNet	0.7064	0.7448	0.7009	0.5793
MMNet	0.7501	0.7385	0.7193	0.6057

MMNet 由于引入了速率约束模块，改善了模型在精准率和 IoU 上的表现。速率约束模块通过捕捉地表形变速率相关的特征，增强了模型对滑坡区域的识别能力，使 MMNet 模型在减少误检的同时，保持了较好的检测覆盖率。这与表 6-4 显示的引入多个输入因子（如地形和光谱因子）提升模型性能的趋势相符，说明增加特定的约束条件或输入因子能够帮助模型更准确地检测滑坡区域。

图 6.11 第三列代表 ResUNet 模型的检测结果，第四列代表加入了速率约束模块的 MMNet 模型的检测结果。图中，绿色为真阳性，红色为假阳性，蓝色为假阴性。通过这两列的对比，发现 ResUNet 模型（第三列）的真阳性存在覆盖不完全的情况，说明模型在检测滑坡区域时存在一定的不稳定性。MMNet 模型（第四列）的绿色区域更为集中，覆盖了更多真实滑坡区域，同时噪声较少，表明加入速率约束模块后，模型在滑坡区域的识别上更加精准。在 ResUNet 中，红色误检区域较多，表明模型容易将非滑坡区域误认为滑坡，尤其是在地形复杂的区域。MMNet 的红色误检显著减少，展示了速率约束模

块的有效性，帮助模型排除了更多的噪声数据。漏检区域（蓝色）：在 ResUNet 中，蓝色区域较为分散，说明模型有更多的滑坡区域未能检测到。相比之下，MMNet 的蓝色区域减少，表明速率约束模块改善了模型的召回率，使得更多的滑坡区域被正确检测。

ResUNet 的表现受限于误检和漏检较多，虽然在一定程度上可以检测滑坡区域，但在复杂场景中表现不够稳定。MMNet 在加入速率约束模块后，不仅减少了误检，还提高了滑坡区域的检测准确率和召回率，整体性能得到提升，符合表 6-5 中 MMNet 在 Precision、mIoU 上的优势。

加入速率约束模块的 MMNet 相较于 ResUNet 明显提高了滑坡检测的精准度，并减少了误检和漏检。这也与表 6-5 中的数值结果一致，表明速率约束模块在提升滑坡检测模型性能方面起到了关键作用。




图 6.11 ResUNet 和 MMNet 识别可视化图

6.4.4 测试区可视化结果分析

图 6.12 展示了不同的模型和输入数据在测试区的编目结果。6.12 (a)是测试区的形变速率，6.12 (b)是以速率为输入的 ResUNet 的编目结果，6.12 (c)是以多模态数据为输入 ResUNet 的编目结果，6.12 (d)是多模态数据输入 MMNet 的编目结果。从图 6.12 中

可以看出, 所提的 MMNet 模型通过速率引导模块可以增加多模态数据中对速率不敏感导致的漏判, 相对于仅有速率输入的噪声抑制也十分显著 (相比于 6.12 (a))。

由此可得, 引入多模态数据可能导致速率数据的信息被辅助的光学因子和地形因子淹没 (6.12 (c)), 导致减少错判的同时增加了漏判。但是, 通过速率引导的多模态输入网络能显著减少漏判, 同时提高仅有速率输入时过多的错判, 是一种高效的自动化潜在滑坡编目方法。




图 6.12 测试区编目可视化结果

6.5 本章小结

针对单一 InSAR 数据和深度学习方法进行潜在滑坡编目边界不准确, 存在错判漏判的问题, 本章采用 InSAR、光学和 DEM 联合的多模态数据集, 并设计了一种多模态输入的速率约束模型, 以提高潜在滑坡形态编目的精度。

研究结合形变速率、光谱因子和地形因子联合构建了潜在滑坡编目的数据集, 其中光谱因子包括归一化植被指数、归一化建筑指数和归一化水体指数, 地形因子包括高程、坡度、坡向。模型方面设计了一种多模态输入的速率约束模型, 通过双端输入提取多模态的信息, 通过速率约束模块中的注意力机制调节速率和多模态之间的决策权重。实验结果表明, 与传统机器学习方法相比, 深度学习方法能全面提升编目效率, 减少椒盐噪声, 提高编目精度。多模态数据能有效减少错判漏判, 显著提升查全率。所提出的 MMNet

相比于单模态网络对多模态数据具有更好的提取能力，同时顾及光学影像、DEM 和 InSAR 的形变特征。采用速率约束模块的 MMNet 能够有效提高潜在滑坡编目的效率和精度。

目前所设计的网络还存在部分背景噪声去除不彻底的现象，在接下来的研究中，考虑进一步改进网络结构，提高多模态数据下潜在滑坡编目的精度。此外，采用多模态数据量较大，需要强大的算力支持，对硬件需求高，需要开发轻量级模型结构以推广应用在更大尺度的区域。在获取滑坡形态的基础上，如何区分滑坡、崩塌、泥石流则需要更丰富的样本、复杂的地学知识支持，采用知识驱动模型进行进一步编目是未来工作的探索方向。

第七章 总结与展望

本章梳理了本文相关研究的工作，总结了研究工作的结论和创新点，并在此基础上分析了研究不足，并展望下一步工作计划和内容。

7.1 研究成果与结论

随着深度学习在地学领域中的不断探索和应用，滑坡编目工作迎来了新的发展机遇。本文从国内外研究学者在该方面的研究成果出发，围绕深度学习在滑坡编目中的问题和局限性，从单时相已发生滑坡编目、双时相事件诱发型滑坡编目、融合 InSAR 产品潜在滑坡位置编目到多模态遥感数据潜在滑坡形态编目，对已发生滑坡和潜在滑坡编目中存在的问题开展了研究工作。主要研究结论如下：

（1）针对精确滑坡样本不足，样本不均衡的问题。研究通过多组数据增强实验证明，有效的数据增强可以降低数据结构的不均衡比，显著提高滑坡编目的精度；所采用的焦点损失函数能降低背景损失值对模型影响，提高少数类对模型损失值的贡献，增强模型对正样本的学习能力；此外，K-折交叉验证能提高结果的鲁棒性。

（2）针对事件诱发型滑坡光谱差异造成变化检测的噪声问题。研究采用的独立成分分析法（ICA）对 13 个辅助光谱特征、纹理特征进行分析，可以改善类内同质性，增强类间异质性，降低多特征造成的噪声影响。研究表明，采用具有多尺度特征跳跃连接的深度监督 UNet3+，有助于减少复杂背景的影响。

（3）针对单一 InSAR 产品和深度学习编目滑坡位置不准确的问题。研究结合 InSAR 形变速率、相位梯度和从 DEM 导出的 C 指数，建立了缓变型滑坡数据集，提出了一种改进的目标检测网络，进行多尺度信息的提取和融合。实验结果显示，融合的数据集能具有准确的边界和连续的栅格数据，相比于单一数据集显著提升潜在滑坡位置编目的精度，并具有较好的泛化性。

（4）针对单一 InSAR 产品滑坡形态编目不准确，错判漏判的问题。研究构建了一个多模态缓变型滑坡编目数据集，提出了一种跨模态变化检测方法，对光谱因子、地形因子和 InSAR 形变速率的输入特征互补，并以速率约束形成稳定的预测结果。实验结果证明，多模态数据能显著提升潜在滑坡编目的精度，减少错判漏判，所提出的网络可有效增强多模态联合特征，并提升速率决策贡献，明显优于机器学习算法，提升潜在滑坡形态编目的效率。

7.2 研究创新点

(1) 提出了一种小样本滑坡编目的策略,采用数据增强、损失函数改进和 K-折交叉验证提高了编目精度,为单时相已发生滑坡编目提供参考。

(2) 采用多特征变化检测、独立成分分析和多尺度深度监督网络,抑制了复杂光谱场景下变化检测噪声,提高了事件诱发型滑坡编目的精度。

(3) 建立了结合形变速率和相位梯度的潜在滑坡位置编目数据集,提出了改进的 Yolo 网络通过多尺度信息提取和融合进行潜在滑坡位置编目的方法,为潜在滑坡位置编目提供了研究基础。

(4) 建立了光谱因子、地形因子和形变速率结合的潜在滑坡形态编目数据集,提出了一种多模态输入的网络结构,利用速率约束模块实现潜在滑坡自动化编目,探索了多模态数据滑坡编目的可行性。

7.3 问题与展望

本文在已有研究基础上,分析了数据源以及模型在滑坡编目中的影响,通过解译的数据集进行了已发生滑坡编目和潜在滑坡编目的方法提升。由于数据不够丰富,在数据解译,模型对比方面还不够完善,论文仍存在诸多不足之处需进一步研究:

(1) 已发生滑坡在长时间样本库缺乏多元性,在植被覆盖率高,滑坡“擦伤”明显的区域泛化性较好,而植被覆盖度低,滑坡面积小的区域则自动提取能力不足,需要考虑多源数据融合编目的应用尝试。

(2) 事件诱发型滑坡编目通常需要高时效性,以服务于灾害应急救援。而光学影像通常在灾害发生容易收到云雾影响,合成孔径雷达数据可以用于事件型滑坡的编目,但纹理信息不足,精度低。因此需要进一步融合异构影像在事件诱发型灾害编目中的应用。

(3) 潜在滑坡编目依赖于光学影像和 InSAR 产品,需要结合地质数据,地理环境因素等影响综合判断,目前所采用的数据集未能考虑到多因素的影响,因此需要进一步开展知识驱动的潜在滑坡编目研究。

(4) 滑坡编目的目的是为了应急救援和防灾减灾,因此在获取编目结果后需要进一步分析其分布和主控因素的影响,分析相关的致灾因子,以提供可靠的灾害应急管理方案。

参考文献

- [1] Guzzetti F. Landslide Hazard and Risk Assessment [D]. Perugia, Italy: University of Perugia, 2006.
- [2] 王治华. 滑坡遥感 [M]. 北京: 科学出版社, 2012.
- [3] Song C, Yu C, Li Z, et al. Triggering and recovery of earthquake accelerated landslides in Central Italy revealed by satellite radar observations [J/OL]. *Nature Communications*, 2022, 13(1): 7278. DOI:10.1038/s41467-022-35035-5.
- [4] Peng J, Fan Z, Wu D, et al. Heavy rainfall triggered loess–mudstone landslide and subsequent debris flow in Tianshui, China [J/OL]. *Engineering Geology*, 2015, 186: 79-90. DOI:10.1016/j.enggeo.2014.08.015.
- [5] Gariano S L, Guzzetti F. Landslides in a changing climate [J/OL]. *Earth-Science Reviews*, 2016, 162: 227-252. DOI:10.1016/j.earscirev.2016.08.011.
- [6] 许强, 陆会燕, 李为乐, 等. 滑坡隐患类型与对应识别方法 [J/OL]. *武汉大学学报 (信息科学版)*, 2022, 47(3): 377-387. DOI:10.13203/j.whugis20210618.
- [7] 殷跃平. 地质灾害风险调查评价方法与应用实践[J]. *中国地质灾害与防治学报*, 2022, 33(4): 5-6.
- [8] Bai S, Lu P, Thiebes B. Comparing characteristics of rainfall- and earthquake-triggered landslides in the Upper Minjiang catchment, China [J/OL]. *Engineering Geology*, 2020, 268: 105518. DOI:10.1016/j.enggeo.2020.105518.
- [9] Lu P, Qin Y, Li Z, et al. Landslide mapping from multi-sensor data through improved change detection-based Markov random field [J/OL]. *Remote Sensing of Environment*, 2019, 231: 111235. DOI:10.1016/j.rse.2019.111235.
- [10] 殷跃平. 中国地质灾害减灾战略初步研究[J]. *中国地质灾害与防治学报*, 2004(2): 4-11.
- [11] Dai L, Fan X, Wang X, et al. Coseismic landslides triggered by the 2022 Luding Ms6.8 earthquake, China [J/OL]. *Landslides*, 2023, 20(6): 1277-1292. DOI:10.1007/s10346-023-02061-3.

-
- [12] Gorum T, Korup O, van Westen C J, et al. Why so few? Landslides triggered by the 2002 Denali earthquake, Alaska [J/OL]. Quaternary Science Reviews, 2014, 95: 80-94. DOI:10.1016/j.quascirev.2014.04.032.
- [13] Ling S, Sun C, Li X, et al. Characterizing the distribution pattern and geologic and geomorphic controls on earthquake-triggered landslide occurrence during the 2017 Ms 7.0 Jiuzhaigou earthquake, Sichuan, China [J/OL]. Landslides, 2021, 18(4): 1275-1291. DOI:10.1007/s10346-020-01549-6.
- [14] Braham N A A, Mairal J, Chanussot J, et al. Enhancing Contrastive Learning with Positive Pair Mining for Few-shot Hyperspectral Image Classification [J/OL]. IEEE Journal of Selected Topics in Applied Earth Observations and Remote Sensing, 2024: 1-18. DOI:10.1109/JSTARS.2024.3371909.
- [15] Chen L, Zhao C, Li B, et al. Deformation monitoring and failure mode research of mining-induced Jianshanying landslide in karst mountain area, China with ALOS/PALSAR-2 images [J/OL]. Landslides, 2021, 18(8): 2739-2750. DOI:10.1007/s10346-021-01678-6.
- [16] Wu Z, Wang T, Wang Y, et al. Deep Learning for the Detection and Phase Unwrapping of Mining-Induced Deformation in Large-Scale Interferograms [J/OL]. IEEE Transactions on Geoscience and Remote Sensing, 2022, 60: 1-18. DOI:10.1109/TGRS.2021.3121907.
- [17] Lacroix P, Dehecq A, Taipe E. Irrigation-triggered landslides in a Peruvian desert caused by modern intensive farming [J/OL]. Nature Geoscience, 2020, 13(1): 56-60. DOI:10.1038/s41561-019-0500-x.
- [18] Koller C, Kauermann G, Zhu X X. Going Beyond One-Hot Encoding in Classification: Can Human Uncertainty Improve Model Performance in Earth Observation? [J/OL]. IEEE Transactions on Geoscience and Remote Sensing, 2024, 62: 1-11. DOI:10.1109/TGRS.2023.3336357.
- [19] Ubydul Haque, Paula F.da Silva, Graziella Devoli, et al. The human cost of global warming: Deadly landslides and their triggers (1995–2014)[J]. Science of The Total Environment, 2019, 682(1-2): 673-684.

- [20] 许强, 董秀军, 李为乐. 基于天-空-地一体化的重大地质灾害隐患早期识别与监测预警 [J/OL]. 武汉大学学报 (信息科学版), 2019, 44(7): 957-966. DOI:10.13203/j.whugis20190088.
- [21] 张勤, 赵超英, 陈雪蓉. 多源遥感地质灾害早期识别技术进展与发展趋势[J]. 测绘学报, 2022, 51(6): 885-896.
- [22] Guzzetti F, Mondini A C, Cardinali M, et al. Landslide inventory maps: New tools for an old problem [J/OL]. Earth-Science Reviews, 2012, 112(1-2): 42-66. DOI:10.1016/j.earscirev.2012.02.001.
- [23] Reichenbach P, Rossi M, Malamud B D, et al. A review of statistically-based landslide susceptibility models [J/OL]. Earth-Science Reviews, 2018, 180: 60-91. DOI:10.1016/j.earscirev.2018.03.001.
- [24] Xue Z, Xu C, Gao H, et al. Disaster chain thinking improves the capabilities of disaster prevention, mitigation, and relief in China [J/OL]. Natural Hazards Research, 2023: S2666592123001233. DOI:10.1016/j.nhres.2023.11.013.
- [25] Mondini A C, Chang K tsung. Combining spectral and geoenvironmental information for probabilistic event landslide mapping [J/OL]. Geomorphology, 2014, 213: 183-189. DOI:10.1016/j.geomorph.2014.01.007.
- [26] Lan H, Liu X, Li L, et al. Remote Sensing Precursors Analysis for Giant Landslides [J/OL]. Remote Sensing, 2022, 14(17): 4399. DOI:10.3390/rs14174399.
- [27] Xu Q, Zhao B, Dai K, et al. Remote sensing for landslide investigations: A progress report from China [J/OL]. Engineering Geology, 2023, 321: 107156. DOI:10.1016/j.enggeo.2023.107156.
- [28] Zhong C, Liu Y, Gao P, et al. Landslide mapping with remote sensing: challenges and opportunities [J/OL]. International Journal of Remote Sensing, 2020, 41(4): 1555-1581. DOI:10.1080/01431161.2019.1672904.
- [29] Alexander D E. A brief survey of GIS in mass-movement studies, with reflections on theory and methods [J/OL]. Geomorphology, 2008, 94(3-4): 261-267. DOI:10.1016/j.geomorph.2006.09.022.

- [30] Li Y, Chen G, Han Z, et al. A hybrid automatic thresholding approach using panchromatic imagery for rapid mapping of landslides [J/OL]. *GIScience & Remote Sensing*, 2014, 51(6): 710-730. DOI:10.1080/15481603.2014.972867.
- [31] 许冲, 戴福初, 姚鑫, 等. GIS 支持下基于层次分析法的汶川地震区滑坡易发性评价[J]. *岩石力学与工程学报*, 2009, 28(S2): 3978-3985.
- [32] Metternicht G, Hurni L, Gogu R. Remote sensing of landslides: An analysis of the potential contribution to geo-spatial systems for hazard assessment in mountainous environments [J/OL]. *Remote Sensing of Environment*, 2005, 98(2-3): 284-303. DOI:10.1016/j.rse.2005.08.004.
- [33] Vance T C, Huang T, Butler K A. Big data in Earth science: Emerging practice and promise [J/OL]. *Science*, 2024, 383(6688): eadh9607. DOI:10.1126/science.adh9607.
- [34] Ghorbanzadeh O, Blaschke T, Gholamnia K, et al. Evaluation of Different Machine Learning Methods and Deep-Learning Convolutional Neural Networks for Landslide Detection [J/OL]. *Remote Sensing*, 2019, 11(2): 196. DOI:10.3390/rs11020196.
- [35] Chen X, Zhao C, Xi J, et al. Deep Learning Method of Landslide Inventory Map with Imbalanced Samples in Optical Remote Sensing [J/OL]. *Remote Sensing*, 2022, 14(21): 5517. DOI:10.3390/rs14215517.
- [36] Martha T R, Kerle N, van Westen C J, et al. Segment Optimization and Data-Driven Thresholding for Knowledge-Based Landslide Detection by Object-Based Image Analysis [J/OL]. *IEEE Transactions on Geoscience and Remote Sensing*, 2011, 49(12): 4928-4943. DOI:10.1109/TGRS.2011.2151866.
- [37] Lasko K. Gap Filling Cloudy Sentinel-2 NDVI and NDWI Pixels with Multi-Frequency Denoised C-Band and L-Band Synthetic Aperture Radar (SAR), Texture, and Shallow Learning Techniques [J/OL]. *Remote Sensing*, 2022, 14(17): 4221. DOI:10.3390/rs14174221.
- [38] Lu P, Stumpf A, Kerle N, et al. Object-Oriented Change Detection for Landslide Rapid Mapping [J/OL]. *IEEE Geoscience and Remote Sensing Letters*, 2011, 8(4): 701-705. DOI:10.1109/LGRS.2010.2101045.

- [39] Li Z, Shi W, Lu P, et al. Landslide mapping from aerial photographs using change detection-based Markov random field [J/OL]. *Remote Sensing of Environment*, 2016, 187: 76-90. DOI:10.1016/j.rse.2016.10.008.
- [40] Hungr O, Leroueil S, Picarelli L. The Varnes classification of landslide types, an update [J/OL]. *Landslides*, 2014, 11(2): 167-194. DOI:10.1007/s10346-013-0436-y.
- [41] Gutiérrez F, Parise M, De Waele J, et al. A review on natural and human-induced geohazards and impacts in karst [J/OL]. *Earth-Science Reviews*, 2014, 138: 61-88. DOI:10.1016/j.earscirev.2014.08.002.
- [42] 张茂省, 雷学武, 校培喜, 等. 遥感技术在黄土高原区地质灾害详细调查中的应用[J]. *西北地质*, 2007(3): 92-97.
- [43] Bontemps N, Lacroix P, Doin M P. Inversion of deformation fields time-series from optical images, and application to the long term kinematics of slow-moving landslides in Peru [J/OL]. *Remote Sensing of Environment*, 2018, 210: 144-158. DOI:10.1016/j.rse.2018.02.023.
- [44] 王治华. 滑坡遥感调查、监测与评估 [J]. *国土资源遥感*, 2007(1): 10-15+23+103.
- [45] 许冲, 徐锡伟. 2008 年汶川地震导致的斜坡物质响应率及其空间分布规律分析[J]. *岩石力学与工程学报*, 2013, 32(S2): 3888-3908.
- [46] Arinta R R, Andi W.R. E. Natural Disaster Application on Big Data and Machine Learning: A Review[C/OL]//2019 4th International Conference on Information Technology, Information Systems and Electrical Engineering (ICITISEE). Yogyakarta, Indonesia: IEEE, 2019: 249-254. DOI:10.1109/ICITISEE48480.2019.9003984.
- [47] Keyport R N, Oommen T, Martha T R, et al. A comparative analysis of pixel- and object-based detection of landslides from very high-resolution images [J/OL]. *International Journal of Applied Earth Observation and Geoinformation*, 2018, 64: 1-11. DOI:10.1016/j.jag.2017.08.015.
- [48] Su Z, Chow J K, Tan P S, et al. Deep convolutional neural network-based pixel-wise landslide inventory mapping [J/OL]. *Landslides*, 2021, 18(4): 1421-1443. DOI:10.1007/s10346-020-01557-6.

- [49] Xu Y, Lu Z, Schulz W H, et al. Twelve-Year Dynamics and Rainfall Thresholds for Alternating Creep and Rapid Movement of the Hooskanaden Landslide From Integrating InSAR, Pixel Offset Tracking, and Borehole and Hydrological Measurements [J/OL]. Journal of Geophysical Research: Earth Surface, 2020, 125(10): e2020JF005640. DOI:10.1029/2020JF005640.
- [50] Chen T, Trinder J, Niu R. Object-Oriented Landslide Mapping Using ZY-3 Satellite Imagery, Random Forest and Mathematical Morphology, for the Three-Gorges Reservoir, China [J/OL]. Remote Sensing, 2017, 9(4): 333. DOI:10.3390/rs9040333.
- [51] Dou J, Chang K T, Chen S, et al. Automatic Case-Based Reasoning Approach for Landslide Detection: Integration of Object-Oriented Image Analysis and a Genetic Algorithm [J/OL]. Remote Sensing, 2015, 7(4): 4318-4342. DOI:10.3390/rs70404318.
- [52] Rau J Y, Chen L C, Liu J K, et al. Dynamics Monitoring and Disaster Assessment for Watershed Management Using Time-Series Satellite Images [J/OL]. IEEE Transactions on Geoscience and Remote Sensing, 2007, 45(6): 1641-1649. DOI:10.1109/TGRS.2007.894928.
- [53] Li Z, Shi W, Myint S W, et al. Semi-automated landslide inventory mapping from bitemporal aerial photographs using change detection and level set method [J/OL]. Remote Sensing of Environment, 2016, 175: 215-230. DOI:10.1016/j.rse.2016.01.003.
- [54] Yang W, Wang Y, Sun S, et al. Using Sentinel-2 time series to detect slope movement before the Jinsha River landslide [J/OL]. Landslides, 2019, 16(7): 1313-1324. DOI:10.1007/s10346-019-01178-8.
- [55] Pawluszek K, Borkowski A, Tarolli P. Sensitivity analysis of automatic landslide mapping: numerical experiments towards the best solution [J/OL]. Landslides, 2018, 15(9): 1851-1865. DOI:10.1007/s10346-018-0986-0.
- [56] Stumpf A, Lachiche N, Malet J P, et al. Active Learning in the Spatial Domain for Remote Sensing Image Classification [J/OL]. IEEE Transactions on Geoscience and Remote Sensing, 2014, 52(5): 2492-2507. DOI:10.1109/TGRS.2013.2262052.

- [57] Stumpf A, Malet J P, Delacourt C. Correlation of satellite image time-series for the detection and monitoring of slow-moving landslides [J/OL]. Remote Sensing of Environment, 2017, 189: 40-55. DOI:10.1016/j.rse.2016.11.007.
- [58] Behling R, Roessner S, Kaufmann H, et al. Automated Spatiotemporal Landslide Mapping over Large Areas Using RapidEye Time Series Data [J/OL]. Remote Sensing, 2014, 6(9): 8026-8055. DOI:10.3390/rs6098026.
- [59] Anantrasirichai N, Biggs J, Kelevitz K, et al. Detecting Ground Deformation in the Built Environment using Sparse Satellite InSAR data with a Convolutional Neural Network[J]. 2020.
- [60] 龚健雅, 季顺平. 摄影测量与深度学习[J]. 测绘学报, 2018, 47(6): 693-704.
- [61] Zhang L, Zhang L, Du B. Deep Learning for Remote Sensing Data: A Technical Tutorial on the State of the Art [J/OL]. IEEE Geoscience and Remote Sensing Magazine, 2016, 4(2): 22-40. DOI:10.1109/MGRS.2016.2540798.
- [62] Zhu X X, Tuia D, Mou L, et al. Deep Learning in Remote Sensing: A Comprehensive Review and List of Resources [J/OL]. IEEE Geoscience and Remote Sensing Magazine, 2017, 5(4): 8-36. DOI:10.1109/MGRS.2017.2762307.
- [63] Casagli N, Intrieri E, Tofani V, et al. Landslide detection, monitoring and prediction with remote-sensing techniques [J/OL]. Nature Reviews Earth & Environment, 2023, 4(1): 51-64. DOI:10.1038/s43017-022-00373-x.
- [64] Ji S, Yu D, Shen C, et al. Landslide detection from an open satellite imagery and digital elevation model dataset using attention boosted convolutional neural networks [J/OL]. Landslides, 2020, 17(6): 1337-1352. DOI:10.1007/s10346-020-01353-2.
- [65] Lei T, Zhang Y, Lv Z, et al. Landslide Inventory Mapping From Bitemporal Images Using Deep Convolutional Neural Networks [J/OL]. IEEE Geoscience and Remote Sensing Letters, 2019, 16(6): 982-986. DOI:10.1109/LGRS.2018.2889307.
- [66] 巨袁臻, 许强, 金时超, 等. 使用深度学习方法实现黄土滑坡自动识别 [J/OL]. 武汉大学学报(信息科学版), 2020, 45(11): 1747-1755. DOI:10.13203/j.whugis20200132.

- [67] 姜万冬, 席江波, 李振洪, 等. 模拟困难样本的 Mask R-CNN 滑坡分割识别 [J/OL]. 武汉大学学报 (信息科学版), 2023, 48(12): 1931-1942. DOI:10.13203/j.whugis20200692.
- [68] Franklin S E. Interpretation and use of geomorphometry in remote sensing: a guide and review of integrated applications [J/OL]. International Journal of Remote Sensing, 2020, 41(19): 7700-7733. DOI:10.1080/01431161.2020.1792577.
- [69] Prakash N, Manconi A, Loew S. Mapping Landslides on EO Data: Performance of Deep Learning Models vs. Traditional Machine Learning Models [J/OL]. Remote Sensing, 2020, 12(3): 346. DOI:10.3390/rs12030346.
- [70] Jing X Y, Zhang X, Zhu X, et al. Multiset Feature Learning for Highly Imbalanced Data Classification [J/OL]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2021, 43(1): 139-156. DOI:10.1109/TPAMI.2019.2929166.
- [71] Yang H, Shi P, Quincey D, et al. A Heterogeneous Sampling Strategy to Model Earthquake-Triggered Landslides [J/OL]. International Journal of Disaster Risk Science, 2023, 14(4): 636-648. DOI:10.1007/s13753-023-00489-8.
- [72] Qi W, Wei M, Yang W, et al. Automatic Mapping of Landslides by the ResU-Net [J/OL]. Remote Sensing, 2020, 12(15): 2487. DOI:10.3390/rs12152487.
- [73] Cao Y, Hamling I, Massey C, et al. Slow-Moving Landslides Triggered by the 2016 Mw 7.8 Kaikōura Earthquake, New Zealand: A New InSAR Phase-Gradient Based Time-Series Approach [J/OL]. Geophysical Research Letters, 2023, 50(4): e2022GL102064. DOI:10.1029/2022GL102064.
- [74] Chen H, He Y, Zhang L, et al. A Multi-Input Channel U-Net Landslide Detection Method Fusing SAR Multisource Remote Sensing Data [J/OL]. IEEE Journal of Selected Topics in Applied Earth Observations and Remote Sensing, 2024, 17: 1215-1232. DOI:10.1109/JSTARS.2023.3339294.
- [75] Görüm T. Landslide recognition and mapping in a mixed forest environment from airborne LiDAR data [J/OL]. Engineering Geology, 2019, 258: 105155. DOI:10.1016/j.enggeo.2019.105155.

- [76] Yang Z qiang, Qi W wen, Xu C, et al. Exploring deep learning for landslide mapping: A comprehensive review[J]. China Geology, 2024.
- [77] Zhang S, Zhang L M, Glade T. Characteristics of earthquake- and rain-induced landslides near the epicenter of Wenchuan earthquake [J/OL]. Engineering Geology, 2014, 175: 58-73. DOI:10.1016/j.enggeo.2014.03.012.
- [78] Wang J, Jaboyedoff M, Chen G, et al. Landslide susceptibility prediction and mapping using the LD-BiLSTM model in seismically active mountainous regions [J/OL]. Landslides, 2023[2023-10-16]. <https://link.springer.com/10.1007/s10346-023-02141-4>. DOI:10.1007/s10346-023-02141-4.
- [79] Zhang Q, Wang T. Deep Learning for Exploring Landslides with Remote Sensing and Geo-Environmental Data: Frameworks, Progress, Challenges, and Opportunities [J/OL]. Remote Sensing, 2024, 16(8): 1344. DOI:10.3390/rs16081344.
- [80] Bergamasco L, Bovolo F, Bruzzone L. A Dual-Branch Deep Learning Architecture for Multi-Sensor and Multi-Temporal Remote Sensing Semantic Segmentation [J/OL]. IEEE Journal of Selected Topics in Applied Earth Observations and Remote Sensing, 2023: 1-16. DOI:10.1109/JSTARS.2023.3243396.
- [81] Lee H, Li W. Improving interpretability of deep active learning for flood inundation mapping through class ambiguity indices using multi-spectral satellite imagery [J/OL]. Remote Sensing of Environment, 2024, 309: 114213. DOI:10.1016/j.rse.2024.114213.
- [82] Zhu Q, Liao C, Hu H, et al. MAP-Net: Multiple Attending Path Neural Network for Building Footprint Extraction From Remote Sensed Imagery [J/OL]. IEEE Transactions on Geoscience and Remote Sensing, 2021, 59(7): 6169-6181. DOI:10.1109/TGRS.2020.3026051.
- [83] Zheng Z, Zhong Y, Wang J, et al. Building damage assessment for rapid disaster response with a deep object-based semantic change detection framework: From natural disasters to man-made disasters [J/OL]. Remote Sensing of Environment, 2021, 265: 112636. DOI:10.1016/j.rse.2021.112636.

- [84] Zhu Q, Zhang Y, Li Z, et al. Oil Spill Contextual and Boundary-Supervised Detection Network Based on Marine SAR Images [J/OL]. IEEE Transactions on Geoscience and Remote Sensing, 2022, 60: 1-10. DOI:10.1109/TGRS.2021.3115492.
- [85] Zhu Q, Zhang Y, Wang L, et al. A Global Context-aware and Batch-independent Network for road extraction from VHR satellite imagery [J/OL]. ISPRS Journal of Photogrammetry and Remote Sensing, 2021, 175: 353-365. DOI:10.1016/j.isprsjprs.2021.03.016.
- [86] Wang J, Ma A, Zhong Y, et al. Cross-sensor domain adaptation for high spatial resolution urban land-cover mapping: From airborne to spaceborne imagery [J/OL]. Remote Sensing of Environment, 2022, 277: 113058. DOI:10.1016/j.rse.2022.113058.
- [87] Shi W, Zhang M, Ke H, et al. Landslide Recognition by Deep Convolutional Neural Network and Change Detection [J/OL]. IEEE Transactions on Geoscience and Remote Sensing, 2021, 59(6): 4654-4672. DOI:10.1109/TGRS.2020.3015826.
- [88] Liu P, Wei Y, Wang Q, et al. Research on Post-Earthquake Landslide Extraction Algorithm Based on Improved U-Net Model [J/OL]. Remote Sensing, 2020, 12(5): 894. DOI:10.3390/rs12050894.
- [89] Ghorbanzadeh O, Xu Y, Zhao H, et al. The Outcome of the 2022 Landslide4Sense Competition: Advanced Landslide Detection From Multisource Satellite Imagery [J/OL]. IEEE Journal of Selected Topics in Applied Earth Observations and Remote Sensing, 2022, 15: 9927-9942. DOI:10.1109/JSTARS.2022.3220845.
- [90] Nava L, Bhuyan K, Meena S R, et al. Rapid Mapping of Landslides on SAR Data by Attention U-Net [J/OL]. Remote Sensing, 2022, 14(6): 1449. DOI:10.3390/rs14061449.
- [91] Gao X, Chen T, Niu R, et al. Recognition and Mapping of Landslide Using a Fully Convolutional DenseNet and Influencing Factors [J/OL]. IEEE Journal of Selected Topics in Applied Earth Observations and Remote Sensing, 2021, 14: 7881-7894. DOI:10.1109/JSTARS.2021.3101203.
- [92] Soares L P, Dias H C, Garcia G P B, et al. Landslide Segmentation with Deep Learning: Evaluating Model Generalization in Rainfall-Induced Landslides in Brazil [J/OL]. Remote Sensing, 2022, 14(9): 2237. DOI:10.3390/rs14092237.

- [93] Yang Q, Wang X, Zhang X, et al. A Novel Deep Learning Method for Automatic Recognition of Coseismic Landslides [J/OL]. Remote Sensing, 2023, 15(4): 977. DOI:10.3390/rs15040977.
- [94] Han Z, Fu B, Fang Z, et al. Dynahead-YOLO-Otsu: an efficient DCNN-based landslide semantic segmentation method using remote sensing images [J/OL]. Geomatics, Natural Hazards and Risk, 2024, 15(1): 2398103. DOI:10.1080/19475705.2024.2398103.
- [95] Lu W, Hu Y, Shao W, et al. A multiscale feature fusion enhanced CNN with the multiscale channel attention mechanism for efficient landslide detection (MS2LandsNet) using medium-resolution remote sensing data [J/OL]. International Journal of Digital Earth, 2024, 17(1): 2300731. DOI:10.1080/17538947.2023.2300731.
- [96] Ghorbanzadeh O, Shahabi H, Crivellari A, et al. Landslide detection using deep learning and object-based image analysis [J/OL]. Landslides, 2022, 19(4): 929-939. DOI:10.1007/s10346-021-01843-x.
- [97] Wang J, Jaboyedoff M, Chen G, et al. Landslide susceptibility prediction and mapping using the LD-BiLSTM model in seismically active mountainous regions [J/OL]. Landslides, 2023[2023-10-11]. <https://link.springer.com/10.1007/s10346-023-02141-4>. DOI:10.1007/s10346-023-02141-4.
- [98] Wei R. A feature enhancement framework for landslide detection[J]. International Journal of Applied Earth Observation and Geoinformation, 2023.
- [99] Li H, He Y, Xu Q, et al. Semantic segmentation of loess landslides with STAPLE mask and fully connected conditional random field [J/OL]. Landslides, 2023, 20(2): 367-380. DOI:10.1007/s10346-022-01983-8.
- [100] Wu L, Liu R, Ju N, et al. Landslide mapping based on a hybrid CNN-transformer network and deep transfer learning using remote sensing images with topographic and spectral features [J/OL]. International Journal of Applied Earth Observation and Geoinformation, 2024, 126: 103612. DOI:10.1016/j.jag.2023.103612.
- [101] Varnes DJ, Savage W. The Slumgullion earth flow: a large-scale natural laboratory[J]. U.S. Geological Survey Bulletin, 1996, 2130.

- [102] Zhao C, Lu Z. Remote Sensing of Landslides—A Review [J/OL]. Remote Sensing, 2018, 10(2): 279. DOI:10.3390/rs10020279.
- [103] Hu X, Bürgmann R, Schulz W H, et al. Four-dimensional surface motions of the Slumgullion landslide and quantification of hydrometeorological forcing [J/OL]. Nature Communications, 2020, 11(1): 2792. DOI:10.1038/s41467-020-16617-7.
- [104] Xun Z, Zhao C, Kang Y, et al. Automatic Extraction of Potential Landslides by Integrating an Optical Remote Sensing Image with an InSAR-Derived Deformation Map [J/OL]. Remote Sensing, 2022, 14(11): 2669. DOI:10.3390/rs14112669.
- [105] Mondini A C, Guzzetti F, Chang K T, et al. Landslide failures detection and mapping using Synthetic Aperture Radar: Past, present and future [J/OL]. Earth-Science Reviews, 2021, 216: 103574. DOI:10.1016/j.earscirev.2021.103574.
- [106] Liu X, Zhao C, Zhang Q, et al. Integration of Sentinel-1 and ALOS/PALSAR-2 SAR datasets for mapping active landslides along the Jinsha River corridor, China [J/OL]. Engineering Geology, 2021, 284: 106033. DOI:10.1016/j.enggeo.2021.106033.
- [107] Ding L, Tang H, Bruzzone L. LANet: Local Attention Embedding to Improve the Semantic Segmentation of Remote Sensing Images [J/OL]. IEEE Transactions on Geoscience and Remote Sensing, 2021, 59(1): 426-435. DOI:10.1109/TGRS.2020.2994150.
- [108] Robson B A, Bolch T, MacDonell S, et al. Automated detection of rock glaciers using deep learning and object-based image analysis [J/OL]. Remote Sensing of Environment, 2020, 250: 112033. DOI:10.1016/j.rse.2020.112033.
- [109] Wei S, Ji S. Graph Convolutional Networks for the Automated Production of Building Vector Maps From Aerial Images [J/OL]. IEEE Transactions on Geoscience and Remote Sensing, 2022, 60: 1-11. DOI:10.1109/TGRS.2021.3060770.
- [110] Kang Y, Lu Z, Zhao C, et al. Inferring slip-surface geometry and volume of creeping landslides based on InSAR: A case study in Jinsha River basin [J/OL]. Remote Sensing of Environment, 2023, 294: 113620. DOI:10.1016/j.rse.2023.113620.

- [111] Intrieri E, Raspini F, Fumagalli A, et al. The Maoxian landslide as seen from space: detecting precursors of failure with Sentinel-1 data [J/OL]. *Landslides*, 2018, 15(1): 123-133. DOI:10.1007/s10346-017-0915-7.
- [112] Di Traglia F, De Luca C, Manzo M, et al. Joint exploitation of space-borne and ground-based multitemporal InSAR measurements for volcano monitoring: The Stromboli volcano case study [J/OL]. *Remote Sensing of Environment*, 2021, 260: 112441. DOI:10.1016/j.rse.2021.112441.
- [113] Liang R, Dai K, Xu Q, et al. Utilizing a single-temporal full polarimetric Gaofen-3 SAR image to map coseismic landslide inventory following the 2017 Mw 7.0 Jiuzhaigou earthquake (China) [J/OL]. *International Journal of Applied Earth Observation and Geoinformation*, 2024, 127: 103657. DOI:10.1016/j.jag.2024.103657.
- [114] Barra A, Solari L, Béjar-Pizarro M, et al. A Methodology to Detect and Update Active Deformation Areas Based on Sentinel-1 SAR Images [J/OL]. *Remote Sensing*, 2017, 9(10): 1002. DOI:10.3390/rs9101002.
- [115] Festa D, Novellino A, Hussain E, et al. Unsupervised detection of InSAR time series patterns based on PCA and K-means clustering [J/OL]. *International Journal of Applied Earth Observation and Geoinformation*, 2023, 118: 103276. DOI:10.1016/j.jag.2023.103276.
- [116] Crippa C, Valbuzzi E, Frattini P, et al. Semi-automated regional classification of the style of activity of slow rock-slope deformations using PS InSAR and SqueeSAR velocity data [J/OL]. *Landslides*, 2021, 18(7): 2445-2463. DOI:10.1007/s10346-021-01654-0.
- [117] Wang T, Liu M, Zhang H, et al. Landslide Detection Based on Improved YOLOv5 and Satellite Images[C/OL]//2021 4th International Conference on Pattern Recognition and Artificial Intelligence (PRAI). Yibin, China: IEEE, 2021: 367-371[2023-02-15]. <https://ieeexplore.ieee.org/document/9551067/>. DOI:10.1109/PRAI53619.2021.9551067.
- [118] Liang D, Zhang J W, Tang Y P, et al. MUS-CDB: Mixed Uncertainty Sampling With Class Distribution Balancing for Active Annotation in Aerial Object Detection [J/OL].

- IEEE Transactions on Geoscience and Remote Sensing, 2023, 61: 1-13. DOI:10.1109/TGRS.2023.3285443.
- [119] Peng Y, He J, Yuan Q, et al. Automated glacier extraction using a Transformer based deep learning approach from multi-sensor remote sensing imagery [J/OL]. ISPRS Journal of Photogrammetry and Remote Sensing, 2023, 202: 303-313. DOI:10.1016/j.isprsjprs.2023.06.015.
- [120] Anantrasirichai N, Biggs J, Albino F, et al. A deep learning approach to detecting volcano deformation from satellite imagery using synthetic datasets [J/OL]. Remote Sensing of Environment, 2019, 230: 111179. DOI:10.1016/j.rse.2019.04.032.
- [121] Peng M, Lu Z, Zhao C, et al. Mapping land subsidence and aquifer system properties of the Willcox Basin, Arizona, from InSAR observations and independent component analysis [J/OL]. Remote Sensing of Environment, 2022, 271: 112894. DOI:10.1016/j.rse.2022.112894.
- [122] Zhou H, Dai K, Pirasteh S, et al. InSAR Spatial-Heterogeneity Tropospheric Delay Correction in Steep Mountainous Areas Based on Deep Learning for Landslides Monitoring [J/OL]. IEEE Transactions on Geoscience and Remote Sensing, 2023, 61: 1-14. DOI:10.1109/TGRS.2023.3307477.
- [123] Li H, He Y, Xu Q, et al. Detection and segmentation of loess landslides via satellite images: a two-phase framework [J/OL]. Landslides, 2022, 19(3): 673-686. DOI:10.1007/s10346-021-01789-0.
- [124] Chen X, Yao X, Zhou Z, et al. DRs-UNet: A Deep Semantic Segmentation Network for the Recognition of Active Landslides from InSAR Imagery in the Three Rivers Region of the Qinghai-Tibet Plateau [J/OL]. Remote Sensing, 2022, 14(8): 1848. DOI:10.3390/rs14081848.
- [125] Zhang T, Zhang W, Cao D, et al. A New Deep Learning Neural Network Model for the Identification of InSAR Anomalous Deformation Areas [J/OL]. Remote Sensing, 2022, 14(11): 2690. DOI:10.3390/rs14112690.

- [126] Guo H, Yi B, Yao Q, et al. Identification of Landslides in Mountainous Area with the Combination of SBAS-InSAR and Yolo Model [J/OL]. *Sensors*, 2022, 22(16): 6235. DOI:10.3390/s22166235.
- [127] Fu L, Zhang Q, Wang T, et al. Detecting slow-moving landslides using InSAR phase-gradient stacking and deep-learning network [J/OL]. *Frontiers in Environmental Science*, 2022, 10: 963322. DOI:10.3389/fenvs.2022.963322.
- [128] Fiorucci F, Giordan D, Santangelo M, et al. Criteria for the optimal selection of remote sensing optical images to map event landslides [J/OL]. *Natural Hazards and Earth System Sciences*, 2018, 18(1): 405-417. DOI:10.5194/nhess-18-405-2018.
- [129] 殷跃平, 王猛, 李滨, 等. 汶川地震大光包滑坡动力响应特征研究[J]. *岩石力学与工程学报*, 2012, 31(10): 1969-1982.
- [130] 李为乐. 典型强震同震地质灾害分布规律及后效应研究[D/OL]. 成都理工大学, 2021.
- [131] Shao Z, Wu Y, Ji L, et al. Assessment of strong earthquake risk in the Chinese mainland from 2021 to 2030 [J/OL]. *Earthquake Research Advances*, 2022: 100177. DOI:10.1016/j.eqrea.2022.100177.
- [132] 朱建军, 李志伟, 胡俊. InSAR 变形监测方法与研究进展[J]. *测绘学报*, 2017, 46(10): 1717-1733.
- [133] 刘晓杰. 星载雷达遥感广域滑坡早期识别与监测预测关键技术研究[D]. 西安: 长安大学, 2023.
- [134] 廖明生, 张路, 史绪国, 等. 滑坡变形雷达遥感监测方法与实践[M]. 北京: 科学出版社, 2017.
- [135] Berardino P, Fornaro G, Lanari R, et al. A new algorithm for surface deformation monitoring based on small baseline differential SAR interferograms [J/OL]. *IEEE Transactions on Geoscience and Remote Sensing*, 2002, 40(11): 2375-2383. DOI:10.1109/TGRS.2002.803792.
- [136] Wang C Y, Mark Liao H Y, Wu Y H, et al. CSPNet: A New Backbone that can Enhance Learning Capability of CNN[C/OL]//2020 IEEE/CVF Conference on Computer Vision

- and Pattern Recognition Workshops (CVPRW). Seattle, WA, USA: IEEE, 2020: 1571-1580[2023-10-07]. DOI:10.1109/CVPRW50498.2020.00203.
- [137] Quan Y, Zhang D, Zhang L, et al. Centralized Feature Pyramid for Object Detection [J/OL]. IEEE Transactions on Image Processing, 2023, 32: 4341-4354. DOI:10.1109/TIP.2023.3297408.
- [138] Liu S, Qi L, Qin H, et al. Path Aggregation Network for Instance Segmentation[C/OL]//2018 IEEE/CVF Conference on Computer Vision and Pattern Recognition. Salt Lake City, UT: IEEE, 2018: 8759-8768[2023-10-07]. DOI:10.1109/CVPR.2018.00913.
- [139] Guo M H, Xu T X, Liu J J, et al. Attention Mechanisms in Computer Vision: A Survey [J/OL]. Computational Visual Media, 2022, 8(3): 331-368. DOI:10.1007/s41095-022-0271-y.
- [140] Huang H, Lin L, Tong R, et al. UNet 3+: A Full-Scale Connected UNet for Medical Image Segmentation[C/OL]//ICASSP 2020 - 2020 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP). Barcelona, Spain: IEEE, 2020: 1055-1059[2022-06-23]. DOI:10.1109/ICASSP40776.2020.9053405.
- [141] Tang W, He F, Liu Y, et al. MATR: Multimodal Medical Image Fusion via Multiscale Adaptive Transformer[J]. IEEE TRANSACTIONS ON IMAGE PROCESSING, 2022, 31.
- [142] Liu Z, Hu H, Lin Y, et al. Swin Transformer V2: Scaling Up Capacity and Resolution[A/OL]. arXiv, 2022[2023-09-25]. <http://arxiv.org/abs/2111.09883>.
- [143] Zhu X, Lyu S, Wang X, et al. TPH-YOLOv5: Improved YOLOv5 Based on Transformer Prediction Head for Object Detection on Drone-captured Scenarios[A/OL]. arXiv, 2021[2023-03-12]. <http://arxiv.org/abs/2108.11539>.
- [144] Zi N, Li X M, Gade M, et al. Ocean eddy detection based on YOLO deep learning algorithm by synthetic aperture radar data [J/OL]. Remote Sensing of Environment, 2024, 307: 114139. DOI:10.1016/j.rse.2024.114139.

- [145] Martis R J, Acharya U R, Min L C. ECG beat classification using PCA, LDA, ICA and Discrete Wavelet Transform [J/OL]. Biomedical Signal Processing and Control, 2013, 8(5): 437-448. DOI:10.1016/j.bspc.2013.01.005.
- [146] Yin M, Liu X, Liu Y, et al. Medical Image Fusion With Parameter-Adaptive Pulse Coupled Neural Network in Nonsampled Shearlet Transform Domain [J/OL]. IEEE Transactions on Instrumentation and Measurement, 2019, 68(1): 49-64. DOI:10.1109/TIM.2018.2838778.
- [147] He K, Zhang X, Ren S, et al. Deep Residual Learning for Image Recognition[C/OL]//2016 IEEE Conference on Computer Vision and Pattern Recognition (CVPR). Las Vegas, NV, USA: IEEE, 2016: 770-778[2022-11-07]. <http://ieeexplore.ieee.org/document/7780459/>. DOI:10.1109/CVPR.2016.90.
- [148] Diakogiannis F I. ResUNet-a_ A deep learning framework for semantic segmentation of remotely sensed data[J]. ISPRS Journal of Photogrammetry and Remote Sensing, 2020.
- [149] Alrfou K, Zhao T, Kordijazi A. Transfer Learning for Microstructure Segmentation with CS-UNet: A Hybrid Algorithm with Transformer and CNN Encoders[A/OL]. arXiv, 2023[2023-10-09]. <http://arxiv.org/abs/2308.13917>.
- [150] Ren S, He K, Girshick R, et al. Faster R-CNN: Towards Real-Time Object Detection with Region Proposal Networks [J/OL]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2017, 39(6): 1137-1149. DOI:10.1109/TPAMI.2016.2577031.
- [151] Shelhamer E, Long J, Darrell T. Fully Convolutional Networks for Semantic Segmentation [J/OL]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2017, 39(4): 640-651. DOI:10.1109/TPAMI.2016.2572683.
- [152] Badrinarayanan V, Kendall A, Cipolla R. SegNet: A Deep Convolutional Encoder-Decoder Architecture for Image Segmentation [J/OL]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2017, 39(12): 2481-2495. DOI:10.1109/TPAMI.2016.2644615.
- [153] Li Y, Huang C, Yi S, et al. Study on seismic fault and source rupture tectonic dynamic mechanism of Jiuzhaigou Ms7.0 earthquake.[J]. Journal of Engineering Geology, 2017, 25(4): 1141-1150 (In Chinese with English Abstract).

- [154] Tian Y, Xu C, Ma S, et al. Inventory and Spatial Distribution of Landslides Triggered by the 8th August 2017 MW 6.5 Jiuzhaigou Earthquake, China [J/OL]. Journal of Earth Science, 2019, 30(1): 206-217. DOI:10.1007/s12583-018-0869-2.
- [155] Glenn Jocher, Alex Stoken, Jirka Borovec, et al. ultralytics/yolov5: v5.0 - YOLOv5-P6 1280 models[C]//AWS. Supervise.ly and YouTube integrations, 2021.
- [156] Notti D, Herrera G, Bianchini S, et al. A methodology for improving landslide PSI data analysis [J/OL]. International Journal of Remote Sensing, 2014, 35(6): 2186-2214. DOI:10.1080/01431161.2014.889864.
- [157] Liu X, Zhao C, Yin Y, et al. Refined InSAR method for mapping and classification of active landslides in a high mountain region: Deqin County, southern Tibet Plateau, China [J/OL]. Remote Sensing of Environment, 2024, 304: 114030. DOI:10.1016/j.rse.2024.114030.
- [158] Xiong Z, Zhang M, Ma J, et al. InSAR-based landslide detection method with the assistance of C-index [J/OL]. Landslides, 2023[2023-11-16]. <https://link.springer.com/10.1007/s10346-023-02120-9>. DOI:10.1007/s10346-023-02120-9.
- [159] Liu J, Fan X, Jiang J, et al. Learning a Deep Multi-Scale Feature Ensemble and an Edge-Attention Guidance for Image Fusion [J/OL]. IEEE Transactions on Circuits and Systems for Video Technology, 2022, 32(1): 105-119. DOI:10.1109/TCSVT.2021.3056725.