

分类号: P642; TP751

单位代码: 11775

编号 : 21661104

密级: 公 开



防灾科技学院 硕士学位论文

基于深度学习的滑坡识别方法——以四川省泸定县为例
Landslide Segmentation Method Based on Deep Learning
—A Case Study in Luding County, Sichuan Province

作者姓名: 胡文杰

专 业: 资源与环境

研 究 方 向: 灾害信息处理技术

第一导师: 李 峰 教 授

第二导师: 窦爱霞 研究员

学 位 类 别: 资源与环境硕士专业学位

学位授予单位: 防灾科技学院

2024 年 6 月

Landslide Segmentation Method Based on Deep Learning
—A Case Study in Luding County, Sichuan Province

Dissertation Submitted
In Fulfillment of the Requirement
for the Master Degree

By
HU Wenjie

Supervisor: Prof. LI Feng
Prof. DOU Aixia

Institute of Disaster Prevention
June 2024

基于深度学习的滑坡识别方法——以四川省泸定县为例

姓 名：胡文杰

导 师：李 峰 教 授

窦爱霞 研究员

专 业：资源与环境

摘 要

滑坡作为一种重大的自然灾害，对人类的生产活动、生命财产安全构成了严重威胁。滑坡位置和区域数据不仅是滑坡易发性评估研究的基础，而且在灾后救援中起到了关键作用。因此，如何准确且高效地识别并获取滑坡区域，是一个具有重要研究价值的问题。尽管依赖专家知识的常规滑坡识别方法在识别精度上表现优秀，但其存在耗时且适用范围狭小的局限性。目前以深度学习技术为代表的自动化处理方法已在多个领域取得了显著的成功。这种方法采用数据驱动的方式，以大量的样本数据作为基础，利用随机梯度下降算法拟合模型，使其能够胜任各种复杂的任务。

本研究利用深度学习技术，结合前人研究成果，针对 RGB 光学遥感影像中滑坡与背景特征相似性的问题，发展了一种基于交叉注意力机制的滑坡识别模型。为了验证该模型的性能，本文将其与当前主流的滑坡识别模型，U-Net、Link Net、DeepLab v3+及 SegFormer 进行了对比实验。此外，本研究实施了深度迁移学习（Deep Transfer Learning, DTL）策略，有效地将模型从源数据集中学习到的特征知识迁移至目标数据集。通过 DTL 策略进行的微调显著提升了模型的性能，有效证明了 DTL 策略在提高模型的泛化能力及适应新数据集方面的显著效益。本文的研究贡献主要体现在以下几个方面：

（1）对三个公开的滑坡数据集进行处理和融合，得到了一个多区域且样本特征丰富的滑坡基准数据集，该数据集按照 80%和 20%的比例随机划分为训练集和验证集。训练集包含了 6939 个样本，其中滑坡区域样本为 2460 个，非滑坡

区域样本为 4479 个,验证集则包含了 1734 个样本,其中滑坡区域样本为 616 个,非滑坡区域样本为 1118 个;

(2) 本研究发展了一种应用于滑坡识别任务的深度学习模型,该模型以 RGB 图像为输入,基于 Swin Transformer Block 构建,并设计集成了一种交叉注意力机制模块。对比实验的结果显示,该模型的交并比 (Intersection over Union, IoU) 达到了 82.65%, F1 分数为 81.14%,相较于 U-Net、Link Net、DeepLab v3+ 及 SegFormer 模型,表现出显著的性能提升,从而验证了所提模型的有效性及其在滑坡识别领域的应用潜力;

(3) 在将训练良好的模型应用于数据匮乏的其他区域时,通过对模型进行微调,与直接预测相比,可以实现显著的性能提升。通过 DTL 策略实施的微调显著增强了模型的性能,使得 ZiHao Net、U-Net、Link Net、DeepLab v3+ 及 SegFormer 五种模型的 IoU 提升了 11.69%至 37.1%,同时 F1 分数也增加了 12.0%至 43.1%;

(4) 本研究提出了一种针对大尺度区域滑坡识别的模型推理算法,并选择四川泸定作为实验区域进行验证。该算法在装备有 Intel Core i9-10980HK 处理器和 NVIDIA RTX 3080 Laptop GPU 的平台上进行测试。处理的遥感影像来源于谷歌地球,为 RGB 光学影像,具有 0.6 m 的分辨率,尺寸为 136929 像素宽和 180963 像素高,总数据量为 92.3 GB。以本研究开发的模型为例,该算法成功完成了 1973530 个样本的推理处理,总耗时 2 小时 23 分 55 秒。

关键词: 滑坡识别; 深度学习; 交叉注意力机制; 泸定滑坡

Landslide Segmentation Method Based on Deep Learning

—A Case Study in Luding County, Sichuan Province

Author: HU Wenjie

Supervisor: LI Feng

DOU Aixia

Major: Resource and Environment

ABSTRACT

As a significant natural disaster, landslides pose severe threats to human production activities and the safety of lives and properties. The data of landslide locations and areas are not only the foundation of landslide susceptibility assessment research but also play a crucial role in post-disaster rescue. Therefore, accurately and efficiently mapping and obtaining landslide areas is a problem of significant research value. Although conventional landslide mapping methods relying on expert knowledge perform excellently in identification accuracy, they are time-consuming and limited in scope. At present, automated processing methods represented by deep learning technology have achieved remarkable success in various fields. These methods adopt a data-driven approach, use a large amount of sample data as the foundation, and fit the model using the stochastic gradient descent algorithm, enabling them to handle various complex tasks.

This study utilizes deep learning technology and builds on previous research findings. The focus is on the similarity between landslide features and background in RGB optical remote sensing images. A new landslide segmentation model based on a cross-attention mechanism has been developed. To validate this model's performance, it was compared with mainstream models such as U-Net, Link Net, DeepLab v3+, and SegFormer. Additionally, a Deep Transfer Learning (DTL) strategy was implemented. This strategy effectively transferred learned features from the source dataset to the target dataset. Fine-tuning through the DTL strategy significantly improved the

model's performance. This improvement demonstrates the DTL strategy's effectiveness in enhancing the model's generalization ability and adaptation to new datasets. The contributions of this paper are outlined in the following sections:

(1) Three publicly available landslide datasets were processed and merged to create a multi-regional and feature-rich landslide benchmark dataset. This dataset was randomly divided into a training set and a validation set at a ratio of 80% to 20%. The training set contained 6939 samples, including 2460 landslide area samples and 4479 non-landslide area samples. The validation set included 1734 samples, with 616 landslide area samples and 1118 non-landslide area samples;

(2) This study developed a deep learning model for landslide segmentation tasks, which takes RGB images as input and is built on the Swin Transformer Block, incorporating a cross-attention module. Comparative experimental results showed that this model achieved an Intersection over Union (IoU) of 82.65% and an F1 score of 81.14%, demonstrating significant performance improvements compared to the U-Net, Link Net, DeepLab v3+, and SegFormer models, thereby validating the effectiveness of the proposed model and its potential application in landslide segmentation.

(3) When applying the well-trained model to other areas with scarce data, significant performance improvements can be achieved through fine-tuning the model compared to direct prediction. The fine-tuning implemented through the DTL strategy significantly enhanced the model's performance, resulting in an increase in IoU from 11.69% to 37.1% and in F1 scores from 12.0% to 43.1% for the ZiHao Net, U-Net, Link Net, DeepLab v3+, and SegFormer models.

(4) This study proposed a model inference algorithm for large-scale regional landslide segmentation and selected Luding, Sichuan, as the experimental area for validation. The algorithm was tested on a platform equipped with an Intel Core i9-10980HK processor and an NVIDIA RTX 3080 Laptop GPU. The processed remote sensing images were sourced from Google Earth and are RGB optical images. They have a resolution of 0.6 m, dimensions of 136929 pixels in width and 180963 pixels in height, with a total data volume of 92.3 GB. Using the model developed in this study as an example, the algorithm successfully completed the inference processing of 1973530 samples in a total time of 2 hours, 23 minutes, and 55 seconds.

Key words: Landslide Segmentation; Deep Learning; Cross Attention; Luding Landslide

目 录

第一章 绪论.....	1
1.1 研究背景与意义.....	1
1.2 滑坡识别研究现状.....	3
1.3 研究内容及创新点.....	9
1.4 本文组织结构.....	10
1.5 本文技术路线图.....	11
1.6 本章小结.....	12
第二章 深度学习算法相关理论	13
2.1 多层感知机.....	13
2.2 卷积神经网络.....	17
2.3 Transformer 模型.....	21
2.4 语义分割概述.....	25
2.5 特征可视化.....	28
2.6 损失函数.....	28
2.7 评价指标.....	29
2.8 本章小结.....	31
第三章 研究区域概况及基准数据集构建	32
3.1 研究区域概况.....	32
3.2 基准数据集构建.....	33
3.3 本章小结.....	37
第四章 基于交叉注意力机制的滑坡识别模型	38
4.1 基于交叉注意力机制模块设计	38
4.2 基于交叉注意力机制的滑坡识别模型设计	41
4.3 本章小结.....	47
第五章 模型性能评估	48
5.1 实验环境与超参数设置.....	48
5.2 消融实验.....	49
5.3 对比实验.....	54
5.4 本章小结.....	58
第六章 泸定县滑坡识别	60
6.1 大尺度区域的滑坡识别模型推理算法	60
6.2 迁移学习.....	61
6.3 实验结果.....	63
6.4 实验结论.....	65

6.5 本章小结.....	66
第七章 总结与展望	67
7.1 总结.....	67
7.2 展望.....	68
参考文献.....	70

第一章 绪 论

1.1 研究背景与意义

滑坡是一种重要的自然灾害，是斜坡上的岩土在重力为主导，受自然或人为因素导致坡面岩土失稳而作整体地或分散地沿斜坡向下和向前滑动的现象^[1]。在过去几十年中，由于城市化地区（Urbanized Area）的扩张和气候变化的影响，滑坡发生的范围和规模显著扩大，成为中国主要的地质灾害类型^[2,3]。据国家统计局发布的《中国统计年鉴 2023》显示，仅 2022 年全国发生地质灾害 5659 起，滑坡灾害达 3919 起，为当年地质灾害总数的 69.25%，其中藏东南地区、川滇地区为滑坡灾害高发区^[4]。四川地处青藏高原东南缘，地形高差悬殊，地层岩性复杂，气候复杂多变，受龙门山、鲜水河、安宁河等三大地震活动带影响，是全国地质灾害最为严重的省份之一。据四川省自然资源厅发布的《四川省“十四五”地质灾害防治规划》数据，截至 2020 年底，四川已排查各类地质灾害隐患点 35992 处，其中滑坡灾害达 22133 处，占比 61.49%，鲜水河断裂带泸定、康定等区域更是滑坡等地质灾害高易发区域^[5]。本文的研究区域泸定县，位于四川省甘孜藏族自治州东南部，是由青藏高原向四川盆地过渡的高山峡谷地带，地形高差大，地质活动活跃，水系发育，属于我国高山峡谷地质灾害的重点防治区域^[6-8]。泸定县位于众山环绕之中，其植被丰富繁茂，地质灾害具有强烈的隐蔽性、突发性和动态性。近年来，全球极端气候的影响以及我国新一轮的地震活跃期，都使得地质灾害的动态变化性和时空不确定性愈发明显，滑坡为主的地质灾害对研究区域的影响尤为严重，造成了重大的人员伤亡及经济财产损失^[9]。鉴于此，开展泸定县的滑坡灾害识别工作是非常重要和必要的。

滑坡调查数据不仅是评估滑坡易发性的基础，同时也在灾后的迅速救援和有效减灾中，发挥了至关重要的作用^[10]。早期的滑坡识别方法多以野外调查，需要研究人员前往现场勘察确定滑坡发生的位置、规模以及形状特征等信息^[11]。此方法耗费大量的人力且效率较低，部分区域山高林密给现场勘察造成了不小的困难。自 20 世纪 70 年代起，遥感技术以其全天候、高速和高效的特性在灾害救援领域得到了广泛的应用，其在掌握总体灾情和制定救援策略等方面发挥了至关重要的作用^[12]。通过将遥感技术与野外调查相结合，研究人员能够利用遥感影像对滑坡区域进行精确解译，然后通过野外调查来验证其解译精度。相对于单一的野外调

查,引入遥感技术能够显著降低外业调查人员的工作负担,提高滑坡识别的工作效率。此外,研究人员能够通过遥感影像更直观地观察滑坡区域,这无疑有助于提高滑坡识别的精度。然而,这种方法对遥感影像解译人员的专业知识和实践经验有较高的要求。遥感影像场景的复杂性和多变性需要解译人员具备深厚的专业知识和丰富的实践经验。在面对大范围场景的滑坡识别任务时,仍然需要投入相当的人力资源。

自 2012 年 AlexNet 在 ImageNet 挑战赛中取得冠军以来,深度学习已在多个研究领域引发了广泛的关注,并实现了重大的技术突破^[13]。这种先进的机器学习方法在图像分类、语义分割、目标检测等任务中已经取得了显著的成果^[14]。近年来,研究人员开始尝试将深度学习技术应用于滑坡识别领域,并发现其在这一领域中具有巨大的潜力^[15,16]。作为一种自动化工具,深度学习可以处理大规模的数据,执行高精度的任务,并具有持续学习和改进的能力。此外,深度学习可以全天候工作,无限扩展,并实现自动化决策。这些优势显著降低了人工成本,同时提高了工作效率和准确性。因此,深度学习在滑坡识别领域的应用,为提高灾害预警的响应效率以及准确性提供了新的可能性,这一发现为进一步优化和改进滑坡识别流程提供了新的研究方向^[17,18]。然而,滑坡的发生和发展受到地质环境、滑坡类型以及滑坡发展阶段等多种因素的影响,使得滑坡隐患区在不同阶段表现出的识别特征存在巨大的差异性^[19]。这些因素显著地提升了滑坡灾害识别的复杂性和挑战性。因此,尽管已经针对泸定地区进行了一定程度的滑坡调查与评估,但评估的精确性和覆盖范围仍然有待提高^[20]。此外,深度学习等现代技术在滑坡治理方面已经展示了潜力,但是在该领域的应用仍然不够充分,存在着较大的性能提升空间^[21]。根据无免费午餐理论(No Free Lunch, NFL)^[22],没有一种算法在所有可能的问题空间中都具有优越性。因此,需要根据滑坡灾害识别的特定环境和需求,选择并优化适当的模型和方法,以实现滑坡灾害识别精度和效率的最大化。

本研究基于前人在滑坡防治领域的研究成果,针对该领域存在的问题进行了深入探讨,以满足国家在灾害防治方面的紧迫需求为立题依据,选定四川省甘孜藏族自治州东南部的泸定县为研究区域。以深度学习为主要的技术手段,结合遥感技术提供的数据能力,在研究区域地形复杂、滑坡灾害频发的背景下,开展基于深度学习技术的滑坡识别研究。通过深入研究泸定县的滑坡灾害情况,为该地

区的灾害防治工作提供重要的参考和指导,以降低滑坡灾害的风险,保障人民群众的生命财产安全,推动该领域的可持续发展,并为其他类似地区的灾害防治工作提供借鉴和启示。

1.2 滑坡识别研究现状

滑坡识别技术在过去的几十年中经历了显著的发展,从最初的地质野外调查,到利用无人机和卫星影像进行的目视解译和半自动分类,再到借助机器学习和深度学习技术实现的精细化监督分类,滑坡识别的精度及效率得到了较大的提升。本节将对滑坡识别的发展轨迹进行回顾总结,主要分为以下三个部分:传统滑坡识别的研究方法、基于机器学习的滑坡识别研究方法以及基于深度学习的滑坡识别研究方法。这三个部分将分别对滑坡识别技术的历史演进、现有方法和最新的科研进展进行全面梳理和回顾。下面机器学习方法指代不包括深度学习的其他机器学习方法,本文所研究的滑坡识别方法仅局限于通过深度学习技术获取滑坡的轮廓。

1.2.1 传统滑坡识别的研究方法

在早期的滑坡识别研究中,其识别工作主要依赖于地质野外调查以及立体航空相片的视觉解译。在特定的研究区域内进行的滑坡地质野外调查被视为地貌分析的一部分,滑坡调查的关键步骤之一是通过野外地质调查、历史档案的深入分析收集到足够的数据,对其进行详尽的描述^[11]。然而,在现场确认滑坡边界时,会存在一定的困难。在发生滑坡的区域地形复杂、地表起伏不平和植被覆盖茂密使得研究人员很难以相同的视角观测滑坡的完整结构,受局部视角的影响,坡面破坏区的可见性降低使得滑坡边界通常显得模糊不清^[23]。野外地质调查通常用于识别和绘制由特定事件触发的滑坡,该方法获取的滑坡信息和视觉特征可以用于提高航空或卫星影像的目视解译质量,也可以用于验证其他技术获取滑坡地图的准确性^[24-26]。立体航空摄影是早期滑坡识别的重要手段,对于经过专业训练的研究人员,解译这些立体航空照片是一种直观且不需要复杂技术的过程^[27]。立体视觉引入的垂直夸大(Vertical Exaggeration)增强了地形形态的视觉效果,使微小的地形变化更为明显,有助于揭示滑坡的典型地形特征^[28]。立体航空照片的航向和旁向重叠,使研究人员能够找到最适合识别滑坡的照片组合,相比于其他滑坡检测方法,该技术所需的设备和工具相对简单,成本更低。但是,通过对立体航空照片进行视觉分析来识别滑坡是一种经验性的技术,需要充足的实践经验、专

业的培训和明确的解译标准。

遥感技术的发展为滑坡识别提供了新的数据基础,并催生了一系列创新的检测方法。其中,高分辨率数字高程模型(High Resolution Digital Elevation Model, HR-DEM)在地貌分析方面的应用,以及卫星影像在滑坡识别中的使用,都体现了遥感技术在此领域的重要贡献^[29]。滑坡事件会引起地表形态的显著变化,留下独有的特征痕迹^[1,28]。通过运用机载激光测量仪,研究人员能够获取高精度的地形数据,这为观察和理解滑坡及其相关地表过程产生的特殊痕迹,提供了一个全新的视角,使得研究人员能够更准确地检测和绘制滑坡区域。从航空 LiDAR 测量中获得的 HR-DEM,已被广泛地用于检测、绘制和监测滑坡灾害^[30-32]。滑坡灾害发生后会导致大范围的植被破坏,使得岩石和土壤暴露在地表,从而引发地表覆盖的显著改变,这种改变会影响地表的光学特性,而卫星传感器能够捕获地表光谱特征的变化^[33]。通过卫星监测滑坡的技术方法不仅能够实现大范围、高效率的滑坡监测,而且可以提供连续的地表信息,这对于滑坡的预测和防治具有重要的价值。利用卫星影像识别滑坡的应用可以追溯到 20 世纪 70 年代,最初的研究人员使用 Landsat 和 SPOT 图像来检测滑坡^[34]。在过去的二十年中,由于高分辨率和超高分辨率传感器的可用性增加,以及用于处理、可视化和分析卫星影像的计算机硬件及软件的进步,卫星遥感技术在滑坡识别中的应用显著增加^[29]。Nichol 等^[27]将超高分辨率卫星影像与 DEM 相结合获得地形的三维视图,从而能够更直观地展示滑坡地貌,提高滑坡的视觉解译效率。Rosin 等^[35]将超高分辨率影像和阈值分割方法相结合,用于探索滑坡的半自动识别,实验结果证明了该方法对绘制与滑坡相关的地表变化是有用的。Parker 等^[36]利用阈值分割技术,结合 SPOT 5 和 EO-1 卫星影像,半自动地分类和识别了 2008 年汶川地震产生的滑坡区域。杨树文等^[37]研究人员采用常量化修正的土壤调节植被指数(Constant Modified Soil Adjusted Vegetation Index)方法来获取非植被区域,并结合阈值分割技术实现滑坡的识别。闫琦等^[38]研究人员采用大津法(OTSU)自动计算特征阈值,并通过多特征阈值分层和逐步剔除干扰地物的策略,成功实现了地震滑坡体的提取。

上述研究方法在推动滑坡识别方面已经取得了显著的进步。从最初的野外调查到后来的半自动识别,滑坡识别所需的人力与资源消耗已经大幅降低。然而,这些研究方法的自动化程度仍有待提高,以满足大规模滑坡识别的需求。

1.2.2 基于机器学习的滑坡识别研究方法

机器学习是一种强大的计算统计方法,其独特之处在于能够从经验中学习并自我改进。这种学习过程通常涉及对数据的观察或与环境交互。随着经验的积累,机器学习算法的性能会逐步提升。机器学习方法的主要组成部分包括数据、模型、目标函数,以及优化算法。数据通常由一组特征属性构成,模型则基于这些特征属性进行学习和预测。目标函数设定了一个度量标准,用以评估模型的性能。研究人员通常期望目标函数的值尽可能低,因此在许多情况下,目标函数也被称为损失函数。优化算法的任务就是寻找最佳的模型参数,以最小化目标函数,进而提升模型的预测能力^[39]。

在滑坡识别领域,机器学习算法已经得到了广泛地应用,滑坡识别可以被视为一个分类任务,即区分滑坡区域和非滑坡区域。研究人员通常会根据滑坡形成的地质学原理,通过人工干预选择或设计适当的特征提取算法来优化样本特征并增强特征信息,最后利用机器学习算法进行分类处理,生成最终的滑坡地图。王庆雅等^[40]根据滑坡纹理特征采用了 Gabor 滤波算法分析,并将其与光谱特征进行融合,随后采用支持向量机实现了滑坡的有效提取。李政等^[41]将词袋特征与支持向量机相结合构建一种用于无人机影像的滑坡识别模型,经过实验,验证了该模型可用于大面积高山影像滑坡灾害的快速识别和定位。Stumpf 等^[42]提出了一种利用面向对象的图像分析技术和随机森林算法的有监督工作流程,其目的在于减轻滑坡识别过程中的人工劳动负担,并以客观的方式选择重要的对象特征和分类阈值。Ghorbanzadeh 等^[21]采用了人工神经网络、支持向量机以及随机森林等机器学习方法对喜马拉雅山脉易受灾的地区,进行了深入的滑坡识别研究。Mahrooghy 等^[43]采用支持向量机模型对堤坝滑坡进行识别和分析,获得了令人满意的识别效果。Heleno 等^[44]对基于支持向量机模型的对象分类方法、基于 Textons 的像素分类方法以及基于 RuleSet 的对象分类方法,这三种不同的监督式滑坡识别方法进行了比较,通过将验证区域的结果与地面实际的滑坡图进行对比,发现基于对象的机器学习方法所得到的结果具有更高的准确性。

机器学习算法在滑坡识别问题上已经取得了显著的成果,这些算法具有自动化识别滑坡的能力,能够从大量复杂的地质数据中提取有效信息,从而实现对滑坡的准确识别。此外,机器学习算法的计算开销相对较小,这使得其在大规模数据处理和实时监测应用中具有显著优势。更为重要的是,机器学习算法的识别精

度往往能达到较高水平，能够满足多种研究和实践任务的需求。

虽然机器学习模型在滑坡识别任务上的表现令人瞩目，但其仍然存在一些局限性。在计算机视觉领域，原始像素往往并非直接输入，而是需要通过特征处理流程进行预处理。传统的机器学习方法大量依赖于人工设计的特征处理流程，其中大部分的优化和进步都源自对特征的创新处理。在机器学习的样本预处理阶段，尺度不变特征变换算法（Scale Invariant Feature Transform）^[45]、定向梯度直方图算法（Histogram of Oriented Gradient）^[46]以及加速鲁棒特征算法（Speeded Up Robust Features）^[47]是常用的特征提取技术。这些方法能够从样本图像中提炼出关键特征的描述符。经过这种特征提取处理，得到的特征信息被用作模型的输入，这些特征已通过精心设计的处理流程得到增强，凸显出对模型预测性能至关重要的隐含特征。

这一情况在基于遥感数据的滑坡识别中也是相似的，遥感影像通常是多光谱数据，相比于 RGB 三通道图像具有更强的特征表示能力，但研究人员仍需要运用特殊算法或加入 DEM、地形、坡度、降雨量等因素，以增强其特征表达能力。因此，研究人员可能需要为特定区域设计专用算法；然而，这些算法可能不适用于其他区域。同时，利用不同传感器获取同一目标的数据可能存在差异，这可能导致识别精度下降。这些因素均增加了机器学习算法的应用复杂性，影响模型的迁移应用效果。

1.2.3 基于深度学习的滑坡识别研究方法

深度学习，作为机器学习中神经网络部分的一种扩展和深化，已经在各个领域取得了卓越的成就。相比于机器学习需依赖专家知识进行精细的特征工程，深度学习能通过其强大的特征学习能力，在与海量数据的交互中，自我学习并抽取有用的特征。2012 年 AlexNet 的成功首次证实了，通过深度学习所得到的特征可以超过人工设计的特征^[13]。这一发现不仅验证了深度学习在特征提取方面的卓越性，也为深度学习在其他领域的应用开启了新的可能性。

许多研究人员已经开始尝试将深度学习技术应用到滑坡识别领域，这些尝试大致可以分为两种处理方式：基于像素的分类和基于对象的语义分割。在基于像素的分类方法中，每个像素或像素块对应的多波段值被用作特征输入，预测其所属类别，这些波段分别代表了不同的传感器或地表特性信息^[21,48]。随后通过遍历整个遥感影像以生成滑坡地图。另一种方法是基于对象的语义分割，它将一定尺

寸（通常宽高为 224，256 或者 512 像素）的样本整体作为输入，通过模型主干（Backbone）的降采样获取样本的语义信息，随后通过解码器（Decoder）上采样，将其还原为原始样本尺寸，从而获得该样本的滑坡分类^[49]。

Ding 等^[50]将卷积神经网络模型（Convolutional Neural Network, CNN）用于滑坡识别并取得了不错的识别效果。Liu 等^[51]将 U-Net 模型用于地震滑坡的提取，引入自动提取分层特征模块改进 U-Net 模型，实现了地震后滑坡信息的智能提取。Sameen 等^[52]将 RGB 波段和 DEM、坡度、坡向、曲率等地形因子组合构成样本集，设计了一种残差网络用于识别马来西亚 Cameron 高地的滑坡，取得了不错的识别效果。Zhang 等^[52]采用了滑坡发生前后的影像数据，构建了一种用于变化检测的残差模型，采用了基于多目标域自适应（Multitarget Domain Adaptation）技术的原型引导域感知渐进表示学习（Prototype-Guided Domain-aware Progressive Representation Learning）方法增强模型的迁移能力，为验证模型迁移学习性能，该研究团队人工标注了全球范围内 17 个滑坡区域用于制作全球高分辨率滑坡地图（Global Very-high-resolution Landslide Mapping, GVLM）数据库，并用该数据库验证模型性能，实验结果表明，这种方法在滑坡识别任务上的表现优秀，精度高，具有较强的迁移学习能力。Ji 等^[53]提出了一种基于 CNN 的方法，用于从高分辨率光学卫星图像中识别滑坡，其引入了空间通道注意力机制提升模型对于图像中的空间信息及不同因子间重要性的关注学习，为了验证所提出的模型的性能，该研究团队精心制作并公开了一份中国毕节市的滑坡数据集，实验结果表明，所提出的模型在这个数据集上展现出了较高的准确率。许灏支等^[54]提出了一种结合了残差网络和通道注意力机制的高效模型，在九寨沟滑坡无人机遥感影像数据集上进行了实证研究，结果显示，该模型在保持滑坡完整性和区分光谱信息混淆方面有显著的提升。王颖等^[55]将注意力机制与 ResU-Net 模型相结合，样本集加入归一化植被指数（Normalized Vegetation Index, NDVI）和归一化差异水体指数（Normalized Difference Water Index, NDWI）等地表特征数据扩充样本特征，经过实验验证，该模型在滑坡检测任务上性能良好。姜万冬等^[56]选择了一些典型的易混淆地物作为滑坡检测的背景，采用了 Mask R-CNN 的方法提取滑坡特征，选择了中国甘肃省天水地区的实际滑坡区域进行了实证研究，研究结果进一步证明了所提出的方法在处理复杂地物背景下的滑坡检测任务上的有效性。

滑坡识别任务受到领域特性的深刻影响，其使用的数据样本与传统的 RGB

图像样本存在着显著的差异。在遥感领域,多光谱或高光谱影像是常用的数据源,这些影像相较于 RGB 影像,包含了更丰富的特征信息。一些研究人员甚至会根据分类任务的需求,引入诸如 DEM、NDVI、NDWI 等附加信息,以此间接增强样本的特征信息。这使得在传统图像分割领域中不适用的逐像素分类方式,在遥感图像分割领域却能够展现出优秀的性能。基于地理空间相关性的原则^[57],单像素识别方法并未充分挖掘该像素周围地物的信息。因此,部分研究人员尝试使用一定范围的像素块作为分类输入。然而,这种方法可能会导致分类结果的分辨率降低,同时,像素块的大小也可能影响到分类效果。因此相较于传统的滑坡识别方法,利用深度学习技术构建的语义分割模型能够学习并理解滑坡的特征,从而在图像中准确地标记出滑坡的位置,生成更精确的分割结果。

基于深度学习的滑坡识别不需要研究人员利用专家知识,根据样本数据构建相适应的、精妙的特征处理流程。深度学习依靠其强大的学习能力,从样本中学习到的特征信息,往往比人工设计的特征更具有广泛性,更能迁移到类似的任务当中。虽然机器学习也能实现深度学习算法类似的效果,但是其往往涉及复杂的特征处理流程,以及针对不同研究问题设计的数据预处理算法,这极大地提高了研究人员的工作难度,且设计的算法很多时候不具有普适性,存在迁移困难等问题。相比于机器学习以及传统的基于统计或者专家知识的滑坡识别方法,深度学习能极大地简化滑坡识别流程,降低人工消耗,以及能以较高的精度完成识别任务,使得研究人员能以更多的精力完成后续的研究任务。

纵观历史长河,万事万物皆有对立与统一,深度学习算法在取得令人瞩目的成绩之下,仍然存在一些不可忽视的问题。首先,深度学习是数据驱动的算法,依靠大量样本数据作为支撑,当数据量过小,深度学习模型的性能可能会断崖式下降。这是因为深度学习模型通常需要大量的数据来学习和抽象出有用的特征,而数据量的缺乏可能会导致模型无法充分学习,从而影响其预测推理能力。这种现象被称为欠拟合(Underfitting),即模型在训练数据上的性能较差,无法捕捉到数据中的潜在模式^[58,59]。其次,深度学习模型可能会受到极端样本或者噪声数据的影响,学习并纳入这些无效或者误导性的特征,这可能导致模型在实际应用中的性能下降。这种现象被称为过拟合(Overfitting),即模型在训练数据上的性能过好,但在新的、未见过的数据上的性能较差^[60,61]。另外深度学习算法的训练和推理过程计算密集且耗时,大量依靠高性能的计算处理设备,导致高昂的硬

件和维护成本,使得小型企业和个人研究人员面对高额成本时,对深度学习的使用望而却步。因此,尽管深度学习在许多领域都取得了显著的成果,但仍然需要对其存在的问题进行深入的研究和探讨,以推动深度学习技术在滑坡识别领域的进一步发展。

1.3 研究内容及创新点

1.3.1 研究内容

本研究采用了广泛应用且易于获取的谷歌地球 RGB 光学影像作为样本数据,旨在探索深度学习技术与遥感影像相结合的滑坡灾害自动化识别方法。本研究整合了前人的研究成果,构建了一个覆盖多个地区的滑坡基准数据集,用于训练和评估不同模型以及不同组件的性能差异。其次,设计并构建了一个专门针对滑坡识别的深度学习模型,并设计交叉注意力机制模块提升识别精度。为了验证所提出的方法的可靠性,本文选择四川省泸定县作为实证研究的地点。

基于上述的研究目标和方法,本文将围绕以下三个主要的研究内容展开:

(1) 构建用于模型评估的基准数据集。为确保数据集的多样性和质量,以便能够全面准确地评估后续提出的模型在面对各种滑坡情况时的性能表现,本研究从三个公开可获取的滑坡数据集中筛选并处理样本数据,以形成一个综合性强、具有代表性的、以 RGB 图像为样本的基准数据集。这个基准数据集的构建过程涵盖了数据的筛选、裁剪和尺度变换。通过这个基准数据集,能够在公平和一致的环境下,对模型的精度、鲁棒性、泛化能力等关键指标进行评估。

(2) 针对实验区域复杂的滑坡识别问题,本研究设计了一种专门用于滑坡识别任务的深度学习模型,该模型以 RGB 图像为输入数据,基于 Swin Transformer Block 构建,并集成了一种新颖的交叉注意力模块。该模块能有效地捕捉和利用主干网络产生的全局特征,用于加强模型颈部与滑坡相关的有用特征,从而增强模型对复杂滑坡识别的能力。为了验证所设计模型的性能及交叉注意力机制的有效性与可靠性,本研究使用了构建的基准数据集进行了消融实验,并与其他最新的滑坡识别模型进行了性能比较。

(3) 为了验证本研究提出的模型和方法的有效性,选取了四川省泸定县作为实验案例。泸定地区的地质环境和滑坡状况具有典型性,复杂的地形地质因素提高了滑坡识别的难度。以泸定县为实验区域,应用提出的模型和方法生成了该地区的滑坡地图,旨在验证本研究提出模型性能的可靠性和有效性。

1.3.2 创新点

本工作的创新点如下：

(1) 本研究汇集了前人的研究成果，经过处理得到了一个覆盖广泛、样本特征丰富的基准数据集。这个数据集包含了世界各地的滑坡数据，样本丰富，为滑坡识别模型的精度和性能评估提供了一个公平的基础平台。该数据集按照 80% 和 20% 的比例随机划分为训练集和验证集，训练集包含了 6939 个样本，其中滑坡区域样本为 2460 个，非滑坡区域样本为 4479 个。验证集则包含了 1734 个样本，其中滑坡区域样本为 616 个，非滑坡区域样本为 1118 个。

(2) 本研究发展了一种名为 ZiHao Net 的基于交叉注意力机制的深度学习模型，用于滑坡识别任务。该模型通过 MLP Head 模块获取样本的全局特征以及获取样本的滑坡相关性分数，随后使用交叉注意力模块，利用全局特征向量和样本的滑坡相关性分数，对样本的滑坡特征进行增强并抑制背景噪音，旨在提升模型的预测精度。本文设计的模型与 U-Net、Link Net、DeepLab v3+ 以及 SegFormer 模型相比，IoU 提高了 8.05% 至 10.78%，F1 分数提升了 1.05% 至 8.9%。

(3) 本研究采用了一种 DTL 策略来提高模型在特定任务上的性能。该技术利用少量目标数据集的样本，将从源数据集中学习得到的特征知识迁移到目标数据集。通过对 ZiHao Net、U-Net、Link Net、DeepLab v3+ 及 SegFormer 模型进行 DTL 微调，实验结果显示模型性能得到了显著提升。IoU 的提升范围为 11.69% 至 37.1%，而 F1 分数的增幅则介于 12.0% 至 43.1% 之间。

(4) 本研究开发了一种适用于大尺度区域的模型推理算法，该算法采用了一种舍弃边缘的滑动窗口技术。在算法设计中，对研究区域样本的重叠度设定为 0.5，而边缘舍弃率则定为 0.25。模型处理的输入样本尺寸为 224 像素，而处理的遥感影像具有 136929 像素宽和 180963 像素高，存储格式为 TIFF，总数据量约为 92.3 GB。利用本研究开发的模型，该算法的整体耗时 2 小时 23 分 55 秒，总计完成 1973530 个样本的推理，能够有效地完成该地区的滑坡识别任务。

1.4 本文组织结构

本文的具体章节及其内容安排如下：

第一章：绪论。本章主要阐述了本研究的背景和意义，并对国内外滑坡识别的方法和研究现状进行了详细的概述。最后，对本研究的主要工作内容以及整篇论文的结构进行了简要介绍。

第二章：深度学习算法相关理论。本章主要阐述与本研究相关的深度学习理论，并对常用的损失和评估指标进行了介绍。

第三章：研究区域概况及基准数据集构建。本章主要描述了研究区域的基本情况，并详细介绍了后续使用的基准数据集的构建过程。

第四章：基于交叉注意力机制的滑坡识别模型。本章介绍了本研究所提出方法的算法结构，以及专为滑坡识别设计的模型的基本架构。

第五章：模型性能评估。本章设计相应的消融实验，验证所设计模块的有效性。随后，通过对比实验比较本研究所设计模型与其他滑坡识别模型的性能差异。

第六章：泸定县滑坡识别。本章通过迁移学习技术，将模型从基准数据集所学的特征知识迁移到泸定地区。随后，使用本文设计的模型并结合本文所设计的大尺度滑坡识别算法完成了泸定县的滑坡识别任务。

第七章：总结与展望。本章汇总了本研究的主要贡献，并对未来的优化和改进工作进行了前瞻性的展望。

1.5 本文技术路线图




图 1.1 论文技术路线图

1.6 本章小结

本章全面而深入地阐述了本研究的背景和意义,对滑坡识别方法国内外的研究现状进行了详尽的概述,重点调研了深度学习滑坡识别方法。此外,本章还对研究的主要内容进行了概括,并对整篇论文的结构进行了清晰的介绍。

第二章 深度学习算法相关理论

深度学习技术，作为人工智能的核心分支，已从最初的多层感知机（Multilayer Perceptron, MLP）演变到基于卷积层的卷积神经网络，再到当前基于 Transformer^[62] 的模型。MLP 通过多个全连接层和非线性激活函数处理非线性问题，尽管结构简单但对数据形状敏感且容易过拟合。相比之下，CNN 通过卷积层和汇聚层有效提取局部特征并降低维度，优化了图像数据的处理。然而，CNN 在处理全局空间结构方面存在局限。

Transformer 模型通过自注意力机制有效处理长序列依赖关系，在自然语言处理领域外，该模型亦被广泛应用于计算机视觉。例如，Vision Transformer (ViT) 通过将图像分割成序列的形式，为图像处理任务提供了一种新的方法^[63]。然而，Transformer 架构在图像处理领域面临计算复杂度高的挑战，为此，Swin Transformer^[64] 被开发出来以应对此问题。

总体而言，深度学习的发展历程展示了技术的持续迭代和性能的逐步提升，每一代技术都为解决更复杂的问题提供了更精细化的工具。本章将详细阐述 MLP、CNN 以及 Transformer 的算法原理。

2.1 多层感知机

2.1.1 模型结构

MLP 是一种基于前馈神经网络的结构，其设计的灵感主要源于生物神经系统的基本组成单元——神经元。MLP 由一系列全连接层堆叠构成。在这个结构中，每层含有多个神经元，不同层之间的神经元通过加权连接进行交互，并利用非线性激活函数为输入信号添加非线性映射。值得注意的是，每个神经元节点都与其前一层的所有节点以及后一层的所有节点相连接，这也是全连接层的主要特点。

MLP 架构通常被划分为输入层、隐藏层和输出层，每一部分都有其特定的功能。输入层主要是接收数据，本身并不执行任何计算操作。隐藏层是 MLP 的核心部分，负责执行大部分计算任务。最后，输出层根据特定的任务需求，将隐藏层的输出进行最终的转化，得到最后的输出结果。假设一个 MLP 模型具有 L 层，则可以将前 $L-1$ 层视为特征表示部分，而将最后一层视为线性预测器。这种方式下，前 $L-1$ 层的任务是学习输入数据的有效表示，而最后一层则基于这些表示进

行预测^[39]。

以图 2.1 为例，图中展示的是一个单隐藏层的 MLP 模型结构，该隐藏层包含 6 个隐藏单元。该多层感知机接收 5 个输入并产生 3 个输出。虽然输入层在这个模型中起到了数据接收的作用，但它并不涉及任何计算过程，实际的计算仅在隐藏层和输出层中进行。因此，该 MLP 模型的层数为 2，且均为全连接层。

尽管 MLP 是最基础的深度学习模型，但它包含了深度学习所需的所有关键步骤。接下来，本文将以一个单隐藏层的 MLP 模型为例，详细解析模型计算过程中的前向传播计算流程、激活函数的作用、前向传播计算图，以及反向传播的计算过程。




图 2.1 单隐藏层的 MLP 模型（改编自阿斯顿·张等，2023^[39]）

2.1.2 前向传播

在神经网络中，前向传播（Forward Propagation）是按照模型的层级结构，从输入层逐步向输出层进行的计算过程。在这个过程中，每一层的计算结果都会被储存，以便于后续的计算和使用。以单隐藏层的 MLP 模型为例，设 X 为输入矩阵，其中包含 n 个样本，每个样本具有 d 个特征，隐藏层具有 h 个隐藏神经元。该 MLP 隐藏层的前向传播计算过程可由公式 2.1 表示，其输出层的前向传播计算过程可由公式 2.2 表示。

$$H = \sigma(XW^{(1)} + b^{(1)}) \quad (2.1)$$

$$O = HW^{(2)} + b^{(2)} \quad (2.2)$$

式中， $H \in R^{n \times h}$ 代表隐藏层的输出，而 $O \in R^{n \times q}$ 则代表输出层的输出， $X \in R^{n \times d}$ 为输入样本， $W^{(1)} \in R^{d \times h}$ 代表隐藏层神经元节点权重， $b^{(1)} \in R^{1 \times h}$ 为隐藏层偏执， $W^{(2)} \in R^{h \times q}$ 代表输出层神经元节点权重， $b^{(2)} \in R^{1 \times q}$ 为输出层偏执， $\sigma(\cdot)$ 为隐藏层激活函数。

2.1.3 激活函数

激活函数是一种非线性函数,通常用于为神经元节点的输出提供非线性映射。如果在公式 2.1 中未使用激活函数,那么 MLP 的前向传播将会转变为公式 2.3 所示。在这种情况下,MLP 模型将退化为单层模型。显然,如果不添加激活函数,无论 MLP 的层数如何,其行为都将等价于单层模型,从而失去多层网络结构的优势。

修正线性单元函数 (Rectified Linear Unit, ReLU) 是深度学习模型中常用的激活函数,如公式 2.4 所示。ReLU 函数的优点在于其实现简单,且在各种预测任务中都有良好的表现。ReLU 提供了一种简单但有效的非线性变换。对于给定的输入元素,ReLU 函数的输出被定义为该输入元素与 0 的最大值。即为 ReLU 函数通过将所有负数输入值设为 0,从而只保留正数输入值。这种操作简单有效地引入了非线性,使得深度学习模型能够学习并逼近复杂的函数。

$$\begin{aligned} \mathbf{O} &= (\mathbf{X}\mathbf{W}^{(1)} + \mathbf{b}^{(1)})\mathbf{W}^{(2)} + \mathbf{b}^{(2)} = \mathbf{X}\mathbf{W}^{(1)}\mathbf{W}^{(2)} + (\mathbf{b}^{(1)}\mathbf{W}^{(2)} + \mathbf{b}^{(2)}) \\ &= \mathbf{X}\mathbf{W} + \mathbf{b} \end{aligned} \quad (2.3)$$

$$\text{ReLU}(x) = \max(x, 0) \quad (2.4)$$

式中, $\mathbf{W} = \mathbf{W}^{(1)}\mathbf{W}^{(2)}$, $\mathbf{b} = \mathbf{b}^{(1)}\mathbf{W}^{(2)} + \mathbf{b}^{(2)}$, x 为 ReLU 函数的输入。

2.1.4 前向传播计算图

在深度学习中,计算图是一种核心工具,它以图形的方式表达复杂的数学表达式,使得复杂的数学运算可视化。更重要的是,通过绘制计算图,能够简单、有效地计算出每个参数的梯度,大大简化了神经网络的训练和优化过程。最后,计算图的存在还使得深度学习框架能够在运行前,通过优化计算图消除冗余计算、重新排列计算顺序以减少内存需求,从而达到优化计算性能的目的。因此,计算图在深度学习中发挥着至关重要的作用。

如下图 2.2 所示,以下将以计算图的形式详细描绘和解释单隐藏层多层感知器模型的计算过程,即将公式 2.1 和 2.2 的计算流程用计算图进行可视化表示。图中每个矩形方框代表变量,每个圆圈表示一个运算操作,每个箭头指代数据的流动方向,图中变量 $\mathbf{U}$ 、 $\mathbf{Z}$ 和 $\mathbf{V}$ 为计算过程中产生的中间变量,符号 $\mathcal{L}$ 表示通过损失函数计算模型输出 $\mathbf{O}$ 与真实标签 $\mathbf{Y}$ 之间的损失值 ℓ 。




图 2.2 单隐藏层 MLP 模型前项传播计算图

2.1.5 反向传播

反向传播（Backward Propagation）^[65]是一种高效计算神经网络参数梯度的策略，其主要优势在于其计算效率和准确性。它依据微积分中的链式法则，从输出层向输入层反向遍历网络。在这个过程中，该算法会保存在计算特定参数梯度时所需要的所有中间变量（即偏导数）。这种策略避免了直接计算复杂函数的梯度，从而大大提高了计算效率。此外，通过存储和利用中间变量，反向传播能够保证梯度计算的准确性，从而提高神经网络的学习效率和模型性能。下面，以上述单隐藏层 MLP 模型为例，结合前向传播计算图 2.2 来推导计算模型参数 $W^{(1)}$ ， $W^{(2)}$ ， $b^{(1)}$ 和 $b^{(2)}$ 的误差梯度公式。

为了计算输出层偏置项 $b^{(2)}$ 的梯度，需要求解损失函数输出值 ℓ 对 $b^{(2)}$ 的偏导数。根据链式法则和计算图，可以推导得出对应的公式 2.5。在这个公式中， $\frac{\partial \ell}{\partial O}$ 代表损失函数对输出层输出的偏导数。

$$\frac{\partial \ell}{\partial b^{(2)}} = \frac{\partial \ell}{\partial O} \frac{\partial O}{\partial b^{(2)}} = \frac{\partial \ell}{\partial O} \quad (2.5)$$

接下来求解输出层权重 $W^{(2)}$ 的梯度，同样根据链式法则和计算图，得到如下的公式 2.6。

$$\frac{\partial \ell}{\partial W^{(2)}} = \frac{\partial \ell}{\partial O} \frac{\partial O}{\partial V} \frac{\partial V}{\partial W^{(2)}} = \frac{\partial \ell}{\partial O} H^T \quad (2.6)$$

将梯度反向传播至隐藏层，以便计算隐藏层参数的相关梯度。隐藏层输出 H 的梯度的计算公式如公式 2.7 所示。

$$\frac{\partial \ell}{\partial \mathbf{H}} = \frac{\partial \ell}{\partial \mathbf{O}} \frac{\partial \mathbf{O}}{\partial \mathbf{V}} \frac{\partial \mathbf{V}}{\partial \mathbf{H}} = \frac{\partial \ell}{\partial \mathbf{O}} \mathbf{W}^{(2)} \quad (2.7)$$

中间变量 $\mathbf{Z}$ 的梯度由公式 2.8 所示，式中 $\sigma'(\cdot)$ 为激活函数的导数，符号 $\circ$ 表示为哈达玛乘积运算符^[66]。

$$\frac{\partial \ell}{\partial \mathbf{Z}} = \frac{\partial \ell}{\partial \mathbf{H}} \frac{\partial \mathbf{H}}{\partial \mathbf{Z}} = \frac{\partial \ell}{\partial \mathbf{H}} \circ \sigma'(\mathbf{Z}) \quad (2.8)$$

接下来，继续应用链式法则并参考计算图，以计算隐藏层参数 $\mathbf{b}^{(l)}$ 和 $\mathbf{W}^{(l)}$ 的梯度值。偏置项 $\mathbf{b}^{(l)}$ 的梯度计算公式为公式 2.9，而权重项 $\mathbf{W}^{(l)}$ 的计算公式为公式 2.10。至此，完成了该模型参数的误差梯度计算公式推导。

$$\frac{\partial \ell}{\partial \mathbf{b}^{(l)}} = \frac{\partial \ell}{\partial \mathbf{Z}} \frac{\partial \mathbf{Z}}{\partial \mathbf{b}^{(l)}} = \frac{\partial \ell}{\partial \mathbf{Z}} \quad (2.9)$$

$$\frac{\partial \ell}{\partial \mathbf{W}^{(l)}} = \frac{\partial \ell}{\partial \mathbf{Z}} \frac{\partial \mathbf{Z}}{\partial \mathbf{U}} \frac{\partial \mathbf{U}}{\partial \mathbf{W}^{(l)}} = \frac{\partial \ell}{\partial \mathbf{Z}} \mathbf{X}^T \quad (2.10)$$

2.2 卷积神经网络

2.2.1 模型结构

CNN 是一种特殊的人工神经网络，其设计原理受到生物视觉系统的启发。CNN 通过卷积层和汇聚层的层次结构，逐步扩大输入样本的感受野，从而捕获全局特征。CNN 模型的卷积层和汇聚层可以在计算过程中最大限度地保留样本的空间结构信息。此外，CNN 的参数共享策略显著降低了模型的计算复杂度。因此，当处理固定大小的网格数据（如图像数据）时，CNN 表现出显著的优势。

CNN 主要由三种类型的层构成：卷积层，汇聚层，和全连接层。卷积层是 CNN 的关键组成部分，通过一系列核函数对输入数据进行处理，生成相应的特征图（Feature Maps）。每个核函数能够学习并提取输入数据的不同特征。汇聚层通常紧随卷积层之后，其主要任务是降低特征图的维度，从而有助于减轻模型的计算负担，同时增强模型对空间或时间变换的鲁棒性。全连接层位于一系列卷积层和汇聚层之后，用于整合所有已学习的特征，并产生最终的分类或回归结果。全连接层的设计与传统的 MLP 模型相似。图 2.3 为典型卷积神经网络 AlexNet 模型的结构概述。




图 2.3 AlexNet 结构概述

2.2.2 卷积层

在数学中，卷积（Convolution）^[67]是一个非常重要的概念，它将两个函数组合成一个新的函数，这个新函数描述了一个函数在另一个函数上的加权平均值的累积效应。对于连续函数 $f(\cdot)$ 和 $h(\cdot)$ ，卷积定义为公式 2.11。在该定义中，连续函数 $f(\cdot)$ 和 $h(\cdot)$ 的卷积用 $(f * h)(s)$ 表示，是函数 $f(\tau)$ 和 $h(s - \tau)$ 的乘积在所有 τ 上的积分。这个过程可以理解为，函数 $h(\cdot)$ 被翻转并移动，然后与函数 $f(\cdot)$ 相乘，最后对其相乘结果进行积分运算。对于离散序列，卷积定义为公式 2.12，该定义与连续函数的卷积非常类似，只是积分运算被换成了求和运算。

$$(f * h)(s) = \int_{-\infty}^{\infty} f(\tau)h(s - \tau)d\tau \quad (2.11)$$

$$(f * h)[n] = \sum_{m=-\infty}^{\infty} f[m]h[n - m] \quad (2.12)$$

式中， $*$ 为卷积运算符号， $f[\cdot]$ 和 $h[\cdot]$ 为取整函数用于表示离散序列。

尽管深度学习中，卷积层的名字来源于数学中的卷积运算，但实际上，卷积层的运算过程中并未执行数学卷积所必需的核函数翻转步骤，其操作更接近于互相关运算（Cross-correlation）^[68]。考虑到卷积层中的核函数是通过学习获得，因此无论卷积层执行的是卷积运算还是互相关运算，卷积层的输出都不会受到影响^[69]。为了与大多数深度学习文献保持一致，本文将继续使用卷积一词指代卷积层的运算过程。

对于卷积层的运算过程，可设卷积层的输入为 I 其宽度和高度为 W 和 H ；设核函数为 K ，其宽度和高度为 W_K 和 H_K ；在特征图 I 上，核函数 K 沿 W 方向滑动的步幅为 s_W ，沿 H 方向滑动的步幅为 s_H 。在这种设定下，卷积层的运算过程可以由公式 2.13 表示。设输入特征图 I 在 W 方向的填充量为 p_W ，在 H 方向的填充量为 p_H 。则通过卷积运算后，输出特征图 O 与输入特征图 I 的尺寸关系可以由公式 2.14 和公式 2.15 描述。

$$O(i, j) = \sum_{m=0}^{W_k-1} \sum_{n=0}^{H_k-1} I(i \cdot s_W + m, j \cdot s_H + n) K(m, n) \quad (2.13)$$

$$W_O = (W - W_K + p_W + s_W) / s_W \quad (2.14)$$

$$H_O = (H - H_K + p_H + s_H) / s_H \quad (2.15)$$

式中, i, j 为卷积层输出特征图的空间像素坐标, m, n 为卷积层卷积运算时, 特征图 I 当前位置与卷积窗口左上角的相对偏移, W_O 和 H_O 为卷积层输出特征图的宽度和高度。

图 2.4 展示了卷积运算过程, 设输入特征图 I 的宽和高均为 4, 在 W 和 H 方向上的填充均为 0; 核函数 K 的尺寸为 3×3 , 沿着特征图 W 和 H 方向上滑动的步幅均为 1。在图示中, 卷积窗口从输入张量的左上角开始, 按照从左到右、从上到下的顺序滑动。当卷积窗口滑动至新的位置时, 窗口所覆盖的输入张量部分与卷积核张量进行元素级别的相乘运算。然后, 这些乘积元素求和, 得到一个标量值。输出特征图尺寸可由公式 2.14 和公式 2.15 计算得出。

输入		核函数		输出																													
<table border="1" style="border-collapse: collapse; width: 100px; height: 100px;"> <tr><td>0</td><td>1</td><td>2</td><td>3</td></tr> <tr><td>4</td><td>0</td><td>6</td><td>0</td></tr> <tr><td>0</td><td>3</td><td>5</td><td>0</td></tr> <tr><td>0</td><td>8</td><td>7</td><td>0</td></tr> </table>	0	1	2	3	4	0	6	0	0	3	5	0	0	8	7	0	*	<table border="1" style="border-collapse: collapse; width: 100px; height: 100px;"> <tr><td>0</td><td>1</td><td>2</td></tr> <tr><td>3</td><td>1</td><td>5</td></tr> <tr><td>2</td><td>1</td><td>0</td></tr> </table>	0	1	2	3	1	5	2	1	0	=	<table border="1" style="border-collapse: collapse; width: 100px; height: 100px;"> <tr><td>50</td><td>19</td></tr> <tr><td>48</td><td>43</td></tr> </table>	50	19	48	43
0	1	2	3																														
4	0	6	0																														
0	3	5	0																														
0	8	7	0																														
0	1	2																															
3	1	5																															
2	1	0																															
50	19																																
48	43																																

图 2.4 卷积运算 (改编自阿斯顿·张等, 2023^[39])

2.2.3 汇聚层

在图像处理的神经网络设计中, 通常会逐渐降低隐藏层的空间分辨率并汇总信息, 这种设计策略旨在扩大神经元的感受野, 使其对图像的全局特征更加敏感。这样的信息聚合策略有助于模型实现全局特征学习的目标, 同时保留了卷积层的优势。汇聚层则提供了一种有效的方法, 减少模型对小空间变化的敏感度, 帮助模型更好地提取和学习图像的全局特征, 而不仅仅是局部特征。

汇聚层的工作方式, 类似于卷积层, 通过在输入特征图上滑动固定形状的窗口计算输出, 但汇聚层不包含计算参数。在深度学习中, 汇聚层通常用于计算窗口中所有元素的最大值或平均值, 窗口按照从左到右、从上到下的顺序在输入张量内滑动, 并在每个位置计算窗口中的最大值或平均值, 相关操作分别称为最大汇聚 (Maximum Pooling) 和平均汇聚 (Average Pooling)。

以图 2.5 为例, 该图展示了最大汇聚层的计算过程。图中的蓝色部分表示特

征图的第一个输出元素及其对应的输入元素。通过最大汇聚操作，从输入窗口中选取了最大的元素值作为输出。




图 2.5 最大汇聚层运算（改编自阿斯顿·张等，2023^[39]）

2.2.4 模块化结构

在深度学习中，模块化是一种重要的设计思路，它允许研究人员创建可重用的组件，使复杂的深度学习模型更易于理解和维护。同时，模块化为深度学习模型提供了巨大的灵活性，使得研究人员能够轻松地修改模型结构，扩展模型深度或者添加新的功能模块。VGG^[70]模型和 ResNet^[71]模型的结构设计充分展示了模块化的优势。

VGG 模型是首个采用模块化结构设计的深度学习模型，其由多个 VGG 块堆叠而成。VGG 块采用多个连续的小型 3×3 卷积核取代了 AlexNet 中的较大卷积核的策略，在保持感受野大小相同的情况下，减少计算消耗。此外，这种设计策略通过引入多层线性层，增加了网络的深度，使其能够学习更复杂的模式，从而有效地提升了神经网络的性能。与早期的深度学习模型相比，采用模块化设计思路的 VGG 模型更易于扩展，具有更高的易用性和灵活性，使得深度学习模型能够进一步增加深度和规模。图 2.6 为 VGG 块和 VGG 网络结构概述。




图 2.6 VGG 块和 VGG 模型概述（改编自阿斯顿·张等，2023^[39]）

ResNet 模型继承了 VGG 的模块化设计思路，并通过引入残差块（Residual Block）有效地解决了深度网络的退化问题，提高了网络性能，并通过添加跳跃连接，使得梯度可以直接反向传播，从而缓解了梯度消失问题，使网络更易于训练，从而实现了更深、更大的网络结构。图 2.7 为 ResNet 残差块结构概述。




图 2.7 ResNet 残差块结构概述（改自阿斯頓·张等，2023^[39]）

ResNet 模块化设计策略提供了高度的灵活性，通过堆叠残差模块，允许研究人员和开发人员根据特定任务的需求和计算资源的限制，轻松地修改网络的深度，能够构建出非常深的 ResNet 模型，例如在计算机视觉中广泛应用的 ResNet-152 架构，其深度达到了数百层^[72]。

2.3 Transformer 模型

2.3.1 模型结构

Transformer^[62]模型与传统深度学习模型在结构上存在显著的区别，它是一个完全基于自注意力机制的深度学习框架。尽管最初 Transformer 模型主要在自然语言处理（Natural Language Processing, NLP）领域得到应用，但其独特的优点使得它逐渐被扩展到包括计算机视觉在内的多种现代深度学习场景。相较于传统模型，Transformer 的并行计算能力、处理长距离依赖性的效率、优秀的可解释性和良好的扩展性，使其在多种任务中取得了前沿性能。

如图 2.8 所示，Transformer 模型采用了模块化的设计策略，其整体架构由多个自注意力模块堆叠构成。在这些模块内部，Transformer 利用残差连接和层规范化（Layer Normalization, LN）^[73]来提升模型的训练稳定性，并有效防止过拟合现象。模型主要由编码器（Encoder）和解码器（Decoder）两部分组成，编码器的职责是理解和编码输入数据，而解码器则根据编码器的编码结果，生成最终的输出结果。在 Transformer 模型中，编码器和解码器均由自注意力模块构成。

输入序列和输出序列首先被转化为嵌入（Embedding）^[74]表示，并加上位置编码（Positional Encoding）^[62]，然后分别输入到编码器和解码器中进行处理。这种设计使 Transformer 模型能够有效地处理序列数据，并且保留了序列中的位置信息，进一步提高了模型的性能。




图 2.8 Transformer 架构概述（改编自阿斯顿·张等，2023^[39]）

2.3.2 注意力机制

在自然环境中，人类和动物经常需要从海量的无效信息中筛选出重要的信息。受此启发，人工智能领域的研究者引入了注意力机制，这种机制通过动态调整输入数据特征的权重，使模型能够更加关注重要的信息。

在注意力机制（Attention）的框架中，主要涉及三个核心元素：查询（Query）、键（Key）和值（Value）。查询可以被理解为一个问题或需求，它是驱动模型进行信息选取的动力。对于这个问题或需求，注意力机制会在一组值中进行筛选，这些值可以视为潜在的答案或响应。为了辅助模型在这些值中进行有效地选择，每个值都配有一个对应的键。这个键可以被视为一种标签或索引，帮助模型在众多值中找到与查询最匹配的答案。因此，注意力机制整体流程可简化为，通过提出一个问题（即查询），匹配一组标签（即键），从而在相应的信息（即值）中找出最相关的答案。假设存在一个查询 q 和 n 个键值对，那么注意力汇聚函数 f 可表示为公式 2.16 所示的加权和。

$$f(q, (k_1, v_1), \dots, (k_n, v_n)) = \sum_{i=1}^n \frac{\exp(\alpha(q, k_i))}{\sum_{j=1}^n \exp(\alpha(q, k_j))} v_i \quad (2.16)$$

式中, $q \in R^q$, $k_i \in R^k$, $v_i \in R^v$, α 为注意力评分函数。

在实际应用中, 通常希望在给定相同的查询、键和值集合的情况下, 模型能够通过相同的注意力机制学习并表现出不同的行为。这些不同的行为可以被视为各种知识的组合, 能够捕捉序列中不同范围的依赖关系, 这与卷积神经网络中不同的卷积核识别不同模式的原理类似。因此, 允许注意力机制将查询、键和值映射到不同子空间, 再求解注意力汇聚是有益的。因此, 可以利用 h 组不同的线性投影对查询、键和值进行转换, 将其映射到不同的子空间, 然后并行地将它们送入注意力聚合模块。随后, 将这 h 个输出拼接并通过另一个线性投影得到最终输出, 这种设计策略被称为多头注意力 (Multi-Head Attention, MHA) [62], 可用公式 2.17 表示。

$$h_i = f(W_i^{(q)} q, W_i^{(k)} k, W_i^{(v)} v) \quad (2.17)$$

式中, $q \in R^q$, $k \in R^k$, $v \in R^v$, h_i 为第 i 个注意力头的输出, $W_i^{(q)} \in R^{q \times q}$ 为查询 q 的第 i 个线性映射, $W_i^{(k)} \in R^{k \times k}$ 为键 k 的第 i 个线性映射, $W_i^{(v)} \in R^{v \times v}$ 为值 v 的第 i 个线性映射。

自注意力机制[62]是对传统注意力机制的一种扩展, 它能够捕捉输入特征内部的相关性, 而无需依赖外部信息。在应用自注意力机制时, 序列在被输入到注意力聚合的过程中, 同一组序列同时扮演查询、键和值的角色, 每个查询都会与所有的键值对进行交互, 并据此生成一个注意力输出。由于查询、键和值都源自同一组输入, 因此, 该机制被称为自注意力, 它可由公式 2.18 表示。

$$y_i = f(x_i, (x_1, x_1), \dots, (x_m, x_m)) \quad (2.18)$$

式中, y_i 为第 i 个自注意力输出, f 为注意力汇聚函数, $x_i \in R^d$ 是一组序列输入。

2.3.3 Swin Transformer 模型结构

Swin Transformer[64]是一种由微软研究院在 2021 年提出的模型, 其整体结构如图 2.9 所示。它采用了与卷积神经网络类似的层次化特征映射构建方法, 通过在特征图上进行不同尺度的下采样操作, 获取多尺度的特征表示, 从而有效地处理多尺度问题。通过在不同尺度的特征图上提取特征, 模型能够捕捉到目标在不

同尺度上的特性获取更丰富的信息，从而提高模型的性能。




图 2.9 Swin Transformer 模型结构概述（改自 Liu 等，2021^[64]）

为了减轻计算负担，Swin Transformer 设计使用了窗口多头自注意力机制（Windows Multi-Head Self-Attention, W-MSA）模块。在进行特征图的下采样过程中，模型将特征图划分为多个不相交的窗口，并在每个窗口内执行 MHA 操作。然而，这种方法虽然有效地降低了计算量，却也阻碍了不同窗口间的信息交流。为了解决这一问题，Swin Transformer 的作者提出了一种新的策略，即偏移窗口多头自注意力机制（Shifted Windows Multi-Head Self-Attention, SW-MSA）。该策略通过对窗口进行偏移，实现窗口与其周围窗口的信息交互，从而解决了信息隔离的问题。因此，每一个包含 W-MSA 模块的 Swin Transformer Block 都会紧接着一个采用 SW-MSA 模块的 Swin Transformer Block。W-MSA 模块以及

SW-MSA 模块的工作原理如图 2.10 所示。




图 2.10 W-MSA 模块和 SW-MSA 模块示意（改自 Liu 等，2021^[64]）

相对于 ViT 模型架构，Swin Transformer 通过多次下采样的设计策略，能够更有效地获取丰富的多尺度特征信息。这种设计使得 Swin Transformer 作为 Backbone，能够为各种下游任务提供更广泛的支持，特别适合于目标检测、语义分割等任务的实现。另外，Swin Transformer 引入的窗口注意力机制有助于降低模型的计算复杂度，使其在保持高性能的同时，提高了计算效率。

2.4 语义分割概述

2.4.1 语义分割

语义分割是计算机视觉中的一项关键任务，其目标是理解图像在像素级别上的含义。这是一种像素级的分类预测任务，其核心在于根据各对象的语义重要性对图像进行划分，并为图像中的每个目标生成像素级别的掩码。语义分割的目的是简化或改变图像的表达形式，使图像更易于理解和分析。这个过程涉及将每个像素与类别标签相关联，其中同一类别的所有目标之间并没有明显的区别。换句话说，语义分割不仅能标注出图像中的对象，还能确定这些对象在图像中的精确位置，从而实现对图像中每个像素内容的识别和理解，其语义区域的标注和预测均达到了像素级别。

在传统的图像分割方法中，图像通常采用 RGB 三通道数据格式，这意味着每个像素包含红色、绿色和蓝色三种原色信息。如果对单个像素进行分类，可能会将颜色相同的像素归为一类，这显然与实际情况不符。因此，研究人员通常会根据图像的颜色、纹理和形状等特征设计相应的分割算法。随后，利用这些低级特征和分割算法将图像划分为多个区域或对象。然而，这些方法往往无法理解图像的高级语义信息，仅能识别出不同的颜色或形状区域。在复杂的实际环境中，这些方法的效果可能会受到较大影响，为特定区域精心设计的算法可能无法在其

他地方起到同样的效果。

相比之下,语义分割的优势在于其能够理解图像的语义信息,通过解析图像的含义,将图像划分为不同的类别。语义分割是通过训练深度学习模型实现的,这些模型属于数据驱动算法,能够学习从像素到对象类别的映射关系。这种方法避免了研究人员需要针对特定区域投入大量精力来设计分割算法,而且学习到的特征信息具有更广泛的代表性。因此,相较于传统的图像分割方法,语义分割具有更高的普适性。


总体而言,语义分割的主要优势在于其提供了一种强大的工具,能够解读和分析图像的高级语义信息。这对于许多计算机视觉任务,例如遥感地物划分、自动驾驶、医疗图像分析等,具有至关重要的意义。

2.4.2 常用的语义分割模型及其架构


语义分割,作为计算机视觉中的一项重要任务,主要依赖于深度学习算法来实现。典型的语义分割模型会输出一个与原始图像分辨率相对应的掩码图,该掩码图通常包含 n 个通道,对应模型的输出类别数。在这 n 个通道中,每个通道的掩码图通常是一个二值图像,其中目标对象存在的位置被标记为 1,而其余区域则被填充为 0,类别的索引则从 0 到 $n-1$ 进行编号。

FCN^[75]被认为是用深度学习网络实现语义分割的奠基性工作。FCN 首次将 CNN 扩展到像素级别的预测,使得网络能够接受任意大小的输入,并输出与输入相同大小的分割图。FCN 通过使用反卷积(Deconvolution)完成特征图上采样操作,将卷积层的特征图恢复到原始图像的分辨率,从而实现像素级别的分类。

U-Net^[76]模型可以被视作是 FCN 的一种扩展和优化。U-Net 采用了编解码器架构,其中编码器部分充当网络的特征提取器,它通过压缩原始图像并逐步提取出富含高级语义信息的特征图,完成图像压缩和去噪任务,而解码器则负责将编码器提取出的高级特征进行上采样,恢复到与原始图像相对应的分辨率,以实现端到端的训练。U-Net 引入了长跳跃连接,以弥补编码过程中由于下采样导致的信息损失,帮助网络在解码过程中更精准地恢复物体的细节定位。通过这种方式,U-Net 实现了不同层级特征之间的信息融合,从而形成了一种隐式的特征金字塔结构^[77]。图 2.11 为 U-Net 模型结构概述。

图 2.11 U-Net 模型结构概述 (改编自 Ronneberger 等, 2015^[76])

SegFormer^[78]是基于 Transformer 架构的语义分割模型的重要创新,它成功地解决了 SETR^[79]模型的核心问题。SETR 模型采用 ViT-larger 作为主干,其参数量巨大,并且随着输入图片的尺寸增大,计算量会以平方级别增长。其次,ViT 的柱状结构只能产生固定分辨率的特征图,这在某种程度上会导致细节信息的丧失,从而对解码器在恢复特征时造成困扰,因此并不适用于需要多尺度特征信息的语义分割任务。此外,对于语义分割任务,如果输入样本的分辨率发生变化,ViT 固定分辨率的位置编码可能会因位置编码的插值操作,导致模型的性能受到影响并出现下降。而 SegFormer 的设计有效地解决了这些问题。图 2.12 为 SegFormer 模型的结构概述

图 2.12 SegFormer 结构概述 (改编自 Xie 等, 2021^[76])

SegFormer 通过巧妙地设计分层 Transformer 编码器和轻量级的全连接多层感知机 (All-MLP) 解码器,实现了高效的特征提取和精确的像素级分类。在该

模型中舍弃了位置编码操作，使用 Mix-FFN (Mix Feed-Forward Network) 模块替代传统的 Transformer Block 中的前馈神经网络 (Feed-Forward Neural Network) 模块，以学习位置信息。这一改进解决了标准 Transformer 架构中，样本分辨率不一致时，由于位置编码的插值导致模型性能下降的关键问题。此外，SegFormer 的编码器引入了 Overlap Patch Merging 操作，有效地捕获了图像的局部细节和全局上下文信息，同时保留了 Patch 周围的局部连续性。解码器则采用简洁的 MLP 结构，避免了复杂的设计和计算密集型的模块。最后，该模型提出的 MLP 解码器能够从不同层级聚合信息，结合局部注意力和全局注意力，生成强大的表示，从而在保持高准确性的同时显著提高了模型的运行效率。

2.5 特征可视化

在滑坡识别的语义分割任务中，梯度加权类激活图 (Gradient-weighted Class Activation Mapping, Grad-CAM) [80] 为研究人员提供了一种高效的可视化工具，用于深入分析深度学习模型如何处理与滑坡相关的图像区域。Grad-CAM 通过生成热力图，揭示了模型在决策过程中依赖的关键图像区域，其中亮度较高的区域通常标示出对模型决策具有重大影响的部分。如果模型的预测是准确的，预期中的滑坡区域应在 Grad-CAM 图像中被显著突出显示。相反，如果滑坡区域没有被突出显示，或者非关键区域被错误地高亮，这可能表明模型在处理此类图像任务时存在缺陷。此外，Grad-CAM 不仅提升了模型的可解释性，还有助于优化模型架构和训练流程，从而增强预测的准确性和模型的鲁棒性。

2.6 损失函数

损失函数在深度学习中是一个关键的组成部分，其用于量化模型预测结果与真实值之间的差异。通过最小化损失函数，可以找到最优的模型参数，使模型的预测结果尽可能接近真实值，从而提高模型的性能和泛化能力。简而言之，损失函数定义了模型学习的目标和优化的方向，是连接模型预测结果和真实目标的重要桥梁。在计算机视觉领域，交叉熵损失 (Cross Entropy Loss, CEL) [81] 和 Dice 损失 (Dice Loss, DL) [82] 被广泛使用。

CEL 常用于处理分类问题，它能有效地衡量模型预测的概率分布与真实分布之间的差距。在图像处理任务中，如果将每个像素的预测视为一个分类问题，那么 CEL 就可以用来度量预测结果与真实值之间的差异，从而指导模型的优化

和学习。其计算公式如公式 2.19 所示。

$$L_{CEL}(y, \hat{y}) = -\sum_{i=1}^C y_i \log(\hat{y}_i) \quad (2.19)$$

式中， C 是类别总数， y_i 是第 i 类的真实标签， $\hat{y}_i$ 是模型预测第 i 类的概率。

DL 主要在图像分割任务中得到应用，特别是在处理类别不平衡的情况时，其性能表现尤为突出。该损失函数基于 Dice 系数，这是一种用于衡量两个样本相似度的指标，其取值范围在 0 和 1 之间，值越接近 1 则表示两个样本的相似度越高。在图像分割任务中，DL 损失函数能够使模型更加关注那些分类错误的像素，从而提升分割的准确性。其计算公式如公式 2.20 所示。

$$L_{DL}(y, \hat{y}) = 1 - \frac{2|y \cap \hat{y}|}{|y| + |\hat{y}|} = 1 - \frac{2\sum_{i=1}^N y_i \hat{y}_i}{\sum_{i=1}^N y_i^2 + \sum_{i=1}^N \hat{y}_i^2 + \varepsilon} \quad (2.20)$$

式中， y 是真实标签， $\hat{y}$ 是模型预测结果， $|y|$ 和 $|\hat{y}|$ 分别代表 y 和 $\hat{y}$ 的元素数量， $|y \cap \hat{y}|$ 表示 y 和 $\hat{y}$ 的交集的元素数量， y_i 是真实分割标签第 i 个像素的值， $\hat{y}_i$ 是模型预测分割结果第 i 个像素的值， N 是像素点的总数， ε 是一个极小数，用于避免分母为 0 的情况。

2.7 评价指标

在深度学习领域，评价指标扮演着衡量模型性能的核心角色。它们为研究者提供了一种工具，以便更深入地理解模型的优势和劣势，以及模型在特定任务上的表现。其中，总体精度 (Overall Accuracy, OA)，交并比 (Intersection over Union, IoU)、F1 分数、精确率 (Precision, P)、召回率 (Recall, R) 等，都可以从混淆矩阵中计算得出。

混淆矩阵是一种用于详细展示模型预测结果的工具，其形状为 $C \times C$ ， C 为类别总数。以二分类问题为例，混淆矩阵包含四个部分：真正例 (True Positive, TP)、假正例 (False Positive, FP)、真反例 (True Negative, TN) 以及假反例 (False Negative, FN)。TP 表示预测结果和标签均为正例的情况；FP 表示模型预测为正例而标签为负例的情况；TN 表示预测结果和标签均为负例的情况；FN 表示模型预测为负例而标签为正例的情况。如图 2.13 所展示，混淆矩阵四个变量之间的关系。




图 2.13 混淆矩阵其变量关系

OA 是评估分类模型性能的常见统计指标，通过比较正确分类的样本数量与总样本数量的比例来衡量模型的精确性。这一指标直观地显示了模型在整体数据分类任务上的表现。尽管 OA 提供了模型性能的快速概览，但它在处理类别不均衡的数据集时可能会掩盖对少数类的分类问题。因此，为了全面评估模型性能，OA 通常与 P、R、F1 分数以及 IoU 等指标结合使用。OA 的计算公式详见公式 2.21。

$$OA = \frac{TP + TN}{TP + FP + FN + TN} \quad (2.21)$$

IoU^[83]是一个常用的评估指标，用来衡量模型预测的分割区域与真实分割区域的一致性。对于每一个类别，计算预测区域和真实区域的交集，并除以它们的并集，得到的比值就是该类别的 IoU。IoU 取值范围是 0 到 1，值越大表示预测结果与真实结果的一致性越好。使用 IoU 作为评估指标的优点在于，它不仅考虑了预测区域和真实区域的大小，还考虑了它们的空间位置和形状。因此，IoU 可以更准确地反映模型的分割性能。IoU 的计算公式如公式 2.22 所示。

$$IoU = \frac{|y \cap \hat{y}|}{|y \cup \hat{y}|} = \frac{TP}{TP + FP + FN} \quad (2.22)$$

式中， y 是真实标签， $\hat{y}$ 是模型预测概率。

F1 分数^[84]是 P 和 R 的调和平均数，其能够平衡考虑模型的精确性和覆盖性。它对数据不平衡的情况具有较好的适应性，能够避免模型过度偏向某一类别的预测。此外，F1 分数易于理解和解释，其值在 0 至 1 之间，值越大表示模型性能越好。P、R 以及 F1 分数的计算公式如公式 2.23 至公式 2.25 所示。

$$P = \frac{TP}{TP + FP} \quad (2.23)$$

$$R = \frac{TP}{TP + FN} \quad (2.24)$$

$$F1 = \frac{2 \cdot P \cdot R}{P + R} \quad (2.25)$$

2.8 本章小结

本章阐述了与本文相关的深度学习理论，首先从 MLP 模型开始，详细阐述了深度学习的基础计算过程，包括前向传播、前向传播的计算图表示，以及通过前向传播计算图简化反向传播算法的计算过程。探讨了卷积的基本原理和汇聚层的概念，以及介绍了经典的卷积神经网络模型 Alex Net。进一步介绍了深度学习模型的模块化思想，并介绍了最初引入模块化设计思路的 VGG 模型，以及对深度学习后续产生重要影响的 ResNet 模型。

之后，本文介绍了 Transformer 模型的结构，并对其注意力机制的原理及运作过程进行了深入阐述。探讨了语义分割的关键技术原理，特别是其在滑坡识别任务中的应用优势。此外，本文还详细描述了如何利用 Grad-CAM 技术可视化模型决策区域。最后，文章介绍了在深度学习研究中常用的损失函数和评估指标，为后续章节的研究奠定了坚实的理论基础。

第三章 研究区域概况及基准数据集构建

依据中国“十四五”期间的地质灾害防治规划，四川南部、云南东北部、贵州东部和西部的高山峡谷地带是滑坡、崩塌及泥石流的主要防治区域。其中，鲜水河和龙门山断裂带周围的陡峭山地是这些防治区的核心部分^[20]。考虑到甘孜藏族自治州的泸定县是这些核心区域的重要组成部分，因此，本文选择泸定县作为滑坡识别研究的实验区域，用于验证本文所设计模型的有效性。其复杂的地质构造以及频繁发生的滑坡灾害，能为模型的性能评估提供良好的基础。

为了全面评估构建模型的性能并验证其有效性，本研究选用了广泛认证的开源滑坡数据集构建基准数据集，用于评估模型性能。这些数据集已在多项研究中得到验证，提供了丰富且多样化的滑坡样本。尽管这些数据集并未直接涵盖泸定研究区域，但其中一些采样地点具有与泸定县相似的地质和气候条件。因此，利用这些开源数据构建的基准数据集，能为模型在泸定研究区域的应用提供了必要的数据支持。

3.1 研究区域概况

泸定县坐落在青藏高原东南边缘的横断山脉地带，拥有典型的高山峡谷地貌特征，该地区的地形受到构造活动显著影响，展现出山川交错的景观。该地区的地势走向起初从北西至南东向，然后逐渐向南偏转，最终近乎呈现出南北走向，泸定县内主峰贡嘎山，位于泸定与康定交界，海拔达 7556 m，为四川最高峰^[20]。大渡河自南向北贯穿全县，形成东西分区，交汇处多有洪积扇或洪积锥地貌；河谷或沟谷多呈“V”型，谷缘至谷底相对高差大，常在 2000 至 3000 m，最高达 6500 m^[85]。

泸定县地貌丰富，特点为高差大、坡度陡、岩体破碎和岩石裸露。冰川地貌发达，主要集中在断裂带两侧，且拥有大量冰碛地形，断裂带沿线的高山山前地带常见冰碛台地，其面积广、表面平、向山外微倾^[20]。地层方面，前震旦系至第四系各有发育，但寒武系缺失，西部为变质岩区，东部为沉积岩、岩浆岩区^[86]。泸定县横跨扬子陆块区与羌塘—三江造山系两大一级构造单元，川滇南北向构造带、北东向龙门山构造带、北西向构造带构成了本区最基本的地质构造格架，区内主要的断裂构造包括鲜水河断裂、磨西断裂、玉科断裂、金坪断裂等^[8]。

泸定县的气候受东南、西南季风和青藏高原冷空气的复合影响，形成了显著

的气候垂直差异，海拔 1800m 以下的大渡河河谷及其支流地区呈现热带季风气候，是知名的干热河谷区^[87]。泸定县的降雨量呈现明显的时空差异性。通常，5 月至 10 月由西南季风控制，雨量增多，此时降雨量占全年的 90%以上，被称为湿半年；而从 11 月至次年 4 月，受南支西风气流影响，空气干冷，雨量稀少，降水量仅占全年的 10%左右，称为干半年^[88]。图 3.1 为泸定实验区域概述图。




图 3.1 实验区域

3.2 基准数据集构建

基准数据集在评估和比较不同算法模型方面起着至关重要的作用，不仅提供了一个公平且一致的环境，还是训练模型的重要资源。本研究整合并处理了三个公开且广泛使用的滑坡数据集，构建了一个基于 RGB 光学影像的多样化且丰富的滑坡基准数据集。该数据集将被用于训练、评估和验证所设计模型的精度，并用于与其他模型的性能比较。

3.2.1 毕节数据集概述

毕节滑坡数据集^[53]是由武汉大学的研究团队创建并发布的。在这个数据集中，

地质学家们利用地面分辨率为 0.8 m 的卫星影像和 DEM 数据，对 770 处滑坡进行了解译。这些滑坡包括落石、岩质滑坡以及少数的碎屑流滑坡。此外，这些解译结果也经过了实地调查的验证，以确保其准确性和可靠性。该数据集包含了 770 个滑坡样本以及 2003 个非滑坡区域样本。图 3.2 为毕节数据集部分样本示例。



图 3.2 毕节滑坡数据集样本示例

3.2.2 GVLM 数据集概述

全球超高分辨率滑坡数据集（Global Very-high-resolution Landslide Mapping, GVLM）^[52]由武汉科技大学的研究团队创建并发布的高分辨率滑坡数据集。该数据集基于谷歌地图 0.59 m 分辨率影像，由地质专家解译生成。图 3.3 为 GVLM 数据集部分样本示例。




图 3.3 GVLM 数据集样本示例

该数据集旨在覆盖全球六大洲的广泛滑坡地点，包括亚洲、非洲、北美洲、南美洲、欧洲和大洋洲。每个子数据集都包含一对双时相超高分辨率图像和相应

的地面真实地图，总覆盖面积达到 163.77 km²。这 17 个子数据集涵盖了各种滑坡类型，其大小、形状、发生时间、空间分布和土地覆盖类型各异，因此在遥感图像中表现出显著的光谱异质性和强度变化。通过这一高度多样化的数据集，可以有效评估深度学习模型的泛化性能。由于该数据集提供的区域整幅影像过大，无法直接用于模型训练，因此将其裁剪成 300×300 像素的样本图片以供实验使用。通过处理，最终得到样本图片共 5723 个，其中滑坡区域样本 2129 个，非滑坡区域样本 3594 个。

3.2.3 四川高精度航空正射影像数据集概述

四川高精度航空正射影像数据集（SCLM）^[89]由自然资源部四川基础地理信息中心团队创建并发布，该数据集是基于 0.2 至 0.9 m 的高分辨率航空正射影像数据构建的，包含了从 2008 年至 2020 年的 59 个滑坡灾害样本和 48 处泥石流灾害样本。这些样本通过人工目视解译方法进行灾害解译和样本标注，覆盖了四川省及其周边地区的典型滑坡和泥石流灾害事件，包括 2008 年汶川地震、2013 年芦山地震、2017 年九寨沟地震等重点灾区，以及金沙江和大渡河沿岸地区。

相较于其他国内外的相关数据集，该数据集在数据源质量、完整性和潜在应用等方面表现出更大的优势。与早期主要依赖卫星影像进行解译的研究相比，该数据集使用更高的空间分辨率和较少受天气、地形等因素影响的优质航空影像作为解译数据，无疑具有更大的优越性。

该数据集提供了单个滑坡的高分辨率数据，其中单个样本的分辨率高达 1181 像素。为了最大限度地发挥该数据集的优势，并扩大其在不同尺度的应用，本研究将其降采样为 580×580 像素和 256×256 像素的图片，从而形成了多分辨率维度的影像样本。通过处理，最终得到拥有三种不同分辨率共 177 个滑坡区域样本。图 3.4 为 SCLM 数据集经过下采样获得的三种不同尺度的滑坡样本。




图 3.4 SCLM 数据集通过下采样获得的三种不同分辨率的滑坡样本

3.2.4 基准数据集

基准数据集在训练和评估验证模型精度方面扮演着关键角色，是评估和比较不同算法模型的基石。笔者整合了毕节数据集、GVLM 数据集和 SCLM 数据集，将它们融合为一个具有强鲁棒性、广泛覆盖范围和多地方特性的基准数据集，以便于后续模型的训练和验证。其处理流程如图 3.5 所示。




图 3.5 基准数据集样本处理流程

该数据集总共包含 8673 个样本数据，其中滑坡区域样本 3076 个，非滑坡区域样本 5597 个。按照 80%和 20%的比例，随机划分了训练集和验证集。训练集包含 6939 个样本，其中滑坡区域样本 2460 个，非滑坡区域样本 4479 个；验证集包含 1734 个样本，其中滑坡区域样本 616 个，非滑坡区域样本 1118 个。图 3.6 为基准数据集部分样本示例。



图 3.6 基准数据集样本示例

3.3 本章小结

本章首先概述了本研究所涉及的泸定研究区域的地理位置、地形地貌、地质构造以及气候降雨等相关特性。然后，详细介绍了毕节滑坡数据集、SCLM 以及 GVLM 三种公开数据集的信息和其各自的特性，并阐述了对这些数据集进行的处理方法，和本文基准数据集的构建过程。最终形成的基准数据集按照 80%和 20%的比例，随机划分为训练集和验证集，训练集包含 6939 个样本，其中滑坡区域样本 2460 个，非滑坡区域样本 4479 个；验证集包含 1734 个样本，其中滑坡区域样本 616 个，非滑坡区域样本 1118 个。

第四章 基于交叉注意力机制的滑坡识别模型

针对 RGB 遥感影像中滑坡与背景特征的相似性, 本研究提出了一种交叉注意力机制模块 (Cross Attention Block, CAB)。该模块旨在加强模型对滑坡区域特征的提取效率, 并有效抑制背景噪声, 从而增强模型的特征识别能力。进一步地, 本研究将所开发的 CAB 模块与 Swin Transformer Block (STB) 整合, 构建了一种专门用于滑坡识别的语义分割模型。

4.1 基于交叉注意力机制模块设计

4.1.1 交叉注意力机制

交叉注意力机制, 作为自注意力机制的一种衍生形式, 主要应用于处理来自不同源的查询、键和值。计算交叉注意力时, 查询信息源自某一输入, 而键和值则源自另一输入。该机制首先计算查询与键之间的注意力得分, 然后通过 softmax 函数将这些得分转换为概率值, 这些概率值代表模型对每个键以及其相关联值的关注程度。最终, 利用这些概率值对相应的值进行加权求和, 得到的结果即为交叉注意力的输出。

在滑坡识别领域, 复杂的地理环境构成了滑坡识别的背景。能够有效地区分滑坡与其环境背景是实现滑坡精确识别和分割的重要步骤。本研究提出了一种基于交叉注意力机制的方法, 该方法通过构建一条包含样本全局滑坡特征的向量, 并将其与后续的特征图进行交叉注意力运算, 抑制背景区域的噪音, 同时增强滑坡区域特征, 以此提升最终的识别精度。

4.1.2 向量相似度

向量余弦相似度是一种常用的衡量向量相似度的方法^[90]。通过计算两个向量的内积, 除以两个向量的模, 可以得到它们在空间中关于夹角 θ 的余弦值, 该值介于 -1 到 1 之间, 可以用于衡量两个向量在空间上的相似度, 其计算公式由公式 4.1 所示。特别地, 当求解向量为单位向量时, 两个向量的模均为 1, 因此向量余弦相似度的计算公式等价于两个单位向量进行内积运算。假设有两个单位向量 $\mathbf{a}$ 和 $\mathbf{b}$ 。在二维空间中, 这两个单位向量可以表示为 $\mathbf{a} = (a_1, a_2)$ 和 $\mathbf{b} = (b_1, b_2)$ 。向量的内积定义为 $\mathbf{a}$ 和 $\mathbf{b}$ 的对应元素乘积之和, 即 $\mathbf{a} \cdot \mathbf{b} = a_1 \times b_1 + a_2 \times b_2$ 。如果两个单位向量的内积越大, 说明它们的方向越接近, 相似度也就越高。反之, 如果内积越小或者为零, 说明它们的方向差距越大或者垂直, 相似度也就越低。

$$\cos(\theta) = \frac{\mathbf{v} \cdot \mathbf{k}}{\|\mathbf{v}\| \|\mathbf{k}\|} \quad (4.1)$$

式中, θ 为向量 $\mathbf{v}$ 和 $\mathbf{k}$ 之间的夹角, $\cdot$ 为向量内积运算符, $\|\mathbf{v}\|$ 为向量 $\mathbf{v}$ 的模, $\|\mathbf{k}\|$ 为向量 $\mathbf{k}$ 的模。

4.1.3 交叉注意力机制模块

考虑到 RGB 光学影像的背景复杂性以及滑坡特征的模糊性, 有效地提取滑坡特征并抑制背景噪声成为至关重要的任务。为了应对这一挑战, 本文设计了一种 CAB 模块。该模块接收光谱特征图以及由 MLP Head 生成的全局滑坡特征向量 $\mathbf{k}$ 和滑坡相关性分数 p 。然后, CAB 模块计算特征图各部分与全局滑坡特征向量的关联性, 以评估其存在滑坡的可能性, 并对光谱特征图不同区域的值进行调整。这一设计使得模型能够弱化背景特征, 同时强化滑坡特征, 使得模型更专注于处理滑坡特征, 从而获得更精确的分割结果。

CAB 模块接收来自两个分支的输入: 一是具有高度 H 、宽度 W 和特征维度为 $C1$ 的光谱特征图 $\mathbf{I} \in \mathbb{R}^{H \times W \times C1}$, 另一个是由 MLP Head 模块输出的具有特征维度 $C2$ 的特征向量 $\mathbf{k} \in \mathbb{R}^{1 \times C2}$ 以及滑坡相关性分数 p 。在处理的初始阶段, 首先将光谱特征图 $\mathbf{I}$ 与特征向量 $\mathbf{k}$ 对齐至同一特征维度 d , 然后将处理后的光谱图的 H 和 W 两个维度合并为一个维度, 得到的结果分别记为 $\mathbf{I}_d \in \mathbb{R}^{n \times d}$ 和 $\mathbf{k}_d \in \mathbb{R}^{1 \times d}$, 其中 n 等于 H 和 W 的乘积。计算过程可由公式 4.2 和 4.3 表示。

$$\mathbf{I}_d = F_{merge}(F_{FC}(\mathbf{I})) \quad (4.2)$$

$$\mathbf{k}_d = F_{FC}(\mathbf{k}) \quad (4.3)$$

式中, $F_{FC}(\cdot)$ 表示一个包含 d 个神经元的全连接层, 该层配备了层规范化 (Layer Normalization) 和高斯误差线性单元 (Gaussian Error Linear Units, GELU) 激活函数; $F_{merge}(\cdot)$ 表示将特征图 $\mathbf{I}$ 的 H 和 W 维度融合为单一维度的操作。

考虑到 $\mathbf{k}_d$ 和 $\mathbf{I}_d$ 的特征空间可能存在不一致, 本文采用 L2 范数归一化^[91]将 $\mathbf{I}_d$ 中的每个特征向量以及 $\mathbf{k}_d$ 映射到同一特征空间, 得到的结果为 $\mathbf{I}_{l2} \in \mathbb{R}^{n \times d}$ 与 $\mathbf{k}_{l2} \in \mathbb{R}^{1 \times d}$ 。其计算过程有公式 4.4 和 4.5 所示。

$$\mathbf{I}_{l2} = L2(\mathbf{I}_d) \quad (4.4)$$

$$\mathbf{k}_{l2} = L2(\mathbf{k}_d) \quad (4.5)$$

式中， $L2(\cdot)$ 表示 L2 范数归一化操作。

接下来，计算 $\mathbf{I}_{l2}$ 与 $\mathbf{k}_{l2}$ 点积，获得两者的注意力特征图 $\mathbf{A} \in \mathbb{R}^{n \times 1}$ ，最后，注意力特征图 $\mathbf{A}$ 的 n 维度还原分解为原始的 H 和 W 维度，得到的结果 $\mathbf{A}_R \in \mathbb{R}^{H \times W \times 1}$ ，表示原始的输入 $\mathbf{I}_{in}$ 的对滑坡特征的全局交叉注意力特征图。接着，将 $\mathbf{A}_R$ 沿着特征维度广播，使其与 $\mathbf{I}_{in}$ 的维度对齐，从而得到 $\mathbf{A}_B \in \mathbb{R}^{H \times W \times C1}$ 。其计算过程可以有公式 4.6 至 4.8 计算得出。

$$\mathbf{A} = \mathbf{I}_{l2} \cdot \mathbf{k}_{l2} \quad (4.6)$$

$$\mathbf{A}_R = R(\mathbf{A}, n, H, W) \quad (4.7)$$

$$\mathbf{A}_B = B(\mathbf{A}_R, C, \mathbf{I}) \quad (4.8)$$

式中， $R(\mathbf{A}, n, H, W)$ 表示将矩阵 $\mathbf{A}$ 的 n 维度拆分为 H 和 W 两个维度； $B(\mathbf{A}_R, C, \mathbf{I})$ 表示 $\mathbf{A}_R$ 沿着 C 维度广播至 $\mathbf{I}$ 的形状大小。

考虑到在样本中可能不存在滑坡区域的情况，即整个样本全为背景区域时，MLP Head 生成的特征向量 $\mathbf{k}$ 可能会反映出与滑坡无关的特征，这可能会干扰 CAB 模块的正常运作。因此，本文引入了滑坡相关性分数 p ，用以约束 CAB 模块的输出。最终，将 $\mathbf{A}_R$ 和 $\mathbf{I}_{in}$ 进行哈达玛积运算并乘以 p 以得到最后的结果。结果可以由公式 4.9 计算得出。

$$\mathbf{O}_{CAB} = p \times \mathbf{I}_{in} \circ \mathbf{A}_B \quad (4.9)$$

式中， $\times$ 为标量乘以矩阵的运算符号； $\circ$ 为哈达玛积运算符。

图 4.1 为 CAB 模块的示意图，其中特征向量 $\mathbf{k}$ 、滑坡相关性分数 p 以及特征图 $\mathbf{I}$ 作为该模块的输入。首先，通过全连接层对 $\mathbf{I}$ 和 $\mathbf{k}$ 进行特征维度的统一，并将特征图 $\mathbf{I}$ 的 H 和 W 维度合并，获取拥有相同特征维度输出的 $\mathbf{I}_d$ 和 $\mathbf{k}_d$ 。接下来，通过 L2 归一化将 $\mathbf{I}_d$ 和 $\mathbf{k}_d$ 映射到相同的特征空间中。最后，将两者与 p 以及原始特征图 $\mathbf{I}$ 一同输入到交叉注意力层，计算得出最终的输出值。




图 4.1 CAB 模块示意图

4.2 基于交叉注意力机制的滑坡识别模型设计

4.2.1 ZiHao Net 模型设计概述

本研究设计了一种名为 ZiHao Net 的滑坡识别模型。该模型接受的输入参数为批次 b 的 224 像素宽度和高度的 RGB 三通道图像，并通过模型处理生成与输入图片尺寸相同的滑坡掩码。在模型的设计中，引入了一个 MLP Head 模块，其主要任务是提取样本的全局特征，并计算样本的滑坡相关性分数。CAB 模块使用从 MLP Head 模块获取的全局特征和滑坡相关性分数信息，对滑坡特征和背景特征进行精细地区分。该模块旨在通过增强滑坡特征和抑制背景噪声，从而提高滑坡识别的准确度。模型的整体可以分为四个部分：Backbone、Neck、MLP Head 以及 Head。

在模型的 Backbone 部分，选择 Swin Transformer^[64]作为特征提取网络，为了提高模型对多尺度特征的利用效率，本文在原有的 Swin Transformer 模型基础上设计添加了三条用于连接模型 Neck 部分的跳跃连接，用以输出不同尺度的特征图，增强模型对不同尺度滑坡目标的识别能力。在模型的 Backbone 和 Neck 的连接部分，采用了特征金字塔的结构设计，目的是让模型更高效地利用多尺度特征，并便于模型的 Head 部分进行样本特征的重构，在针对特征图恢复的部分，采用了 DUpsampling (DUS)^[92]模块实现。

针对模型 Neck 部分，本文融合 CAB 模块，使得模型能够弱化背景噪音，同时强化滑坡特征，使得模型更专注于处理滑坡特征，从而获得更精确的分割结果。

模型的 MLP Head 部分, 本文设计了一种简单的特征提取模块用以输出全局特征和滑坡相关性分数信息。首先采用全局平均汇聚压缩特征, 随后采用全连接层整合特征获得全局特征向量, 最后对全局特征向量加权求和, 求得最后的滑坡相关性分数信息。

对于模型的 Head 部分, 本文设计了一种简洁的语义分割 Head 用以整合 Neck 处理后的特征以及将特征进行还原, 该部分通过全连接层的特征整合能力处理特征图, 然后通过上采样层将特征图恢复为所需的特征尺寸。模型的整体结构如图 4.2 所示。




图 4.2 ZiHao Net 架构图

4.2.2 模型 Backbone 部分设计

在深度学习模型中, Backbone 部分起着关键的特征提取角色, 其能力在于是否能从样本中抽取出与滑坡相关的有益特征, 这将直接影响模型最终的识别性能。本研究选择了 Swin Transformer 作为模型的 Backbone, 并在 Swin Transformer 的基础上设计增加三条额外连接模型 Neck 部分的跳跃连接, 为模型提供多尺度的特征信息。

图 4.3 描绘了模型 Backbone 部分的全局架构。模型首先接受一个批次为 b 分辨率为 224×224 像素的 RGB 图片作为输入。接着, 该图片通过 Patch Partition 模块处理, 按照尺寸为 4×4 像素分割为 Patch, 并将每个 Path 展开为长度 48 的向量。这一转换操作将原始图片重构为一个尺寸为 56×56 的 Patch 矩阵, 每个

Patch 包含 48 个特征通道。然后，每个 Patch 的特征通过线性层被投影到预设的维度上，在 Swin Transformer 模型中，特征维度被设定为 96。接下来，两个连续的 STB 用于特征提取，随后通过 Patch Merging 模块完成模型的第一阶段（Stage 1）处理流程，得到尺寸为 $28 \times 28 \times 192$ 的特征图。最后，在第一阶段输出后面构建一条连接模型 Neck 部分的跳跃连接，用于传递第一阶段处理后的特征图。

在模型的第二阶段，通过两个连续的 STB 进行特征提取。接着，使用 Patch Merging 模块完成特征图的下采样操作，输出尺寸为 $14 \times 14 \times 384$ 的特征图。然后，通过跳跃连接，将这一阶段处理的特征图传递至模型的 Neck 部分。在模型的第三阶段，采用了六个连续的 STB 进行特征提取。然后，使用 Patch Merging 模块将尺寸为 $14 \times 14 \times 384$ 的特征图下采样至尺寸为 $7 \times 7 \times 768$ 的特征图。同样，通过跳跃连接，将这一阶段处理的特征图传递至模型的 Neck 部分。最后，在模型的第四阶段，通过两个连续的 STB 进行特征提取，然后输出尺寸为 $7 \times 7 \times 768$ 的特征图。

因此模型输出的特征图尺寸为 $7 \times 7 \times 768$ ，同时利用跳跃连接额外输出尺寸为 $7 \times 7 \times 768$ 、 $14 \times 14 \times 384$ 以及 $28 \times 28 \times 192$ 三种尺寸包含不同尺度信息的特征图，用以增强模型对于不同尺度滑坡信息的利用。




图 4.3 ZiHao Net 主干结构概述

4.2.3 模型 MLP Head 部分设计

滑坡特征的显著差异性，以及与其他地表特征的相似性，都对滑坡识别构成了显著的挑战。为了解决这个问题，本文设计了一种 MLP Head 模块，其核心职责是从复杂的样本特征中提取出与滑坡直接相关的特定特征，并计算样本的滑坡相关性分数。由于这个模块直接与损失函数相连接，误差梯度能够快速回传到

Backbone 部分, 从而实现 Backbone 参数的优化更新。这种设计策略不仅提升了模型对滑坡特征的提取能力, 而且为后续的 CAB 模块提供了关键信息, 从而使模型能够生成更为精确和准确的识别结果。

假设由 Backbone 处理后得到的特征图 I , 首先通过全局平均汇聚层对其进行压缩, 得到一个长度为 C 的向量 k_a 。随后, k_a 向量被送入一个包含 n 个神经元的全连接层, 进行学习并提取出一个新的特征向量 k 。基于此, 通过对特征向量 k 进行加权求和操作, 计算出一个被称为滑坡相关性分数的值 p 。当 p 值为正时, 模型预测样本存在滑坡, 且 p 值越大, 模型的确定性越强。反之, 当 p 值为负时, 模型预测样本不存在滑坡, 且 p 值越小, 模型的确定性越强。最后, 该模块输出特征向量 k 和滑坡相关性分数 p 。MLP Head 模块的具体结构如图 4.4 所示。




图 4.4 MLP Head 部分结构概述

4.2.4 模型 Neck 部分设计

本文设计的模型在 Neck 部分应用了在第 4 章第 1 节中提出的 CAB 模块, 其主要目的是强化滑坡特征并抑制背景噪声。同时, 该部分也采用了 STB 以增强对滑坡特征的提取以及对特征的重构。

模型的 Neck 部分主要负责特征图的恢复以及特征映射操作, 这部分的任务是处理从 Backbone 部分提取的特征信息, 并将其映射到适应特定任务需求的特征空间中, 以便 Head 部分可以进行有效的特征重构。基于这些需求, 模型的 Neck 部分基于 STB 搭建, 并引入了 CAB 模块。为了更有效地处理和利用从 Backbone 部分提取的特征信息, 模型在 Backbone 和 Neck 部分之间采用了特征金字塔结构。在上采样阶段, 即特征恢复部分, 模型通过对传入的特征图进行维度变换, 并运用其通道补偿特征图分辨率的损失, 以实现特征图的恢复和还原, 此部分是由 DUS 模块完成的。

图 4.5 展示了 Neck 部分的结构概览。在 Neck 的第一阶段, 首先接受经过 Backbone 处理的特征图作为输入。然后, 通过全连接层进行特征映射, 将特征

维度从 768 降至 384，以减轻模型的计算负担。随后，通过两个连续的 STB 进一步处理特征，完成该阶段的运算。从第二阶段开始，后续各模块的设计基本相同，主要的差异在于 STB 的数量。第三阶段采用了 6 个连续的 STB，而其他阶段则均使用两个连续的 STB。考虑到将要采用 CAB 模块，并且将接收来自相应层级 Backbone 跳跃连接的多尺度特征图，因此，首先将 Backbone 跳跃连接传递的特征图与上一阶段的输出在特征维度上拼接，从而生成一个融合了多尺度信息的新特征图。接着，通过全连接层将这个特征图的维度降低，以减少内存需求。然后，利用 CAB 模块进行运算，以进一步提炼特征信息。最后，通过 n 个 STB 对特征进行映射，完成该阶段的计算过程。




图 4.5 ZiHao Net Neck 部分结构概述

为了进一步提升模型的性能、增强对多尺度特征的捕获能力，并便于误差梯度的反向传播，本文在模型的 Neck 部分设计了三条跳跃连接。这些跳跃连接直接通向模型的 Head 部分，将模型 Neck 部分的第二个阶段开始及其后续的输出结果导入模型的 Head 部分，以进行后续的信息融合。这种设计策略不仅让模型能够更有效地处理和利用多尺度的特征信息，而且也有利于梯度的传播，进一步优化了模型的学习过程。

4.2.5 模型 Head 部分设计

本文设计了一种简洁的语义分割 Head，用于整合 Neck 处理后的特征并对这些特征进行还原。该部分通过全连接层的特征整合能力来处理特征图，随后通过上采样层将特征图恢复为所需的特征尺寸。

模型的 Head 部分的主要职责是整合信息，并将最终的信息处理为任务所需的结果。这主要包括融合 Neck 提供的多尺度特征信息，进一步处理并完成特征重构，以生成目标结果，即滑坡区域的掩码。模型的 Head 部分被构造为三个独立的阶段，每个阶段的设计在大体上保持一致。在每个阶段中，首先通过一个全连接层对特征维度进行映射以整合特征信息，然后通过一个上采样模块继续恢复特征。随后，将这三个阶段的输出在特征维度上进行合并，最后通过 1×1 的卷积层完成特征整合，从而产生最终的输出值。

图 4.6 展示了模型 Head 部分的结构概述。首先，Head 部分接收来自 Neck 部分的三个跳跃连接输入，这些输入包含了三种不同尺度的特征图。接下来，通过全连接层将这些特征图的特征维度统一映射为 16，为后续的上采样操作做准备。然后，通过 DUS 模块将特征图的宽度和高度扩大四倍。对于那些即使经过 DUS 模块处理后，其宽度和高度仍然未达到 224 像素的特征图，采用双线性插值的方法将其尺寸调整至 224 像素。最后，将这三张特征图拼接在一起，并利用卷积核尺寸为 1×1 的卷积层进行信息融合，从而生成最终的滑坡区域掩码。




图 4.6 ZiHao Net 模型 Head 部分结构概述

4.2.6 模型损失函数设计

损失函数是用于评估模型预测结果与样本标签之间差异的关键度量。滑坡识别任务可以理解为一个像素级别的分类任务，即其损失可以对单个像素的分类准确性进行评估，同时也可以理解作为一种基于对象的语义分割任务，即对预测区域与样本标签区域的差异性进行评估。为了充分利用这两种特性，本文设计采用了一种结合了交叉熵损失和 Dice 损失的损失函数形式，以构建模型输出结果的损失函数。具体形式如公式 4.10 所示。

$$L(y, \hat{y}) = 1 - \frac{2 \sum_{i=1}^N y_i (1 + \exp(-\hat{y}_i))^{-1}}{\sum_{i=1}^N y_i^2 + \sum_{i=1}^N (1 + \exp(-\hat{y}_i))^{-2} + \varepsilon} - \sum_{i=1}^N \left(y_i \log(1 + \exp(-\hat{y}_i))^{-1} + (1 - y_i) \log(1 - (1 + \exp(-\hat{y}_i))^{-1}) \right) \quad (4.10)$$

式中, y 是真实标签, $\hat{y}$ 是模型预测结果, y_i 是真实分割标签第 i 个像素的值, $\hat{y}_i$ 是模型预测分割结果第 i 个像素的值, N 是像素点的总数, ε 是一个极小数, 用于避免分母为 0 的情况。

在 CAB 模块中, 滑坡相关性分数 p 是一个极其关键的变量, 其准确性直接关系到 CAB 模块的正常运行。为了让 p 能更准确地表达样本的正确类别, 需要对其学习过程施加约束条件。由于 p 本质上为模型输出的 logits, 通过 sigmoid 函数处理后可转变为样本存在滑坡区域的概率值, 这满足交叉熵的约束条件, 因此, 该部分采用交叉熵损失作为约束, 以保证 p 的学习过程能正常进行, 针对 p 的损失函数如公式 4.11 所示。因此, 应用于 ZiHao Net 模型的损失函数是公式 4.10 和公式 4.11 的组合, 最终的损失函数表达形式如公式 4.12 所示。

$$L(p_T, p) = - \sum_{i=1}^N \left(p_T \cdot \log(1 + \exp(-p))^{-1} + (1 - p_T) \log(1 - (1 + \exp(-p))^{-1}) \right) \quad (4.11)$$

$$L(y, \hat{y}, p_T, p) = L(y, \hat{y}) + L(p_T, p) \quad (4.12)$$

式中, p_T 是真实标签存在滑坡的概率值, p 是模型输出的滑坡相关性分数。

4.3 本章小结

本章首先介绍了向量余弦相似度和注意力机制的工作原理, 随后, 详细阐述了通过注意力机制和向量余弦相似度原理设计的 CAB 模块。最后, 本文介绍了结合 STB 和 CAB 模块所设计的滑坡识别模型 ZiHao Net, 以及该模型所使用的损失函数。

第五章 模型性能评估

在上一章中,介绍了本文针对滑坡识别任务设计的语义分割模型 ZiHao Net。为了进一步评估该模型的性能,本章将通过消融实验和对比实验两种方式进行深入分析。消融实验主要旨在验证 CAB 模块的有效性及其对模型整体性能的影响。此外,本章还将通过对比实验,将 ZiHao Net 与当前滑坡识别领域常用的其他语义分割模型进行比较,以展示本研究设计的模型在处理滑坡识别任务时的优势和特点。

5.1 实验环境与超参数设置

为确保实验结果的可靠性和各模型精度性能对比的准确性,本研究对所有实验模型均在第 3 章第 2 节构建的基准数据集下进行,模型的训练使用基准数据集的训练集部分,而验证集用于评估模型间的性能差异。所有模型的软件环境和超参数选择均保持一致,具体设置如下所示。

5.1.1 实验环境

本项研究的实验环境配置于 WSL 2 Ubuntu 22.04.2 LTS 操作系统之上,构建的模型采用 Python 3.11.5 版本,并以 PyTorch 2.1.0 框架为基础进行开发,在该实验环境中,CUDA 的版本为 12.4。在硬件配置上,实验使用了 Intel(R) Core(TM) i9-10980HK 处理器,系统内存为 64 GB,同时配备了一块 GeForce RTX 3080 Laptop 显卡,显存为 16 GB。

5.1.2 超参数设置

在本次实验中,每个批次的大小被设定为 32,输入样本的宽度和高度均被设定为 224 像素,初始学习率被设定为 $1.0e-3$,总共 200 个训练周期。前 20 个周期被指定为预热(Warmup)阶段^[93],以提高模型训练的稳定性和最终性能。在预热周期之后,将采用余弦退火学习率调度器(Cosine Annealing Learning Rate Scheduler)^[94]来调整后续周期的学习率。优化器方面,选择了 AdamW^[95],权重衰减参数设定为 0.05。损失函数方面,ZiHao Net 模型采用公式 4.12 所示的损失函数,其余模型采用公式 4.10 展示的损失函数,计算损失过程使用了在线困难样本挖掘(Online Hard Example Mining, OHEM)^[96]策略,其困难样本保留比例设置为 0.7,最后保存训练过程中验证集 IoU 最高的模型权重。具体超参数设置如表 5.1 所示。

表 5.1 模型超参数设置

参数名称	参数设置	参数名称	参数设置
批次	32	学习率调度器	余弦退火学习率调度器
样本尺寸	224	优化器	AdamW
初始学习率	1.0e-3	权重衰减	0.05
训练周期	200	困难样本保留率	0.7

5.2 消融实验

5.2.1 实验设计

为了全面评估本研究提出的交叉注意力模块的效能,本文设计了一个对照基准模型(Baseline),该模型排除了交叉注意力模块及其关联的MLP Head模块。该基准模型在其他所有方面与原始的ZiHao Net保持一致,并采用了相同的训练参数进行配置。基准模型的架构展示于图5.1中。




图 5.1 基准模型结构图概述

为了深入分析MLP Head模块对模型性能方面的影响,本研究构建了一个增强的基准模型,命名为Baseline MLP Head(BMH)。该模型通过集成MLP Head模块到基准模型中,用于评估此组件对整体模型性能的具体贡献。与完整的ZiHao Net模型相比,BMH模型仅剔除了CAB模块,而保留了MLP Head模块,并且除此之外,其余训练参数与ZiHao Net保持一致。BMH模型的结构展示于图5.2。在后续的研究中,将对基准模型、BMH模型及完整的ZiHao Net这三种模型进行训练,并在验证集上评估它们的性能差异。通过这一比较,本研究旨在验证所提出的交叉注意力模块的有效性。




图 5.2 BMH 模型结构图概述

5.2.2 实验结果定量分析

在消融实验的环节，本研究围绕基准模型、BMH 以及 ZiHao Net 三种不同的模型进行深入探讨，旨在揭示本研究提出的 CAB 模块对模型精度的影响。为了全面评估和比较这些模型的性能，本研究绘制了详尽的训练曲线。在每个训练周期结束时，都准确地记录了各模型的训练精度和验证精度。这种连续的性能追踪使得每个模型的学习过程以及训练中的性能变化得以细致地展现。在此过程中，本研究选用了 IoU 作为精度的度量标准。IoU 是在图像分割任务中广泛使用的精度指标，其能够有效地度量模型预测与真实标签之间的一致性。通过使用 IoU，可以更公正地比较不同模型的性能，并更准确地理解它们的优势和劣势。

图 5.3 展示了三种模型在训练集上的精度曲线。训练集在模型训练和损失回传中起关键作用，是模型学习并调整权重的主要数据源。在这些结果中，ZiHao Net 在训练集 IoU 上达到了最高，为 84.82%。其次是引入了 MLP Head 的 BMH，其 IoU 为 77.16%，而基准模型的 IoU 则为 74.29%。这些数据表明，CAB 模块能有效地提升模型的训练效果。尽管 MLP Head 并未直接参与影响模型最终的预测结果，但其对模型主干部分的训练，起到了积极的作用。MLP Head 模块能增强主干的特征提取能力，由于其直接与损失函数部分相连，形成了一个跳跃连接，使得误差梯度能快速回传到主干部分，从而让主干的参数得到更优的更新。




图 5.3 消融实验训练集曲线

从训练曲线来看，在训练的最初阶段，BMH 的精度变化与基准模型相似，但随着训练的推进，其精度逐渐与基准模型拉开了差距。相比之下，BMH 的训练曲线抖动更小，显示出更为稳定的表现，这表明 MLP Head 对模型的训练有积极的影响，并能使训练过程更加稳定。另一方面，ZiHao Net 的训练曲线波动性

较小，整体精度呈稳定上升趋势。虽然在最初的几个周期内，它的精度明显低于其他两个模型，但随着训练的推进，其精度稳步提升，随后超越了其他两个模型。这一观察结果突显了 CAB 模块在模型训练过程中的优越性能。

图 5.4 详细地描绘了三种不同模型在验证集上精度曲线的变化趋势。尽管验证集与训练集共享相同的数据分布，但由于验证集并未参与模型的训练，因此它成为评估模型对未知数据泛化能力的理想工具。该图形直观地展示了各模型在处理未见过数据时的表现，为评估其性能提供了便利。




图 5.4 消融实验验证集曲线

在验证集精度曲线的比较分析中，ZiHao Net 模型在 IoU 上表现卓越，达到了 82.65%，这一成绩显然超过了其他两种模型。BMH 模型，虽然引入了 MLP Head，其 IoU 为 74.44%，仍稍逊于 ZiHao Net，但优于基准模型。基准模型的表现最差，IoU 仅为 73.92%。

BMH 和基准模型都采用了 OHEM 策略，这导致两者在训练初期曲线波动较大。然而，随着训练的深入，这两种模型的验证集 IoU 曲线逐渐收敛，并趋向稳定。在这两者中，BMH 的曲线变化相对更为稳定，这可能归因于其引入的 MLP Head 部分，这一结果表明，该模块能对稳定模型训练过程有所贡献。值得注意的是，尽管 ZiHao Net 也采用了 OHEM 策略，但其验证集精度曲线表现出稳定的上升趋势，整体波动较小，并取得了最大的验证集 IoU。这一结果验证了该研究提出的 CAB 模块的优秀性能。

5.2.3 实验结果定性分析

图 5.5 揭示了三种模型在验证集上消融实验的可视化结果。观察图像可见，ZiHao Net 模型相较于其他两种模型展现出更优秀的识别性能：（1）对于第 A

行中细长形状的滑坡区域，ZiHao Net 模型展现出强大的识别能力；（2）对于第 B 和 C 行样本的识别结果，基准模型和 BMH 模型由于滑坡特征的不显著，识别效果相对较差。然而，引入交叉注意力机制的 ZiHao Net 模型即使在这种情况下仍然展现出较强的识别能力；（3）尽管样本 D 和 E 位于数据集边缘，缺乏充分的上下文语义信息，ZiHao Net 模型仍然展示了较强的识别能力。




图 5.5 消融实验模型识别结果

图 5.6 描绘了消融实验中三种不同模型的 Grad-CAM 结果。在对这些图像进行比较分析时，显然，具有 CAB 模块的 ZiHao Net 模型在决策区域与滑坡实际范围的一致性上明显优于其他模型。此外，该模型在区域内的注意力分布更为均衡。这些发现揭示了 ZiHao Net 模型在更全面和深入地挖掘滑坡区域特征信息方面的能力，从而在决策过程中提供了更精确的预测，这是其相对于其他模型的显著优势。这些结果进一步证实了本文设计的 CAB 模块在处理滑坡识别任务上的有效性。




图 5.6 消融实验 Grad-CAM 图

5.2.4 实验结论

本研究对三种模型：基准模型、BMH 和 ZiHao Net 进行了深入的训练和验证。通过比较各模型在训练集和验证集上的精度曲线变化，评估了模型性能和稳定性。

在训练阶段，ZiHao Net 在训练集的 IoU 上表现最佳，达到了 84.82%，明显优于 BMH 和基准模型。这一结果表明，ZiHao Net 所采用的 CAB 模块能有效地提升模型的训练效果。此外，尽管 MLP Head 并未直接参与影响最终的预测结果，但其在 BMH 模型训练过程中起到了积极的作用，增强了模型主干的特征提取能力，并使得误差梯度能快速回传到主干部分，从而让主干的参数得到更优的更新。这一点在 BMH 模型的训练曲线中得到了体现，其精度变化较稳定，且随着训练的推进，其精度逐渐与基准模型拉开了差距。

在验证阶段，ZiHao Net 模型在 IoU 上表现较好，达到了 82.65%，显著超过了其他两种模型。尽管 BMH 和基准模型在训练初期曲线波动较大，但随着训练的深入，这两种模型的验证集 IoU 曲线逐渐收敛，并趋向稳定。在这两者中，BMH 的曲线变化相对更为稳定，这可能归因于其引入的 MLP Head 部分。然而，尽管 ZiHao Net 也采用了 OHEM 策略，但其验证集精度曲线表现出稳定的上升

趋势,整体波动较小,并取得了最大的验证集 IoU。这一结果进一步验证了 ZiHao Net 中 CAB 模块的优秀性能。

在接下来的定性分析中, ZiHao Net 模型在滑坡识别任务上表现出了较好的性能。通过对比验证集的滑坡识别结果,可以观察到,相比于其他模型, ZiHao Net 在描绘滑坡边界方面更为清晰,对于滑坡特征不太明显的样本也能够有效地进行识别。进一步观察 Grad-CAM 图,可以发现 ZiHao Net 的决策区域与实际滑坡区域较为一致,且在决策区域内部,类别注意力分布呈现出相对均衡的特性。这些观察结果表明, ZiHao Net 模型在捕获和提取滑坡特征方面具有显著优势。这些发现进一步证实了本研究设计的 CAB 模块在滑坡识别任务中的有效性。

综上所述,本实验研究表明, ZiHao Net 模型在训练和验证阶段均表现出优秀的性能和稳定性,其所采用的 CAB 模块在模型训练过程中具有显著的优势。此外, MLP Head 部分在 BMH 模型训练过程中也起到了积极的作用,对模型的稳定性和性能有所提升。

5.3 对比实验

5.3.1 实验设计

为了深入研究 ZiHao Net 模型在滑坡识别任务中的表现,以及其与其他常用语义分割模型在滑坡识别领域的性能对比,本研究设计了一组详尽的对比实验,选定了四种在滑坡识别领域广泛应用且具有代表性的语义分割模型进行比较,包括 U-Net^[76,97]、DeepLab v3+^[98,99]、Link Net^[100,101]以及 SegFormer^[78,102]模型。

本研究旨在全面且公正地评估各种模型的性能,采用了多种评估指标,包括 OA、IoU、P、R 和 F1 分数。在评估模型性能的过程中,除了关注模型的预测精度,模型的规模和计算复杂度也是重要的考虑因素,这包括统计模型的参数数量 (Params) 以及所需的浮点运算次数 (Floating Point Operations, FLOPs), Params 和 FLOPs 信息通过使用 thop 工具进行详细的统计。

5.3.2 实验结果定量分析

表 5.2 所示为验证集上各模型滑坡识别的评估结果,在对比实验中, ZiHao Net 模型在多个评估指标上展现了显著的优势。首先,从 OA 指标来看,虽然各模型间的差异并不显著,但 ZiHao Net 模型以 97.85%的精度略高于其他模型。其次, ZiHao Net 在 IoU 上的表现达到了 82.65%,明显优于其他模型。这说明 ZiHao Net 模型对预测的分割区域与真实分割区域的重叠程度更高,能更全面地提取滑

坡特征，从而实现对滑坡区域空间的精确划分。

表 5.2 五种模型在验证集上的精度对比

模型名称	OA (%)	IoU (%)	P (%)	R (%)	F1 (%)	Params (MB)	FLOPs (GB)
U-Net	97.25	72.50	86.92	62.95	72.24	31.03	41.81
Link Net	97.66	71.95	79.38	82.63	80.09	11.53	2.31
DeepLab v3+	97.67	71.87	82.32	75.99	78.31	54.51	15.82
SegFormer	97.39	74.60	80.49	73.97	76.38	7.71	2.51
ZiHao Net	97.85	82.65	82.95	80.38	81.14	24.70	3.87

注：红色粗体表示最好结果，绿色粗体表示次好结果。

在精确率和召回率方面，ZiHao Net 模型也展现了显著的优势。其精确率为 82.95%，召回率为 80.38%，均排在第二位。虽然 U-Net 的精确率远高于 ZiHao Net，但其召回率较低，这表明 U-Net 在预测滑坡区域时过于保守，将大量的滑坡区域预测为非滑坡区域，导致大量的正样本被划分为负类。这可能是因为 U-Net 在该数据集上对滑坡特征的提取不完全，忽略了许多滑坡特征细节，导致了滑坡区域的漏识别。相比之下，Link Net 的召回率高于 ZiHao Net，但精确率略低，这表明该模型将过多的非滑坡区域划分为滑坡区域。虽然该模型对滑坡特征的把控较强，但过度地预测滑坡可能表明模型忽视了非滑坡的特征信息。相比之下，ZiHao Net 在精确率和召回率之间达到了更好的平衡，这一点可以从其 F1 分数高于其他两个模型这一事实中看出。

最后，尽管 ZiHao Net 模型的参数量为 24.7 MB，但相比于 U-Net 和 DeepLab v3+ 的参数量，ZiHao Net 模型的参数量显著减少，且模型运算所需的浮点运算次数远低于 U-Net 和 DeepLab v3+，表明其在模型复杂度和计算效率上实现了有效的优化。

5.3.3 实验结果定性分析

图 5.7 展示了五种模型在验证集上的提取结果。显而易见，相较于传统的滑坡提取模型，本研究提出的 ZiHao Net 模型展现出更优秀的提取性能：（1）在第 A 至 D 行的样本中，滑坡的纹理特征相对模糊，与背景颜色相似。这导致其他四种常用模型出现了不同程度的漏识别和错误识别，然而，ZiHao Net 模型依旧能精确地拟合滑坡特征，准确地识别并分割出滑坡的边界；（2）对于 E 和 F 行的样本，尽管滑坡位于样本边界处，ZiHao Net 模型仍能准确地识别出滑坡的

位置，并对其进行精准描述，而其他四种模型的识别效果则表现的差强人意；（3）在 G 行的样本中，本研究提出的模型对于狭长的滑坡特征仍然表现出较好的识别效果，相较于其他模型，其滑坡识别能力更强。




图 5.7 对比实验中验证集样本识别结果

图 5.8 对五种不同模型的 Grad-CAM 图进行了详细的对比。通过对图像的深入观察，可以发现 ZiHao Net 模型的决策区域不仅比其他四种模型更接近真实的滑坡区域，而且其决策区域的注意力分布更均匀，且各区域的注意力都较高。这些特点凸显了 ZiHao Net 在提取各类滑坡特征上的优越能力。无论是处理明显的滑坡特征，还是识别相对隐晦的滑坡特征，ZiHao Net 模型都展现出了有效的识别和提取能力。这些观察结果进一步突显了本研究所提出的基于交叉注意力机制模型在滑坡识别领域的竞争优势，明确表明了其在处理这类复杂任务中的优越性。




图 5.8 对比实验中验证集 Grad-CAM 图

5.3.4 实验结论

在滑坡识别任务中，正负样本的不均衡性常常导致滑坡区域的像素占比远低于非滑坡区域。这使得从复杂且冗余的样本中提取滑坡的有效特征成为一项重大挑战。从 OA 的角度观察，虽然各模型的表现均相当出色，但由于样本不平衡的问题，可能会导致模型在提取滑坡特征时的不完整，从而误将滑坡区域预测为非滑坡区域。由于非滑坡区域的数量远超滑坡区域，这可能会导致预测精度表面上的高涨。这种现象可以从精确率和召回率的结果中得以体现。

虽然各模型在 OA 上均表现出色，但在精确率和召回率上存在显著差异。例如，U-Net 模型的召回率较低，这表明该模型在处理预测滑坡区域时过于保守，导致大量真正的滑坡区域被错误地预测为非滑坡区域，即存在滑坡区域的漏识别问题，DeepLab v3+和 SegFormer 模型也存在类似问题。相较于其他模型，Link Net 在识别滑坡和非滑坡区域的特征上实现了较好的平衡，能够有效地把握滑坡的特征信息。因此，对于这种样本不平衡的数据集，Link Net 展现出了良好的性能，这一点可以从精确率、查全率以及综合两者的 F1 分数上体现。然而，Link Net

的 IoU 偏低,这表明该模型在获取滑坡的空间位置信息上仍存在不足,其识别的模型轮廓与实际轮廓之间存在一定的差异。

ZiHao Net 模型的评估结果显示,该模型在获取正负样本特征以及滑坡区域空间特征提取方面优于其他模型。该模型具有最高的 OA,且精确率和召回率也表现出色,这表明该模型对滑坡和非滑坡区域的特征识别能力更强,这一点从其最好的 F1 分数值上得以验证。同时,该模型的 IoU 最高,这表明该模型对滑坡的空间特征提取能力优于其他模型,能够获取更加精确的滑坡掩码。同时,ZiHao Net 模型在验证集滑坡识别任务上也展现了出色的性能,分析各种样本的实验结果,证明了该模型在精确描绘滑坡边界,以及识别狭长滑坡方面的高效性,展示了其较好的泛化性。最后,ZiHao Net 模型的参数量为 24.7 MB,所需的浮点运算次数为 3.87 GB,但相比于 U-Net 和 DeepLab v3+模型,ZiHao Net 模型的参数量显著减少。虽然 ZiHao Net 在参数量和计算复杂度上略高于 Link Net 和 SegFormer 这两款轻量级模型,但其在精度上的显著优势表明了 ZiHao Net 在模型设计中实现了较好的计算效率和预测精度的平衡。

在对五种模型在验证集上的识别效果以及 Grad-CAM 图进行深度分析和比较后,可以观察到 ZiHao Net 模型的识别效果明显优于其他模型,表现出了较高的识别精度。该模型具有出色的能力,能够精确地识别滑坡的边界,并且其决策区域更加接近真实的滑坡区域。值得注意的是,ZiHao Net 模型在决策区域的注意力分布表现出了显著的均衡性,且对整个区域都持有较高的关注度。这个特性进一步强化了 ZiHao Net 模型在滑坡识别任务中的精确度和可靠性,从而增强了其在实际应用中的有效性和稳健性。

综上所述,实验结果表明,ZiHao Net 模型在该数据集上的表现较好,展现出了优异的性能。相较于其他常用的滑坡识别模型,ZiHao Net 展现出了更为出色的综合性能。其参数量适中,滑坡识别效果优秀,能够更好地满足滑坡识别领域的需求。

5.4 本章小结

在本章节的第一部分,本研究详细设计并执行了一系列消融实验,以评估 CAB 模块的有效性。实验设置了一个不包含 MLP Head 模块和 CAB 模块的基线模型。首先,实验中单独添加 MLP Head 模块,随后引入 CAB 模块,目的是观察 MLP Head 模块和 CAB 模块对模型整体性能的具体影响。实验结果表明,仅

添加 MLP Head 模块的 BMH 模型在验证集上的 IoU 比基线模型提高了 0.52%，并且展示了更高的训练稳定性。当进一步集成 MLP Head 和 CAB 模块的 ZiHao Net 模型，其 IoU 比 BMH 及基线模型分别提升了 8.21%至 8.73%，这一显著的性能提升验证了 CAB 模块的有效性。此外，通过 Grad-CAM 技术分析模型决策过程，发现 ZiHao Net 模型的决策区域更加接近样本标签，且注意力分布更均匀，从而进一步证明了其优越性能。

本章的第二部分聚焦于对比实验，深入分析 ZiHao Net 模型与其他领先模型之间的性能差异。研究初期设计了一系列对比实验，全面评估 ZiHao Net 与现有先进模型 U-Net、Link Net、DeepLab v3+及 SegFormer 等的性能比较。结果显示，ZiHao Net 在 IoU 上实现了 8.05%至 10.78%的提升，而 F1 分数也提高了 1.05%至 8.9%。进一步采用 Grad-CAM 技术对模型决策过程进行可视化分析。Grad-CAM 图表明，ZiHao Net 模型在决策区域的精确度明显优于对比组模型，能够更准确地覆盖滑坡区域，并表现出更高的关注度。

第六章 泸定县滑坡识别

在上一章节中,本研究已经通过消融实验验证了所提出的 CAB 模块的可靠性,并通过对比实验展示了所设计模型的性能。鉴于王等^[103]构建的开源泸定滑坡数据集仅包含 230 个滑坡样本,这一数量不足以支持训练一个性能优异的深度学习模型,直接将模型应用于泸定研究区域存在显著的挑战。因此,本研究采用了深度迁移学习技术(Deep Transfer Learning, DTL),将模型从基准数据集上学习到的特征知识有效迁移至泸定地区的特定环境中。

此外,本研究所使用的预测数据样本来源于谷歌地图,具有 0.6 m 的分辨率遥感影像,影像整体宽度达到 136929 像素,高度为 180963 像素,文件大小为 92.3 GB。鉴于泸定地区采集的影像尺寸过大,无法直接用于模型推理,本研究开发了一种基于块分割的大尺度区域滑坡识别算法。该算法的首步是将大尺寸影像分割成较小的块,每个块内包含多个用于模型推理的样本。接着,对每个块独立应用滑坡识别模型,并最终综合各块的识别结果,完成整个区域的滑坡识别任务。

6.1 大尺度区域的滑坡识别模型推理算法

鉴于遥感影像的尺寸通常较大,直接处理这些影像会导致内存溢出问题。此外,由于样本边缘区域往往缺乏足够的上下文信息,预测精度可能会降低,这可能导致在拼接过程中出现明显的痕迹^[104]。为了解决这些问题,本研究设计了一种舍弃边缘的滑动窗口方法。

该算法以图片块为模型推理的基本单元,并分为两个主要步骤实施:第一步,基于样本的重叠率及每次模型推理所需的样本数量,确定各图片块的尺寸。随后,利用 GDAL 对原始遥感影像进行裁剪,以生成所需的图像块。图片块的尺寸与每次推理的样本数量以及重叠率之间的关系在公式 6.1 中进行了详细说明。

$$p_s = s_s \cdot ((1-r) \times (n-1) + 1) \quad (6.1)$$

式中, p_s 表示图片块的尺寸, s_s 代表模型所需的样本尺寸, r 是样本重叠率,而 n 为每次推理的样本数量开平方后的整数值。

第二步,在模型推理阶段,首先加载这些图像块,并根据预设的重叠率调整其大小以符合模型推理的需求。推理完成后,为避免边缘效应对预测精度的影响,将丢弃等同于重叠率一半的边缘部分。为提高效率,算法设计为第一步和第二步

并行执行。所有图像块的推理完成后，再次使用 GDAL 对处理过的图像块进行拼接，最终生成该区域的滑坡掩码图。整个算法流程旨在优化处理效率同时确保滑坡识别的准确性，适用于处理大尺度区域的滑坡识别任务。其具体的处理流程如图 6.1 所示。




图 6.1 大尺度滑坡识别算法

6.2 迁移学习

本研究采用了一种基于模型的 DTL 策略^[105]，目的是将模型从源域学习到的特征知识迁移至目标域。具体流程如图 6.2 所示。在该策略中，从基于源域训练的模型中选取特定层的参数迁移到目标模型中，这一过程使得目标模型能够有效地吸收并利用源域的知识。随后，通过使用有限的目标域数据对目标模型进行微调，从而精确地适应目标域的特定需求。




图 6.2 迁移学习概述图

本研究选取基准数据集作为源域，并使用王等^[103]构建的泸定滑坡数据集作为目标域，后者包含泸定地区的 230 张滑坡样本。为了微调模型，随机选取了 6 张滑坡样本，而剩余的 224 张样本则用于评估模型迁移后的精度。

定量比较结果如图 6.3 所示，采用 DTL 技术后，模型性能显著提升。IoU 提升范围为 11.69%至 37.1%，F1 分数的增幅在 12.0%至 43.1%之间。此外，经 DTL 处理的 ZiHao Net 模型在 IoU 和 F1 分数方面表现最佳，分别达到 64.01%和 77.87%。图 6.4 进一步展示了经 DTL 处理后模型的可视化结果，图中显示出识别正确率的显著提升及漏识别的大幅减少。这些成果突显了深度迁移学习在滑坡识别领域的广泛有效性。




图 6.3 迁移学习精度对比




图 6.4 迁移学习结果可视化

在本研究中,通过使用核密度估计法进行可视化分析,探讨了基准数据集和泸定数据集中滑坡与背景像素值的分布差异,具体结果展示在图 6.5 中。分析揭示了基准数据集与泸定滑坡数据集之间存在显著的数据分布差异。这种差异表明,直接将在基准数据集上训练的模型应用于泸定滑坡数据集可能面临显著挑战。因此,实施 DTL 不仅是必要的,而且具有实际意义,因为它可以确保模型有效适应新的数据分布,从而提高预测的准确性和模型的泛化能力。




图 6.5 不同像素值下各数据集中滑坡和背景的密度分布

6.3 实验结果

在本研究中,泸定研究区域样本来源于谷歌地图提供的 0.6 m 分辨率遥感影像,该影像的总宽度为 136929 像素,高度为 180963 像素,文件大小为 92.3 GB。样本之间的重叠率设定为 0.5,而样本边缘舍弃率则设定为 0.25。每个推理批次处理的样本数量为 529 个,相应的图像块尺寸设定为 2688 像素。整个滑坡识别过程总耗时为 2 小时 23 分 55 秒,期间共完成了 1973530 个样本的推理流程。

图 6.6 详细呈现了模型在识别滑坡方面的表现,模型对该地区的滑坡进行了较好的提取,其中包括滑坡的边界和形状等关键特征。从图中可以清楚地观察到,模型获取的滑坡边界清晰,较为准确地描绘了滑坡的实际形状和位置。这一结果充分验证了模型的优越的性能,证明了其在实际应用中的可靠性和有效性。




图 6.6 泸定县滑坡识别结果

由图可知，断层与水系的几何展布特征对滑坡体的发育与分布有着显著影响，其几何分布特征主要表现为，滑坡体沿着断层走向和河流延伸方向呈线性展布，因而造成了鲜水河断裂带和龙门山断裂带附近广泛发育滑坡体的现象。在泸定县西北和西南地区，由于地形陡峭且植被覆盖较薄，滑坡发育情况格外明显。值得注意的是，在横断山脉向四川盆地过渡的高山峡谷区域，以贡嘎山地区广泛发育滑坡体的现象最为显著。大渡河沿岸因其水系的长期侵蚀作用和陡峭的地形地貌特征，致使周围地区的滑坡体广泛发育，且滑坡灾害十分严重。

图 6.7 展示了五种模型在泸定地区进行滑坡识别的表现。从总体上看，这些模型的识别结果在空间分布上展现出了明显的相似性。然而，与其他四种模型相比，ZiHao Net 模型表现出了其独特的优势。特别是在识别滑坡边界轮廓的清晰度和连贯性上，ZiHao Net 模型超越了其他四种模型。此外，ZiHao Net 模型还能有效地降低图斑的零散度和不连续性。这些特点使得 ZiHao Net 模型在滑坡识别的精度和准确性上展现出了显著的优势。




图 6.7 泸定地区五种不同模型的识别结果

6.4 实验结论

本文设计的大尺度模型推理算法与模型结合,能够有效地完成泸定地区的滑坡识别任务。该算法使模型在 2 小时 23 分 55 秒内完成了 1973530 个样本的推理流程,并成功实现了识别结果的拼接,同时保留了识别结果的空间位置信息。

泸定县的滑坡识别结果,充分揭示了 ZiHao Net 模型在滑坡识别任务上的优秀表现。对于泸定地区的滑坡,模型能够较为精确地提取其关键特征,且获取的滑坡边界较为清晰,能够准确地描绘了滑坡的实际形状和位置,这一结果充分验证了模型优越的性能,以及其在实际应用中的可靠性和有效性。

另外,实验结果还揭示了断层和水系的几何展布对滑坡体的发育与分布存在显著的影响。滑坡体主要沿着断层走向和河流延伸方向呈线性展布,特别是在鲜水河断裂带和龙门山断裂带附近,以及泸定县西北和西南地区,滑坡发育情况显

著。其中，横断山脉向四川盆地过渡的高山峡谷区域，以及大渡河沿岸，滑坡灾害十分严重。总体而言，这些结果验证了 ZiHao Net 模型在滑坡识别任务上的竞争力，以及其在处理复杂地质环境问题上的广泛应用潜力。

6.5 本章小结

在本章节的首部分，研究主要探讨了 DTL 的应用。通过实施 DTL 策略，实现了从源数据集到目标数据集的特征知识迁移。在此过程中，对 ZiHao Net、U-Net、Link Net、DeepLab v3+ 及 SegFormer 模型进行了 DTL 微调，其性能均显著提升。这些模型的 IoU 增幅范围从 11.69% 至 37.1%，而 F1 分数的提升则介于 12.0% 至 43.1% 之间。

本章的第二部分针对四川泸定地区大尺度滑坡识别的特定需求，设计了一种基于舍弃边缘的滑动窗口算法。在算法设计中，设置样本之间的重叠度为 0.5，边缘舍弃率为 0.25。处理的输入样本尺寸为 224 像素，而处理的遥感影像分辨率为 0.6 m，尺寸为 136929 像素宽和 180963 像素高，数据总量约为 92.3 GB。利用开发的模型，在配备 Intel i9-10980HK 处理器和 NVIDIA RTX 3080 Laptop GPU 的硬件配置下，该算法完成了 1973530 个样本的推理，总耗时为 2 小时 23 分 55 秒，有效地完成了泸定地区的滑坡识别任务。

第七章 总结与展望

7.1 总结

本研究提出了一种新颖的 CAB 模块，专门用于滑坡识别任务。这个模块与 STB 相结合，构建了一个针对滑坡识别任务的模型。通过消融实验和对比实验，证明了该模型的可靠性和有效性。进一步地，使用 DTL 策略将模型应用于泸定县地区的滑坡识别任务，并取得了良好的效果。以下是本文的主要工作贡献：

(1) 本研究汇集了前人的研究成果，构建了一个全面的滑坡基准数据集，该数据集覆盖了世界范围内的多个地区，包含了各种不同类型的滑坡事件，为训练和评估不同模型及其组件的性能提供了丰富的样本。该数据集总共包含 8673 个样本数据，其中滑坡区域样本 3076 个，非滑坡区域样本 5597 个，按照 80% 和 20% 的比例随机划分为训练集和验证集，训练集包含了 6939 个样本，其中滑坡区域样本为 2460 个，非滑坡区域样本为 4479 个。验证集则包含了 1734 个样本，其中滑坡区域样本为 616 个，非滑坡区域样本为 1118 个。该数据集能为其他的滑坡识别研究提供统一的数据评估基础；

(2) 本研究针对 RGB 遥感影像中滑坡特征的多样性及其与其他地表特征相似性的挑战，开发了一种专门针对滑坡识别的深度学习模型。该模型以 MLP Head 模块提取样本的全局滑坡特征向量并计算滑坡相关性分数；引入了 CAB 模块利用全局滑坡特征向量和滑坡相关性分数来增强滑坡特征的表达，同时抑制背景噪声。消融实验验证了交叉注意力机制的有效性，显示其显著增强了模型性能。在构建的基准数据集上的性能比较显示，该模型的 IoU 达到 82.65%，F1 分数达到 81.14%，相较于 U-Net、DeepLab v3+、Link Net 及 SegFormer 等常用滑坡识别模型，IoU 提高了 8.05% 至 10.78%，F1 分数提升了 1.05% 至 8.9%。通过 Grad-CAM 技术解释模型决策过程，进一步证明了 Zi Hao Net 模型相较于其他对照模型在关注滑坡区域方面的优越性；

(3) 在将经过良好训练的模型应用于数据匮乏的新区域时，采用 DTL 对模型进行成本效益高的微调，相较于直接预测，可以显著提高模型的性能。通过 DTL 微调后，ZiHao Net、U-Net、DeepLab v3+、Link Net 及 SegFormer 等五种模型显示出了显著的性能增益。IoU 提升范围从 11.69% 至 37.1%，F1 分数的增幅则在 12.0% 至 43.1% 之间。这一结果强调了 DTL 在提升模型在新环境中适应性

和准确性方面的关键作用；

(4) 本研究开发了一种适用于大尺度区域的模型推理算法，该算法特别采用了一种舍弃边缘的滑动窗口技术。研究区域遥感影像具有 136929 像素宽和 180963 像素高，总数据量约为 92.3 GB。应用此算法，本文设计的模型在 2 小时 23 分 55 秒内完成了 1973530 个样本的推理处理，有效地执行了该地区的滑坡识别任务。

7.2 展望

计算机科学的迅速进步为各个领域带来了巨大的机会和变革。本研究利用深度学习技术解决滑坡识别问题，取得了显著的成果，这再次证明了深度学习技术的广泛适用性和高效性。然而，根据 NFL^[22]理论，目前阶段不可能存在一种能解决所有问题的算法，改进策略也是如此，研究人员必然会面临权衡选择的问题。因此，无论是受到个人能力的局限，还是 NFL 理论的制约，本研究针对滑坡识别领域提出的模型和交叉注意力机制算法都存在一定的不足，未来仍需持续改进和提升。以下是对未来工作的初步规划：

(1) 本研究中样本的大小被设定为 224 像素的矩阵，考虑到样本影像的空间分辨率为 0.6 m，每个样本所覆盖的区域仅限于约 134 m 范围。这意味着对于大型滑坡，获取到的特征将会是有限的，无法有效地获取更全面的样本特征信息。为了解决这一问题，未来的研究将从模型结构的角度出发，设计更合理且高效的滑坡识别模型，以扩大样本区域；

(2) 本研究构建的滑坡识别模型目前依赖于大量的滑坡样本数据进行训练，这一依赖性显著限制了其在数据稀缺区域的有效性。为克服这一挑战，未来研究计划采用弱监督迭代训练与无监督域适应技术。这些方法旨在通过整合少量标注数据与大量未标注数据，显著减少对标注数据的依赖性，同时提升模型的泛化能力与鲁棒性。此举不仅能扩大模型的应用范围，还能增强其在多变环境中的适应性；

(3) RGB 光学影像在滑坡识别任务中由于固有的局限性，往往无法达到高精度的要求。针对此问题，建议采用多源数据融合的策略，如 DEM、NDVI、坡度以及合成孔径雷达 (SAR) 数据，构建多模态的滑坡识别模型。该模型能够整合各类数据源的优势，从而有效弥补单一数据源的不足。同时，在模型的初期训练阶段，可以考虑采用对比学习的方法。通过这种方式，可以将基于 RGB 影像

训练得到的模型与其他数据源的模型进行联合训练,确保各模型在同一特征空间内有效映射;

(4) 随着遥感技术的迅猛发展, SAR 及多种传感器的广泛应用显著提升了遥感数据的时间分辨率。这一进展使得研究人员能够以更短的时间周期内监测区域滑坡情况,从而突显了基于多时相数据的滑坡识别方法的重要性。通过构建滑坡事件的时间序列数据及相应时期的环境参数数据,例如降雨和地震等,进行模型训练,有助于实现滑坡灾害的短期预测。此外,随着数据量的增加,模型的预测准确性预期将逐步提高;

(5) 随着滑坡数据的日益丰富,针对特定地区的滑坡识别任务可以采用以下策略:首先使用在环境条件与目标区域相似的地区训练得到的模型作为初始模型,然后结合该地区的少量样本对其进行微调,以此提升模型的性能。此外,可以采用人机交互方式进一步优化模型,即让研究人员对模型的识别结果进行校正,并使用这些校正后的数据重新训练模型。通过多次迭代,提高模型的识别精度。

参考文献

- [1] 徐邦栋. 滑坡分析与防治[M]. 北京: 中国铁道出版社, 2001.
- [2] 牛朝阳, 高欧阳, 刘伟, 等. 光学遥感图像滑坡检测研究进展[J]. 航天返回与遥感, 2023, 44(3): 133-144.
- [3] Mohan A, Singh A K, Kumar B, et al. Review on remote sensing methods for landslide detection using machine and deep learning[J]. Transactions on Emerging Telecommunications Technologies, 2021, 32(7): e3998.
- [4] 国家统计局. 中国统计年鉴 2023[M]. 北京: 中国统计出版社, 2023.
- [5] 四川省自然资源厅. 四川省“十四五”地质灾害防治规划[EB/OL]. (2021-12-15)[2024-1-19].
<https://www.sc.gov.cn/10462/c108551/2021/12/31/acdb6a06cb074ada80ddf3b9a1561b2e.shtml>.
- [6] 自然资源部. 全国地质灾害防治“十四五”规划[EB/OL]. (2022-12-7)[2024-1-23].
https://www.gov.cn/zhengce/zhengceku/2023-01/04/content_5734957.htm.
- [7] 铁永波, 张宪政, 卢佳燕, 等. 四川省泸定县 Ms6.8 级地震地质灾害发育规律与减灾对策[J]. 水文地质工程地质, 2022, 49(6): 1-12.
- [8] 倪化勇, 李宗亮, 巴仁基, 等. 四川泸定县泥石流灾害成因、特征与防治建议[J]. 工程地质学报, 2010, 18(1): 91-99.
- [9] 郭长宝, 倪嘉伟, 杨志华, 等. 川西大渡河泸定段大型古滑坡发育特征与稳定性评价[J]. 地质通报, 2021, 40(12): 1981-1991.
- [10] 杜宇峰, 黄亮, 赵子龙, 等. 基于 DETR 的高分辨率遥感影像滑坡体识别与检测[J]. 测绘通报, 2023(5): 16-20.
- [11] Brunsden D. Mass movement; the research frontier and beyond: a geomorphological approach[J]. Geomorphology, 1993, 7(1-3): 85-128.
- [12] 马铂程. 基于深度学习的秦巴山区滑坡自动识别研究[D]. 长安大学, 2023.
- [13] Krizhevsky A, Sutskever I, Hinton G E. ImageNet classification with deep convolutional neural networks[J]. Communications of the ACM, 2017, 60(6): 84-90.
- [14] Gu J, Wang Z, Kuen J, et al. Recent Advances in Convolutional Neural Networks[J]. Pattern Recognition, 2018, 77: 354-377.
- [15] Sameen M I, Pradhan B. Landslide Detection Using Residual Networks and the Fusion of Spectral and Topographic Information[J]. IEEE Access, 2019, 7: 114363-114373.

- [16] 邓志勇, 黄海峰, 李清清, 等. 基于 Swin Transformer 目标全景分割的三峡库首土质滑坡识别[J]. 水利水电技术(中英文), 2023: 1-12.
- [17] 唐小川, 涂子涵, 任绪清, 等. 一种识别植被覆盖滑坡的多模态深度神经网络模型[J]. 武汉大学学报(信息科学版), 2023: 1-11.
- [18] 辛鲁斌, 韩玲, 李良志. 基于多源数据融合的滑坡智能识别[J]. 地球科学与环境学报, 2023, 45(4): 920-928.
- [19] 许强, 陆会燕, 李为乐, 等. 滑坡隐患类型与对应识别方法[J]. 武汉大学学报(信息科学版), 2022, 47(3): 377-387.
- [20] 王晶晶. 基于深度学习的泸定县滑坡隐患识别与易发性评估方法研究[D]. 中国地质大学, 2023.
- [21] Ghorbanzadeh O, Blaschke T, Gholamnia K, et al. Evaluation of Different Machine Learning Methods and Deep-Learning Convolutional Neural Networks for Landslide Detection[J]. Remote Sensing, 2019, 11(2): 196.
- [22] Wolpert D H, Macready W G. No free lunch theorems for optimization[J]. IEEE Transactions on Evolutionary Computation, 1997, 1(1): 67-82.
- [23] Santangelo M, Cardinali M, Rossi M, et al. Remote landslide mapping using a laser rangefinder binocular and GPS[J]. Natural Hazards and Earth System Sciences, 2010, 10(12): 2539-2546.
- [24] Cardinali M, Galli M, Guzzetti F, et al. Rainfall induced landslides in December 2004 in south-western Umbria, central Italy: types, extent, damage and risk assessment[J]. Natural Hazards and Earth System Sciences, 2006, 6(2): 237-260.
- [25] Guzzetti F, Cardinali M, Reichenbach P, et al. Comparing Landslide Maps: A Case Study in the Upper Tiber River Basin, Central Italy[J]. Environmental management, 2000, 25(3): 247.
- [26] Cardinali M, Antonini G, Reichenbach P, et al. Photo geological and landslide inventory map for the Upper Tiber River basin[J]. CNR, Gruppo Nazionale per la Difesa dalle Catastrofi Idrogeologiche, Publication, 2001, 2154.
- [27] Nichol J E, Shaker A, Wong M S. Application of high-resolution stereo satellite images to detailed landslide hazard assessment[J]. Geomorphology, 2006, 76(1-2): 68-75.
- [28] Pike R J. The geometric signature: Quantifying landslide-terrain types from digital elevation models[J]. Mathematical Geology, 1988, 20(5): 491-511.
- [29] Guzzetti F, Mondini A C, Cardinali M, et al. Landslide inventory maps: New tools for an old problem[J]. Earth-Science Reviews, 2012, 112(1-2): 42-66.

- [30] Razak K A, Straatsma M W, Van Westen C J, et al. Airborne laser scanning of forested landslides characterization: Terrain model quality and visualization[J]. *Geomorphology*, 2011, 126(1-2): 186-200.
- [31] Lan H, Martin C D, Zhou C, et al. Rockfall hazard analysis using LiDAR and spatial modeling[J]. *Geomorphology*, 2010, 118(1-2): 213-223.
- [32] Chen R F, Chang K J, Angelier J, et al. Topographical changes revealed by high-resolution airborne LiDAR data: The 1999 Tsaoling landslide induced by the Chi-Chi earthquake[J]. *Engineering geology*, 2006, 88(3-4): 160-172.
- [33] Martha T R, Kerle N, Van Westen C J, et al. Object-oriented analysis of multi-temporal panchromatic images for creation of historical landslide inventories[J]. *ISPRS Journal of Photogrammetry and Remote Sensing*, 2012, 67: 105-119.
- [34] MacDonald H C, Grubbs R S. Landsat imagery analysis: an aid for predicting landslide prone areas for highway construction[C]//NASA. Lyndon B. Johnson Space Center NASA Earth Resources Surv. Symp., Vol. 1-B. 1975.
- [35] Rosin P L, Hervás J. Remote sensing image thresholding methods for determining landslide activity[J]. *International Journal of Remote Sensing*, 2005, 26(6): 1075-1092.
- [36] Parker R N, Densmore A L, Rosser N J, et al. Mass wasting triggered by the 2008 Wenchuan earthquake is greater than orogenic growth[J]. *Nature Geoscience*, 2011, 4(7): 449-452.
- [37] 杨树文, 谢飞, 韩惠, 等. 基于 SPOT5 遥感影像的浅层滑坡体自动提取方法[J]. *测绘科学*, 2012, 37(1): 71-88.
- [38] 闫琦, 李慧, 荆林海, 等. 灾后高分辨率遥感影像的地震型滑坡信息自动提取算法研究[J]. *激光与光电子学进展*, 2017, 54(11): 416-426.
- [39] 阿斯顿·张, 扎卡里 C. 立顿, 李沐, 等. 动手学深度学习[M]. 北京: 人民邮电出版社, 2023.
- [40] 王庆雅, 张锦. 高分辨率遥感影像滑坡纹理特征提取方法[J]. *太原理工大学学报*, 2021, 52(4): 547-556.
- [41] 李政, 李永树, 郭加伟, 等. 词袋特征支持下的无人机影像滑坡解译模型[J]. *遥感信息*, 2016, 31(5): 24-29.
- [42] Stumpf A, Kerle N. Object-oriented mapping of landslides using Random Forests[J]. *Remote sensing of environment*, 2011, 115(10): 2564-2577.
- [43] Mahrooghy M, Aanstoos J V, Nobrega R A, et al. A machine learning framework

- for detecting landslides on earthen levees using spaceborne SAR imagery[J]. IEEE Journal of Selected Topics in Applied Earth Observations and Remote Sensing, 2015, 8(8): 3791-3801.
- [44] Heleno S, Silveira M, Matias M, et al. Assessment of supervised methods for mapping rainfall induced landslides in VHR images[C]//2015 IEEE International Geoscience and Remote Sensing Symposium (IGARSS). 2015: 850-853.
- [45] Lowe D G. Distinctive Image Features from Scale-Invariant Keypoints[J]. International Journal of Computer Vision, 2004, 60(2): 91-110.
- [46] Dalal N, Triggs B. Histograms of oriented gradients for human detection[C]//2005 IEEE computer society conference on computer vision and pattern recognition (CVPR'05): Vol. 1. Ieee, 2005: 886-893.
- [47] Bay H, Tuytelaars T, Van Gool L. SURF: Speeded Up Robust Features[C]//Leonardis A, Bischof H, Pinz A. Computer Vision – ECCV 2006: Vol. 3951. Berlin, Heidelberg: Springer Berlin Heidelberg, 2006: 404-417.
- [48] Cai H, Chen T, Niu R, et al. Landslide Detection Using Densely Connected Convolutional Networks and Environmental Conditions[J]. IEEE Journal of Selected Topics in Applied Earth Observations and Remote Sensing, 2021, 14: 5235-5247.
- [49] Gao X, Chen T, Niu R, et al. Recognition and Mapping of Landslide Using a Fully Convolutional DenseNet and Influencing Factors[J]. IEEE Journal of Selected Topics in Applied Earth Observations and Remote Sensing, 2021, 14: 7881-7894.
- [50] Ding A, Zhang Q, Zhou X, et al. Automatic recognition of landslide based on CNN and texture change detection[C]//2016 31st Youth Academic Annual Conference of Chinese Association of Automation (YAC). 2016: 444-448.
- [51] Liu P, Wei Y, Wang Q, et al. Research on post-earthquake landslide extraction algorithm based on improved U-Net model[J]. Remote Sensing, 2020, 12(5): 894.
- [52] Zhang X, Yu W, Pun M O, et al. Cross-domain landslide mapping from large-scale remote sensing images using prototype-guided domain-aware progressive representation learning[J]. ISPRS Journal of Photogrammetry and Remote Sensing, 2023, 197: 1-17.
- [53] Ji S, Yu D, Shen C, et al. Landslide detection from an open satellite imagery and

- digital elevation model dataset using attention boosted convolutional neural networks[J]. Landslides, 2020, 17(6): 1337-1352.
- [54] 许濒支, 朱庆, 李海峰, 等. 基于多尺度深度注意力模型的遥感影像滑坡提取方法[J]. 测绘地理信息, 2022, 47(3): 108-112.
- [55] 王颖, 吴旭, 冷小鹏, 等. 基于改进 ResU-Net 的中分辨遥感影像滑坡检测方法[J]. 计算机技术与发展, 2023, 33(11): 182-188.
- [56] 姜万冬, 席江波, 李振洪, 等. 模拟困难样本的 Mask R-CNN 滑坡分割识别[J]. 武汉大学学报(信息科学版), 2023, 48(12): 1931-1942.
- [57] Tobler W R. A Computer Movie Simulating Urban Growth in the Detroit Region[J]. Economic Geography, 1970, 46: 234.
- [58] Srivastava N, Hinton G, Krizhevsky A, et al. Dropout: A Simple Way to Prevent Neural Networks from Overfitting[J]. Journal of Machine Learning Research: 30.
- [59] 周志华. 机器学习[M]. 北京: 清华大学出版社, 2016.
- [60] Glorot X, Bengio Y. Understanding the difficulty of training deep feedforward neural networks[C]//Proceedings of the thirteenth international conference on artificial intelligence and statistics. JMLR Workshop and Conference Proceedings, 2010: 249-256.
- [61] Zou H, Hastie T. Regularization and variable selection via the elastic net[J]. Journal of the Royal Statistical Society Series B: Statistical Methodology, 2005, 67(2): 301-320.
- [62] Vaswani A, Shazeer N, Parmar N, et al. Attention is all you need[J]. Advances in neural information processing systems, 2017, 30.
- [63] Dosovitskiy A, Beyer L, Kolesnikov A, et al. An Image is Worth 16x16 Words: Transformers for Image Recognition at Scale[EB/OL]. (2021-06-03)[2022-10-29]. <http://arxiv.org/abs/2010.11929>.
- [64] Liu Z, Lin Y, Cao Y, et al. Swin transformer: Hierarchical vision transformer using shifted windows[C]//Proceedings of the IEEE/CVF international conference on computer vision. 2021: 10012-10022.
- [65] Rumelhart D E, Hinton G E, Williams R J. Learning representations by back-propagating errors[J]. nature, 1986, 323(6088): 533-536.
- [66] Huang R. Some inequalities for the Hadamard product and the Fan product of matrices[J]. Linear Algebra and its applications, 2008, 428(7): 1551-1559.
- [67] Boas M L. Mathematical methods in the physical sciences[M]. Hoboken, NJ:

- John Wiley & Sons, 2006.
- [68] Lewis J P. Fast normalized cross-correlation[C]//Vision interface: Vol. 10. 1995: 120-123.
- [69] Dumoulin V, Visin F. A guide to convolution arithmetic for deep learning[EB/OL]. (2018-01-11)[2024-02-20]. <http://arxiv.org/abs/1603.07285>.
- [70] Simonyan K, Zisserman A. Very Deep Convolutional Networks for Large-Scale Image Recognition[EB/OL]. (2015-04-10)[2024-02-22]. <http://arxiv.org/abs/1409.1556>.
- [71] He K, Zhang X, Ren S, et al. Deep residual learning for image recognition[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2016: 770-778.
- [72] Wu Z, Shen C, van den Hengel A. Wider or Deeper: Revisiting the ResNet Model for Visual Recognition[J]. Pattern Recognition, 2019, 90: 119-133.
- [73] Ba J L, Kiros J R, Hinton G E. Layer Normalization[EB/OL]. (2016-07-21)[2024-02-24]. <http://arxiv.org/abs/1607.06450>.
- [74] Devlin J, Chang M W, Lee K, et al. BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding[EB/OL]. (2019-05-24)[2024-02-24]. <http://arxiv.org/abs/1810.04805>.
- [75] Long J, Shelhamer E, Darrell T. Fully Convolutional Networks for Semantic Segmentation[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. 2015: 3431-3440.
- [76] Ronneberger O, Fischer P, Brox T. U-Net: Convolutional Networks for Biomedical Image Segmentation[C]//Navab N, Hornegger J, Wells W M, et al. Medical Image Computing and Computer-Assisted Intervention – MICCAI 2015. Cham: Springer International Publishing, 2015: 234-241.
- [77] Lin T Y, Dollár P, Girshick R, et al. Feature pyramid networks for object detection[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2017: 2117-2125.
- [78] Xie E, Wang W, Yu Z, et al. SegFormer: Simple and efficient design for semantic segmentation with transformers[J]. Advances in neural information processing systems, 2021, 34: 12077-12090.
- [79] Zheng S, Lu J, Zhao H, et al. Rethinking semantic segmentation from a sequence-to-sequence perspective with transformers[C]//Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2021:

- 6881-6890.
- [80] Selvaraju R R, Cogswell M, Das A, et al. Grad-cam: Visual explanations from deep networks via gradient-based localization[C]//Proceedings of the IEEE international conference on computer vision. 2017: 618-626.
 - [81] Nielsen M A. Neural networks and deep learning[M]. San Francisco, CA, USA: Determination press, 2015.
 - [82] Milletari F, Navab N, Ahmadi S A. V-net: Fully convolutional neural networks for volumetric medical image segmentation[C]//2016 fourth international conference on 3D vision (3DV). Ieee, 2016: 565-571.
 - [83] Ren S, He K, Girshick R, et al. Faster R-CNN: Towards Real-Time Object Detection with Region Proposal Networks[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2017, 39(6): 1137-1149.
 - [84] 刘海强. 基于深度学习的火星地形分割技术研究[D]. 吉林大学, 2023.
 - [85] 沈毅, 露丹. 泸定县泥石流灾害特征及降水因子分析[J]. 高原山地气象研究, 2014, 34(2): 81-90.
 - [86] 邓辉, 何政伟, 陈晔, 等. 信息量模型在山地环境地质灾害危险性评价中的应用——以四川泸定县为例[J]. 自然灾害学报, 2014, 23(2): 67-76.
 - [87] 付萧, 鲁恒, 庄文化, 等. 利用“3S”技术进行区域土壤侵蚀研究——以四川省泸定县冷碛镇为例[J]. 中国农村水利水电, 2015(5): 93-96.
 - [88] 邓辉. 基于遥感和 GIS 的泸定县生态地质环境质量评价[D]. 成都理工大学, 2012.
 - [89] 曾超, 曹振宇, 苏凤环, 等. 四川及周边滑坡泥石流灾害高精度航空影像及解译数据集 (2008–2020 年) [J]. 中国科学数据(中英文网络版), 2022, 7(2): 195-205.
 - [90] Mihalcea R, Corley C, Strapparava C. Corpus-based and knowledge-based measures of text semantic similarity[C]//Aaai: Vol. 6. 2006: 775-780.
 - [91] Radford A, Kim J W, Hallacy C, et al. Learning transferable visual models from natural language supervision[C]//International conference on machine learning. PMLR, 2021: 8748-8763.
 - [92] Tian Z, He T, Shen C, et al. Decoders matter for semantic segmentation: Data-dependent decoding enables flexible feature aggregation[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2019: 3126-3135.
 - [93] Goyal P, Dollár P, Girshick R, et al. Accurate, Large Minibatch SGD: Training

- ImageNet in 1 Hour[EB/OL]. (2018-04-30)[2024-03-10]. <http://arxiv.org/abs/1706.02677>.
- [94] Loshchilov I, Hutter F. SGDR: Stochastic Gradient Descent with Warm Restarts[EB/OL]. (2017-05-03)[2024-03-10]. <http://arxiv.org/abs/1608.03983>.
- [95] Loshchilov I, Hutter F. Decoupled Weight Decay Regularization[EB/OL]. (2019-01-04)[2024-03-10]. <http://arxiv.org/abs/1711.05101>.
- [96] Shrivastava A, Gupta A, Girshick R. Training region-based object detectors with online hard example mining[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2016: 761-769.
- [97] Qi W, Wei M, Yang W, et al. Automatic Mapping of Landslides by the ResU-Net[J]. Remote Sensing, 2020, 12(15): 2487.
- [98] Chen L C, Zhu Y, Papandreou G, et al. Encoder-decoder with atrous separable convolution for semantic image segmentation[C]//Proceedings of the European conference on computer vision (ECCV). 2018: 801-818.
- [99] Zheng X, Han L, He G, et al. Semantic Segmentation Model for Wide-Area Coseismic Landslide Extraction Based on Embedded Multichannel Spectral-Topographic Feature Fusion: A Case Study of the Jiuzhaigou Ms7.0 Earthquake in Sichuan, China[J]. Remote Sensing, 2023, 15(4): 1084.
- [100] Chaurasia A, Culurciello E. LinkNet: Exploiting encoder representations for efficient semantic segmentation[C]//2017 IEEE Visual Communications and Image Processing (VCIP). 2017: 1-4.
- [101] Garcia G P B, Soares L P, Espadoto M, et al. Relict landslide detection using deep-learning architectures for image segmentation in rainforest areas: a new framework[J]. International Journal of Remote Sensing, 2023, 44(7): 2168-2195.
- [102] Wu L, Liu R, Ju N, et al. Landslide mapping based on a hybrid CNN-transformer network and deep transfer learning using remote sensing images with topographic and spectral features[J]. International Journal of Applied Earth Observation and Geoinformation, 2024, 126: 103612.
- [103] Wang H, Liu J, Zeng S, et al. A novel landslide identification method for multi-scale and complex background region based on multi-model fusion: YOLO + U-Net[J]. Landslides, 2024, 21(4): 901-917.
- [104] 王振庆, 周艺, 王世新, 等. IEU-Net 高分辨率遥感影像房屋建筑物提取[J]. 遥感学报, 2021, 25(11): 2245-2254.
- [105] Wu L, Liu R, Ju N, et al. Landslide mapping based on a hybrid

CNN-transformer network and deep transfer learning using remote sensing images with topographic and spectral features[J]. International Journal of Applied Earth Observation and Geoinformation, 2024, 126: 103612.